

Risikobasierte Portfoliooptimierung mit GARCH-Modellen

1 Einleitung

Seit Markowitz (1952) ist die Zusammenstellung eines Portfolios als Optimierungsproblem formuliert, bei dem die Gewichte gesucht werden, die bei gegebener erwarteter Rendite die Portfoliovarianz minimieren. In der praktischen Anwendung erweist sich dieser Ansatz jedoch als fragil, da sowohl die Erwartungswerte als auch die Kovarianzmatrix aus historischen Daten geschätzt werden müssen. Weil das Verfahren Anlagen mit zufällig überschätzter Rendite systematisch übergewichtet, verstärkt es Schätzfehler, statt sie auszumitteln. Michaud (1989) bezeichnet die Markowitz-Optimierung deshalb als Fehlermaximierung.

Von diesem Problem sind die beiden Eingangsgrößen unterschiedlich stark betroffen. Broadie (1993) zeigt in einer Simulationsstudie, dass Fehler in den geschätzten Erwartungswerten die Lage der effizienten Grenze deutlich stärker verzerren als Fehler in den geschätzten Varianzen und Kovarianzen. Erwartete Renditen lassen sich aus Kursdaten nur mit großer Unsicherheit bestimmen, während Risikokennzahlen stabiler zu schätzen sind. Wie gravierend die Folgen sind, zeigen DeMiguel et al. (2009), da in ihrem Vergleich über mehrere Datensätze keine der optimierten Strategien das naive, gleichgewichtete 1/N-Portfolio verlässlich schlagen konnte. Der Aufwand einer Optimierung lohnt sich folglich nur, wenn ihr Gewinn den Verlust durch Schätzfehler übersteigt.

An dieser Stelle setzen risikobasierte Portfolioverfahren an, die vollständig auf Renditeprognosen verzichten und die Gewichte allein aus der Kovarianzmatrix bestimmen. Untersucht werden hier das Minimum-Varianz-Portfolio, das Equal-Risk-Contribution-Portfolio sowie die Hierarchical Risk Parity (HRP) von López de Prado (2016). Die drei Verfahren unterscheiden sich vor allem darin, wie intensiv sie die geschätzte Kovarianzmatrix nutzen, weshalb deren Qualität unterschiedlich stark auf die Gewichte durchschlägt. Gerade diese Abstufung macht sie zu einem geeigneten Prüffeld für die Frage, wie viel eine bessere Risikoprognose überhaupt wert sein kann.

Damit rückt die Kovarianzmatrix selbst in den Mittelpunkt, denn werden die Gewichte ausschließlich aus ihr abgeleitet, sollte eine bessere Schätzung auch zu besseren Portfolios führen. Der übliche Stichprobenschätzer unterstellt jedoch konstante Varianzen und Korrelationen über das

gesamte Schätzfenster. Diese Annahme widerspricht der Beobachtung, dass ruhige und turbulente Phasen einander ablösen und große Kursausschläge weitere große Ausschläge nach sich ziehen. Engle (1982) hat diese Volatilitätscluster erstmals ökonometrisch erfasst, worauf Bollerslev (1986) das heute übliche Generalized-Autoregressive-Conditional-Heteroskedasticity-Modell (GARCH) aufbaute.

Für ein Portfolio genügt es allerdings nicht, die Varianzen einzeln zu modellieren, da auch die Abhängigkeitsstruktur zwischen den Anlagen zeitvariabel ist. Dass Korrelationen in Stressphasen ansteigen und die Diversifikation gerade dann versagt, wenn sie am dringendsten gebraucht wird, kann ein Modell mit konstanter Korrelation nicht abbilden. Engle (2002) überträgt die GARCH-Rekursion deshalb auf die Korrelationsmatrix selbst und erhält mit dem Dynamic-Conditional-Correlation-Modell (DCC) eine vollständig zeitvariable Kovarianzprognose. Dass diese Erweiterung für die Allokation relevant ist, legen Ardia et al. (2017) nahe, die eine Fehlspezifikation der Kovarianzmatrix als spürbare Verzerrung der Gewichte risikobasierter Portfolios ausweisen.

Ob eine statistisch bessere Prognose auch zu einer besseren Anlageentscheidung führt, ist damit jedoch nicht beantwortet. Engle und Colacito (2006) weisen darauf hin, dass die Sharpe Ratio als Kriterium für die Auswahl eines Kovarianzschätzers irreführend sein kann, da sie von den realisierten Renditen dominiert wird, auf die die Kovarianzmatrix nur mittelbar wirkt. Als Alternative bietet Patton (2011) Verlustfunktionen an, deren Rangfolge auch bei einem verrauschten Proxy der wahren Varianz erhalten bleibt, während Laurent et al. (2012) dieses Konzept auf vollständige Kovarianzmatrizen übertragen. Wie weit beide Kriterien auseinanderfallen können, zeigen Moura et al. (2020) für hochdimensionale bedingte Kovarianzmatrizen, wo die statistisch beste Spezifikation nicht die ökonomisch beste ist.

Die Verbindung beider Themenfelder, risikobasierter Allokation einschließlich neuerer Verfahren wie HRP auf der einen und multivariater GARCH-Prognosen auf der anderen Seite, ist bislang nur vereinzelt untersucht worden. Vor diesem Hintergrund verfolgt diese Arbeit zwei Fragen. Erstens wird geprüft, ob Minimum-Varianz-, Equal-Risk-Contribution- und Hierarchical-Risk-Parity-Portfolios eine höhere risikoadjustierte Out-of-Sample-Performance erzielen als das naive 1/N-Portfolio. Zweitens wird untersucht, ob GARCH- und DCC-GARCH-basierte Risiko- und Kovarianzprognosen die Ergebnisse gegenüber einer historischen Schätzung verbessern. Beide Fragen werden getrennt nach statistischen und ökonomischen Kriterien beantwortet, da sich gerade in der Differenz zwischen beiden der zentrale Befund dieser Arbeit zeigt.

Die empirische Grundlage bilden tägliche Renditen von 27 US-Sektorindizes über gut 27 Jahre. Zehn Trainingsfenster und vier Prognosehorizonte ergeben 40 Konstellationen, in denen jede der drei Kovarianzschätzungen mit jedem der vier Allokationsverfahren bewertet wird. Als Kriterien dienen statistisch QLIKE-Verlust und Kovarianz-MSE, ökonomisch Sharpe Ratio, realisierte Volatilität und Turnover. Ergänzend prüfen drei simulierte Datensätze mit bekanntem datengenerierendem Prozess, ob die Modelle das leisten, wofür sie konstruiert sind.

Diesem Vorgehen folgt auch der weitere Aufbau der Arbeit. Der folgende Abschnitt beschreibt die Datengrundlage, während der 3. Abschnitt das Untersuchungsdesign darlegt. Im 4. Abschnitt werden die Ergebnisse zunächst zur Prognosequalität und anschließend zur Portfolioperformance berichtet, bevor ihre Stabilität über verschiedene Zeiträume und Anlageuniversen untersucht wird. Anschließend ordnet der 5. Abschnitt die Befunde in die Literatur ein und der 6. Abschnitt diskutiert die Grenzen der Untersuchung. Am Ende werden die zentralen Erkenntnisse zusammengefasst.

2 Daten

In diesem Abschnitt wird die Datengrundlage der empirischen Untersuchung beschrieben.

Verwendet werden tägliche Kurse US-amerikanischer Sektorindizes, die über Datastream bezogen wurden. Als Sektorabgrenzung dienen die Business Groups der Refinitiv Business Classification (TRBC), wobei für die Vereinigten Staaten nur Daten für 28 der insgesamt 32 Business Groups verfügbar sind. Eine davon zeigt an rund zwei Dritteln ihrer Datenpunkte keine Kursbewegung und wird als inaktive Reihe verworfen, sodass 27 Sektoren in die Analyse eingehen. Der Beobachtungszeitraum reicht vom 02.04.1999 bis zum 09.06.2026 und umfasst 7.087 Handelstage, wobei alle Renditen als logarithmierte Tagesrenditen $r_t = \ln(P_t/P_{t-1})$ berechnet werden. Vollständig verfügbar sind die Daten allerdings nur für 16 Sektorindizes, während die übrigen Reihen jeweils lediglich eine Teilmenge abdecken.

Als risikofreier Zins dient die Fed Funds Rate, die als Total-Return-Index vorliegt, wodurch sich die tägliche einfache Verzinsung aus ihrer prozentualen Veränderung ergibt. Diese liegt im Mittel bei 2,08 % p. a.

Die Querschnittsverteilung der Sektorrenditen ist in Tab. 1 dargestellt. Auffällig ist dabei die durchschnittliche paarweise Korrelation von 0,562, die aufgrund der Begrenzung auf den US-Aktienmarkt erwartungsgemäß hoch ausfällt und die Diversifikationsmöglichkeiten innerhalb des Universums von vornherein einschränkt.

Kennzahl	Min.	25 %	Median	75 %	Max.
Beobachtungen	1351	1877	7087	7087	7087
Rendite p.a. (%)	-5,34	4,70	6,02	8,97	20,27
Volatilität p.a. (%)	15,06	19,73	22,41	26,32	49,20

Tabelle 1: Deskriptive Statistik der TRBC-Sektorrenditen

Tägliche logarithmierte Renditen von 27 TRBC-Sektorindizes, 02.04.1999 bis 09.06.2026; durchschnittliche paarweise Korrelation 0,562.

Hinzu kommen drei künstlich erzeugte Datensätze, die ausschließlich der Validierung der Implementierung dienen. Simuliert werden ein Prozess mit konstanter Kovarianzmatrix sowie je ein CCC- und ein DCC-GARCH-Prozess, sodass für jeden der drei Kovarianzschätzer ein Datensatz vorliegt, auf dem er korrekt spezifiziert ist. Die Parametrisierung ist im Anhang A

dokumentiert.

3 Methodik

In diesem Abschnitt wird das Untersuchungsvorgehen vorgestellt. Dabei wird auf die Schätzung der Kovarianzmatrix, die Portfoliooptimierung und die Vergleichsmetriken eingegangen.

3.1 Rolling Window

Um für mögliche Strukturbrüche in den Daten zu kontrollieren, werden sämtliche Ergebnisse in einem rollierenden Fenster erzeugt. Für jedes Trainingsfenster der Länge $T \in \{252, 504, \dots, 2520\}$ Handelstagen (ein bis zehn Jahre) und jeden Prognosehorizont $h \in \{1, 5, 10, 21\}$ Tagen werden die Kovarianzmatrizen auf den Trainingsdaten geschätzt, daraus die Portfoliogewichte bestimmt und diese über die folgenden h Handelstage gehalten. Anschließend rückt das Fenster um h Tage weiter, bis das Ende der Stichprobe erreicht ist, wobei sich aus den zehn Fensterlängen und den vier Prognosehorizonten insgesamt 40 Kombinationen ergeben. Deren Vergleich zeigt zum einen, ob die Befunde robust gegenüber der Wahl von Trainings- und Prognosefenster sind, und zum anderen, bei welcher Fensterlänge sich Schätzfehler aus zu wenigen Beobachtungen und Fehlspezifikation aus sich ändernden Parametern am besten ausgleichen.

Beachtet werden dabei nur Sektoren, die an mindestens 90 % der Handelstage des Trainingsfensters verfügbar sind, um so eine ausreichende Datenbasis für die Schätzung zu gewährleisten und zugleich Sektoren einzubeziehen, für die Daten erst ab einem späteren Zeitpunkt vorliegen. Das investierbare Universum wird somit in jedem Fenster neu bestimmt und variiert sowohl über die Zeit als auch über die Fensterlänge.

Als Basisfall werden durchgängig $T = 1008$ (vier Jahre) und $h = 1$ berichtet, da diese Kombination beide Modellbestandteile am besten zur Geltung bringt. Vier Jahre liefern genügend Beobachtungen, um neben den univariaten GARCH-Parametern auch die beiden DCC-Parameter verlässlich zu schätzen, ohne dass das Fenster so lang wird, dass es über mehrere Marktphasen mittelt. Ein Prognosehorizont von einem Tag entspricht zudem der natürlichen Ein-Schritt-Prognose der Modelle, weshalb sich die Qualität der Kovarianzschätzung dort am unmittelbarsten auf die Gewichte auswirkt.

Allerdings bringt ein rollierendes Design es mit sich, dass der Out-of-Sample-Zeitraum mit der Länge des Trainingsfensters wandert. Ein Vergleich der Spezifikationen über ihre jeweils volle Historie würde deshalb nicht die Fensterlänge isolieren, sondern zugleich unterschiedliche Marktphasen gegenüberstellen. Sämtliche Vergleiche über Trainingsfenster und Prognosehorizonte hinweg werden daher auf dem gemeinsamen Bewertungszeitraum ab dem 01.01.2010 gerechnet, sodass alle Zeilen der Robustheitstabellen dieselben rund 4.280 Handelstage umfassen. Der

Basisfall wird demgegenüber über seine volle verfügbare Historie ab Februar 2003 berichtet, da dort keine Vergleichbarkeitsfrage besteht. Wie weit beide Rechnungen auseinanderliegen und warum die Einschränkung nötig ist, zeigt der Abschnitt zur Robustheit.

3.2 Kovarianzschätzer

Verglichen werden drei Schätzer der bedingten Kovarianzmatrix, die eine aufsteigende Leiter an Dynamik abbilden, wobei jeder Schritt genau eine Modellkomponente hinzufügt. Dadurch lässt sich der Beitrag dieser Komponente isolieren.

Der historische Schätzer ist die schlichte Stichprobenkovarianz der Trainingsrenditen, in der die Konstanzannahme unverändert erhalten bleibt. Er dient als statischer Referenzpunkt, da er keine Parameterschätzung im engeren Sinn benötigt, dafür aber träge ist und erst mit der Verzögerung des gesamten Fensters auf Veränderungen des Risikoniveaus reagiert.

Der GARCH-Schätzer löst dieses Problem für die Varianzen, indem er die Volatilitätscluster explizit modelliert, die ein konstantes Varianzmodell per Konstruktion ignoriert. Ein GARCH(1,1) nach Bollerslev (1986) beschreibt die bedingte Varianz als gewichtete Kombination aus langfristigem Mittel, jüngstem Schock und Vorperiodenvarianz.

$$r_t = \mu + \varepsilon_t, \quad \varepsilon_t = \sqrt{h_t} z_t, \quad h_t = \omega + \alpha \varepsilon_{t-1}^2 + \beta h_{t-1}, \quad (1)$$

Dabei steuert α , wie stark ein neuer Schock die Varianz bewegt, während β deren Persistenz misst, wobei für Stationarität $\omega > 0$, $\alpha, \beta \geq 0$ und $\alpha + \beta < 1$ gelten muss. Die Umsetzung folgt dem Constant-Conditional-Correlation-Ansatz (CCC) von Bollerslev (1990), bei dem für jeden Sektor ein GARCH(1,1) per Quasi-Maximum-Likelihood geschätzt und die Varianzprognose über den Horizont h gemittelt wird. Konstant bleibt hierbei die Korrelationsmatrix, die als Stichprobenkorrelation der standardisierten Residuen z_t geschätzt wird. Diese werden statt der Rohrenditen verwendet, da in ihnen die Volatilitätscluster bereits herausgefiltert sind und Tage hoher Volatilität die Korrelationsschätzung sonst nach oben verzerren würden.

Der DCC-GARCH-Schätzer nimmt die verbleibende Restriktion zurück und überträgt die Rekursion aus Gleichung 1 nach Engle (2002) auf die Korrelation selbst.

$$Q_t = (1 - a - b) \bar{Q} + a z_{t-1} z'_{t-1} + b Q_{t-1}, \quad R_t = \text{diag}(Q_t)^{-1/2} Q_t \text{diag}(Q_t)^{-1/2} \quad (2)$$

Der Parameter a misst die kurzfristige Reaktion der Korrelationen auf neue gemeinsame Schocks und b deren Persistenz, wobei $a, b \geq 0$ und $a + b < 1$ gelten muss. Beide werden per Maximum-Likelihood geschätzt, während $\bar{Q}$ auf die Stichprobenkorrelation der z_t gesetzt wird. Für $h > 1$ wird die Korrelationsprognose gemäß Engle und Sheppard (2001) auf $\bar{Q}$ zurückgeführt und über den Horizont gemittelt, damit sie zur ebenfalls horizontgemittelten Varianzprognose passt. Die

Kovarianzmatrix ergibt sich anschließend als $\Sigma_t = D_t R_t D_t$, wobei D_t die Diagonalmatrix der prognostizierten Standardabweichungen ist.

Da GARCH- und DCC-Schätzer dieselben Varianzprognosen und dieselben standardisierten Residuen verwenden, isoliert ihr Vergleich exakt den Beitrag der dynamischen Korrelation. Der Vergleich beider mit der historischen Matrix isoliert entsprechend den Beitrag der dynamischen Volatilität.

3.3 Portfoliomodelle

Allen vier Allokationsverfahren ist gemeinsam, dass in ihre Gewichte ausschließlich die zweiten Momente eingehen und keine Renditeprognose. Damit entfällt die Fehlerquelle, die nach Broadie die Lage der effizienten Grenze am stärksten verzerrt. Die Darstellung folgt dem eingangs genannten Spektrum und beginnt bei dem Verfahren, das die geschätzte Matrix am intensivsten nutzt und deshalb am empfindlichsten auf ihre Fehler reagiert.

Am einen Ende dieses Spektrums steht das Minimum-Varianz-Portfolio (MVP), das die Portfoliovarianz $w' \Sigma w$ unter der Budgetrestriktion $\mathbf{1}' w = 1$ und einem Leerverkaufsverbot $w \geq 0$ minimiert. Es nutzt die Kovarianzmatrix vollständig aus, einschließlich ihrer Inversen, und überzeugt nach Behr et al. (2008) besonders in volatilen Marktphasen. Zugleich ist es das anfälligste Verfahren, da die Minimierung gezielt die Richtungen kleinster geschätzter Varianz aufsucht, in denen die Schätzfehler relativ am größten sind. Fehler werden dadurch nicht ausgemittelt, sondern verstärkt, weshalb Lee (2011) auf die typischerweise stark konzentrierten MVP-Lösungen hinweist. Weil der Kovarianzschätzer hier am unmittelbarsten durchschlägt, ist das MVP das aussagekräftigste Modell für die zweite Forschungsfrage.

Das Equal-Risk-Contribution-Portfolio (ERC) verfolgt hingegen das Ziel, das Gesamtrisiko nicht zu minimieren, sondern gleichmäßig auf die Anlagen zu verteilen. Der Risikobeitrag der Anlage i beträgt $RC_i = w_i (\Sigma w)_i / \sqrt{w' \Sigma w}$, wobei die Gewichte so gewählt werden, dass alle RC_i übereinstimmen. Das Ergebnis liegt konstruktionsbedingt zwischen MVP und $1/N$ und ist in der Regel deutlich besser diversifiziert. Dennoch schlägt ERC das naive Portfolio nach Chaves et al. (2011) nicht durchgängig.

Hierarchical Risk Parity (HRP) nach López de Prado ersetzt die Matrixinversion durch eine hierarchische Struktur. Zunächst werden die Sektoren über die Korrelationsdistanz $d_{ij} = \sqrt{0,5(1 - \rho_{ij})}$ geclustert und die Kovarianzmatrix quasi-diagonal geordnet, sodass ähnliche Anlagen nebeneinander stehen. Anschließend wird das Kapital durch rekursive Bisektion verteilt, wobei auf jeder Ebene der Teilbaum mit der geringeren Varianz das höhere Gewicht erhält. Entscheidend ist, dass HRP die Kovarianzmatrix nie invertiert und nur ihre Ordnungsinformation sowie die Varianzen der Teilcluster nutzt. Das Verfahren ist dadurch robust gegenüber schlecht konditionierten Matrizen, also gerade gegenüber der Fehlerquelle, die dem MVP zu schaffen macht. López de Prado und Sen et al. (2022) berichten entsprechend stabilere Gewichte und eine konkurrenzfähige

risikoadjustierte Rendite.

Als Vergleichsmaßstab dient das gleichgewichtete 1/N-Portfolio, das keine Schätzung der zweiten Momente benötigt und damit immun gegen Schätzfehler ist. Es bildet den relevanten Maßstab für die erste Forschungsfrage, da ein Optimierungsverfahren seinen Aufwand nur rechtfertigt, wenn dessen Gewinn den Verlust durch Schätzfehler übersteigt.

3.4 Bewertungskriterien

Die Bewertung trennt zwischen der Prognosequalität der Kovarianzmatrix und der ökonomischen Performance der daraus abgeleiteten Portfolios.

Da die wahre bedingte Kovarianzmatrix der Testperiode nicht beobachtbar ist, messen beide statistischen Verlustmaße die Prognose Σ gegen denselben realisierten Proxy.

$$S = \frac{1}{h} \sum_{t=1}^h r_t r_t' \quad (3)$$

Dabei ist r_t der Vektor der logarithmierten Tagesrenditen, wodurch S ein erwartungstreuer, aber verrauschter Schätzer der wahren Kovarianz ist. Für $h = 1$ besteht der Proxy aus einem einzigen äußeren Produkt und hat damit den Rang eins, ist also maximal verrauscht. Genau darauf zielt die Wahl der Verlustfunktionen, da beide zur Klasse der bezüglich unvollkommener Proxies robusten Verluste gehören. Für diese ist die erwartete Rangfolge zweier Prognosen dieselbe, unabhängig davon, ob gegen den verrauschten Proxy oder gegen die unbeobachtbare Wahrheit gemessen wird. Patton entwickelt dieses Konzept für den univariaten Fall der Varianzprognose, während Laurent et al. es auf vollständige Kovarianzmatrizen übertragen. Das Rauschen kostet folglich Teststärke, verzerrt die Rangfolge jedoch nicht.

Als erstes statistisches Maß dient der multivariate Quasi-Likelihood-Verlust (QLIKE), der eine Unterschätzung des Risikos stärker bestraft als eine Überschätzung und dadurch ökonomisch besser motiviert ist als ein symmetrisches Maß.

$$\text{QLIKE}(\Sigma, S) = \ln |\Sigma| + \text{tr}(\Sigma^{-1} S) \quad (4)$$

Als zweites Maß wird der Mean Squared Error (MSE) der Kovarianzeinträge herangezogen, der den quadratischen Abstand über alle Matrixeinträge misst und Über- wie Unterschätzung symmetrisch gewichtet.

$$\text{MSE}(\Sigma, S) = \frac{1}{N^2} \sum_{i,j} (\Sigma_{ij} - S_{ij})^2 \quad (5)$$

Beide Verluste werden je Rebalancierungsfenster berechnet und anschließend über die Fenster gemittelt, wobei niedrigere Werte eine bessere Prognose bedeuten. Die Mittelung erfolgt bewusst über den MSE und nicht über eine je Fenster gezogene Wurzel, da die Wurzeltransformation die robuste Verlustklasse verlässt und die Schätzer dadurch falsch ordnen kann.

Bei der Interpretation der Niveaus sind zwei Eigenschaften zu beachten. Der QLIKE-Verlust ist nicht dimensionsnormiert, da der Term $\ln |\Sigma|$ über alle Eigenwerte summiert und sein Niveau somit mit der Zahl der Anlagen N skaliert. Weit weniger betroffen ist der MSE, der über die Matrixeinträge mittelt, dafür aber dem Volatilitätsniveau der Bewertungsperiode und dem Horizont h des Proxys folgt. In beiden Fällen ist daher nur die Differenz zwischen den Schätzern innerhalb einer Spezifikation aussagekräftig, nicht das Niveau zwischen Spezifikationen.

Ökonomisch werden die annualisierte Rendite, die realisierte Volatilität, die Sharpe Ratio und der Turnover berichtet. Die Sharpe Ratio wird dabei in zwei Varianten ausgewiesen, einmal mit einem risikofreien Zins von null und einmal auf Überschussrenditen über die Fed Funds Rate. Der Turnover ist die Summe der absoluten Gewichtsänderungen zwischen den gedrifteten Endgewichten der Vorperiode und den neuen Zielgewichten und entspricht damit dem je Rebalancierung umgeschlagenen Anteil des Portfoliovolumens. Gerechnet wird dabei kostenfrei, weshalb die Wirkung von Transaktionskosten erst ex post über eine Kostenstaffel auf den Turnover quantifiziert wird.

Signifikanzaussagen beruhen auf zwei Tests. Unterschiede in der Prognosegüte werden mit dem Test von Diebold und Mariano (1995) in der Erweiterung von West (1996) auf die Verlustdifferenzen geprüft, wobei die Langfristvarianz dieses DMW-Tests mit einem Bartlett-Kern geschätzt wird. Für Unterschiede in den Sharpe Ratios dient der Test von Jobson und Korkie (1981) in der Korrektur von Memmel (2003), der die Korrelation der beiden Renditereihen berücksichtigt.

4 Ergebnisse

Die Darstellung folgt der Trennung der Bewertungskriterien. Zunächst wird geprüft, ob die GARCH-basierten Schätzer die Kovarianzmatrix besser prognostizieren, bevor untersucht wird, ob sich ein solcher Vorteil auch in der Portfolioperformance niederschlägt. Anschließend wird die Stabilität beider Befunde über Trainingsfenster, Prognosehorizonte und Teilperioden betrachtet.

4.1 Statistische Prognosequalität

Im Basisfall ordnet sich die Prognosegüte unter beiden Verlustmaßen nach der Modellkomplexität, wie Tab. 2 zeigt. Die historische Matrix schneidet am schlechtesten ab, während der GARCH-Schätzer sie deutlich verbessert und DCC-GARCH nochmals einen kleinen Zusatzgewinn liefert.

QLIKE und MSE stimmen in dieser Reihenfolge überein.

Kovarianzschätzer	QLIKE	MSE ($\times 10^{-7}$)
Historisch	-152,81	4,28
GARCH	-155,94	3,52
DCC-GARCH	-156,68	3,44

Tabelle 2: Prognosequalität der Kovarianzschätzer im Basisfall

TRBC, Training 1008 Handelstage, Prognosehorizont 1 Tag; niedrigere Werte bedeuten eine bessere Prognose.

Wie scharf die beiden Verlustmaße trennen, unterscheidet sich allerdings erheblich. Der DMW-Test in Tab. 3 verwirft die Nullhypothese gleicher erwarteter Verluste unter QLIKE in allen drei paarweisen Vergleichen auf dem 1-%-Niveau. Besonders präzise geschätzt ist dabei der Vorsprung von DCC gegenüber GARCH, obwohl die Differenz klein ausfällt. Der Grund hierfür liegt darin, dass beide Schätzer dieselben Varianzprognosen verwenden, wodurch sich die Verlustdifferenz fast ausschließlich aus dem Korrelationsbeitrag speist. Unter dem MSE sind die Abstände zur historischen Matrix hingegen nur auf dem 5-%-Niveau signifikant, während der Unterschied zwischen DCC und GARCH nicht mehr von null zu trennen ist. Ursache ist das Rauschen, da der symmetrische Verlust von wenigen extremen Beobachtungen dominiert wird. Belastbar ist somit, dass beide dynamischen Schätzer die historische Matrix unter beiden Maßen schlagen, während sich der Zusatznutzen der dynamischen Korrelation nur unter QLIKE nachweisen lässt.

Vergleich	$\emptyset \Delta$ Verlust	t -Statistik	p -Wert	Termine
<i>QLIKE</i>				
GARCH vs. Historisch	-2,563	-4,18	<0,001***	6013
DCC-GARCH vs. Historisch	-3,308	-5,28	<0,001***	6013
DCC-GARCH vs. GARCH	-0,744	-13,86	<0,001***	6079
<i>MSE ($\times 10^{-7}$)</i>				
GARCH vs. Historisch	-0,764	-2,23	0,026**	6079
DCC-GARCH vs. Historisch	-0,846	-2,11	0,035**	6079
DCC-GARCH vs. GARCH	-0,082	-1,26	0,207	6079

Tabelle 3: Diebold-Mariano-West-Tests auf die Verlustdifferenzen (Basisfall)

Negative Differenzen bedeuten, dass der erstgenannte Schätzer besser prognostiziert; ***, **, * = 1-, 5-, 10-%-Niveau.

Über das gesamte Untersuchungsdesign hinweg ist der statistische Vorsprung nahezu vollständig, da DCC-GARCH unter dem MSE in sämtlichen 40 Kombinationen besser prognostiziert als die historische Matrix und unter QLIKE in nahezu allen. Wie stark der Vorsprung ausfällt, hängt jedoch von der Spezifikation ab, wie Tab. 4 zeigt. Mit der Länge des Trainingsfensters nimmt er monoton zu, wobei DCC bei einjährigem Training unter QLIKE keinen Vorteil mehr liefert. Die rund 250 Beobachtungen reichen dort nicht aus, um die DCC-Parameter zusätzlich zu den univariaten GARCH-Parametern verlässlich zu schätzen. Über den Prognosehorizont fällt der Vorsprung dagegen ab, da die Korrelationsprognose mit wachsendem Horizont gegen ihren unbedingten Mittelwert konvergiert und sich der dynamische Anteil auswäscht. Der MSE zeigt dasselbe Muster, ordnet DCC aber auch im kürzesten Fenster vorne ein.

Spezifikation	QLIKE			MSE ($\times 10^{-7}$)		
	Historisch	Δ GARCH	Δ DCC	Historisch	GARCH	DCC-GARCH
252	-176,1	0,25	0,04	2,99	2,48	2,47
504	-171,0	-0,37	-0,81	3,42	2,81	2,74
756	-165,2	-0,95	-1,58	3,41	2,84	2,75
1008	-159,7	-1,36	-2,15	3,43	2,87	2,77
1260	-154,3	-1,84	-2,76	3,42	2,83	2,75
1512	-150,1	-1,74	-2,78	3,18	2,60	2,52
1764	-146,0	-1,71	-2,81	3,11	2,53	2,45
2016	-142,0	-1,80	-2,94	3,09	2,52	2,45
2268	-140,6	-1,85	-3,05	3,05	2,46	2,41
2520	-140,0	-2,02	-3,32	3,02	2,45	2,40
$h = 1$	-159,7	-1,36	-2,15	3,43	2,87	2,77
$h = 5$	-159,5	-1,37	-2,04	1,68	1,23	1,17
$h = 10$	-159,3	-1,53	-2,14	1,32	0,95	0,90
$h = 21$	-158,9	-1,25	-1,73	0,82	0,49	0,46

Tabelle 4: Prognosequalität über Trainingsfenster und Prognosehorizonte (TRBC)

Oberer Block: Trainingsfenster in Handelstagen ($h = 1$), unterer Block: Prognosehorizonte, bewertet ab 01.01.2010;
 Δ ist die Differenz zur historischen Matrix.

Die Niveaus beider Verluste sind zwischen den Zeilen dieser Tabelle nicht vergleichbar, obwohl alle Zeilen denselben Zeitraum abdecken. Beim QLIKE liegt das an der Dimension der Kovarianzmatrix, beim MSE im unteren Block dagegen am Horizont, über den der Proxy mittelt. Für die statistische Lesart der zweiten Forschungsfrage fällt die Antwort dennoch eindeutig aus, da GARCH- und DCC-GARCH-Modelle die Prognose der Kovarianzmatrix gegenüber der historischen Schätzung signifikant und unter dem MSE ausnahmslos verbessern.

4.2 Ökonomische Performance

Die ökonomische Auswertung führt zu einem differenzierteren Bild. Für die erste Forschungsfrage zeigt Tab. 5 zunächst den erwarteten Befund, da alle neun risikobasierten Kombinationen im Basisfall eine höhere Sharpe Ratio erreichen als das naive 1/N-Portfolio. Vorne liegt dabei das MVP, gefolgt von HRP und ERC. Der Vorsprung entsteht vollständig über die Risikoseite, da das 1/N-Portfolio zwar die höchste Rendite im Feld erzielt, diese aber mit der mit Abstand höchsten Volatilität erkauft.

Innerhalb der Portfoliomodelle kehrt sich die statistische Rangfolge im Basisfall weitgehend um, da bei MVP und ERC die historische Matrix vorne liegt und allein beim HRP der DCC-Schätzer marginal besser abschneidet. Ein Teil der Erklärung liegt darin, dass das MVP sein eigenes Zielmaß durchaus erreicht, denn die realisierte Volatilität der DCC-Variante liegt minimal unter der historischen. Dieser Vorsprung ist jedoch so klein, dass ihn die etwas höhere Rendite der historischen Variante überkompensiert. Der eigentliche Treiber steht in der letzten Spalte, in der der mittlere Turnover des MVP mit der DCC-Kovarianz rund 32-mal so hoch ausfällt wie mit der historischen. Die dynamischen Schätzer reagieren auf jede neue Volatilitätsschätzung und

Modell	Kovarianz	Rendite (%)	Vola (%)	Sharpe ($r_f = 0$)	Sharpe	Turnover
MVP	Historisch	9,03	13,82	0,695	0,567	0,008
MVP	GARCH	8,55	13,94	0,658	0,532	0,258
MVP	DCC-GARCH	8,65	13,81	0,671	0,543	0,255
HRP	Historisch	9,27	16,74	0,614	0,509	0,012
HRP	GARCH	8,96	16,21	0,611	0,502	0,072
HRP	DCC-GARCH	9,13	16,17	0,622	0,513	0,094
ERC	Historisch	9,46	17,67	0,601	0,501	0,006
ERC	GARCH	9,14	17,32	0,592	0,490	0,034
ERC	DCC-GARCH	9,13	17,31	0,591	0,490	0,034
1/N	–	9,58	18,79	0,581	0,488	0,006

Tabelle 5: Out-of-Sample-Performance im Basisfall

TRBC, Training 1008 Handelstage, Prognosehorizont 1 Tag; Rendite, Volatilität und Sharpe Ratio annualisiert, Turnover ohne Kosten.

schichten das Portfolio permanent um, während die träge Stichprobenkovarianz die Gewichte nahezu unverändert lässt. Bei HRP und ERC fällt der Anstieg mit dem Faktor acht beziehungsweise sechs erheblich geringer aus, was die Robustheitsorientierung dieser Verfahren widerspiegelt.

Statistisch abgesichert sind die Unterschiede in der Sharpe Ratio allerdings nicht, da Tab. 6 für keinen der relevanten Vergleiche einen auch nur annähernd signifikanten p -Wert ausweist. Dies gilt sowohl zwischen den Kovarianzschätzern als auch gegenüber dem 1/N-Portfolio. Das ist weniger ein Argument gegen die Modelle als eines gegen die Sharpe Ratio als Auswahlkriterium, da sie von den realisierten Renditen dominiert wird, auf die die Kovarianzmatrix nur mittelbar wirkt. Genau diesen Einwand formulieren Engle und Colacito.

Vergleich	Sharpe A	Sharpe B	Differenz	z -Statistik	p -Wert
MVP Historical vs. MVP DCC	0,567	0,543	0,0243	0,37	0,709
HRP Historical vs. HRP DCC	0,509	0,513	-0,0041	-0,18	0,859
ERC Historical vs. ERC DCC	0,501	0,490	0,0111	0,98	0,329
MVP GARCH vs. MVP DCC	0,532	0,543	-0,0109	-0,78	0,435
MVP Historical vs. Naive	0,567	0,488	0,0797	0,69	0,487
HRP Historical vs. Naive	0,509	0,488	0,0210	0,66	0,509
ERC Historical vs. Naive	0,501	0,488	0,0132	0,85	0,395

Tabelle 6: Tests auf Unterschiede der Sharpe Ratios (Basisfall)

Auf Überschussrenditen über die Fed Funds Rate; ***, **, * = 1-, 5-, 10-%-Niveau.

Was sich in der Sharpe Ratio nicht sichern lässt, wird über die Kosten des Turnovers hingegen unmittelbar greifbar. Legt man eine Staffel proportionaler Transaktionskosten auf das umgeschlagene Volumen, fällt die Sharpe Ratio des MVP mit DCC-Kovarianz bereits bei 5 Basispunkten unter die des 1/N-Portfolios, während die historische Variante nahezu unverändert bleibt. Bei 20 Basispunkten werden die dynamischen MVP-Varianten negativ, wie Tab. 7 zeigt. Der ökonomische Nachteil der dynamischen Schätzer ist damit bereits ohne Kosten angelegt und wird mit Kosten dominant.

Die Zählbilanz über alle 40 Läufe in Tab. 8 ordnet den Basisfall ein und macht sichtbar,

Modell	Kovarianz	Turnover	0 Bp.	5 Bp.	10 Bp.	20 Bp.
MVP	Historisch	0,008	0,695	0,688	0,680	0,666
MVP	GARCH	0,258	0,658	0,425	0,192	-0,274
MVP	DCC-GARCH	0,255	0,671	0,438	0,205	-0,261
HRP	Historisch	0,012	0,614	0,605	0,595	0,577
HRP	GARCH	0,072	0,611	0,555	0,499	0,388
HRP	DCC-GARCH	0,094	0,622	0,548	0,474	0,327
ERC	Historisch	0,006	0,601	0,596	0,592	0,584
ERC	GARCH	0,034	0,592	0,568	0,543	0,494
ERC	DCC-GARCH	0,034	0,591	0,567	0,542	0,492
1/N	–	0,006	0,581	0,577	0,573	0,565

Tabelle 7: Sharpe Ratios nach proportionalen Transaktionskosten (Basisfall)

Sharpe Ratio ($r_f = 0$) nach Abzug von c Basispunkten auf das je Rebalancierung umgeschlagene Volumen.

dass der ökonomische Befund je nach Portfoliomodell unterschiedlich ausfällt. Zur ersten Forschungsfrage zeigt sich, dass HRP und ERC mit historischer Kovarianz das 1/N-Portfolio in allen 40 Konstellationen schlagen, das MVP dagegen nur in der Hälfte der Fälle. Ausschlaggebend ist die bereits angelegte Anfälligkeit des MVP, dessen Varianzminimierung Schätzfehler in den kleinsten Eigenwerten der Kovarianzmatrix maximal ausnutzt und zu konzentrierten Portfolios führt. Die im Basisfall beste Sharpe Ratio des MVP ist insofern nicht repräsentativ.

Zur zweiten Forschungsfrage zeigt sich ein klares Muster entlang der Portfoliomodelle, da die dynamischen Schätzer die historische Matrix beim MVP in gut der Hälfte der Läufe schlagen, beim HRP nur vereinzelt und beim ERC in keinem einzigen. Ökonomisch ist das gut erklärbar, weil das MVP als einziges Verfahren die Kovarianzmatrix vollständig einschließlich ihrer Inversen ausnutzt, während HRP lediglich die Clusterordnung und die Varianzen der Teilcluster verwendet und ERC die Risikobeiträge ausbalanciert. Eine bessere Kovarianzprognose zahlt sich folglich dort aus, wo sie am intensivsten genutzt wird, und bleibt folgenlos, wo das Verfahren die Matrix bewusst nur grob verwendet. Dem steht ein statistischer Vorsprung gegenüber, der unter dem MSE in allen 40 Läufen auftritt.

Modell	Kovarianz	vs. 1/N	vs. historische Matrix		
		Sharpe	Sharpe	QLIKE	MSE
MVP	Historisch	20/40	–	–	–
MVP	GARCH	19/40	22/40	36/40	40/40
MVP	DCC-GARCH	20/40	25/40	37/40	40/40
HRP	Historisch	40/40	–	–	–
HRP	GARCH	32/40	3/40	36/40	40/40
HRP	DCC-GARCH	31/40	3/40	37/40	40/40
ERC	Historisch	40/40	–	–	–
ERC	GARCH	31/40	0/40	36/40	40/40
ERC	DCC-GARCH	32/40	0/40	37/40	40/40

Tabelle 8: Zählbilanz über alle empirischen Läufe

Alle 40 Kombinationen aus Trainingsfenster und Prognosehorizont, bewertet ab 01.01.2010.

Auch über die Trainingsfenster hinweg bleibt dieses Muster erhalten, wie Tab. 9 zeigt. Beim MVP liegt DCC in neun von zehn Fenstern über der historischen Matrix, bei HRP in einem und bei ERC in keinem. Die absoluten Unterschiede fallen dabei klein aus, weshalb angesichts der insignifikanten Tests auf Sharpe-Differenzen keine belastbare Rangfolge abgeleitet werden sollte.

Training	MVP			HRP			ERC			1/N
	Hist.	GARCH	DCC	Hist.	GARCH	DCC	Hist.	GARCH	DCC	
252	0,628	0,612	0,625	0,695	0,677	0,665	0,685	0,676	0,674	0,676
504	0,605	0,735	0,741	0,696	0,700	0,690	0,688	0,682	0,681	0,685
756	0,633	0,668	0,672	0,695	0,683	0,685	0,689	0,678	0,678	0,676
1008	0,714	0,706	0,728	0,684	0,686	0,706	0,692	0,680	0,682	0,677
1260	0,721	0,699	0,729	0,686	0,669	0,672	0,675	0,663	0,665	0,656
1512	0,681	0,669	0,696	0,685	0,667	0,669	0,675	0,663	0,665	0,660
1764	0,642	0,670	0,686	0,656	0,641	0,649	0,642	0,634	0,636	0,621
2016	0,631	0,652	0,655	0,657	0,649	0,647	0,650	0,644	0,645	0,628
2268	0,657	0,689	0,683	0,671	0,653	0,656	0,661	0,654	0,655	0,635
2520	0,627	0,690	0,689	0,679	0,663	0,660	0,669	0,661	0,662	0,647

Tabelle 9: Sharpe Ratios über die Trainingsfenster (TRBC, $h = 1$)

Annualisierte Sharpe Ratio ($r_f = 0$), bewertet ab 01.01.2010.

Deutlicher ist der Befund über den Prognosehorizont in Tab. 10. Wird seltener rebalanciert, bleibt die Sharpe Ratio der historischen Matrix beim MVP praktisch konstant, während sie für DCC deutlich fällt und der Turnover je Rebalancierung gleichzeitig auf mehr als das Doppelte steigt. Über längere Horizonte handeln die dynamischen Modelle somit gegen zunehmend veraltete Prognosen an, wodurch sich ihr Vorteil auch ohne Kosten in einen Nachteil umkehrt. Da der Bewertungszeitraum über alle Zeilen identisch ist und allein die Rebalancierungsfrequenz variiert, ist dieser Vergleich frei von den Stichprobenproblemen, die der folgende Abschnitt behandelt.

h (Tage)	MVP		HRP		ERC		1/N	Turnover MVP	
	Hist.	DCC	Hist.	DCC	Hist.	DCC		Hist.	DCC
1	0,714	0,728	0,684	0,706	0,692	0,682	0,677	0,008	0,255
5	0,705	0,762	0,681	0,690	0,694	0,684	0,680	0,021	0,522
10	0,717	0,654	0,692	0,670	0,698	0,680	0,684	0,033	0,598
21	0,721	0,640	0,697	0,689	0,700	0,689	0,685	0,058	0,587

Tabelle 10: Sharpe Ratios und Turnover über die Prognosehorizonte (TRBC, Training 1008 Tage)

Annualisierte Sharpe Ratio ($r_f = 0$), bewertet ab 01.01.2010; Turnover je Rebalancierung, also nicht auf gleiche Frequenz normiert.

4.3 Robustheit über Zeiträume und Anlageuniversen

Sämtliche bisher berichteten Vergleiche über Trainingsfenster hinweg wurden bereits auf dem gemeinsamen Zeitraum ab 2010 gerechnet. Dieser Abschnitt begründet, warum diese Einschränkung nötig ist, und zeigt, was ohne sie gemessen würde.

Ohne die Einschränkung bewertet jedes Trainingsfenster einen anderen Zeitraum, da der Out-of-Sample-Beginn von März 2000 beim kürzesten auf November 2008 beim längsten Fenster wandert. Der Lauf mit einem Jahr Training enthält damit das Platzen der Dotcom-Blase, während der Lauf mit zehn Jahren Training erst nach dem Einbruch der Finanzkrise beginnt und nur die anschließende Erholung abdeckt. Das hebt seine Kennzahlen an, ohne dass dies etwas über die Schätzqualität aussagt. In seiner klarsten Form zeigt Tab. 11 diesen Effekt, da das 1/N-Portfolio über die volle Historie beim längsten Fenster eine merklich höhere Sharpe Ratio erreicht als bei allen anderen Fenstern. Weil es überhaupt keine Schätzung vornimmt und die Fensterlänge für seine Konstruktion nahezu bedeutungslos ist, handelt es sich um einen reinen Stichprobeneffekt. Auf dem gemeinsamen Zeitraum verschwindet dieser Sprung, wodurch sich die Spannweite der MVP-Sharpe-Ratio nahezu halbiert.

Training	$\varnothing N$	QLIKE DCC		Sharpe MVP Hist.		Sharpe 1/N	
		voll	gem.	voll	gem.	voll	gem.
252	20,3	-162,0	-176,1	0,568	0,628	0,505	0,676
504	19,7	-161,0	-172,1	0,539	0,605	0,502	0,685
756	19,1	-158,9	-167,3	0,558	0,633	0,514	0,676
1008	18,5	-156,7	-162,6	0,695	0,714	0,581	0,677
1260	17,9	-153,6	-157,7	0,624	0,721	0,507	0,656
1512	17,4	-150,2	-152,9	0,571	0,681	0,501	0,660
1764	16,9	-147,0	-148,8	0,522	0,642	0,462	0,621
2016	16,4	-143,7	-144,9	0,469	0,631	0,458	0,628
2268	16,2	-142,3	-143,7	0,468	0,657	0,466	0,635
2520	16,2	-142,7	-143,3	0,654	0,627	0,677	0,647

Tabelle 11: Voller versus gemeinsamer Bewertungszeitraum (TRBC, $h = 1$)

voll bezeichnet die volle Historie des jeweiligen Fensters, *gem.* den gemeinsamen Zeitraum ab 01.01.2010.

Ein zweiter Effekt bleibt jedoch auch nach Angleichung des Zeitraums bestehen, da das QLIKE-Niveau weiterhin von der Fensterlänge abhängt. Ursache ist die Zusammensetzung des Universums, weil die 90-%-Verfügbarkeitsregel die 2019 hinzugekommenen Sektoren in langen Fenstern erst spät oder gar nicht zulässt und die Fensterlänge somit die Dimension der Kovarianzmatrix mitbestimmt. Die Korrelation zwischen mittlerer Universumsgröße und QLIKE-Niveau beträgt $-0,9999$, wodurch das Niveau der Kennzahl praktisch vollständig durch die Dimension und nicht durch die Prognosequalität determiniert ist. Den direkten Beleg liefert erneut das 1/N-Portfolio, das im identischen Bewertungszeitraum je nach Trainingsfenster unterschiedlich abschneidet. Da sich an seiner Konstruktion nichts ändert, kann dieser Unterschied nur aus dem unterschiedlichen Anlageuniversum stammen.

Zeitlich lokalisieren lässt sich der Bruch über die Teilperioden des Basisfalls in Tab. 12. Das QLIKE-Niveau springt ab 2022 deutlich nach unten, wobei dieser Sprung exakt mit der Erweiterung des Universums von 17 auf 25 Sektoren im September 2022 zusammenfällt. Der MSE zeigt an dieser Stelle keinen vergleichbaren Bruch, folgt dafür aber dem Volatilitätsniveau der Periode und steigt in der Finanzkrise auf mehr als das Siebzigfache des Werts der ruhigen Phase 2003–2007. Beide Kennzahlen sind über Perioden hinweg somit nur eingeschränkt vergleichbar,

wenn auch aus unterschiedlichen Gründen.

Periode	N	QLIKE		MSE ($\times 10^{-7}$)		Sharpe		
		Hist.	Δ DCC	Hist.	DCC	MVP Hist.	MVP DCC	1/N
2003–2007	16–16	-143,5	-3,79	0,28	0,23	1,490	1,485	1,087
2008–2009	16–16	-119,7	-11,50	21,03	16,72	-0,200	-0,294	-0,092
2010–2019	16–17	-146,1	-1,75	0,79	0,60	0,940	1,036	0,760
2020–2021	17–17	-133,1	-7,15	20,18	15,88	0,446	0,427	0,836
2022–2026	17–27	-205,1	-0,69	1,79	1,70	0,578	0,462	0,461

Tabelle 12: Teilperioden des Basisfalls: Universum, Prognosequalität und Performance

N ist die Spannweite der investierbaren Sektoren; QLIKE-Niveaus sind zwischen Perioden mit unterschiedlichem N nicht vergleichbar.

Aussagekräftig bleibt die Differenz zwischen den Schätzern innerhalb einer Periode, die erheblich variiert. In der Finanzkrise 2008/09 und im COVID-Zeitraum fällt sie um ein Vielfaches größer aus als in den ruhigen Phasen. Der Mehrwert der dynamischen Modellierung konzentriert sich damit auf Phasen mit ausgeprägten Volatilitätsschocks, also genau dort, wo eine statische Matrix am stärksten hinterherhinkt.

Ökonomisch ist die Rangfolge ebenfalls periodenabhängig, da das MVP mit DCC-Kovarianz die historische Variante in der Phase 2010–2019 klar schlägt, in allen übrigen Teilperioden jedoch zurückliegt. Genau hierin liegt der Unterschied zwischen dem Basisfall und den Robustheitstabellen. Der Basisfall umfasst die volle Historie ab 2003 und mittelt über gegenläufige Teilperioden, weshalb dort die historische Matrix vorne liegt, während die auf 2010 eingeschränkten Tabellen für das MVP zugunsten von DCC ausfallen. Beide Rechnungen sind korrekt, messen aber Unterschiedliches, wobei sich angesichts durchgängig insignifikanter Unterschiede in beide Richtungen eine starke Aussage verbietet.

Der Vergleich über Trainingsfenster variiert somit selbst nach Angleichung des Zeitraums noch zwei Größen gleichzeitig, nämlich Schätzpräzision und Anlageuniversum, und ist als Robustheitsprüfung im engeren Sinn nur eingeschränkt geeignet. Dass es sich dabei um eine Eigenschaft der empirischen Datenbasis und nicht um einen Fehler der Implementierung handelt, zeigt der Gegentest an den synthetischen Datensätzen im Anhang. Dort ist das Universum mit 20 Anlagen konstant und der datengenerierende Prozess parameterstabil, weshalb das QLIKE-Niveau über alle Fensterlängen praktisch unverändert bleibt und sich die Rangfolge der Schätzer in keinem einzigen Fenster umkehrt.

Robust ist der Befund dort, wo tatsächlich nur ein Faktor variiert wird. Über die Prognosehorizonte bleiben Bewertungszeitraum und Universum konstant, wodurch der Vorteil der historischen Matrix monoton mit dem Horizont wächst. Zudem gilt die statistische Rangfolge unter dem MSE über alle 40 Läufe hinweg ausnahmslos.

5 Einordnung in die Literatur

Dieser Abschnitt hält die Befunde gegen die eingangs skizzierte Literatur und benennt, wo sie diese stützen und wo sie ihr widersprechen.

Der Befund, dass alle drei risikobasierten Verfahren das naive Portfolio im Basisfall übertreffen, steht in Spannung zu DeMiguel et al., die $1/N$ gegenüber optimierten Strategien als schwer zu schlagen ausweisen. Die Ursache dürfte weniger in den Verfahren als im Untersuchungsobjekt liegen, da hier über breit diversifizierte Sektorindizes statt über Einzeltitel optimiert wird und die Kovarianzmatrix dadurch stabiler zu schätzen ist. Innerhalb der risikobasierten Verfahren fügen sich die Ergebnisse dagegen gut in die vorliegende Evidenz ein. Die hohe Robustheit von HRP mit 40 von 40 Läufen über $1/N$ entspricht den Aussagen von López de Prado und Sen et al. Mit Chaves et al. deckt sich zudem die Beobachtung, dass ERC zwar besser diversifiziert, das naive Portfolio aber nicht durchgängig schlägt. Dass das MVP im Basisfall dennoch die höchste Sharpe Ratio erzielt, über alle Läufe hinweg aber nur in der Hälfte der Fälle über $1/N$ liegt, illustriert genau die Instabilität, die Lee und Behr et al. beschreiben.

Das zentrale Ergebnis dieser Arbeit, ein nahezu vollständiger statistischer, aber nur beim MVP nennenswerter ökonomischer Vorsprung der GARCH-Modelle, reiht sich in eine etablierte Diskussion ein. Die durchweg insignifikanten Tests in Tab. 6 bestätigen den Einwand von Engle und Colacito für den vorliegenden Datensatz unmittelbar, während die von Patton und Laurent et al. vorgeschlagenen robusten Verluste im selben Datensatz sehr wohl trennscharf sind. Nur scheinbar im Widerspruch dazu stehen Ardia et al., die eine Fehlspezifikation der Kovarianzmatrix als spürbare Verzerrung der Portfoliogewichte ausweisen. Verzerrte Gewichte schlagen sich hier nämlich nur dort in der Performance nieder, wo ein Verfahren die Matrix intensiv nutzt, sodass sich beide Befunde nicht ausschließen, sondern die Verzerrung je nach Allokationsverfahren unterschiedlich teuer ist. Am nächsten liegt jedoch Moura et al., da die Autoren für hochdimensionale bedingte Kovarianzmatrizen ebenfalls finden, dass die statistisch beste Spezifikation nicht die ökonomisch beste sein muss und Transaktionskosten den Ausschlag geben. Die Turnover- und Kostenrechnung in Tab. 7 repliziert diesen Mechanismus in einem Sektoruniversum.

6 Limitationen

Die Aussagekraft der Ergebnisse ist in mehrfacher Hinsicht begrenzt, wobei die Einschränkungen im Folgenden nach ihrem Gewicht für die Interpretation geordnet werden.

Am schwersten wiegt, dass der Backtest ohne Handelskosten rechnet und diese erst ex post auf den ausgewiesenen Turnover angesetzt werden. Die Rechnung ist damit eine Näherung, da ein kostenbewusster Optimierer weniger handeln und einen Teil der Belastung vermeiden würde. Sie

kehrt die Aussage des Abschnitts zur ökonomischen Performance allerdings nicht um, sondern verschärft sie, weil der ökonomische Nachteil der dynamischen Schätzer bereits ohne Kosten vorhanden ist.

Der unbalancierte Panelaufbau begrenzt zudem die Vergleichbarkeit über Trainingsfenster und Teilperioden hinweg, da die Einschränkung auf den gemeinsamen Bewertungszeitraum ab 2010 zwar den Stichprobeneffekt behebt, nicht aber den Universumseffekt. Eine sauberere Untersuchung würde das Universum über alle Spezifikationen hinweg auf die 16 durchgängig verfügbaren Sektoren fixieren, wofür allerdings auf rund 40 % der zuletzt verfügbaren Sektoren verzichtet werden müsste. Ein solcher Robustheitslauf steht ebenso aus wie eine Normierung des QLIKE-Verlusts auf N , die Niveauvergleiche über unterschiedliche Dimensionen hinweg zulassen würde. Die synthetischen Datensätze können diese Lücke nicht schließen, da sie ein vollständig balanciertes Panel bilden, in dem alle 20 Anlagen ab dem ersten Tag verfügbar sind. Das ist gewollt, weil es die Gegenprobe zum Strukturbruch erst ermöglicht, bedeutet aber zugleich, dass erst ein simuliertes Panel mit gestaffelt eintretenden Anlagen den Universumseffekt isoliert quantifizieren könnte.

Ein technisches Problem derselben Ursache betrifft die historische Matrix, die im Anschluss an die Universumserweiterung 2022 an 66 Rebalancierungsterminen nicht positiv definit ist und dort keinen QLIKE-Verlust zulässt. Die Mittelwerte der Schätzer beruhen dadurch streng genommen auf unterschiedlichen Terminmengen, was die dynamischen Schätzer geringfügig begünstigt, da an den fehlenden Terminen besonders negative QLIKE-Werte auftreten. Auf einer gemeinsamen Terminmenge gerechnet schrumpft ihr Vorsprung um rund einen halben QLIKE-Punkt, ohne dass sich die Rangfolge ändert. Der MSE ist von dem Problem nicht betroffen, da er keine Invertierung voraussetzt, während sich das Problem systematisch durch einen Shrinkage-Schätzer im Sinne von Ledoit und Wolf (2004) lösen ließe. Dieser wäre zugleich ein interessanterer Vergleichsmaßstab als die rohe Stichprobenkovarianz.

Auf der Messseite ist der realisierte Proxy die wesentliche Einschränkung, da er für $h = 1$ aus einem einzigen äußeren Produkt besteht und damit den Rang eins hat. Die Verlustfunktionen bleiben nach Patton zwar rangerhaltend, jedoch begrenzt das geringe Signal-Rausch-Verhältnis die Teststärke des MSE-basierten DMW-Tests spürbar. Intraday-Daten würden einen erheblich präziseren Proxy liefern, standen für diese Arbeit aber nicht zur Verfügung. Hinzu kommt, dass ausschließlich die relative Prognosegüte bewertet wurde und nicht die absolute Kalibrierung der prognostizierten Volatilität. Ob die Modelle das Risikoniveau im Mittel treffen, was für Value-at-Risk-Anwendungen entscheidend wäre, bleibt damit offen.

Auf der Modellseite wird ausschließlich GARCH(1,1) unter Normalverteilungsannahme geschätzt, obwohl Aktienrenditen typischerweise linksschief und leptokurtisch sind. Erweiterungen um Asymmetrie, etwa GJR-GARCH oder EGARCH, sowie um fat-tailed Innovationen liegen daher nahe. Die DCC-Parameter werden zudem mit korrelationsgetargetem $\bar{Q}$ und begrenzter Iterationszahl geschätzt, ohne dass Standardfehler ausgewiesen werden. Auf der Allokationsseite

sind Leerverkaufsverbot und Vollinvestition die einzigen Restriktionen, während praxisübliche Obergrenzen je Position nicht gesetzt werden.

Schließlich werden über 40 Läufe hinweg zahlreiche Tests durchgeführt, ohne für multiples Testen zu korrigieren. Die Analyse beschränkt sich außerdem auf ein einziges Marktsegment, wobei Sektorindizes zudem nicht unmittelbar investierbar sind und Replikationskosten daher unberücksichtigt bleiben.

7 Fazit

Die Arbeit hat zwei Fragen getrennt untersucht, nämlich ob risikobasierte Portfoliomodelle das naive 1/N-Portfolio schlagen und ob GARCH-basierte Kovarianzprognosen gegenüber der historischen Schätzung einen Mehrwert stiften.

Zur ersten Frage hängt die Antwort stark vom gewählten Verfahren ab. HRP und ERC mit historischer Kovarianz übertreffen das 1/N-Portfolio in allen 40 untersuchten Konstellationen und erweisen sich als robust gegenüber Variationen von Trainings- und Prognosefenster. Das Minimum-Varianz-Portfolio erzielt im Basisfall zwar die höchste Sharpe Ratio, schlägt 1/N über alle Läufe hinweg aber nur in der Hälfte der Fälle und reagiert am empfindlichsten auf Schätzfehler. Für die Praxis sprechen diese Ergebnisse damit eher für die robusteren Verfahren als für die theoretisch elegantere Varianzminimierung, wobei einschränkend gilt, dass keiner der Vorsprünge gegenüber 1/N statistisch signifikant ist.

Zur zweiten Frage entscheidet das angelegte Kriterium über die Antwort, worin zugleich der Hauptbefund liegt. Statistisch ist das Ergebnis eindeutig, da DCC-GARCH die Kovarianzmatrix in allen 40 Läufen unter dem MSE und in nahezu allen unter dem QLIKE-Verlust besser prognostiziert als die historische Schätzung und die Unterschiede im DMW-Test signifikant sind. Ökonomisch übersetzt sich dieser Vorsprung jedoch nur dort, wo die Kovarianzmatrix tatsächlich intensiv genutzt wird, also beim MVP und nicht bei HRP oder ERC. Das ist konsistent mit der Konstruktion der Verfahren, da beide die Matrix bewusst nur grob nutzen und gerade deshalb robust, zugleich aber auch unempfindlich gegenüber ihrer Verbesserung sind. Der Preis der Dynamik ist der Turnover, der beim MVP um den Faktor 32 höher liegt und bereits bei Transaktionskosten von 5 Basispunkten ausreicht, um die dynamischen Varianten unter das 1/N-Portfolio zu drücken.

Ein methodischer Nebenefund verdient darüber hinaus Beachtung. Die Auswertung über verschiedene Trainingsfenster, die üblicherweise als Robustheitsprüfung verstanden wird, variiert im vorliegenden Design zugleich den Bewertungszeitraum und die Zusammensetzung des Anlageuniversums. Beide Effekte sind erheblich und gerichtet, da über die volle Historie das längste Trainingsfenster überlegen erscheint, weil es den Einbruch der Finanzkrise ausschließt und nur die Erholung erfasst. Dass sich dieser Effekt auch beim 1/N-Portfolio zeigt, das gar

nicht schätzt, belegt seinen rein stichprobenbedingten Charakter. Nach der Angleichung des Bewertungszeitraums ab 2010 verschwindet rund die Hälfte der scheinbaren Fenstersensitivität, während der verbleibende Teil mit einer Korrelation von $-0,9999$ praktisch vollständig auf die Zahl der investierbaren Sektoren zurückgeht. Auf den synthetischen Datensätzen mit konstantem Universum und parameterstabilem Prozess tritt dieses Muster erwartungsgemäß nicht auf, weshalb Niveauvergleiche über Fensterlängen hinweg ohne Kontrolle von Zeitraum und Universum nicht belastbar sind.

Der übergreifende Schluss lautet damit, dass eine bessere Risikoprognose nicht automatisch eine bessere Anlageentscheidung ist. Die GARCH-Modelle leisten das, wofür sie konstruiert sind, und die synthetische Validierung zeigt, dass sie genau dann einen Mehrwert liefern, wenn der datengenerierende Prozess ihre Annahmen erfüllt. Auf realen Sektordaten ist die verwertbare Struktur jedoch zu schwach, um die Kosten der laufenden Umschichtung zu rechtfertigen. Nicht die Prognosegüte ist folglich die bindende Restriktion, sondern der Handel, den ihre Nutzung auslöst.

A Synthetische Validierung

Ob die Modelle korrekt implementiert sind, lässt sich an echten Daten nicht prüfen, da der wahre datengenerierende Prozess unbekannt ist. Dafür werden drei simulierte Datensätze mit jeweils 20 Anlagen und 6.000 Handelstagen verwendet, die dieselbe unbedingte Risikostruktur besitzen und sich ausschließlich in der Dynamik der zweiten Momente unterscheiden. Die annualisierten Volatilitäten liegen dabei zwischen 15 % und 35 % bei einer durchschnittlichen Korrelation von 0,35. Der Monte-Carlo-Datensatz enthält unabhängige Ziehungen mit konstanter Kovarianz und bildet den Nullfall ab, in dem die historische Matrix korrekt spezifiziert ist. Beim GARCH-Datensatz kommt eine GARCH(1,1)-Dynamik je Anlage mit $\alpha = 0,08$ und $\beta = 0,90$ bei konstanter Korrelation hinzu, während der DCC-Datensatz zusätzlich eine DCC-Rekursion mit $a = 0,03$ und $b = 0,96$ enthält. Die Ergebnisse bilden damit eine Leiter, auf der jeweils ein Schätzer korrekt spezifiziert ist.

Dass die Modelle dieser Leiter folgen, zeigt Tab. 13. Im Monte-Carlo-Fall unterscheiden sich die drei Schätzer unter beiden Verlustmaßen praktisch nicht, wobei die historische Matrix beim MVP die minimal höchste Sharpe Ratio erzielt. Wo keine Struktur vorhanden ist, bringt das komplexere Modell folglich nichts. Im GARCH-Fall schlagen beide dynamischen Schätzer die historische Matrix deutlich, sowohl in der Prognosegüte als auch in Sharpe Ratio und realisierter Volatilität. Im DCC-Fall schlägt DCC schließlich auch den GARCH-Schätzer klar.

Die DMW-Tests in Tab. 14 bestätigen dieses Muster formal. Im Monte-Carlo-Prozess ist die Verlustdifferenz der dynamischen Schätzer gegenüber der historischen Matrix positiv, also minimal schlechter, und zwischen GARCH und DCC nicht von null verschieden, weshalb die zusätzliche Parametrisierung dort reines Rauschen erzeugt. Im GARCH-Prozess sind beide dynamischen

Datensatz	Kovarianz	QLIKE	MSE ($\times 10^{-8}$)	Vola (%)	Sharpe	Turnover
Monte Carlo	Historisch	-154,50	7,04	11,92	1,011	0,011
	GARCH	-154,47	7,04	11,95	1,003	0,074
	DCC-GARCH	-154,47	7,04	11,95	1,002	0,075
GARCH-Sim.	Historisch	-154,23	7,84	11,37	0,869	0,010
	GARCH	-157,25	7,57	9,85	0,984	0,154
	DCC-GARCH	-157,25	7,57	9,85	0,984	0,154
DCC-Sim.	Historisch	-154,13	9,86	11,93	0,668	0,011
	GARCH	-157,02	9,19	9,62	0,907	0,160
	DCC-GARCH	-162,13	8,98	8,99	0,925	0,152

Tabelle 13: Synthetische Validierung: Basisfall je Datengenerierungsprozess

20 simulierte Anlagen, Training 1008 Handelstage, Prognosehorizont 1 Tag; Performancekennzahlen für das MVP.

Schätzer signifikant besser als die historische Matrix, unterscheiden sich untereinander jedoch nicht, was korrekt ist, da die Korrelation dort konstant ist. Erst im DCC-Prozess wird der Unterschied zwischen DCC und GARCH signifikant, sodass die Implementierung jeweils genau die Struktur erkennt, die tatsächlich vorhanden ist.

Datensatz	Δ G–H	t	Δ D–H	t	Δ D–G	t
Monte Carlo	0,029***	6,07	0,029***	6,12	0,000	0,32
GARCH-Sim.	-3,025***	-24,69	-3,024***	-24,68	0,000	1,28
DCC-Sim.	-2,887***	-15,64	-7,998***	-35,68	-5,111***	-49,85

Tabelle 14: Synthetische Validierung: DMW-Tests auf die QLIKE-Differenzen

G = GARCH, D = DCC-GARCH, H = historisch; negative Differenzen bedeuten eine bessere Prognose. ***, **, * = 1-, 5-, 10-%-Niveau.

Für die Diskussion des Strukturbruchs ist Tab. 15 der entscheidende Gegentest. Da das Universum konstant 20 Anlagen umfasst und die Parameter des Prozesses über die gesamte Stichprobe unverändert bleiben, sollte sich das Niveau der Prognosekennzahlen über die Trainingsfenster hinweg nicht systematisch verschieben. Bewertet wird nach demselben Protokoll wie im empirischen Teil, also ab 2010. Genau das ist der Fall, da das QLIKE-Niveau der historischen Matrix über alle zehn Fenster nur um wenige Zehntel schwankt, während die entsprechende Spannweite in den empirischen Daten über 30 Punkte beträgt. Beim MSE ist das Niveau sogar praktisch konstant. Auch die Rangfolge kehrt sich in keinem Fenster um, weil DCC in allen 20 ausgewiesenen Läufen unter beiden Verlustmaßen besser prognostiziert als die historische Matrix und sich die Differenz bei längeren Trainingsfenstern auf einem konstanten Niveau stabilisiert.

Erwähnenswert ist, dass die ökonomischen Kennzahlen auch hier spürbar schwanken, obwohl der Prozess vollkommen stabil ist. Beim GARCH-Datensatz schlägt der historische Schätzer in den beiden kürzesten Fenstern sogar den DCC-Schätzer, obwohl er dort mit Sicherheit falsch spezifiziert ist. Das ist kein Widerspruch, sondern eine weitere Bestätigung des Arguments aus dem Abschnitt zur ökonomischen Performance. Selbst bei bekanntem datengenerierendem Prozess ist die Sharpe Ratio zu verrauscht, um Kovarianzschätzer zuverlässig zu ordnen, während die Prognosekennzahlen ein klares Signal liefern.

Datensatz	Training	N	QLIKE		MSE ($\times 10^{-8}$)		Sharpe MVP	
			Hist.	Δ DCC	Hist.	DCC	Hist.	DCC
GARCH-Sim.	252	20	-154,1	-2,09	7,03	6,90	1,110	0,973
	504	20	-154,3	-2,68	7,03	6,87	1,073	0,986
	756	20	-154,4	-2,83	7,02	6,86	0,942	0,956
	1008	20	-154,4	-2,90	7,02	6,86	0,870	0,936
	1260	20	-154,6	-2,82	7,02	6,86	0,828	0,923
	1512	20	-154,7	-2,79	7,02	6,86	0,840	0,921
	1764	20	-154,6	-2,83	7,02	6,85	0,832	0,905
	2016	20	-154,6	-2,89	7,02	6,85	0,847	0,907
	2268	20	-154,7	-2,85	7,02	6,85	0,840	0,899
	2520	20	-154,7	-2,83	7,02	6,85	0,837	0,896
DCC-Sim.	252	20	-156,1	-4,14	10,06	9,27	0,898	1,021
	504	20	-154,9	-6,62	10,13	9,22	1,041	1,072
	756	20	-154,5	-7,46	10,16	9,21	1,008	1,020
	1008	20	-154,2	-7,89	10,15	9,20	1,032	1,010
	1260	20	-154,1	-8,09	10,16	9,20	1,042	0,996
	1512	20	-154,1	-8,19	10,16	9,20	0,997	1,010
	1764	20	-154,1	-8,29	10,18	9,19	0,941	0,992
	2016	20	-154,0	-8,42	10,18	9,19	0,983	0,995
	2268	20	-153,9	-8,50	10,19	9,19	1,001	0,996
	2520	20	-153,9	-8,53	10,19	9,20	0,996	1,002

Tabelle 15: Synthetische Validierung: Stabilität über die Trainingsfenster
Bewertet ab 01.01.2010; das Universum ist mit 20 Anlagen konstant.

Literaturverzeichnis

- Ardia, D., Bolliger, G., Boudt, K., & Gagnon-Fleury, J.-P. (2017). The impact of covariance misspecification in risk-based portfolios. *Annals of Operations Research*, 254(1–2), 1–16. <https://doi.org/10.1007/s10479-017-2474-7>
- Behr, P., Güttler, A., & Miebs, F. (2008). *Is minimum-variance investing really worth the while? An analysis with robust performance inference* (Techn. Ber.). EDHEC-Risk Institute. https://www.cfr-cologne.de/download/kolloquium/2009/behret_al.pdf
- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327. [https://doi.org/10.1016/0304-4076\(86\)90063-1](https://doi.org/10.1016/0304-4076(86)90063-1)
- Bollerslev, T. (1990). Modelling the Coherence in Short-Run Nominal Exchange Rates: A Multivariate Generalized ARCH Model. *The Review of Economics and Statistics*, 72(3), 498–505. <https://doi.org/10.2307/2109358>
- Broadie, M. (1993). Computing efficient frontiers using estimated parameters. *Annals of Operations Research*, 45(1), 21–58. <https://doi.org/10.1007/BF02282040>
- Chaves, D., Hsu, J., Li, F., & Shakernia, O. (2011). Risk Parity Portfolio vs. Other Asset Allocation Heuristic Portfolios. *The Journal of Investing*, 20(1), 108–118. <https://doi.org/10.3905/joi.2011.20.1.108>
- DeMiguel, V., Garlappi, L., & Uppal, R. (2009). Optimal Versus Naive Diversification: How Inefficient is the 1/N Portfolio Strategy? *The Review of Financial Studies*, 22(5), 1915–1953. <https://doi.org/10.1093/rfs/hhm075>

- Diebold, F. X., & Mariano, R. S. (1995). Comparing Predictive Accuracy. *Journal of Business and Economic Statistics*, 13(3), 253–263. <https://doi.org/10.1080/07350015.1995.10524599>
- Engle, R. F. (1982). Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation. *Econometrica*, 50(4), 987–1007. <https://doi.org/10.2307/1912773>
- Engle, R. F. (2002). Dynamic Conditional Correlation: A Simple Class of Multivariate Generalized Autoregressive Conditional Heteroskedasticity Models. *Journal of Business and Economic Statistics*, 20(3), 339–350. <https://doi.org/10.1198/073500102288618487>
- Engle, R. F., & Colacito, R. (2006). Testing and Valuing Dynamic Correlations for Asset Allocation. *Journal of Business and Economic Statistics*, 24(2), 238–253. <https://doi.org/10.1198/073500106000000017>
- Engle, R. F., & Sheppard, K. (2001). *Theoretical and Empirical Properties of Dynamic Conditional Correlation Multivariate GARCH* (NBER Working Paper Nr. 8554). National Bureau of Economic Research. <https://doi.org/10.3386/w8554>
- Jobson, J. D., & Korkie, B. M. (1981). Performance Hypothesis Testing with the Sharpe and Treynor Measures. *The Journal of Finance*, 36(4), 889–908. <https://doi.org/10.1111/j.1540-6261.1981.tb04891.x>
- Laurent, S., Rombouts, J. V. K., & Violante, F. (2012). On the forecasting accuracy of multivariate GARCH models. *Journal of Applied Econometrics*, 27(6), 934–955. <https://doi.org/10.1002/jae.1248>
- Ledoit, O., & Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411. [https://doi.org/10.1016/S0047-259X\(03\)00096-4](https://doi.org/10.1016/S0047-259X(03)00096-4)
- Lee, W. (2011). Risk-Based Asset Allocation: A New Answer to an Old Question? *The Journal of Portfolio Management*, 37(4), 11–28. <https://doi.org/10.3905/jpm.2011.37.4.011>
- López de Prado, M. (2016). Building Diversified Portfolios that Outperform Out of Sample. *The Journal of Portfolio Management*, 42(4), 59–69. <https://doi.org/10.3905/jpm.2016.42.4.059>
- Markowitz, H. (1952). Portfolio Selection. *The Journal of Finance*, 7(1), 77–91. <https://doi.org/10.1111/j.1540-6261.1952.tb01525.x>
- Memmel, C. (2003). Performance Hypothesis Testing with the Sharpe Ratio. *Finance Letters*, 1(1), 21–23.
- Michaud, R. O. (1989). The Markowitz Optimization Enigma: Is 'Optimized' Optimal? *Financial Analysts Journal*, 45(1), 31–42. <https://doi.org/10.2469/faj.v45.n1.31>
- Moura, G. V., Santos, A. A. P., & Ruiz, E. (2020). Comparing high-dimensional conditional covariance matrices: Implications for portfolio selection. *Journal of Banking & Finance*, 118, 105882. <https://doi.org/10.1016/j.jbankfin.2020.105882>
- Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256. <https://doi.org/10.1016/j.jeconom.2010.03.034>

- Sen, J., Mehtab, S., Dutta, A., & Mondal, S. (2022). Hierarchical Risk Parity and Minimum Variance Portfolio Design on NIFTY 50 Stocks. <https://doi.org/10.48550/arXiv.2202.02728>
- West, K. D. (1996). Asymptotic Inference about Predictive Ability. *Econometrica*, 64(5), 1067–1084. <https://doi.org/10.2307/2171956>