

Risikobasierte Portfoliooptimierung mit GARCH-Modellen

1 Einleitung

2 Daten

In diesem Abschnitt wird die Datengrundlage der empirischen Untersuchung beschrieben. Dabei wird zwischen den empirischen Sektordaten und den simulierten Datensätzen unterschieden.

2.1 Sektorindizes

Verwendet werden tägliche Kurse US-amerikanischer Sektorindizes, die über Datastream bezogen wurden. Als Sektorabgrenzung dienen die Business Groups der Refinitiv Business Classification (TRBC), wobei für die Vereinigten Staaten nur Daten für 28 der insgesamt 32 Business Groups verfügbar sind. Eine davon zeigt an rund zwei Dritteln ihrer Datenpunkte keine Kursbewegung und wird als inaktive Reihe verworfen, sodass 27 Sektoren in die Analyse eingehen. Der Beobachtungszeitraum reicht vom 02.04.1999 bis zum 09.06.2026 und umfasst 7.087 Handelstage, wobei nur für 16 Sektorindizes Daten über die gesamte Historie vorliegen, während die übrigen Datenreihen erst zu späteren Zeitpunkten starten.

Die Querschnittsverteilung der Sektorrenditen ist in Tabelle 1 dargestellt. Auffällig ist dabei die durchschnittliche paarweise Korrelation von 0,562, die aufgrund der Begrenzung auf den US-Aktienmarkt erwartungsgemäß hoch ausfällt und die Diversifikationsmöglichkeiten innerhalb des Universums von vornherein einschränkt.

2.2 Risikofreier Zins

Als risikofreier Zinssatz dient die Fed Funds Rate, die wie auch die Sektorindizes über Datastream bezogen wird. Sie fließt nicht in die Optimierung der einzelnen Portfolios ein, sondern wird ausschließlich für die Berechnung der Sharpe Ratio verwendet.

Kennzahl	Min.	25 %	Median	75 %	Max.
Beobachtungen	1351	1877	7087	7087	7087
Rendite p.a. (%)	-5,34	4,70	6,02	8,97	20,27
Volatilität p.a. (%)	15,06	19,73	22,41	26,32	49,20

Tabelle 1: Deskriptive Statistik der TRBC-Sektorrenditen

Tägliche logarithmierte Renditen von 27 TRBC-Sektorindizes, 02.04.1999 bis 09.06.2026; durchschnittliche paarweise Korrelation 0,562.

2.3 Synthetische Datensätze

Hinzu kommen drei künstlich erzeugte Datensätze, die ausschließlich der Validierung der Implementierung dienen. Simuliert werden ein Prozess mit konstanter Kovarianzmatrix sowie je ein CCC- und ein DCC-GARCH-Prozess, sodass für jeden der drei Kovarianzschätzer ein Datensatz vorliegt, auf dem er korrekt spezifiziert ist. Auf diese Weise lässt sich prüfen, ob die Modelle genau die Struktur erkennen, für die sie konstruiert sind, was an echten Daten wegen des unbekannten datengenerierenden Prozesses nicht möglich ist. Die Parametrisierung ist im Anhang B dokumentiert.

3 Methodik

In diesem Abschnitt wird das Untersuchungsvorgehen vorgestellt. Dabei wird auf die Schätzung der Kovarianzmatrix, die Portfoliooptimierung und die Vergleichsmetriken eingegangen.

3.1 Rolling Window

Um für mögliche Strukturbrüche in den Daten zu kontrollieren und zugleich einer realistischen Anwendung nahe zu kommen, wird ein Rolling-Window-Ansatz gewählt. Die Kovarianzmatrix wird dabei auf einem Trainingsfenster der Länge T geschätzt, daraus werden die Portfoliogewichte bestimmt und diese über den Prognosehorizont von h Handelstagen gehalten, bevor das Fenster um h Tage weiterrückt. Variiert werden beide Größen, wobei das Trainingsfenster zwischen einem und zehn Jahren liegt und der Prognosehorizont 1, 5, 10 oder 21 Handelstage beträgt. Der Vergleich der daraus resultierenden 40 Kombinationen zeigt zum einen, ob die Befunde robust gegenüber der Wahl von Trainings- und Prognosefenster sind, und zum anderen, bei welcher Fensterlänge sich Schätzfehler aus zu wenigen Beobachtungen und Fehlspezifikation aus sich ändernden Parametern am besten ausgleichen. Als Basisfall werden durchgängig $T = 1008$ (vier Jahre) und $h = 1$ berichtet und von da ausgehend die Robustheit der Ergebnisse überprüft.

Je Zeitfenster werden dabei nur Sektoren berücksichtigt, die an mindestens 90 % der Handelstage verfügbar sind, um so eine ausreichende Datenbasis für die Schätzung zu gewährleisten und zugleich nicht ganze Anlagen wegen einzelner fehlender Datenpunkte auszuschließen. Das

investierbare Universum wird somit in jedem Fenster neu bestimmt und variiert sowohl über die Zeit als auch über die Fensterlänge.

Ein Nachteil des Untersuchungsdesigns ist jedoch, dass ein längeres Trainingsfenster den Out-of-Sample-Zeitraum verkürzt. So beginnt dieser bei einem Jahr Trainingsdaten bereits im März 2000, bei zehn Jahren dagegen erst im November 2008. Der lange Lauf schließt damit den Einbruch der Finanzkrise aus und deckt im Wesentlichen nur die anschließende Erholung ab. Diese Unterschiede führen dazu, dass die Ergebnisse durch die jeweils abgedeckten Marktphasen beeinflusst werden, wodurch die Vergleichbarkeit eingeschränkt wird. Sämtliche Vergleiche über Trainingsfenster und Prognosehorizonte werden daher auf dem gemeinsamen Bewertungszeitraum ab dem 01.01.2010 gerechnet, sodass alle Testzeiträume rund 4.280 Handelstage umfassen und alle Ergebnisse über die gleichen Marktphasen bestimmt werden. Der Basisfall wird zusätzlich zuerst über seine volle verfügbare Historie ab Februar 2003 berichtet, da sich die Frage der Vergleichbarkeit dort nicht stellt. Wie weit beide Rechnungen auseinanderliegen zeigt der Abschnitt zur Robustheit.

3.2 Kovarianzschätzer

Verglichen werden drei Schätzer der bedingten Kovarianzmatrix, die eine aufsteigende Leiter an Dynamik abbilden. Den Ausgangspunkt bildet der statische historische Schätzer, der zunächst um eine zeitvariable Varianz im GARCH-Modell und anschließend um eine dynamische Korrelation im DCC-GARCH-Modell erweitert wird. Da jeder Schritt genau eine Annahme aufhebt, lässt sich der Beitrag der jeweiligen Komponente isoliert bewerten.

Historische Kovarianzmatrix: Verwendet wird zunächst die Stichprobenkovarianz der Trainingsrenditen, in der die Annahme konstanter Varianzen und Korrelationen über das gesamte Fenster unverändert erhalten bleibt.

Der Vorteil dieses Schätzers liegt in seiner Einfachheit, da er keine Parameterschätzung im engeren Sinn benötigt und deshalb weder von Konvergenzproblemen noch von einer Fehlspezifikation der Dynamik betroffen sein kann. Dem steht seine Trägheit gegenüber, weil ein Volatilitätsschock nur mit einem geringen Gewicht in die Schätzung eingeht und erst nach T Handelstagen wieder aus ihr verschwindet. Aus diesen Gründen dient die historische Matrix in dieser Arbeit als statischer Referenzpunkt, gegen den der Mehrwert der beiden dynamischen Modelle gemessen wird.

Generalized Autoregressive Conditional Heteroskedasticity (GARCH): Das GARCH-Modell wurde im Jahr 1986 von Bollerslev vorgestellt und verallgemeinert das ARCH-Modell, mit dem Engle (1982) die zeitvariable Varianz von Finanzzeitreihen erstmals ökonometrisch erfasst hatte. Beide Modelle greifen die Beobachtung auf, dass große Kursausschläge gehäuft auftreten und weitere große Ausschläge nach sich ziehen, was der historische Schätzer per Konstruktion ignoriert. Der Grundgedanke besteht darin, die Varianz nicht als Konstante, sondern

als bedingte Größe zu behandeln, die aus der Information bis zur Vorperiode fortgeschrieben wird.

Ein GARCH(1,1) beschreibt die Rendite als Summe aus einem konstanten Mittelwert und einem Störterm, dessen Varianz einer eigenen Rekursion folgt.

$$r_t = \mu + \varepsilon_t \quad (1)$$

$$\varepsilon_t = \sqrt{h_t} z_t, \quad z_t \sim \mathcal{N}(0, 1) \quad (2)$$

$$h_t = \omega + \alpha \varepsilon_{t-1}^2 + \beta h_{t-1} \quad (3)$$

Die bedingte Varianz h_t setzt sich damit aus drei Bestandteilen zusammen (Gleichung 3). Die Konstante ω verankert das langfristige Varianzniveau, während α steuert, wie stark ein neuer Schock die Varianz bewegt, und β misst, wie lange dieser Einfluss anhält. Damit die unbedingte Varianz existiert und der Prozess stationär bleibt, müssen $\omega > 0$, $\alpha, \beta \geq 0$ sowie $\alpha + \beta < 1$ gelten (Bollerslev, 1986).

Da die Portfoliogewichte nicht nur für den Folgetag, sondern für die kommenden h Handelstage gelten, wird die Rekursion über den Horizont fortgeschrieben und anschließend gemittelt. Weil der erwartete quadrierte Schock der bedingten Varianz entspricht, vereinfacht sich die Fortschreibung ab dem zweiten Schritt zu einer Konvergenz gegen die unbedingte Varianz.

$$E_t[h_{t+k}] = \omega + (\alpha + \beta) E_t[h_{t+k-1}], \quad k \geq 2 \quad (4)$$

$$\bar{h}_{t,h} = \frac{1}{h} \sum_{k=1}^h E_t[h_{t+k}] \quad (5)$$

Die horizontgemittelte Varianzprognose $\bar{h}_{t,h}$ aus Gleichung 5 geht als Diagonalelement in die Kovarianzmatrix ein.

Für ein Portfolio genügt die Modellierung der einzelnen Varianzen allerdings nicht, da für die Gewichte die vollständige Kovarianzmatrix benötigt wird. Die Umsetzung folgt deshalb dem Constant-Conditional-Correlation-Ansatz (CCC) von Bollerslev (1990), bei dem für jeden Sektor ein eigenes GARCH(1,1) geschätzt, die Korrelationsmatrix dagegen konstant gehalten wird:

$$\Sigma_t = D_t R D_t, \quad D_t = \text{diag}(\sqrt{\bar{h}_1}, \dots, \sqrt{\bar{h}_N}) \quad (6)$$

Die Diagonalmatrix D_t enthält die prognostizierten Standardabweichungen der N Sektoren, während R als Stichprobenkorrelation der standardisierten Residuen z_t aus Gleichung 2 geschätzt wird. Diese werden statt der Rohrenditen verwendet, da in ihnen die Volatilitätscluster bereits

herausgefiltert sind und Tage hoher Volatilität die Korrelationsschätzung sonst verzerren würden. Gegenüber der historischen Matrix ändert sich damit ausschließlich die Behandlung der Varianzen, wodurch der Vergleich beider Schätzer den Beitrag der dynamischen Volatilität isoliert.

Dynamic Conditional Correlation (DCC-GARCH): Da das GARCH-Modell weiterhin von einer konstanten Korrelation ausgeht, die in der Realität nur selten vorliegt, entwickelte Engle (2002) mit dem DCC-GARCH-Modell eine Erweiterung, die auch diese Restriktion aufhebt. Engle überträgt dafür die Rekursion aus Gleichung 3 auf die Korrelation selbst und erhält so eine vollständig zeitvariable Kovarianzprognose.

Modelliert wird dabei zunächst eine Hilfsmatrix Q_t , die anschließend zu einer gültigen Korrelationsmatrix normiert wird.

$$Q_t = (1 - a - b) \bar{Q} + a z_{t-1} z'_{t-1} + b Q_{t-1} \quad (7)$$

$$R_t = \text{diag}(Q_t)^{-1/2} Q_t \text{diag}(Q_t)^{-1/2} \quad (8)$$

$$\Sigma_t = D_t R_t D_t \quad (9)$$

Der Aufbau von Gleichung 7 entspricht dem der GARCH-Rekursion, wobei $\bar{Q}$ die Rolle des langfristigen Niveaus übernimmt und auf die Stichprobenkorrelation der standardisierten Residuen gesetzt wird. Wie stark die Korrelationen auf neue gemeinsame Schocks reagieren, misst der Parameter a , während b deren Persistenz angibt. Analog zum univariaten Fall müssen dafür $a, b \geq 0$ und $a + b < 1$ gelten. Da Q_t auf der Diagonale keine Einsen aufweisen muss, ist die Normierung in Gleichung 8 nötig, um eine Korrelationsmatrix zu erhalten. Aus dieser und den prognostizierten Standardabweichungen ergibt sich die Kovarianzmatrix schließlich nach Gleichung 9.

Geschätzt wird das Modell in zwei Schritten, indem zuerst die univariaten GARCH-Modelle und anschließend die beiden Parameter a und b per Maximum-Likelihood auf den standardisierten Residuen bestimmt werden. Für $h > 1$ wird die Korrelationsprognose gemäß Engle und Sheppard (2001) auf $\bar{Q}$ zurückgeführt und über den Horizont gemittelt, damit sie zur ebenfalls horizontgemittelten Varianzprognose passt.

Da GARCH- und DCC-Schätzer dieselben Varianzprognosen und dieselben standardisierten Residuen verwenden, isoliert ihr Vergleich exakt den Beitrag der dynamischen Korrelation. Die drei Schätzer bilden somit die eingangs beschriebene Leiter, deren Stufen sich um jeweils genau eine Annahme unterscheiden.

3.3 Portfoliomodelle

Allen vier Allokationsverfahren ist gemeinsam, dass in ihre Gewichte ausschließlich die zweiten Momente eingehen und keine Renditeprognose benötigt wird. Damit entfällt die Fehlerquelle, die nach Broadie (1993) die Lage der effizienten Grenze am stärksten verzerrt. Berücksichtigt werden Verfahren mit unterschiedlichen Zielen, die die geschätzte Kovarianzmatrix verschieden intensiv nutzen und deshalb auch verschieden empfindlich auf deren Fehler reagieren.

Minimum-Varianz-Portfolio (MVP) Das Minimum-Varianz-Portfolio bildet nach dem Ansatz von Markowitz (1952) das Portfolio, das ohne Berücksichtigung der erwarteten Renditen die geringste Volatilität aufweist. Daraus ergibt sich die folgende Zielfunktion:

$$\min_w w' \Sigma w \quad \text{unter} \quad \mathbf{1}' w = 1, \quad w \geq 0 \quad (10)$$

Der Vektor w enthält die Portfoliogewichte und Σ die prognostizierte Kovarianzmatrix, während die Budgetrestriktion $\mathbf{1}' w = 1$ die Vollinvestition sicherstellt. Zusätzlich wird mit $w \geq 0$ ein Leerverkaufsverbot gesetzt. Nach Behr et al. (2008) überzeugt das MVP besonders in volatilen Marktphasen.

Zugleich ist es das anfälligste Verfahren, da die Minimierung gezielt die Richtungen kleinster geschätzter Varianz aufsucht, in denen die Schätzfehler relativ am größten sind. Fehler werden dadurch nicht ausgemittelt, sondern verstärkt, weshalb Lee (2011) auf die typischerweise stark konzentrierten MVP-Lösungen hinweist.

Equal Risk Contribution (ERC) Das Equal-Risk-Contribution-Portfolio verfolgt nach Maillard et al. (2010) das Ziel, das Gesamtrisiko nicht zu minimieren, sondern gleichmäßig auf die Anlagen zu verteilen. Grundlage ist die Zerlegung der Portfoliovolatilität in die Risikobeiträge der einzelnen Anlagen, die sich in der Summe genau zur Gesamtvolatilität ergänzen.

$$RC_i = \frac{w_i (\Sigma w)_i}{\sqrt{w' \Sigma w}} \quad (11)$$

$$RC_i = RC_j \quad \text{für alle } i, j \quad (12)$$

Der Risikobeitrag RC_i aus Gleichung 11 ist das Produkt aus dem Gewicht der Anlage und ihrem Grenzkrisikobeitrag, wobei die Gewichte so bestimmt werden, dass alle Beiträge übereinstimmen (Gleichung 12). Anders als das MVP nutzt ERC die Kovarianzmatrix somit nur über das Produkt Σw und nicht über ihre Inverse, weshalb Schätzfehler weniger stark durchschlagen und ein robusteres Portfolio entsteht.

Das Ergebnis liegt konstruktionsbedingt zwischen dem MVP und dem gleichgewichteten Portfolio und ist in der Regel deutlich besser diversifiziert. Dennoch schlägt ERC das naive Portfolio nach Chaves et al. (2011) nicht durchgängig.

Hierarchical Risk Parity (HRP) Hierarchical Risk Parity wurde von López de Prado (2016) mit dem Ziel entwickelt, die Matrixinversion des MVP durch eine hierarchische Struktur zu ersetzen und das Verfahren dadurch robuster gegenüber schlecht konditionierten Kovarianzmatrizen zu machen. Der Algorithmus läuft in drei Schritten ab, von denen der erste die Korrelationen in eine Distanz überführt.

$$d_{ij} = \sqrt{0,5 (1 - \rho_{ij})} \quad (13)$$

Zwei Sektoren stehen sich nach Gleichung 13 umso näher, je höher ihre Korrelation ρ_{ij} ausfällt. Auf Basis dieser Distanz werden die Sektoren im zweiten Schritt zu einem Binärbaum geclustert und die Kovarianzmatrix quasi-diagonal geordnet, sodass ähnliche Anlagen nebeneinander stehen. Im dritten Schritt wird das Kapital durch rekursive Bisektion verteilt, wobei die geordnete Liste wiederholt halbiert und das Gewicht zwischen beiden Hälften invers zu deren Varianz aufgeteilt wird.

Entscheidend ist, dass HRP die Kovarianzmatrix nie invertiert und von ihr nur die Ordnungsinformation sowie die Varianzen der Teilcluster nutzt. Das Verfahren ist dadurch robuster als das MVP, verwertet aber im Umkehrschluss eine bessere Schätzung auch nur eingeschränkt. López de Prado (2016) und Sen et al. (2022) berichten entsprechend stabilere Gewichte und eine konkurrenzfähige risikoadjustierte Rendite.

Benchmark Als Vergleichsmaßstab dient das gleichgewichtete 1/N-Portfolio, das jeder im Fenster verfügbaren Anlage denselben Anteil zuweist. Es benötigt keine Schätzung der zweiten Momente und ist damit als einziges der vier Verfahren immun gegen Schätzfehler.

Das naive Portfolio bildet den relevanten Maßstab für die erste Forschungsfrage, da ein Optimierungsverfahren seinen Aufwand nur rechtfertigt, wenn dessen Gewinn den Verlust durch Schätzfehler übersteigt. Wie hoch dieser Maßstab liegt, zeigt der Vergleich von DeMiguel et al. (2009), in dem keine der optimierten Strategien das gleichgewichtete Portfolio verlässlich schlagen konnte.

3.4 Bewertungskriterien

Die Bewertung trennt zwischen der Prognosequalität der Kovarianzmatrix und der ökonomischen Performance der daraus abgeleiteten Portfolios.

Statistische Verlustmaße Die Prognosequalität wird über zwei Verlustmaße gemessen, den multivariaten Quasi-Likelihood-Verlust (QLIKE) und den Mean Squared Error (MSE) der Kovarianzeinträge. Da die wahre bedingte Kovarianzmatrix der Testperiode nicht beobachtbar ist, wird die Prognose bei beiden gegen denselben realisierten Proxy gemessen.

$$S = \frac{1}{h} \sum_{t=1}^h r_t r_t' \quad (14)$$

$$\text{QLIKE}(\Sigma, S) = \ln |\Sigma| + \text{tr}(\Sigma^{-1} S) \quad (15)$$

$$\text{MSE}(\Sigma, S) = \frac{1}{N^2} \sum_{i,j} (\Sigma_{ij} - S_{ij})^2 \quad (16)$$

Dabei ist Σ die prognostizierte und S die realisierte Kovarianzmatrix, r_t der Vektor der logarithmierten Tagesrenditen und N die Zahl der Anlagen im jeweiligen Fenster. Beide Verluste werden je Rebalancierungsfenster berechnet und anschließend über die Fenster gemittelt, wobei niedrigere Werte eine bessere Prognose bedeuten.

Die beiden Maße unterscheiden sich darin, wie sie Fehler in beide Richtungen gewichten. Der QLIKE-Verlust aus Gleichung 15 bestraft eine Unterschätzung des Risikos stärker als eine Überschätzung, da der Term $\text{tr}(\Sigma^{-1} S)$ stark ansteigt, sobald die Matrix zu klein prognostiziert wurde. Damit ist er ökonomisch besser motiviert als ein symmetrisches Maß. Der MSE aus Gleichung 16 misst dagegen den quadratischen Abstand über alle Matrixeinträge und gewichtet Über- wie Unterschätzung gleich.

Die Wahl gerade dieser beiden Maße folgt aus den Eigenschaften des Proxys, der zwar erwartungstreu, aber verrauscht ist. Für $h = 1$ besteht er aus einem einzigen äußeren Produkt, wodurch insbesondere in diesem Fall das Rauschen des Schätzers zu beachten ist. QLIKE und MSE gehören beide zu den Verlusten, die gegen ein solches Rauschen robust sind. Für die beiden Metriken ist daher die erwartete Rangfolge zweier Prognosen dieselbe, unabhängig davon, ob gegen den verrauschten Proxy oder gegen die unbeobachtbare Wahrheit gemessen wird. Patton (2011) entwickelt dieses Konzept für den univariaten Fall der Varianzprognose, während Laurent et al. (2013) es auf vollständige Kovarianzmatrizen übertragen. Beide hier verwendeten Maße gehören zu den Verlustfunktionen, die Laurent et al. (2012) auf dieser Grundlage für den Vergleich multivariater GARCH-Modelle einsetzen. Folglich ist der absolute Wert der Metriken zwar nur eingeschränkt interpretierbar, jedoch ist die Rangfolge robust, weshalb Qualitätsunterschiede zwischen den Schätzern erkannt werden können.

Da die Länge des Trainingsfensters die Zahl der investierbaren Anlagen und damit die Dimension der Kovarianzmatrix beeinflusst, sind die Verlustniveaus zwischen den Kombinationen nur mit Vorsicht zu vergleichen. Aussagekräftig ist daher in erster Linie die Differenz zwischen den Schätzern innerhalb einer Spezifikation.

Ökonomische Kennzahlen Berichtet werden die annualisierte Rendite, die realisierte Volatilität, die Sharpe Ratio und der Turnover. Alle vier Kennzahlen beruhen auf der Tagesrendite des Portfolios $r_{p,t}$, die sich als mit den Portfoliogewichten gewichtete Summe der Sektorrenditen ergibt.

$$R_{\text{ann}} = \left(\prod_{t=1}^n (1 + r_{p,t}) \right)^{\frac{252}{n}} - 1 \quad (17)$$

$$\sigma_{\text{ann}} = \sqrt{252} \text{ sd}(r_{p,t}) \quad (18)$$

$$\text{SR} = \frac{252 \overline{(r_{p,t} - r_{f,t})}}{\sqrt{252} \text{ sd}(r_{p,t} - r_{f,t})} \quad (19)$$

Die annualisierte Rendite aus Gleichung 17 ist die geometrische Wachstumsrate über die n Handelstage des Bewertungszeitraums, während die realisierte Volatilität als annualisierte Standardabweichung derselben Reihe berechnet wird. Bei der Sharpe Ratio beruhen Zähler und Nenner auf derselben Überschussrenditereihe, damit die Annualisierung beider Größen konsistent bleibt.

Der Turnover misst, wie viel Handel ein Verfahren je Rebalancierung auslöst.

$$\text{TO}_k = \sum_{i=1}^N \left| w_{i,k}^{\text{Ziel}} - w_{i,k-1}^{\text{Ende}} \right| \quad (20)$$

Dabei sind $w_{i,k}^{\text{Ziel}}$ die neuen Zielgewichte der Rebalancierung k und $w_{i,k-1}^{\text{Ende}}$ die über die vorangegangene Halteperiode gedrifteten Endgewichte. Bestimmt wird damit der Anteil des Portfolios, der umgeschichtet werden muss, um die neue Zielallokation zu erreichen, weshalb der Turnover als Proxy für Transaktionskosten verstanden werden kann. In dieser Studie werden die Transaktionskosten beim Rebalancing zwar nicht berücksichtigt, jedoch würde ein deutlich höherer Turnover die Rendite und somit auch die Sharpe Ratio stark negativ beeinflussen.

Signifikanztests Signifikanzaussagen beruhen auf zwei Tests. Unterschiede in der Prognosegüte werden mit dem Test von Diebold und Mariano (1995) auf die Verlustdifferenzen geprüft. Für Unterschiede in den Sharpe Ratios dient der Test von Jobson und Korkie (1981) in der Korrektur von Memmel (2003), der die Korrelation der beiden Renditereihen berücksichtigt. Ohne die Berücksichtigung dieser Korrelation fiel der Test zu großzügig aus, da die Renditereihen zweier risikobasierter Portfolios auf demselben Universum hoch korreliert sind (Memmel, 2003).

4 Ergebnisse

Zunächst wird geprüft, ob die GARCH-basierten Schätzer die Kovarianzmatrix besser prognostizieren, bevor untersucht wird, ob sich ein solcher Vorteil auch in der Portfolioperformance niederschlägt. Diese Reihenfolge folgt dem Einwand von Engle und Colacito (2006), wonach die Sharpe Ratio von den realisierten Renditen dominiert wird, auf die die Kovarianzmatrix nur mittelbar wirkt, was sich ebenso auf andere renditebasierte Kennzahlen übertragen lässt. Anschließend wird die Stabilität beider Befunde über Trainingsfenster, Prognosehorizonte und Teilperioden betrachtet.

4.1 Statistische Prognosequalität

Im Basisfall ordnet sich die Prognosegüte unter beiden Verlustmaßen nach der Modellkomplexität, wie Tabelle 2 zeigt. Die historische Matrix schneidet am schlechtesten ab, während der GARCH-Schätzer sie deutlich verbessert und DCC-GARCH nochmals einen kleinen Zusatzgewinn liefert. QLIKE und MSE stimmen in dieser Reihenfolge überein.

Kovarianzschätzer	QLIKE	MSE ($\times 10^{-7}$)
Historisch	-152,81	4,28
GARCH	-155,94	3,52
DCC-GARCH	-156,68	3,44

Tabelle 2: Prognosequalität der Kovarianzschätzer im Basisfall

TRBC, Training 1008 Handelstage, Prognosehorizont 1 Tag; niedrigere Werte bedeuten eine bessere Prognose.

Wie scharf die beiden Verlustmaße trennen, unterscheidet sich allerdings erheblich. Der DM-Test in Tabelle 3 verwirft die Nullhypothese gleicher erwarteter Verluste unter QLIKE in allen drei paarweisen Vergleichen auf dem 1-%-Niveau, wobei dies trotz der insgesamt geringen Differenz auch für den Vergleich von DCC-GARCH und GARCH gilt. Unter dem MSE sind die Abstände zur historischen Matrix hingegen nur auf dem 5-%-Niveau signifikant, während der Unterschied zwischen DCC und GARCH nicht mehr von null zu trennen ist. Belastbar ist somit, dass beide dynamischen Schätzer die historische Matrix unter beiden Maßen schlagen, während sich der Zusatznutzen der dynamischen Korrelation nur unter QLIKE nachweisen lässt.

Über das gesamte Untersuchungsdesign hinweg ist der statistische Vorsprung nahezu vollständig, da DCC-GARCH unter dem MSE in sämtlichen 40 Kombinationen besser prognostiziert als die historische Matrix und unter QLIKE in nahezu allen. Wie stark der Vorsprung ausfällt, hängt jedoch von der Spezifikation ab, wie Tabelle 4 zeigt. Mit der Länge des Trainingsfensters nimmt er monoton zu, wobei bei einjährigem Training unter QLIKE kein Vorteil vorliegt und der GARCH-Schätzer sogar schlechter abschneidet als die historische Matrix. Eine mögliche Erklärung hierfür ist, dass die dynamischen Modelle insgesamt mehr Parameter schätzen müssen und deshalb bei einer geringen Datenbasis schlechter abschneiden, obwohl ihre Annahmen näher

Vergleich	$\emptyset \Delta$ Verlust	t -Statistik	p -Wert	Termine
<i>QLIKE</i>				
GARCH vs. Historisch	-2,563	-4,18	<0,001***	6013
DCC-GARCH vs. Historisch	-3,308	-5,28	<0,001***	6013
DCC-GARCH vs. GARCH	-0,744	-13,86	<0,001***	6079
<i>MSE ($\times 10^{-7}$)</i>				
GARCH vs. Historisch	-0,764	-2,23	0,026**	6079
DCC-GARCH vs. Historisch	-0,846	-2,11	0,035**	6079
DCC-GARCH vs. GARCH	-0,082	-1,26	0,207	6079

Tabelle 3: Diebold-Mariano-Tests auf die Verlustdifferenzen (Basisfall)

Negative Differenzen bedeuten, dass der erstgenannte Schätzer besser prognostiziert; ***, **, * = 1-, 5-, 10-%-Niveau.

an der Realität liegen. Über den Prognosehorizont fällt der Vorsprung dagegen ab, da Varianz- wie Korrelationsprognose mit wachsendem Horizont gegen ihre unbedingten Werte konvergieren und die Dynamik entsprechend weniger abbilden können. Der MSE zeigt dasselbe Muster, ordnet beide dynamischen Schätzer aber auch im kürzesten Fenster vor der historischen Matrix ein.

Spezifikation	QLIKE			MSE ($\times 10^{-7}$)		
	Historisch	GARCH	DCC-GARCH	Historisch	GARCH	DCC-GARCH
252	-176,1	-175,9	-176,1	2,99	2,48	2,47
504	-171,0	-171,7	-172,1	3,42	2,81	2,74
756	-165,2	-166,7	-167,3	3,41	2,84	2,75
1008	-159,7	-161,8	-162,6	3,43	2,87	2,77
1260	-154,3	-156,8	-157,7	3,42	2,83	2,75
1512	-150,1	-151,9	-152,9	3,18	2,60	2,52
1764	-146,0	-147,7	-148,8	3,11	2,53	2,45
2016	-142,0	-143,8	-144,9	3,09	2,52	2,45
2268	-140,6	-142,5	-143,7	3,05	2,46	2,41
2520	-140,0	-142,0	-143,3	3,02	2,45	2,40
$h = 1$	-159,7	-161,8	-162,6	3,43	2,87	2,77
$h = 5$	-159,5	-161,7	-162,3	1,68	1,23	1,17
$h = 10$	-159,3	-161,6	-162,2	1,32	0,95	0,90
$h = 21$	-158,9	-160,9	-161,4	0,82	0,49	0,46

Tabelle 4: Prognosequalität über Trainingsfenster und Prognosehorizonte (TRBC)

Oberer Block: Trainingsfenster in Handelstagen ($h = 1$), unterer Block: Prognosehorizonte, bewertet ab 01.01.2010.

Neben der bereits genannten Dimensionsabhängigkeit des QLIKE ist im unteren Block zu beachten, dass der Proxy über h Tage mittelt und damit umso weniger streut, je länger der Horizont ist. Das MSE-Niveau fällt deshalb über die Horizonte, ohne dass die Prognosen dort besser wären. Für die zweite Forschungsfrage fällt die statistische Antwort dennoch eindeutig aus, da beide dynamischen Modelle die Prognose der Kovarianzmatrix im Basisfall signifikant verbessern und DCC-GARCH die historische Schätzung unter dem MSE in sämtlichen 40 Kombinationen schlägt.

4.2 Ökonomische Performance

Die ökonomische Auswertung führt zu einem differenzierteren Bild. Für die erste Forschungsfrage zeigt Tabelle 5 zunächst, dass alle neun risikobasierten Kombinationen im Basisfall eine höhere Sharpe Ratio erreichen als das naive 1/N-Portfolio. Vorne liegt dabei das MVP, gefolgt von HRP und ERC. Der Vorsprung entsteht vollständig auf der Risikoseite, da das 1/N-Portfolio zwar die höchste Rendite im Feld erzielt, diese aber mit der mit Abstand höchsten Volatilität erkaufte.

Modell	Kovarianz	Rendite (%)	Vola (%)	Sharpe	Turnover
MVP	Historisch	9,03	13,82	0,567	0,008
MVP	GARCH	8,55	13,94	0,532	0,258
MVP	DCC-GARCH	8,65	13,81	0,543	0,255
HRP	Historisch	9,27	16,74	0,509	0,012
HRP	GARCH	8,96	16,21	0,502	0,072
HRP	DCC-GARCH	9,13	16,17	0,513	0,094
ERC	Historisch	9,46	17,67	0,501	0,006
ERC	GARCH	9,14	17,32	0,490	0,034
ERC	DCC-GARCH	9,13	17,31	0,490	0,034
1/N	–	9,58	18,79	0,488	0,006

Tabelle 5: Out-of-Sample-Performance im Basisfall

TRBC, Training 1008 Handelstage, Prognosehorizont 1 Tag; Rendite, Volatilität und Sharpe Ratio annualisiert, Turnover ohne Kosten.

Innerhalb der Portfoliomodelle kehrt sich die statistische Rangfolge im Basisfall weitgehend um, da bei MVP und ERC die historische Matrix vorne liegt und allein beim HRP der DCC-Schätzer marginal besser abschneidet. Der GARCH-Schätzer bleibt dabei in allen drei Modellen hinter der historischen Matrix zurück. Hierbei ist jedoch zu beachten, dass beim MVP der DCC-Schätzer die niedrigste Volatilität und damit die beste modellspezifische Performance liefert, wobei dieser kleine Vorteil in der Sharpe Ratio durch die Einbindung der Rendite vollständig verschwindet. Genau diese Größe schlagen Engle und Colacito (2006) als ökonomisches Auswahlkriterium vor, da die realisierte Volatilität des Minimum-Varianz-Portfolios unmittelbar von der Kovarianzmatrix abhängt und nicht von den Renditen überlagert wird.

Gleichzeitig fällt der mittlere Turnover des MVP mit der DCC- wie auch mit der GARCH-Kovarianz rund 32-mal so hoch aus wie mit der historischen, wodurch beide dynamischen Schätzer bei einer realen Umsetzung nochmals schlechter abschneiden würden. Grund für den hohen Turnover ist, dass die beiden dynamischen Modelle deutlich schneller auf Änderungen in der Volatilität reagieren, wodurch auch die Gewichtsverteilung der Portfolios angepasst wird, während die träge Stichprobenkovarianz die Gewichte nahezu unverändert lässt. Bei HRP und ERC fällt der Anstieg mit dem Faktor acht beziehungsweise sechs erheblich geringer aus, was auf die robustere Konstruktion der beiden Modelle zurückzuführen ist.

Statistisch abgesichert sind die Unterschiede in der Sharpe Ratio allerdings nicht, da Tabelle 6 für keinen der relevanten Vergleiche einen auch nur annähernd signifikanten p -Wert ausweist.

Dies gilt sowohl zwischen den Kovarianzschätzern als auch gegenüber dem 1/N-Portfolio. Legt man dagegen die von Engle und Colacito favorisierte realisierte Volatilität an, kehrt sich das Bild um, da der DCC-Schätzer sie in allen drei Portfoliomodellen senkt.

Vergleich	Δ Sharpe	z -Statistik	p -Wert
MVP Historical vs. MVP GARCH	0,0352	0,55	0,584
MVP Historical vs. MVP DCC	0,0243	0,37	0,709
MVP GARCH vs. MVP DCC	-0,0109	-0,78	0,435
HRP Historical vs. HRP GARCH	0,0063	0,30	0,764
HRP Historical vs. HRP DCC	-0,0041	-0,18	0,859
HRP GARCH vs. HRP DCC	-0,0104	-1,23	0,220
ERC Historical vs. ERC GARCH	0,0105	0,95	0,342
ERC Historical vs. ERC DCC	0,0111	0,98	0,329
ERC GARCH vs. ERC DCC	0,0006	0,27	0,784
MVP Historical vs. Naive	0,0797	0,69	0,487
HRP Historical vs. Naive	0,0210	0,66	0,509
ERC Historical vs. Naive	0,0132	0,85	0,395

Tabelle 6: Tests auf Unterschiede der Sharpe Ratios (Basisfall)

Auf Überschussrenditen über die Fed Funds Rate; ***, **, * = 1-, 5-, 10-%-Niveau.

Tabelle 7 fasst die Ergebnisse über alle 40 Kombinationen aus Trainingsfenster und Prognosehorizont zusammen, wobei je Portfoliomodell angegeben wird, wie oft das 1/N-Portfolio geschlagen wird und wie oft die dynamischen Schätzer die historische Matrix übertreffen. Bewertungsmaßstab ist dabei die Sharpe Ratio, wobei der Befund je nach Portfoliomodell unterschiedlich ausfällt. Zur ersten Forschungsfrage zeigt sich, dass HRP und ERC mit historischer Kovarianz das 1/N-Portfolio in rund neun von zehn Konstellationen schlagen, das MVP dagegen nur in einem Fünftel der Fälle. Ausschlaggebend ist die bereits angelegte Anfälligkeit des MVP, dessen Varianzminimierung Schätzfehler in den kleinsten Eigenwerten der Kovarianzmatrix maximal ausnutzt und zu konzentrierten Portfolios führt. Die im Basisfall beste Sharpe Ratio des MVP ist insofern nicht repräsentativ.

Zur zweiten Forschungsfrage zeigt sich ein klares Muster entlang der Portfoliomodelle, da die dynamischen Schätzer die historische Matrix beim MVP in gut der Hälfte der Läufe schlagen, beim HRP nur vereinzelt und beim ERC in keinem einzigen. Ökonomisch ist das gut erklärbar, weil das MVP als einziges Verfahren die Kovarianzmatrix vollständig einschließlich ihrer Inversen ausnutzt, während HRP lediglich die Clusterordnung und die Varianzen der Teilcluster verwendet und ERC die Risikobeiträge ausbalanciert. Eine bessere Kovarianzprognose zahlt sich folglich dort aus, wo sie am intensivsten genutzt wird, und bleibt folgenlos, wo das Verfahren die Matrix nur grob verwendet. Somit steht das ökonomische Ergebnis im Gegensatz zum statistischen Befund.

Auch über die Trainingsfenster hinweg bleibt dieses Muster erhalten (siehe Abb. 1). Beim MVP liegt DCC in neun von zehn Fenstern über der historischen Matrix, bei HRP in einem und bei ERC in keinem, wobei sich GARCH jeweils nahezu identisch verhält. Dass DCC hier beim MVP vorne liegt, während im Basisfall die historische Matrix führt, ist kein Widerspruch, sondern ein

Modell	Kovarianz	vs. 1/N	vs. historischer Matrix
MVP	Historisch	8/40	–
MVP	GARCH	15/40	22/40
MVP	DCC-GARCH	17/40	26/40
HRP	Historisch	35/40	–
HRP	GARCH	16/40	2/40
HRP	DCC-GARCH	19/40	3/40
ERC	Historisch	36/40	–
ERC	GARCH	17/40	0/40
ERC	DCC-GARCH	20/40	0/40

Tabelle 7: Ergebnisse über alle empirischen Läufe

Alle 40 Kombinationen aus Trainingsfenster und Prognosehorizont, bewertet ab 01.01.2010; ausgewiesen ist, wie oft die Sharpe Ratio höher ausfällt als beim jeweiligen Vergleichsmaßstab.

Zeitraumeffekt, da diese Vergleiche auf dem gemeinsamen Zeitraum ab 2010 beruhen und das MVP mit dynamischer Kovarianz gerade in der Phase 2010–2019 vorne liegt (siehe Anhang A). Die absoluten Unterschiede fallen dabei klein aus, weshalb angesichts der insignifikanten Tests auf Sharpe-Differenzen keine belastbare Rangfolge abgeleitet werden sollte.




Abbildung 1: Sharpe Ratio über die Trainingsfenster

TRBC, Prognosehorizont 1 Tag, Bewertung ab 01.01.2010 für alle Fenster.

Deutlicher ist der Befund über den Prognosehorizont in Tabelle 8. Wird seltener rebalanciert, bleibt die Sharpe Ratio der historischen Matrix beim MVP praktisch konstant, während sie für DCC und ebenso für GARCH bei den beiden längeren Horizonten deutlich fällt und der Turnover je Rebalancierung gleichzeitig auf mehr als das Doppelte steigt. Eine Erklärung hierfür ist, dass sich die historisch geschätzte Kovarianzmatrix nur langsam mit der Zeit verändert, weshalb ihre Prognose schon bei kurzen Vorhersagezeiträumen keine aktuelle Dynamik abbildet und über eine längere Halteperiode entsprechend wenig veraltet. Die GARCH-Modelle hingegen reflektieren Abweichungen nahezu sofort, weshalb ihre Prognose zwar den Formationszeitpunkt genau trifft, über die Halteperiode hinweg aber schnell veraltet. Erkennbar ist das auch am Turnover, da dessen hohes Niveau anzeigt, wie stark sich die Kovarianzmatrix der dynamischen Modelle über

eine längere Halteperiode verändert. Aufgrund des selteneren Rebalancings fällt der über die gesamte Historie kumulierte Turnover trotz des höheren Werts je Rebalancierung jedoch geringer aus, womit auch die Kostenbelastung einer realen Umsetzung sinken würde.

h (Tage)	1/N	Kovarianz	MVP	HRP	ERC	Turnover MVP
1	0,594	Historisch	0,606	0,592	0,604	0,008
		GARCH	0,599	0,592	0,591	0,258
		DCC-GARCH	0,620	0,611	0,592	0,255
5	0,597	Historisch	0,597	0,588	0,605	0,021
		GARCH	0,639	0,587	0,592	0,527
		DCC-GARCH	0,654	0,596	0,594	0,522
10	0,601	Historisch	0,610	0,600	0,610	0,033
		GARCH	0,524	0,578	0,589	0,603
		DCC-GARCH	0,545	0,575	0,590	0,598
21	0,602	Historisch	0,615	0,605	0,612	0,058
		GARCH	0,524	0,598	0,598	0,587
		DCC-GARCH	0,532	0,595	0,600	0,587

Tabelle 8: Sharpe Ratios und Turnover über die Prognosehorizonte (TRBC, Training 1008 Tage)
Annualisierte Sharpe Ratio, bewertet ab 01.01.2010; Turnover je Rebalancierung, also nicht auf gleiche Frequenz normiert.

4.3 Robustheit über Zeiträume und Anlageuniversen

Sämtliche bisher berichteten Vergleiche über Trainingsfenster hinweg wurden bereits auf dem gemeinsamen Zeitraum ab 2010 gerechnet. Dieser Abschnitt begründet, warum diese Einschränkung nötig ist, und zeigt, was ohne sie gemessen würde.

Ohne die Einschränkung bewertet jedes Trainingsfenster einen anderen Zeitraum, da der Out-of-Sample-Beginn von März 2000 beim kürzesten auf November 2008 beim längsten Fenster wandert. Der Lauf mit einem Jahr Training enthält damit das Platzen der Dotcom-Blase, während der Lauf mit zehn Jahren Training erst nach der Finanzkrise beginnt und nur die Erholung abdeckt, wodurch dessen Kennzahlen angehoben werden, ohne dass dies etwas über die Schätzqualität aussagt. Wie stark der Effekt wiegt, zeigt Abbildung 2, in der die Sharpe Ratio über die Trainingsfenster einmal über die volle Historie und einmal über den gemeinsamen Zeitraum aufgetragen ist. Der Sprung beim längsten Fenster tritt links auch beim 1/N-Portfolio auf, obwohl dieses überhaupt keine Schätzung vornimmt, und verschwindet rechts vollständig. Es handelt sich somit um einen reinen Stichprobeneffekt, dessen Werte je Trainingsfenster im Anhang A ausgewiesen sind.

Dass die Rangfolge der Schätzer nicht am Basisfall hängt, zeigt die Auszählung über alle 40 Kombinationen in Tabelle 10 im Anhang A. Unter beiden Verlustmaßen liegt DCC-GARCH nahezu durchgängig vorne, während ökonomisch bei HRP und ERC die historische Matrix dominiert.




Abbildung 2: Sharpe Ratio über die Trainingsfenster, voller und gemeinsamer Bewertungszeitraum TRBC, Prognosehorizont 1 Tag, links die volle Historie des jeweiligen Fensters, rechts der für alle Fenster identische Zeitraum ab 01.01.2010.

5 Einordnung in die Literatur

6 Limitationen

Die Aussagekraft der Ergebnisse ist in mehrfacher Hinsicht begrenzt, wobei die Einschränkungen im Folgenden nach ihrem Gewicht für die Interpretation geordnet werden.

Eine zentrale Limitation ist dabei, dass der Backtest ohne Handelskosten rechnet, obwohl sich die Verfahren im Turnover um den Faktor 32 unterscheiden. Die berichteten Kennzahlen begünstigen damit die dynamischen Schätzer, deren Nachteil unter realen Kosten größer ausfiel als ausgewiesen. Umgekehrt wird die Aussage des Abschnitts zur ökonomischen Performance dadurch nicht geschwächt, sondern verschärft, da dieser Nachteil bereits ohne Kosten vorhanden ist.

Auf der Messseite ist der realisierte Proxy die wesentliche Einschränkung, da er für $h = 1$ aus einem einzigen äußeren Produkt besteht und damit den Rang eins hat. Beide Verlustfunktionen bleiben nach Patton (2011) und Laurent et al. (2013) unabhängig von der Genauigkeit des Proxys rangerhaltend, jedoch begrenzt das geringe Signal-Rausch-Verhältnis die Teststärke des DM-Tests, wobei der MSE stärker betroffen ist als der QLIKE-Verlust. Intraday-Daten würden einen erheblich präziseren Proxy liefern, standen für diese Arbeit aber nicht zur Verfügung. Hinzu kommt, dass ausschließlich die relative Prognosegüte bewertet wurde und nicht die absolute Kalibrierung der prognostizierten Volatilität. Ob die Modelle das Risikoniveau im Mittel treffen, bleibt damit offen.

Des Weiteren beruht die gesamte Auswertung auf einem einzigen Universum, dessen Sektorindizes rechnerische Größen sind und sich nicht unmittelbar handeln lassen, weshalb eine direkte

Replikation der optimierten Portfolios nicht möglich ist. Gezeigt ist damit, dass die Befunde für diese Datengrundlage gelten, nicht aber, ob sie sich auf andere Märkte übertragen lassen.

7 Fazit

Die Arbeit hat zwei Fragen getrennt untersucht, nämlich ob risikobasierte Portfoliomodelle das naive 1/N-Portfolio schlagen und ob GARCH-basierte Kovarianzprognosen gegenüber der historischen Schätzung einen Mehrwert stiften.

Zur ersten Frage hängt die Antwort stark vom gewählten Verfahren ab. HRP und ERC mit historischer Kovarianz übertreffen das 1/N-Portfolio in rund neun von zehn untersuchten Konstellationen und erweisen sich als robust gegenüber Variationen von Trainings- und Prognosefenster. Das Minimum-Varianz-Portfolio erzielt im Basisfall zwar die höchste Sharpe Ratio, schlägt 1/N über alle Läufe hinweg aber nur in einem Fünftel der Fälle und reagiert am empfindlichsten auf Schätzfehler. Für die Praxis sprechen diese Ergebnisse damit eher für die robusteren Verfahren als für die Varianzminimierung, wobei einschränkend gilt, dass keiner der Vorsprünge gegenüber 1/N statistisch signifikant ist.

Zur zweiten Frage entscheidet das angelegte Kriterium über die Antwort, worin zugleich der Hauptbefund liegt. Statistisch ist das Ergebnis eindeutig, da DCC-GARCH die Kovarianzmatrix in allen 40 Läufen unter dem MSE und in nahezu allen unter dem QLIKE-Verlust besser prognostiziert als die historische Schätzung und die Abstände zur historischen Matrix im DM-Test signifikant sind. Ökonomisch schlägt sich dieser Vorsprung jedoch nur dort nieder, wo die Kovarianzmatrix tatsächlich intensiv genutzt wird, also beim MVP und nicht bei HRP oder ERC. Das ist konsistent mit der Konstruktion der Verfahren, da beide die Matrix nur grob nutzen und gerade deshalb robust, zugleich aber auch unempfindlich gegenüber ihrer Verbesserung sind. Der Preis der Dynamik ist der Turnover, der beim MVP um den Faktor 32 höher liegt und den ohnehin geringen Vorsprung unter realen Handelskosten aufzehren würde.

Der übergreifende Schluss lautet damit, dass eine bessere Risikoprognose nicht automatisch eine bessere Anlageentscheidung ist. Die GARCH-Modelle leisten das, wofür sie konstruiert sind, und die synthetische Validierung zeigt, dass sie genau dann einen Mehrwert liefern, wenn der datengenerierende Prozess ihre Annahmen erfüllt. Auf realen Sektordaten ist die verwertbare Struktur jedoch zu schwach, um die Kosten der laufenden Umschichtung zu rechtfertigen. Nicht die Prognosegüte ist folglich die bindende Restriktion, sondern der Handel, den ihre Nutzung auslöst.

8 Weitergehende Forschung

Aus den Ergebnissen und den genannten Einschränkungen ergeben sich vier Ansatzpunkte für weitere Untersuchungen.

Auf der Modellseite wird ausschließlich ein GARCH(1,1) unter Normalverteilungsannahme geschätzt, obwohl diese Annahme in der Realität nicht standhält. Zudem zeigt sich in empirischen Untersuchungen, dass negative Schocks in der Regel einen stärkeren Einfluss auf die nachfolgende Volatilität haben als positive. Anders als das einfache GARCH-Modell binden Modelle wie GJR-GARCH und EGARCH diese Asymmetrie ein und sind somit realitätsnäher, während sich über höhere Ordnungen oder ein GARCH-MIDAS zusätzlich längerfristige Komponenten der Volatilität erfassen lassen. Da der ökonomische Nachteil der dynamischen Schätzer hier aus dem Turnover und nicht aus der Prognosegüte stammt, wäre allerdings zu prüfen, ob eine realitätsnähere Varianzdynamik daran überhaupt etwas ändert.

Auf der Allokationsseite ließe sich das Feld um Verfahren wie Hierarchical Equal Risk Contribution oder Nested Clustered Optimization erweitern, die die hierarchische Struktur von HRP anders auswerten. Interessant ist das vor allem, weil sich der Mehrwert einer besseren Kovarianzprognose in dieser Arbeit genau danach richtet, wie intensiv ein Verfahren die Matrix nutzt. Offen bleibt zudem, ob eine bessere Kovarianzmatrix in Verfahren, die zusätzlich eine Renditeprognose verwenden, einen größeren Vorteil liefert, da die Matrix dort nicht nur das Risiko begrenzt, sondern auch die Gewichtung der erwarteten Renditen bestimmt.

Der dritte Ansatzpunkt betrifft die Transaktionskosten, die hier weder im Backtest noch in der Optimierung berücksichtigt werden. Ein kostenbewusster Optimierer würde den Turnover in die Zielfunktion aufnehmen und dadurch einen Teil der Belastung vermeiden, statt sie nur zu erleiden. Ob die dynamischen Schätzer unter einer solchen Nebenbedingung weiterhin zurückfallen, ist offen und wäre für die praktische Bewertung der entscheidende Test.

Schließlich sollten die Befunde an weiteren Datensätzen überprüft werden, etwa an Einzeltiteln, anderen Regionen oder Anlageklassen mit geringerer durchschnittlicher Korrelation. Gerade die hohe paarweise Korrelation des hier verwendeten Universums begrenzt die Diversifikationsmöglichkeiten von vornherein und könnte den Spielraum für eine bessere Kovarianzprognose systematisch verengen.

A Voller und gemeinsamer Bewertungszeitraum

Tabelle 9 stellt je Trainingsfenster die Kennzahlen über die volle Historie denen über den gemeinsamen Zeitraum ab 2010 gegenüber. Angegeben werden die mittlere Größe des Anlageuniversums, der QLIKE-Verlust des GARCH- und des DCC-GARCH-Schätzers sowie die Sharpe Ratio des MVP mit historischer und mit GARCH-Kovarianz und des 1/N-Portfolios. Die 90-%-Verfügbarkeitsregel lässt die zuletzt hinzugekommenen Sektoren in langen Fenstern erst spät oder gar nicht zu, weshalb die Fensterlänge über die Dimension der Kovarianzmatrix auch das QLIKE-Niveau mitbestimmt.

Training	$\varnothing N$	QLIKE GARCH		QLIKE DCC		Sharpe MVP Hist.		Sharpe MVP GARCH		Sharpe 1/N	
		voll	gem.	voll	gem.	voll	gem.	voll	gem.	voll	gem.
252	20,3	-161,8	-175,9	-162,0	-176,1	0,419	0,515	0,377	0,505	0,400	0,592
504	19,7	-160,7	-171,7	-161,0	-172,1	0,406	0,495	0,453	0,627	0,406	0,601
756	19,1	-158,3	-166,7	-158,9	-167,3	0,432	0,525	0,427	0,561	0,422	0,593
1008	18,5	-155,9	-161,8	-156,7	-162,6	0,567	0,606	0,532	0,599	0,488	0,594
1260	17,9	-152,8	-156,8	-153,6	-157,7	0,496	0,613	0,458	0,592	0,412	0,573
1512	17,4	-149,2	-151,9	-150,2	-152,9	0,445	0,574	0,424	0,562	0,407	0,576
1764	16,9	-145,9	-147,7	-147,0	-148,8	0,403	0,535	0,429	0,563	0,373	0,537
2016	16,4	-142,4	-143,8	-143,7	-144,9	0,363	0,525	0,398	0,545	0,378	0,545
2268	16,2	-141,0	-142,5	-142,3	-143,7	0,375	0,550	0,427	0,581	0,395	0,551
2520	16,2	-141,3	-142,0	-142,7	-143,3	0,556	0,521	0,606	0,582	0,603	0,563

Tabelle 9: Voller versus gemeinsamer Bewertungszeitraum (TRBC, $h = 1$)

voll bezeichnet die volle Historie des jeweiligen Fensters, *gem.* den gemeinsamen Zeitraum ab 01.01.2010.

Wie oft welcher Schätzer über alle 40 Kombinationen vorne liegt, weist Tabelle 10 aus, getrennt nach der Sharpe Ratio je Portfoliomodell und den beiden Verlustmaßen.

Kennzahl	Historisch	GARCH	DCC-GARCH
Sharpe MVP	14/40	6/40	20/40
Sharpe HRP	36/40	1/40	3/40
Sharpe ERC	40/40	0/40	0/40
QLIKE	3/40	0/40	37/40
Kovarianz-MSE	0/40	1/40	39/40

Tabelle 10: Häufigkeit des besten Kovarianzschätzers je Kennzahl

Alle 40 Kombinationen aus Trainingsfenster und Prognosehorizont, bewertet ab 01.01.2010. Ausgewiesen ist, wie oft der jeweilige Schätzer die höchste Sharpe Ratio beziehungsweise den niedrigsten Verlust liefert.

Zeitlich lokalisieren lässt sich der Bruch über die Teilperioden des Basisfalls in Tabelle 11. Das QLIKE-Niveau springt ab 2022 deutlich nach unten, wobei dieser Sprung exakt mit der Erweiterung des Universums von 17 auf 25 Sektoren im September 2022 zusammenfällt. Der MSE zeigt an dieser Stelle keinen vergleichbaren Bruch, folgt dafür aber dem Volatilitätsniveau der Periode und steigt in der Finanzkrise auf mehr als das Siebzigfache des Werts der ruhigen Phase 2003–2007. Beide Kennzahlen sind über Perioden hinweg somit nur eingeschränkt vergleichbar, wenn auch aus unterschiedlichen Gründen.

Periode	N	QLIKE			MSE ($\times 10^{-7}$)			Sharpe			
		Hist.	GARCH	DCC	Hist.	GARCH	DCC	MVP Hist.	MVP GARCH	MVP DCC	1/N
2003–2007	16–16	-143,5	-146,8	-147,3	0,28	0,23	0,23	1,190	1,146	1,158	0,845
2008–2009	16–16	-119,7	-130,1	-131,2	21,03	16,87	16,72	-0,246	-0,303	-0,339	-0,120
2010–2019	16–17	-146,1	-147,2	-147,8	0,79	0,61	0,60	0,886	0,969	0,982	0,719
2020–2021	17–17	-133,1	-139,5	-140,3	20,18	16,67	15,88	0,436	0,391	0,417	0,828
2022–2026	17–27	-205,1	-204,7	-205,9	1,79	1,71	1,70	0,259	0,116	0,144	0,224

Tabelle 11: Teilperioden des Basisfalls: Universum, Prognosequalität und Performance

N ist die Spannweite der investierbaren Sektoren; QLIKE-Niveaus sind zwischen Perioden mit unterschiedlichem N nicht vergleichbar.

Aussagekräftig bleibt die Differenz zwischen den Schätzern innerhalb einer Periode, die erheblich variiert. In der Finanzkrise 2008/09 und im COVID-Zeitraum fällt sie um ein Vielfaches größer aus als in den ruhigen Phasen. Der Mehrwert der dynamischen Modellierung konzentriert sich damit auf Phasen mit ausgeprägten Volatilitätsschocks, in denen eine statische Matrix dem Risikoniveau am stärksten nachläuft.

Ökonomisch ist die Rangfolge ebenfalls periodenabhängig, da das MVP mit DCC-Kovarianz und ebenso mit GARCH-Kovarianz die historische Variante in der Phase 2010–2019 klar schlägt, in allen übrigen Teilperioden jedoch zurückliegt. Der Basisfall umfasst die volle Historie ab 2003 und mittelt über gegenläufige Teilperioden, weshalb dort die historische Matrix vorne liegt, während die auf 2010 eingeschränkten Tabellen für das MVP zugunsten von DCC ausfallen. Beide Rechnungen sind korrekt, messen aber Unterschiedliches, wobei die Unterschiede in beide Richtungen durchgängig insignifikant sind und daher keine starke Aussage zulassen.

B Synthetische Validierung

Ob die Modelle korrekt implementiert sind, lässt sich an echten Daten nicht prüfen, da der wahre datengenerierende Prozess unbekannt ist. Stattdessen werden drei simulierte Datensätze mit jeweils 20 Anlagen und 6.000 Handelstagen verwendet, die dieselbe unbedingte Risikostruktur besitzen und sich ausschließlich in der Dynamik der zweiten Momente unterscheiden. Die annualisierten Volatilitäten liegen dabei zwischen 15 % und 35 % bei einer durchschnittlichen Korrelation von 0,35. Der Monte-Carlo-Datensatz enthält unabhängige Ziehungen mit konstanter Kovarianz und bildet den Nullfall ab, in dem die historische Matrix korrekt spezifiziert ist. Beim GARCH-Datensatz kommt eine GARCH(1,1)-Dynamik je Anlage mit $\alpha = 0,08$ und $\beta = 0,90$ bei konstanter Korrelation hinzu, während der DCC-Datensatz zusätzlich eine DCC-Rekursion mit $a = 0,03$ und $b = 0,96$ enthält. Die drei Datensätze bilden damit eine Leiter, auf der jeweils ein anderer Schätzer korrekt spezifiziert ist.

Dass die Modelle dieser Leiter folgen, zeigt Tabelle 12. Im Monte-Carlo-Fall unterscheiden sich die drei Schätzer unter beiden Verlustmaßen praktisch nicht, wobei die historische Matrix beim MVP eine minimal höhere Sharpe Ratio erzielt. Wo keine Struktur vorhanden ist, bringt das komplexere Modell folglich nichts. Im GARCH-Fall schlagen beide dynamischen Schätzer die

historische Matrix deutlich, sowohl in der Prognosegüte als auch in Sharpe Ratio und realisierter Volatilität. Sobald mit dem DCC-Prozess auch die Korrelation dynamisch ist, schlägt DCC schließlich den GARCH-Schätzer klar.

Datensatz	Kovarianz	QLIKE	MSE ($\times 10^{-8}$)	Vola (%)	Sharpe	Turnover
Monte Carlo	Historisch	-154,50	7,04	11,92	0,903	0,011
	GARCH	-154,47	7,04	11,95	0,896	0,074
	DCC-GARCH	-154,47	7,04	11,95	0,896	0,075
GARCH-Sim.	Historisch	-154,23	7,84	11,37	0,756	0,010
	GARCH	-157,25	7,57	9,85	0,854	0,154
	DCC-GARCH	-157,25	7,57	9,85	0,854	0,154
DCC-Sim.	Historisch	-154,13	9,86	11,93	0,561	0,011
	GARCH	-157,02	9,19	9,62	0,773	0,160
	DCC-GARCH	-162,13	8,98	8,99	0,783	0,152

Tabelle 12: Synthetische Validierung: Basisfall je Datengenerierungsprozess

20 simulierte Anlagen, Training 1008 Handelstage, Prognosehorizont 1 Tag; Performancekennzahlen für das MVP.

Die DM-Tests in Tabelle 13 bestätigen dieses Muster formal. Im Monte-Carlo-Prozess ist die Verlustdifferenz der dynamischen Schätzer gegenüber der historischen Matrix positiv, also minimal schlechter, und zwischen GARCH und DCC nicht von null verschieden, weshalb die zusätzliche Parametrisierung dort keinen Beitrag liefert. Beide dynamischen Schätzer sind im GARCH-Prozess signifikant besser als die historische Matrix, unterscheiden sich untereinander jedoch nicht, was korrekt ist, da die Korrelation dort konstant ist. Erst im DCC-Prozess wird der Unterschied zwischen DCC und GARCH signifikant, sodass die Implementierung jeweils genau die Struktur erkennt, die tatsächlich vorhanden ist.

Datensatz	$\Delta G-H$	t	$\Delta D-H$	t	$\Delta D-G$	t
Monte Carlo	0,029***	6,07	0,029***	6,12	0,000	0,32
GARCH-Sim.	-3,025***	-24,69	-3,024***	-24,68	0,000	1,28
DCC-Sim.	-2,887***	-15,64	-7,998***	-35,68	-5,111***	-49,85

Tabelle 13: Synthetische Validierung: DM-Tests auf die QLIKE-Differenzen

G = GARCH, D = DCC-GARCH, H = historisch; negative Differenzen bedeuten eine bessere Prognose. ***, **, * = 1-, 5-, 10-%-Niveau.

Den Gegenteilstest zur Diskussion des Strukturbruchs liefert Tabelle 14. Bewertet wird nach demselben Protokoll wie im empirischen Teil, also ab 2010. Da das Universum konstant 20 Anlagen umfasst und die Parameter des Prozesses über die gesamte Stichprobe unverändert bleiben, sollte sich das Niveau der Prognosekennzahlen über die Trainingsfenster hinweg nicht systematisch verschieben. Genau das ist der Fall, da das QLIKE-Niveau der historischen Matrix über alle zehn Fenster nur um wenige Zehntel schwankt, während die entsprechende Spannweite in den empirischen Daten über 30 Punkte beträgt. Beim MSE ist das Niveau sogar praktisch konstant. Auch die Rangfolge kehrt sich in keinem Fenster um, weil DCC in allen 20 ausgewiesenen Läufen unter beiden Verlustmaßen besser prognostiziert als die historische Matrix und sich die Differenz bei längeren Trainingsfenstern auf einem konstanten Niveau stabilisiert. Im GARCH-Datensatz stimmen die

Werte des GARCH- und des DCC-Schätzers dabei exakt überein, da die Korrelation dort konstant ist und die zusätzliche Rekursion folglich nichts beiträgt.

Datensatz	Training	N	QLIKE			MSE ($\times 10^{-8}$)			Sharpe MVP		
			Hist.	GARCH	DCC	Hist.	GARCH	DCC	Hist.	GARCH	DCC
GARCH-Sim.	252	20	-154,1	-156,2	-156,2	7,03	6,90	6,90	1,053	0,911	0,911
	504	20	-154,3	-157,0	-157,0	7,03	6,87	6,87	1,017	0,924	0,924
	756	20	-154,4	-157,2	-157,2	7,02	6,86	6,86	0,886	0,893	0,893
	1008	20	-154,4	-157,3	-157,3	7,02	6,86	6,86	0,814	0,872	0,872
	1260	20	-154,6	-157,4	-157,4	7,02	6,86	6,86	0,772	0,860	0,860
	1512	20	-154,7	-157,4	-157,4	7,02	6,86	6,86	0,784	0,858	0,857
	1764	20	-154,6	-157,5	-157,5	7,02	6,85	6,85	0,777	0,842	0,842
	2016	20	-154,6	-157,5	-157,5	7,02	6,85	6,85	0,793	0,843	0,843
	2268	20	-154,7	-157,5	-157,5	7,02	6,85	6,85	0,785	0,835	0,835
	2520	20	-154,7	-157,5	-157,5	7,02	6,85	6,85	0,782	0,833	0,833
DCC-Sim.	252	20	-156,1	-157,8	-160,2	10,06	9,38	9,27	0,836	0,950	0,953
	504	20	-154,9	-157,3	-161,5	10,13	9,39	9,22	0,983	1,094	1,002
	756	20	-154,5	-157,1	-161,9	10,16	9,40	9,21	0,952	1,065	0,950
	1008	20	-154,2	-157,0	-162,1	10,15	9,40	9,20	0,977	1,050	0,940
	1260	20	-154,1	-156,9	-162,2	10,16	9,40	9,20	0,987	1,015	0,925
	1512	20	-154,1	-157,0	-162,3	10,16	9,40	9,20	0,942	0,997	0,939
	1764	20	-154,1	-156,9	-162,4	10,18	9,40	9,19	0,885	0,942	0,921
	2016	20	-154,0	-156,9	-162,4	10,18	9,40	9,19	0,927	0,943	0,924
	2268	20	-153,9	-156,9	-162,4	10,19	9,40	9,19	0,946	0,951	0,925
	2520	20	-153,9	-156,9	-162,5	10,19	9,41	9,20	0,941	0,955	0,931

Tabelle 14: Synthetische Validierung: Stabilität über die Trainingsfenster

Bewertet ab 01.01.2010; das Universum ist mit 20 Anlagen konstant.

Die ökonomischen Kennzahlen schwanken auch hier spürbar, obwohl der Prozess vollkommen stabil ist. Beim GARCH-Datensatz schlägt der historische Schätzer in den beiden kürzesten Fenstern sogar den DCC-Schätzer, obwohl er dort mit Sicherheit falsch spezifiziert ist. Das ist kein Widerspruch, sondern eine weitere Bestätigung des Arguments aus dem Abschnitt zur ökonomischen Performance. Selbst bei bekanntem datengenerierendem Prozess ist die Sharpe Ratio zu verrauscht, um Kovarianzschätzer zuverlässig zu ordnen, während die Prognosekennzahlen ein klares Signal liefern.

Literaturverzeichnis

- Behr, P., Güttler, A., & Miebs, F. (2008). *Is minimum-variance investing really worth the while? An analysis with robust performance inference* (Techn. Ber.). EDHEC-Risk Institute. https://www.cfr-cologne.de/download/kolloquium/2009/beh_r_et_al.pdf
- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327. [https://doi.org/10.1016/0304-4076\(86\)90063-1](https://doi.org/10.1016/0304-4076(86)90063-1)
- Bollerslev, T. (1990). Modelling the Coherence in Short-Run Nominal Exchange Rates: A Multivariate Generalized ARCH Model. *The Review of Economics and Statistics*, 72(3), 498–505. <https://doi.org/10.2307/2109358>

- Broadie, M. (1993). Computing efficient frontiers using estimated parameters. *Annals of Operations Research*, 45(1), 21–58. <https://doi.org/10.1007/BF02282040>
- Chaves, D., Hsu, J., Li, F., & Shakernia, O. (2011). Risk Parity Portfolio vs. Other Asset Allocation Heuristic Portfolios. *The Journal of Investing*, 20(1), 108–118. <https://doi.org/10.3905/joi.2011.20.1.108>
- DeMiguel, V., Garlappi, L., & Uppal, R. (2009). Optimal Versus Naive Diversification: How Inefficient is the 1/N Portfolio Strategy? *The Review of Financial Studies*, 22(5), 1915–1953. <https://doi.org/10.1093/rfs/hhm075>
- Diebold, F. X., & Mariano, R. S. (1995). Comparing Predictive Accuracy. *Journal of Business and Economic Statistics*, 13(3), 253–263. <https://doi.org/10.1080/07350015.1995.10524599>
- Engle, R. F. (1982). Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation. *Econometrica*, 50(4), 987–1007. <https://doi.org/10.2307/1912773>
- Engle, R. F. (2002). Dynamic Conditional Correlation: A Simple Class of Multivariate Generalized Autoregressive Conditional Heteroskedasticity Models. *Journal of Business and Economic Statistics*, 20(3), 339–350. <https://doi.org/10.1198/073500102288618487>
- Engle, R. F., & Colacito, R. (2006). Testing and Valuing Dynamic Correlations for Asset Allocation. *Journal of Business and Economic Statistics*, 24(2), 238–253. <https://doi.org/10.1198/073500106000000017>
- Engle, R. F., & Sheppard, K. (2001). *Theoretical and Empirical Properties of Dynamic Conditional Correlation Multivariate GARCH* (NBER Working Paper Nr. 8554). National Bureau of Economic Research. <https://doi.org/10.3386/w8554>
- Jobson, J. D., & Korkie, B. M. (1981). Performance Hypothesis Testing with the Sharpe and Treynor Measures. *The Journal of Finance*, 36(4), 889–908. <https://doi.org/10.1111/j.1540-6261.1981.tb04891.x>
- Laurent, S., Rombouts, J. V. K., & Violante, F. (2012). On the forecasting accuracy of multivariate GARCH models. *Journal of Applied Econometrics*, 27(6), 934–955. <https://doi.org/10.1002/jae.1248>
- Laurent, S., Rombouts, J. V. K., & Violante, F. (2013). On loss functions and ranking forecasting performances of multivariate volatility models. *Journal of Econometrics*, 173(1), 1–10. <https://doi.org/10.1016/j.jeconom.2012.08.004>
- Lee, W. (2011). Risk-Based Asset Allocation: A New Answer to an Old Question? *The Journal of Portfolio Management*, 37(4), 11–28. <https://doi.org/10.3905/jpm.2011.37.4.011>
- López de Prado, M. (2016). Building Diversified Portfolios that Outperform Out of Sample. *The Journal of Portfolio Management*, 42(4), 59–69. <https://doi.org/10.3905/jpm.2016.42.4.059>
- Maillard, S., Roncalli, T., & Teïletche, J. (2010). The Properties of Equally Weighted Risk Contribution Portfolios. *The Journal of Portfolio Management*, 36(4), 60–70. <https://doi.org/10.3905/jpm.2010.36.4.060>

- Markowitz, H. (1952). Portfolio Selection. *The Journal of Finance*, 7(1), 77–91. <https://doi.org/10.1111/j.1540-6261.1952.tb01525.x>
- Memmel, C. (2003). Performance Hypothesis Testing with the Sharpe Ratio. *Finance Letters*, 1(1), 21–23.
- Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256. <https://doi.org/10.1016/j.jeconom.2010.03.034>
- Sen, J., Mehtab, S., Dutta, A., & Mondal, S. (2022). Hierarchical Risk Parity and Minimum Variance Portfolio Design on NIFTY 50 Stocks. <https://doi.org/10.48550/arXiv.2202.02728>