

Risikobasierte Portfoliooptimierung mit GARCH-Modellen

1 Einleitung

Seit **markowitz1952**<empty citation> ist die Zusammenstellung eines Portfolios als Optimierungsproblem formuliert, bei dem die Gewichte gesucht werden, die bei gegebener erwarteter Rendite die Portfoliovarianz minimieren. In der praktischen Anwendung erweist sich dieser Ansatz jedoch als fragil, da sowohl die Erwartungswerte als auch die Kovarianzmatrix aus historischen Daten geschätzt werden müssen. Weil das Verfahren Anlagen mit zufällig überschätzter Rendite systematisch übergewichtet, verstärkt es Schätzfehler, statt sie auszumitteln. **michaud1989**<empty citation> bezeichnet die Markowitz-Optimierung deshalb als Fehlermaximierung.

Von diesem Problem sind die beiden Eingangsgrößen unterschiedlich stark betroffen. **broadie1993**<empty citation> zeigt in einer Simulationsstudie, dass Fehler in den geschätzten Erwartungswerten die Lage der effizienten Grenze deutlich stärker verzerren als Fehler in den geschätzten Varianzen und Kovarianzen. Erwartete Renditen lassen sich aus Kursdaten nur mit großer Unsicherheit bestimmen, während Risikokennzahlen stabiler zu schätzen sind. Wie gravierend die Folgen sind, zeigen **demiguel2009**<empty citation>, da in ihrem Vergleich über mehrere Datensätze keine der optimierten Strategien das naive, gleichgewichtete 1/N-Portfolio verlässlich schlagen konnte. Der Aufwand einer Optimierung lohnt sich folglich nur, wenn ihr Gewinn den Verlust durch Schätzfehler übersteigt.

An dieser Stelle setzen risikobasierte Portfolioverfahren an, die vollständig auf Renditeprognosen verzichten und die Gewichte allein aus der Kovarianzmatrix bestimmen. Das Minimum-Varianz-Portfolio minimiert die Portfoliovarianz und überzeugt nach **behr2008**<empty citation> besonders in volatilen Marktphasen, bleibt aber anfällig für Schätzfehler und neigt zu konzentrierten Lösungen (**lee2011**). Das Equal-Risk-Contribution-Portfolio verteilt stattdessen die Risikobeiträge gleichmäßig auf alle Anlagen und ist dadurch besser diversifiziert, wobei es das naive Portfolio nach **chaves2011**<empty citation> nicht durchgängig schlägt. Hierarchical Risk Parity (HRP) von **deprado2016**<empty citation> verzichtet schließlich ganz auf die Matrixinversion und verteilt das Kapital über eine hierarchische

Clusterstruktur, wodurch sich stabilere Gewichte ergeben (**sen2022**). Die drei Verfahren unterscheiden sich damit vor allem darin, wie intensiv sie die geschätzte Kovarianzmatrix nutzen, weshalb deren Qualität unterschiedlich stark durchschlägt.

Damit rückt die Kovarianzmatrix selbst in den Mittelpunkt, denn werden die Gewichte ausschließlich aus ihr abgeleitet, sollte eine bessere Schätzung auch zu besseren Portfolios führen. Der übliche Stichprobenschätzer unterstellt jedoch konstante Varianzen und Korrelationen über das gesamte Schätzfenster. Diese Annahme widerspricht der Beobachtung, dass ruhige und turbulente Phasen einander ablösen und große Kursausschläge weitere große Ausschläge nach sich ziehen. **engle1982**<empty citation> hat diese Volatilitätscluster erstmals ökonometrisch erfasst, worauf **bollerslev1986**<empty citation> das heute übliche GARCH-Modell aufbaute. Die bedingte Varianz wird dort als gewichtete Kombination aus langfristigem Mittel, jüngstem Schock und Vorperiodenvarianz modelliert, wodurch sie unmittelbar auf neue Information reagiert.

Für ein Portfolio genügt es allerdings nicht, die Varianzen einzeln zu modellieren, da auch die Abhängigkeitsstruktur zwischen den Anlagen zeitvariabel ist. Dass Korrelationen in Stressphasen ansteigen und die Diversifikation gerade dann versagt, wenn sie am dringendsten gebraucht wird, kann ein Modell mit konstanter Korrelation nicht abbilden. **engle2002**<empty citation> überträgt die GARCH-Rekursion deshalb auf die Korrelationsmatrix selbst und erhält mit dem DCC-Modell eine vollständig zeitvariable Kovarianzprognose. Dass sich präzisere Prognosen auch in der Allokation auszahlen sollten, legen **ardia2017**<empty citation> nahe, da eine Fehlspezifikation der Kovarianzmatrix die Gewichte risikobasierter Portfolios spürbar verzerrt.

Ob diese Erwartung zutrifft, ist damit jedoch nicht beantwortet, weil eine statistisch bessere Prognose nicht automatisch eine bessere Anlageentscheidung ist. **engle2006**<empty citation> weisen darauf hin, dass die Sharpe Ratio als Kriterium für die Auswahl eines Kovarianzschätzers irreführend sein kann, da sie von den realisierten Renditen dominiert wird, auf die die Kovarianzmatrix nur mittelbar wirkt. Als Alternative bietet **patton2011**<empty citation> Verlustfunktionen an, deren Rangfolge auch bei einem verrauschten Proxy der wahren Varianz erhalten bleibt, wobei **laurent2012**<empty citation> dieses Konzept auf vollständige Kovarianzmatrizen übertragen. Für hochdimensionale bedingte Kovarianzmatrizen finden **moura2020**<empty citation> schließlich, dass die statistisch beste Spezifikation nicht die ökonomisch beste sein muss. Die Verbindung beider Themenfelder, risikobasierter Allokation einschließlich neuerer Verfahren wie HRP auf der einen und multivariater GARCH-Prognosen auf der anderen Seite, ist bislang nur vereinzelt untersucht worden.

Vor diesem Hintergrund verfolgt diese Arbeit zwei Fragen. Erstens wird geprüft, ob Minimum-Varianz-, Equal-Risk-Contribution- und Hierarchical-Risk-Parity-Portfolios ei-

ne höhere risikoadjustierte Out-of-Sample-Performance erzielen als das naive 1/N-Portfolio. Zweitens wird untersucht, ob GARCH- und DCC-GARCH-basierte Risiko- und Kovarianzprognosen die Ergebnisse gegenüber einer historischen Schätzung verbessern. Beide Fragen werden getrennt nach statistischen und ökonomischen Kriterien beantwortet, da sich gerade in der Differenz zwischen beiden der zentrale Befund dieser Arbeit zeigt.

Die empirische Grundlage bilden tägliche Renditen von 27 US-Sektorindizes über gut 27 Jahre. In einem rollierenden Design werden zehn Trainingsfenster mit vier Prognosehorizonten kombiniert, sodass jede der drei Kovarianzschätzungen und jedes der vier Allokationsverfahren in 40 Konstellationen bewertet wird. Statistisch dienen der QLIKE-Verlust und der Kovarianz-MSE als Kriterium, ökonomisch die Sharpe Ratio, die realisierte Volatilität und der Turnover. Ergänzend prüfen drei simulierte Datensätze mit bekanntem datengenerierendem Prozess, ob die Modelle das leisten, wofür sie konstruiert sind.

Der weitere Aufbau der Arbeit folgt diesem Vorgehen. Der folgende Abschnitt beschreibt die Datengrundlage, während der ?? Abschnitt das Untersuchungsdesign darlegt. Im ?? Abschnitt werden die Ergebnisse zunächst zur Prognosequalität und anschließend zur Portfolioperformance berichtet, bevor ihre Stabilität über verschiedene Zeiträume untersucht wird. Anschließend ordnet der ?? Abschnitt die Befunde in die Literatur ein und der ?? Abschnitt diskutiert die Grenzen der Untersuchung. Am Ende werden die zentralen Erkenntnisse zusammengefasst.

2 Daten

Die empirische Analyse beruht auf täglichen Kursen US-amerikanischer Sektorindizes, die über Datastream bezogen wurden. Verwendet werden die Business Groups der Refinitiv Business Classification (TRBC), wobei für die Vereinigten Staaten nur Daten für 28 der insgesamt 32 Business Groups verfügbar sind. Eine davon zeigt an rund zwei Dritteln ihrer Notierungstage keine Kursbewegung und wird als inaktive Reihe verworfen, sodass 27 Sektoren in die Analyse eingehen. Der Beobachtungszeitraum reicht vom 02.04.1999 bis zum 09.06.2026 und umfasst 7.087 Handelstage, wobei alle Renditen als logarithmierte Tagesrenditen $r_t = \ln(P_t/P_{t-1})$ berechnet werden. Da nicht für alle Sektoren Daten über den gesamten Betrachtungszeitraum vorliegen, variiert die Zahl der verfügbaren Anlagen über die Zeit. Durchgängig verfügbar sind lediglich 16 Sektoren, die übrigen kommen erst im Lauf der Zeit hinzu. Zusätzlich hängt die Zahl der möglichen Anlagen von der Länge des Trainingsfensters ab, da das investierbare Universum in jedem Rollfenster neu aus den Trainingsdaten bestimmt wird.

Als risikofreier Zins dient die Fed Funds Rate, die als Total-Return-Index vorliegt, wodurch

sich die tägliche einfache Verzinsung aus ihrer prozentualen Veränderung ergibt. Diese liegt im Mittel bei 2,08 % p. a. und wird ausschließlich für die Berechnung der Sharpe Ratio verwendet.

Die Querschnittsverteilung der Sektorrenditen ist in Tab. ?? dargestellt. Auffällig ist dabei die durchschnittliche paarweise Korrelation von 0,562, die aufgrund der Begrenzung auf den US-Aktienmarkt erwartungsgemäß hoch ausfällt und die Diversifikationsmöglichkeiten innerhalb des Universums begrenzt.

Kennzahl	Min.	25 %	Median	75 %	Max.
Beobachtungen	1351	1877	7087	7087	7087
Rendite p.a. (%)	-5,34	4,70	6,02	8,97	20,27
Volatilität p.a. (%)	15,06	19,73	22,41	26,32	49,20

Tabelle 1: Deskriptive Statistik der TRBC-Sektorrenditen

Tägliche logarithmierte Renditen von 27 TRBC-Sektorindizes, 02.04.1999 bis 09.06.2026;
durchschnittliche paarweise Korrelation 0,562.

Ergänzend werden drei künstlich erzeugte Datensätze verwendet, deren datengenerierender Prozess bekannt ist. Diese dienen ausschließlich der Validierung der Implementierung und werden im Anhang ?? dargestellt.

3 Methodik

3.1 Rollfensterdesign

Für die Auswertung der Ergebnisse wird ein rolling Window verwendet, um für mögliche Strukturbrüche in den Daten zu kontrollieren. Für jedes Trainingsfenster der Länge $T \in \{252, 504, \dots, 2520\}$ Handelstagen (ein bis zehn Jahre) und jeden Prognosehorizont $h \in \{1, 5, 10, 21\}$ Tagen werden die Kovarianzmatrizen auf den Trainingsdaten geschätzt, daraus die Portfoliogewichte bestimmt und diese über die folgenden h Handelstage gehalten. Anschließend rückt das Fenster um h Tage weiter, sodass sich insgesamt 40 Kombinationen ergeben. Als Basisfall werden durchgängig $T = 1008$ (vier Jahre) und $h = 1$ berichtet, da diese Kombination beide Modellbestandteile am besten zur Geltung bringt. Vier Jahre liefern genügend Beobachtungen, um neben den univariaten GARCH-Parametern auch die beiden DCC-Parameter verlässlich zu schätzen, ohne dass das Fenster so lang wird, dass es über mehrere Marktphasen mittelt. Ein Prognosehorizont von einem Tag entspricht zudem der natürlichen Ein-Schritt-Prognose der Modelle, weshalb sich die Qualität der Kovarianzschätzung dort am unmittelbarsten auf die Gewichte auswirkt. Durch den Vergleich der Ergebnisse des Basisfalls mit den übrigen Kombinationen kann überprüft werden, ob die beobachteten Ergebnisse robust gegenüber anderen Trainings- und

Prognosefenstern sind. Zudem kann überprüft werden, welche Fensterlänge den optimalen Trade-off zwischen Schätzfehlern aufgrund von zu wenigen Daten und Fehlspezifikation aufgrund von sich mit der Zeit ändernden Parametern liefert.

Um die unterschiedlichen Datenzeiträume der einzelnen Sektor-Indizes zu berücksichtigen, werden in jedem Zeitfenster nur die Sektoren verwendet, die an mindestens 90% der Handelstage im Trainingsfenster verfügbar sind, wodurch die Anzahl an Anlagen über die Zeit variiert.

Bewertungszeitraum. Ein rollierendes Design hat die Eigenschaft, dass der Out-of-Sample-Zeitraum mit der Länge des Trainingsfensters wandert, da die Bewertung bei einem Jahr Training im März 2000 beginnt, bei zehn Jahren jedoch erst im November 2008. Ein Vergleich der Spezifikationen über ihre jeweils volle Historie würde deshalb nicht die Fensterlänge isolieren, sondern zugleich unterschiedliche Marktphasen gegenüberstellen. Der Effekt ist dabei gerichtet, weil das längste Fenster nach dem Einbruch der Finanzkrise beginnt und nur die anschließende Erholung abdeckt, wodurch seine Sharpe Ratio gegenüber kurzen Fenstern systematisch angehoben wird.

Sämtliche Vergleiche über Trainingsfenster und Prognosehorizonte hinweg werden daher auf dem gemeinsamen Bewertungszeitraum ab dem 01.01.2010 gerechnet. Damit sind Einbruch und Erholung der Finanzkrise für alle Spezifikationen gleichermaßen ausgeschlossen, sodass alle Zeilen der Robustheitstabellen dieselben rund 4.280 Handelstage umfassen. Der Basisfall wird demgegenüber über seine volle verfügbare Historie ab Februar 2003 berichtet, da dort keine Vergleichbarkeitsfrage besteht. Beide Rechnungen werden im Abschnitt zum Strukturbruch ausdrücklich gegenübergestellt.

3.2 Kovarianzschätzer

Verglichen werden drei Schätzer der bedingten Kovarianzmatrix, die eine aufsteigende Leiter an Dynamik abbilden, wobei jeder Schritt genau eine Modellkomponente hinzufügt. Dadurch lässt sich der Beitrag dieser Komponente isolieren.

Der historische Schätzer ist die Stichprobenkovarianz der Trainingsrenditen und unterstellt konstante Varianzen und Korrelationen über das gesamte Fenster. Er dient als statischer Referenzpunkt, da er keine Parameterschätzung im engeren Sinn benötigt, dafür aber träge ist und erst mit der Verzögerung des gesamten Fensters auf Veränderungen des Risikoniveaus reagiert.

Der GARCH-Schätzer löst dieses Problem für die Varianzen, indem er die Volatilitätscluster explizit modelliert, die ein konstantes Varianzmodell per Konstruktion ignoriert. Ein GARCH(1,1) nach **bollerslev1986**<empty citation> beschreibt die bedingte Varianz

als gewichtete Kombination aus langfristigem Mittel, jüngstem Schock und Vorperiodenvarianz.

$$r_t = \mu + \varepsilon_t, \quad \varepsilon_t = \sqrt{h_t} z_t, \quad h_t = \omega + \alpha \varepsilon_{t-1}^2 + \beta h_{t-1}, \quad (1)$$

Dabei steuert α , wie stark ein neuer Schock die Varianz bewegt, während β deren Persistenz misst, wobei für Stationarität $\omega > 0$, $\alpha, \beta \geq 0$ und $\alpha + \beta < 1$ gelten muss. Die Umsetzung folgt dem CCC-Ansatz von **bollerslev1990**[<empty citation>](#), bei dem für jeden Sektor ein GARCH(1,1) per Quasi-Maximum-Likelihood geschätzt und die Varianzprognose über den Horizont h gemittelt wird. Die Korrelationsmatrix bleibt hierbei die konstante Stichprobenkorrelation der standardisierten Residuen z_t . Diese werden statt der Rohrenditen verwendet, da in ihnen die Volatilitätscluster bereits herausgefiltert sind und Tage hoher Volatilität die Korrelationsschätzung sonst nach oben verzerren würden.

Der DCC-GARCH-Schätzer nimmt die verbleibende Restriktion zurück, weil eine konstante Korrelationsmatrix nicht abbilden kann, dass Korrelationen in Stressphasen ansteigen. **engle2002**[<empty citation>](#) überträgt die Rekursion aus Gleichung ?? daher auf die Korrelation selbst.

$$Q_t = (1 - a - b) \bar{Q} + a z_{t-1} z'_{t-1} + b Q_{t-1}, \quad R_t = \text{diag}(Q_t)^{-1/2} Q_t \text{diag}(Q_t)^{-1/2} \quad (2)$$

Der Parameter a misst die kurzfristige Reaktion der Korrelationen auf neue gemeinsame Schocks und b deren Persistenz, wobei $a, b \geq 0$ und $a + b < 1$ gelten muss. Beide werden per Maximum-Likelihood geschätzt, während $\bar{Q}$ auf die Stichprobenkorrelation der z_t gesetzt wird. Für $h > 1$ wird die Korrelationsprognose gemäß **engle2001**[<empty citation>](#) auf $\bar{Q}$ zurückgeführt und über den Horizont gemittelt, damit sie zur ebenfalls horizontgemittelten Varianzprognose passt. Die Kovarianzmatrix ergibt sich anschließend als $\Sigma_t = D_t R_t D_t$, wobei D_t die Diagonalmatrix der prognostizierten Standardabweichungen ist.

Da GARCH- und DCC-Schätzer dieselben Varianzprognosen und dieselben standardisierten Residuen verwenden, isoliert ihr Vergleich exakt den Beitrag der dynamischen Korrelation. Der Vergleich beider mit der historischen Matrix isoliert entsprechend den Beitrag der dynamischen Volatilität.

3.3 Portfoliomodelle

Allen vier Allokationsverfahren ist gemeinsam, dass sie ohne Renditeprognosen auskommen und die Gewichte allein aus Varianzen, Kovarianzen und Korrelationen bestimmen. Damit entfällt die Fehlerquelle, die nach **broadie1993**<empty citation> die Lage der effizienten Grenze am stärksten verzerrt. Die Verfahren unterscheiden sich jedoch darin, wie stark sie die geschätzte Kovarianzmatrix ausnutzen, weshalb sie unterschiedlich anfällig für deren Fehler sind.

Am einen Ende dieses Spektrums steht das Minimum-Varianz-Portfolio (MVP), das die Portfoliovarianz $w'\Sigma w$ unter der Budgetrestriktion $\mathbf{1}'w = 1$ und einem Leerverkaufsverbot $w \geq 0$ minimiert. Es nutzt die Kovarianzmatrix vollständig aus, einschließlich ihrer Inversen, und überzeugt nach **behr2008**<empty citation> besonders in volatilen Marktphasen. Zugleich ist es das anfälligste Verfahren, da die Minimierung gezielt die Richtungen kleinsten geschätzter Varianz aufsucht, in denen die Schätzfehler relativ am größten sind. Fehler werden dadurch nicht ausgemittelt, sondern verstärkt, weshalb **lee2011** auf die typischerweise stark konzentrierten MVP-Lösungen hinweist. Weil der Kovarianzschätzer hier am unmittelbarsten durchschlägt, ist das MVP das aussagekräftigste Modell für die zweite Forschungsfrage.

Das Equal-Risk-Contribution-Portfolio (ERC) verfolgt hingegen das Ziel, das Gesamtrisiko nicht zu minimieren, sondern gleichmäßig auf die Anlagen zu verteilen. Der Risikobeitrag der Anlage i beträgt $RC_i = w_i (\Sigma w)_i / \sqrt{w'\Sigma w}$, wobei die Gewichte so gewählt werden, dass alle RC_i übereinstimmen. Das Ergebnis liegt konstruktionsbedingt zwischen MVP und $1/N$ und ist in der Regel deutlich besser diversifiziert, wobei **chaves2011**<empty citation> zeigen, dass ERC das naive Portfolio dennoch nicht durchgängig schlägt.

Hierarchical Risk Parity (HRP) nach **deprado2016**<empty citation> ersetzt die Matrixinversion durch eine hierarchische Struktur. Zunächst werden die Sektoren über die Korrelationsdistanz $d_{ij} = \sqrt{0,5(1 - \rho_{ij})}$ geclustert und die Kovarianzmatrix quasi-diagonal geordnet, sodass ähnliche Anlagen nebeneinander stehen. Anschließend wird das Kapital durch rekursive Bisektion verteilt, wobei auf jeder Ebene der Teilbaum mit der geringeren Varianz das höhere Gewicht erhält. Entscheidend ist, dass HRP die Kovarianzmatrix nie invertiert und nur ihre Ordnungsinformation sowie die Varianzen der Teilcluster nutzt. Das Verfahren ist dadurch robust gegenüber schlecht konditionierten Matrizen, also gerade gegenüber der Fehlerquelle, die dem MVP zu schaffen macht. **deprado2016** und **sen2022**<empty citation> berichten entsprechend stabilere Gewichte und eine konkurrenzfähige risikoadjustierte Rendite.

Als Vergleichsmaßstab dient das gleichgewichtete $1/N$ -Portfolio, das keine Schätzung der zweiten Momente benötigt und damit immun gegen Schätzfehler ist. Es bildet den relevan-

ten Maßstab für die erste Forschungsfrage, da ein Optimierungsverfahren seinen Aufwand nur rechtfertigt, wenn dessen Gewinn den Verlust durch Schätzfehler übersteigt.

3.4 Bewertungskriterien

Die Bewertung trennt zwischen der Prognosequalität der Kovarianzmatrix und der ökonomischen Performance der daraus abgeleiteten Portfolios.

Realisierter Proxy. Da die wahre bedingte Kovarianzmatrix der Testperiode nicht beobachtbar ist, messen beide statistischen Verlustmaße die Prognose Σ gegen denselben realisierten Proxy.

$$S = \frac{1}{h} \sum_{t=1}^h r_t r_t' \quad (3)$$

Dabei ist r_t der Vektor der logarithmierten Tagesrenditen, wodurch S ein erwartungstreuer, aber verrauschter Schätzer der wahren Kovarianz ist. Für $h = 1$ besteht der Proxy aus einem einzigen äußeren Produkt und hat damit den Rang eins, ist also maximal verrauscht. Genau darauf zielt die Wahl der Verlustfunktionen, da beide zur Klasse der bezüglich unvollkommener Proxies robusten Verluste gehören. Für diese ist die erwartete Rangfolge zweier Prognosen dieselbe, unabhängig davon, ob gegen den verrauschten Proxy oder gegen die unbeobachtbare Wahrheit gemessen wird. **patton2011** <empty citation> entwickelt dieses Konzept für den univariaten Fall der Varianzprognose, während **laurent2012** <empty citation> es auf vollständige Kovarianzmatrizen übertragen. Das Rauschen kostet folglich Teststärke, verzerrt die Rangfolge jedoch nicht.

Statistische Kriterien. Als erstes Maß dient der multivariate QLIKE-Verlust, der eine Unterschätzung des Risikos stärker bestraft als eine Überschätzung und dadurch ökonomisch besser motiviert ist als ein symmetrisches Maß.

$$\text{QLIKE}(\Sigma, S) = \ln |\Sigma| + \text{tr}(\Sigma^{-1}S) \quad (4)$$

Als zweites Maß wird der Kovarianz-MSE herangezogen, der den quadratischen Abstand über alle Matrixeinträge misst und Über- und Unterschätzung symmetrisch gewichtet.

$$\text{MSE}(\Sigma, S) = \frac{1}{N^2} \sum_{i,j} (\Sigma_{ij} - S_{ij})^2 \quad (5)$$

Beide Verluste werden je Rebalancierungsfenster berechnet und anschließend über die Fenster gemittelt, wobei niedrigere Werte eine bessere Prognose bedeuten. Die Mittelung erfolgt bewusst über den MSE und nicht über eine je Fenster gezogene Wurzel, da die Wurzeltransformation die robuste Verlustklasse verlässt und die Schätzer dadurch falsch ordnen kann.

Bei der Interpretation der Niveaus sind zwei Eigenschaften zu beachten. Der QLIKE-Verlust ist nicht dimensionsnormiert, da der Term $\ln |\Sigma|$ über alle Eigenwerte summiert und sein Niveau somit mit der Zahl der Anlagen N skaliert. Der MSE mittelt hingegen über die Matrixeinträge und ist von der Dimension weit weniger betroffen, folgt dafür aber dem Volatilitätsniveau der Bewertungsperiode und dem Horizont h , über den der Proxy mittelt. In beiden Fällen ist daher nur die Differenz zwischen den Schätzern innerhalb einer Spezifikation aussagekräftig, nicht das Niveau zwischen Spezifikationen.

Ökonomische Kriterien. Ökonomisch werden die annualisierte Rendite, die realisierte Volatilität, die Sharpe Ratio und der Turnover berichtet. Die Sharpe Ratio wird dabei in zwei Varianten ausgewiesen, einmal mit einem risikofreien Zins von null und einmal auf Überschussrenditen über die Fed Funds Rate. Der Turnover ist die Summe der absoluten Gewichtsänderungen zwischen den gedrifteten Endgewichten der Vorperiode und den neuen Zielgewichten und entspricht damit dem je Rebalancierung umgeschlagenen Anteil des Portfoliovolumens. Der Backtest selbst rechnet kostenfrei, weshalb die Wirkung von Transaktionskosten erst im Abschnitt zu den Limitationen ex post quantifiziert wird.

Signifikanzaussagen beruhen auf zwei Tests. Unterschiede in der Prognosegüte werden mit dem Test von **diebold1995**<empty citation> in der Erweiterung von **west1996**<empty citation> auf die Verlustdifferenzen geprüft, wobei die Langfristvarianz mit einem Bartlett-Kern geschätzt wird. Unterschiede in den Sharpe Ratios werden mit dem Test von **jobson1981**<empty citation> in der Korrektur von **memmel2003**<empty citation> geprüft, der die Korrelation der beiden Renditereihen berücksichtigt.

4 Ergebnisse

Die Darstellung folgt der Trennung der Bewertungskriterien. Zunächst wird geprüft, ob die GARCH-basierten Schätzer die Kovarianzmatrix besser prognostizieren, bevor untersucht wird, ob sich ein solcher Vorteil auch in der Portfolioperformance niederschlägt. Anschließend wird die Stabilität beider Befunde über die Trainings- und Prognosefenster betrachtet.

4.1 Statistische Prognosequalität

Im Basisfall ordnet sich die Prognosegüte unter beiden Verlustmaßen nach der Modellkomplexität, wie Tab. ?? zeigt. Die historische Matrix schneidet am schlechtesten ab, während der GARCH-Schätzer sie deutlich verbessert und DCC-GARCH nochmals einen kleinen Zusatzgewinn liefert. QLIKE und MSE stimmen in dieser Reihenfolge überein.

Kovarianzschätzer	QLIKE	MSE ($\times 10^{-7}$)
Historisch	-152,81	4,28
GARCH	-155,94	3,52
DCC-GARCH	-156,68	3,44

Tabelle 2: Prognosequalität der Kovarianzschätzer im Basisfall

TRBC, Training 1008 Handelstage, Prognosehorizont 1 Tag; niedrigere Werte bedeuten eine bessere Prognose.

Der DMW-Test in Tab. ?? zeigt jedoch, dass die beiden Verlustmaße unterschiedlich scharf trennen. Unter QLIKE wird die Nullhypothese gleicher erwarteter Verluste in allen drei paarweisen Vergleichen auf dem 1-%-Niveau verworfen. Besonders präzise geschätzt ist dabei der Vorsprung von DCC gegenüber GARCH, obwohl die Differenz klein ausfällt. Der Grund hierfür liegt darin, dass beide Schätzer dieselben Varianzprognosen verwenden, wodurch sich die Verlustdifferenz fast ausschließlich aus dem Korrelationsbeitrag speist. Unter dem MSE sind die Abstände zur historischen Matrix hingegen nur auf dem 5-%-Niveau signifikant, während der Unterschied zwischen DCC und GARCH nicht mehr von null zu trennen ist. Der symmetrische Verlust wird von wenigen extremen Beobachtungen dominiert und ist daher erheblich verrauschter. Belastbar ist somit, dass beide dynamischen Schätzer die historische Matrix unter beiden Maßen schlagen, wobei sich der Zusatznutzen der dynamischen Korrelation nur unter QLIKE nachweisen lässt.

Vergleich	Δ Verlust	t -Statistik	p -Wert	Termine
<i>QLIKE</i>				
GARCH vs. Historisch	-2,563	-4,18	<0,001***	6013
DCC-GARCH vs. Historisch	-3,308	-5,28	<0,001***	6013
DCC-GARCH vs. GARCH	-0,744	-13,86	<0,001***	6079
<i>MSE ($\times 10^{-7}$)</i>				
GARCH vs. Historisch	-0,764	-2,23	0,026**	6079
DCC-GARCH vs. Historisch	-0,846	-2,11	0,035**	6079
DCC-GARCH vs. GARCH	-0,082	-1,26	0,207	6079

Tabelle 3: Diebold-Mariano-West-Tests auf die Verlustdifferenzen (Basisfall)

Negative Differenzen bedeuten, dass der erstgenannte Schätzer besser prognostiziert; ***, **, * = 1-, 5-, 10-%-Niveau.

Über das gesamte Untersuchungsdesign hinweg ist der statistische Vorsprung nahezu vollständig, da DCC-GARCH unter dem MSE in sämtlichen 40 Kombinationen besser prognostiziert als die historische Matrix und unter QLIKE in nahezu allen. Wie stark der

Vorsprung ausfällt, hängt jedoch von der Spezifikation ab, wie Tab. ?? zeigt. Mit der Länge des Trainingsfensters nimmt er monoton zu, wobei DCC bei einjährigem Training unter QLIKE keinen Vorteil mehr liefert. Die rund 250 Beobachtungen reichen dort nicht aus, um die DCC-Parameter zusätzlich zu den univariaten GARCH-Parametern verlässlich zu schätzen. Über den Prognosehorizont fällt der Vorsprung dagegen ab, da die Korrelationsprognose mit wachsendem Horizont gegen ihren unbedingten Mittelwert konvergiert und sich der dynamische Anteil auswäscht. Der MSE zeigt dasselbe Muster, ordnet DCC aber auch im kürzesten Fenster vorne ein.

Spezifikation	QLIKE			MSE ($\times 10^{-7}$)		
	Historisch	Δ GARCH	Δ DCC	Historisch	GARCH	DCC-GARCH
252	-176,1	0,25	0,04	2,99	2,48	2,47
504	-171,0	-0,37	-0,81	3,42	2,81	2,74
756	-165,2	-0,95	-1,58	3,41	2,84	2,75
1008	-159,7	-1,36	-2,15	3,43	2,87	2,77
1260	-154,3	-1,84	-2,76	3,42	2,83	2,75
1512	-150,1	-1,74	-2,78	3,18	2,60	2,52
1764	-146,0	-1,71	-2,81	3,11	2,53	2,45
2016	-142,0	-1,80	-2,94	3,09	2,52	2,45
2268	-140,6	-1,85	-3,05	3,05	2,46	2,41
2520	-140,0	-2,02	-3,32	3,02	2,45	2,40
$h = 1$	-159,7	-1,36	-2,15	3,43	2,87	2,77
$h = 5$	-159,5	-1,37	-2,04	1,68	1,23	1,17
$h = 10$	-159,3	-1,53	-2,14	1,32	0,95	0,90
$h = 21$	-158,9	-1,25	-1,73	0,82	0,49	0,46

Tabelle 4: Prognosequalität über Trainingsfenster und Prognosehorizonte (TRBC)

Oberer Block: Trainingsfenster in Handelstagen ($h = 1$), unterer Block: Prognosehorizonte, bewertet ab 01.01.2010; Δ ist die Differenz zur historischen Matrix.

Die Niveaus beider Verluste sind zwischen den Zeilen dieser Tabelle nicht vergleichbar, obwohl alle Zeilen denselben Zeitraum abdecken. Beim QLIKE liegt das an der Dimension der Kovarianzmatrix, beim MSE im unteren Block dagegen am Horizont, über den der Proxy mittelt. Für die statistische Lesart der zweiten Forschungsfrage fällt die Antwort damit dennoch eindeutig aus, da GARCH- und DCC-GARCH-Modelle die Prognose der Kovarianzmatrix gegenüber der historischen Schätzung signifikant und unter dem MSE ausnahmslos verbessern.

4.2 Ökonomische Performance

Die ökonomische Auswertung führt zu einem differenzierteren Bild. Für die erste Forschungsfrage zeigt Tab. ?? zunächst den erwarteten Befund, da alle neun risikobasierten Kombinationen im Basisfall eine höhere Sharpe Ratio erreichen als das naive 1/N-Portfolio. Vorne liegt dabei das MVP, gefolgt von HRP und ERC. Der Vorsprung entsteht

vollständig über die Risikoseite, da das 1/N-Portfolio zwar die höchste Rendite im Feld erzielt, diese aber mit der mit Abstand höchsten Volatilität erkaufte.

Modell	Kovarianz	Rendite (%)	Vola (%)	Sharpe ($r_f = 0$)	Sharpe	Turnover
MVP	Historisch	9,03	13,82	0,695	0,567	0,008
MVP	GARCH	8,55	13,94	0,658	0,532	0,258
MVP	DCC-GARCH	8,65	13,81	0,671	0,543	0,255
HRP	Historisch	9,27	16,74	0,614	0,509	0,012
HRP	GARCH	8,96	16,21	0,611	0,502	0,072
HRP	DCC-GARCH	9,13	16,17	0,622	0,513	0,094
ERC	Historisch	9,46	17,67	0,601	0,501	0,006
ERC	GARCH	9,14	17,32	0,592	0,490	0,034
ERC	DCC-GARCH	9,13	17,31	0,591	0,490	0,034
1/N	–	9,58	18,79	0,581	0,488	0,006

Tabelle 5: Out-of-Sample-Performance im Basisfall

TRBC, Training 1008 Handelstage, Prognosehorizont 1 Tag; Rendite, Volatilität und Sharpe Ratio annualisiert, Turnover ohne Kosten.

Innerhalb der Portfoliomodelle kehrt sich die statistische Rangfolge im Basisfall weitgehend um, da bei MVP und ERC die historische Matrix vorne liegt und allein beim HRP der DCC-Schätzer marginal besser abschneidet. Ein Teil der Erklärung liegt darin, dass das MVP sein eigenes Zielmaß durchaus erreicht, denn die realisierte Volatilität der DCC-Variante liegt minimal unter der historischen. Dieser Vorsprung ist jedoch so klein, dass ihn die etwas höhere Rendite der historischen Variante überkompensiert. Der eigentliche Treiber steht in der letzten Spalte, in der der mittlere Turnover des MVP mit der DCC-Kovarianz rund 32-mal so hoch ausfällt wie mit der historischen. Die dynamischen Schätzer reagieren auf jede neue Volatilitätsschätzung und schichten das Portfolio permanent um, während die träge Stichprobenkovarianz die Gewichte nahezu unverändert lässt. Bei HRP und ERC fällt der Anstieg mit dem Faktor acht beziehungsweise sechs erheblich geringer aus, was die Robustheitsorientierung dieser Verfahren widerspiegelt.

Statistisch abgesichert sind diese Unterschiede allerdings nicht, da Tab. ?? für keinen der relevanten Vergleiche einen auch nur annähernd signifikanten p -Wert ausweist. Dies gilt sowohl zwischen den Kovarianzschätzern als auch gegenüber dem 1/N-Portfolio. Das ist weniger ein Argument gegen die Modelle als eines gegen die Sharpe Ratio als Auswahlkriterium, da sie von den realisierten Renditen dominiert wird, auf die die Kovarianzmatrix nur mittelbar wirkt. Genau diesen Einwand formulieren **engle2006**.

Die Zählbilanz über alle 40 Läufe in Tab. ?? ordnet den Basisfall ein und macht sichtbar, dass der ökonomische Befund je nach Portfoliomodell unterschiedlich ausfällt. Zur ersten Forschungsfrage zeigt sich, dass HRP und ERC mit historischer Kovarianz das 1/N-Portfolio in allen 40 Konstellationen schlagen, das MVP dagegen nur in der Hälfte der Fälle. Das MVP ist das anfälligste der drei Verfahren, da die Varianzminimierung

Vergleich	Sharpe A	Sharpe B	Differenz	z-Statistik	p-Wert
MVP Historical vs. MVP DCC	0,567	0,543	0,0243	0,37	0,709
HRP Historical vs. HRP DCC	0,509	0,513	-0,0041	-0,18	0,859
ERC Historical vs. ERC DCC	0,501	0,490	0,0111	0,98	0,329
MVP GARCH vs. MVP DCC	0,532	0,543	-0,0109	-0,78	0,435
MVP Historical vs. Naive	0,567	0,488	0,0797	0,69	0,487
HRP Historical vs. Naive	0,509	0,488	0,0210	0,66	0,509
ERC Historical vs. Naive	0,501	0,488	0,0132	0,85	0,395

Tabelle 6: Tests auf Unterschiede der Sharpe Ratios (Basisfall)

Auf Überschussrenditen über die Fed Funds Rate; ***, **, * = 1-, 5-, 10-%-Niveau.

Schätzfehler in den kleinsten Eigenwerten der Kovarianzmatrix maximal ausnutzt und zu konzentrierten Portfolios führt. Die im Basisfall beste Sharpe Ratio des MVP ist insofern nicht repräsentativ.

Zur zweiten Forschungsfrage zeigt sich ein klares Muster entlang der Portfoliomodelle, da die dynamischen Schätzer die historische Matrix beim MVP in gut der Hälfte der Läufe schlagen, beim HRP nur vereinzelt und beim ERC in keinem einzigen. Ökonomisch ist das gut erklärbar, weil das MVP als einziges Verfahren die Kovarianzmatrix vollständig einschließlich ihrer Inversen ausnutzt, während HRP lediglich die Clusterordnung und die Varianzen der Teilcluster verwendet und ERC die Risikobeiträge ausbalanciert. Eine bessere Kovarianzprognose zahlt sich folglich dort aus, wo sie am intensivsten genutzt wird, und bleibt folgenlos, wo das Verfahren die Matrix bewusst nur grob verwendet. Dem steht ein statistischer Vorsprung gegenüber, der unter dem MSE in allen 40 Läufen auftritt.

Modell	Kovarianz	vs. 1/N	vs. historische Matrix		
		Sharpe	Sharpe	QLIKE	MSE
MVP	Historisch	20/40	–	–	–
MVP	GARCH	19/40	22/40	36/40	40/40
MVP	DCC-GARCH	20/40	25/40	37/40	40/40
HRP	Historisch	40/40	–	–	–
HRP	GARCH	32/40	3/40	36/40	40/40
HRP	DCC-GARCH	31/40	3/40	37/40	40/40
ERC	Historisch	40/40	–	–	–
ERC	GARCH	31/40	0/40	36/40	40/40
ERC	DCC-GARCH	32/40	0/40	37/40	40/40

Tabelle 7: Zählbilanz über alle empirischen Läufe

Alle 40 Kombinationen aus Trainingsfenster und Prognosehorizont, bewertet ab 01.01.2010.

Auch über die Trainingsfenster hinweg bleibt dieses Muster erhalten, wie Tab. ?? zeigt. Beim MVP liegt DCC in neun von zehn Fenstern über der historischen Matrix, bei HRP in einem und bei ERC in keinem. Die absoluten Unterschiede fallen dabei klein aus, weshalb angesichts der insignifikanten Tests auf Sharpe-Differenzen keine belastbare Rangfolge

abgeleitet werden sollte.

Training	MVP			HRP			ERC			1/N
	Hist.	GARCH	DCC	Hist.	GARCH	DCC	Hist.	GARCH	DCC	
252	0,628	0,612	0,625	0,695	0,677	0,665	0,685	0,676	0,674	0,676
504	0,605	0,735	0,741	0,696	0,700	0,690	0,688	0,682	0,681	0,685
756	0,633	0,668	0,672	0,695	0,683	0,685	0,689	0,678	0,678	0,676
1008	0,714	0,706	0,728	0,684	0,686	0,706	0,692	0,680	0,682	0,677
1260	0,721	0,699	0,729	0,686	0,669	0,672	0,675	0,663	0,665	0,656
1512	0,681	0,669	0,696	0,685	0,667	0,669	0,675	0,663	0,665	0,660
1764	0,642	0,670	0,686	0,656	0,641	0,649	0,642	0,634	0,636	0,621
2016	0,631	0,652	0,655	0,657	0,649	0,647	0,650	0,644	0,645	0,628
2268	0,657	0,689	0,683	0,671	0,653	0,656	0,661	0,654	0,655	0,635
2520	0,627	0,690	0,689	0,679	0,663	0,660	0,669	0,661	0,662	0,647

Tabelle 8: Sharpe Ratios über die Trainingsfenster (TRBC, $h = 1$)

Annualisierte Sharpe Ratio ($r_f = 0$), bewertet ab 01.01.2010.

Deutlicher ist der Befund über den Prognosehorizont in Tab. ?? . Wird seltener rebalanciert, bleibt die Sharpe Ratio der historischen Matrix beim MVP praktisch konstant, während sie für DCC deutlich fällt und der Turnover je Rebalancierung gleichzeitig auf mehr als das Doppelte steigt. Über längere Horizonte handeln die dynamischen Modelle somit gegen zunehmend veraltete Prognosen an, wodurch sich ihr Vorteil in einen Nachteil umkehrt. Da der Bewertungszeitraum über alle Zeilen identisch ist und allein die Rebalancierungsfrequenz variiert, ist dieser Vergleich frei von den Stichprobenproblemen, die der folgende Abschnitt behandelt.

h (Tage)	MVP		HRP		ERC		1/N	Turnover MVP	
	Hist.	DCC	Hist.	DCC	Hist.	DCC		Hist.	DCC
1	0,714	0,728	0,684	0,706	0,692	0,682	0,677	0,008	0,255
5	0,705	0,762	0,681	0,690	0,694	0,684	0,680	0,021	0,522
10	0,717	0,654	0,692	0,670	0,698	0,680	0,684	0,033	0,598
21	0,721	0,640	0,697	0,689	0,700	0,689	0,685	0,058	0,587

Tabelle 9: Sharpe Ratios und Turnover über die Prognosehorizonte (TRBC, Training 1008 Tage)

Annualisierte Sharpe Ratio ($r_f = 0$), bewertet ab 01.01.2010; Turnover je Rebalancierung, also nicht auf gleiche Frequenz normiert.

4.3 Robustheit über Zeiträume und ein Strukturbruch

Sämtliche bisher berichteten Vergleiche über Trainingsfenster hinweg wurden bereits auf dem gemeinsamen Zeitraum ab 2010 gerechnet. Dieser Abschnitt begründet, warum diese Einschränkung nötig ist, und zeigt, was ohne sie gemessen würde.

Ohne die Einschränkung bewertet jedes Trainingsfenster einen anderen Zeitraum, da der Out-of-Sample-Beginn von März 2000 beim kürzesten auf November 2008 beim längs-

ten Fenster wandert. Der Lauf mit einem Jahr Training enthält damit das Platzen der Dotcom-Blase, während der Lauf mit zehn Jahren Training erst nach dem Einbruch der Finanzkrise beginnt und nur die anschließende Erholung abdeckt. Das hebt seine Kennzahlen an, ohne dass dies etwas über die Schätzqualität aussagt. In seiner klarsten Form zeigt Tab. ?? diesen Effekt, da das 1/N-Portfolio über die volle Historie beim längsten Fenster eine merklich höhere Sharpe Ratio erreicht als bei allen anderen Fenstern. Weil es überhaupt keine Schätzung vornimmt und die Fensterlänge für seine Konstruktion nahezu bedeutungslos ist, handelt es sich um einen reinen Stichprobeneffekt. Auf dem gemeinsamen Zeitraum verschwindet dieser Sprung, wodurch sich die Spannweite der MVP-Sharpe-Ratio nahezu halbiert.

Training	N	QLIKE DCC		Sharpe MVP Hist.		Sharpe 1/N	
		voll	gem.	voll	gem.	voll	gem.
252	20,3	-162,0	-176,1	0,568	0,628	0,505	0,676
504	19,7	-161,0	-172,1	0,539	0,605	0,502	0,685
756	19,1	-158,9	-167,3	0,558	0,633	0,514	0,676
1008	18,5	-156,7	-162,6	0,695	0,714	0,581	0,677
1260	17,9	-153,6	-157,7	0,624	0,721	0,507	0,656
1512	17,4	-150,2	-152,9	0,571	0,681	0,501	0,660
1764	16,9	-147,0	-148,8	0,522	0,642	0,462	0,621
2016	16,4	-143,7	-144,9	0,469	0,631	0,458	0,628
2268	16,2	-142,3	-143,7	0,468	0,657	0,466	0,635
2520	16,2	-142,7	-143,3	0,654	0,627	0,677	0,647

Tabelle 10: Voller versus gemeinsamer Bewertungszeitraum (TRBC, $h = 1$)

voll bezeichnet die volle Historie des jeweiligen Fensters, *gem.* den gemeinsamen Zeitraum ab 01.01.2010.

Ein zweiter Effekt bleibt jedoch auch nach Angleichung des Zeitraums bestehen, da das QLIKE-Niveau weiterhin von der Fensterlänge abhängt. Ursache ist die Zusammensetzung des Universums, weil die 90-%-Verfügbarkeitsregel die 2019 hinzugekommenen Sektoren in langen Fenstern erst spät oder gar nicht zulässt und die Fensterlänge somit die Dimension der Kovarianzmatrix mitbestimmt. Die Korrelation zwischen mittlerer Universumsgröße und QLIKE-Niveau beträgt $-0,9999$, wodurch das Niveau der Kennzahl praktisch vollständig durch die Dimension und nicht durch die Prognosequalität determiniert ist. Den direkten Beleg liefert erneut das 1/N-Portfolio, das im identischen Bewertungszeitraum je nach Trainingsfenster unterschiedlich abschneidet. Da sich an seiner Konstruktion nichts ändert, kann dieser Unterschied nur aus dem unterschiedlichen Anlageuniversum stammen.

Zeitlich lokalisieren lässt sich der Bruch über die Teilperioden des Basisfalls in Tab. ?. Das QLIKE-Niveau springt ab 2022 deutlich nach unten, wobei dieser Sprung exakt mit der Erweiterung des Universums von 17 auf 25 Sektoren im September 2022 zusammenfällt. Der MSE zeigt an dieser Stelle keinen vergleichbaren Bruch, folgt dafür aber dem Volatilitätsniveau der Periode und steigt in der Finanzkrise auf mehr als das Siebzigfache

des Werts der ruhigen Phase 2003–2007. Beide Kennzahlen sind über Perioden hinweg somit nur eingeschränkt vergleichbar, wenn auch aus unterschiedlichen Gründen.

Periode	N	QLIKE		MSE ($\times 10^{-7}$)		Sharpe			
		Hist.	Δ DCC	Hist.	DCC	MVP Hist.	MVP DCC	$1/N$	
2003–2007	16–16	-143,5	-3,79	0,28	0,23	1,490	1,485	1,087	
2008–2009	16–16	-119,7	-11,50	21,03	16,72	-0,200	-0,294	-0,092	
2010–2019	16–17	-146,1	-1,75	0,79	0,60	0,940	1,036	0,760	
2020–2021	17–17	-133,1	-7,15	20,18	15,88	0,446	0,427	0,836	
2022–2026	17–27	-205,1	-0,69	1,79	1,70	0,578	0,462	0,461	

Tabelle 11: Teilperioden des Basisfalls: Universum, Prognosequalität und Performance

N ist die Spannweite der investierbaren Sektoren; QLIKE-Niveaus sind zwischen Perioden mit unterschiedlichem N nicht vergleichbar.

Aussagekräftig bleibt die Differenz zwischen den Schätzern innerhalb einer Periode, die erheblich variiert. In der Finanzkrise 2008/09 und im COVID-Zeitraum fällt sie um ein Vielfaches größer aus als in den ruhigen Phasen. Der Mehrwert der dynamischen Modellierung konzentriert sich damit auf Phasen mit ausgeprägten Volatilitätsschocks, also genau dort, wo eine statische Matrix am stärksten hinterherhinkt.

Ökonomisch ist die Rangfolge ebenfalls periodenabhängig, da das MVP mit DCC-Kovarianz die historische Variante in der Phase 2010–2019 klar schlägt, in allen übrigen Teilperioden jedoch zurückliegt. Genau hierin liegt der Unterschied zwischen dem Basisfall und den Robustheitstabellen. Der Basisfall umfasst die volle Historie ab 2003 und mittelt über gegenläufige Teilperioden, weshalb dort die historische Matrix vorne liegt, während die auf 2010 eingeschränkten Tabellen für das MVP zugunsten von DCC ausfallen. Beide Rechnungen sind korrekt, messen aber Unterschiedliches, wobei sich angesichts durchgängig insignifikanter Unterschiede in beide Richtungen eine starke Aussage verbietet.

Der Vergleich über Trainingsfenster variiert somit selbst nach Angleichung des Zeitraums noch zwei Größen gleichzeitig, nämlich Schätzpräzision und Anlageuniversum, und ist als Robustheitsprüfung im engeren Sinn nur eingeschränkt geeignet. Dass es sich dabei um eine Eigenschaft der empirischen Datenbasis und nicht um einen Fehler der Implementierung handelt, zeigt der Gegentest an den synthetischen Datensätzen im Anhang. Dort ist das Universum mit 20 Anlagen konstant und der datengenerierende Prozess parameterstabil, weshalb das QLIKE-Niveau über alle Fensterlängen praktisch unverändert bleibt und sich die Rangfolge der Schätzer in keinem einzigen Fenster umkehrt.

Robust ist der Befund dort, wo tatsächlich nur ein Faktor variiert wird. Über die Prognosehorizonte bleiben Bewertungszeitraum und Universum konstant, wodurch der Vorteil der historischen Matrix monoton mit dem Horizont wächst. Über alle 40 Läufe hinweg gilt zudem die statistische Rangfolge unter dem MSE ausnahmslos.

5 Einordnung in die Literatur

Grobentwurf. Die Belege sind zu vervollständigen und die Argumentation an die endgültige Fassung der Ergebnisse anzupassen.

Risikobasierte Allokation gegenüber $1/N$. Der Befund, dass alle drei risikobasierten Verfahren das naive Portfolio im Basisfall übertreffen, steht in Spannung zu **demiguel2009** die $1/N$ gegenüber optimierten Strategien als schwer zu schlagen ausweisen. Der Unterschied dürfte weniger auf die Verfahren als auf das Untersuchungsobjekt zurückgehen, da hier über breit diversifizierte Sektorindizes statt über Einzeltitel optimiert wird, wodurch die Kovarianzmatrix stabiler zu schätzen ist. Innerhalb der risikobasierten Verfahren fügen sich die Ergebnisse gut in die vorliegende Evidenz. Die hohe Robustheit von HRP mit 40 von 40 Läufen über $1/N$ entspricht den Aussagen von **deprado2016** und **sen2022**, während die Beobachtung, dass ERC besser diversifiziert, das naive Portfolio aber nicht durchgängig schlägt, sich mit **chaves2011** deckt. Die Anfälligkeit des MVP für Schätzfehler samt seiner Konzentrationsneigung ist bei **lee2011** und **behr2008** beschrieben. Dass das MVP im Basisfall dennoch die höchste Sharpe Ratio erzielt, über alle Läufe hinweg aber nur in der Hälfte der Fälle über $1/N$ liegt, illustriert genau diese Instabilität.

Statistische gegenüber ökonomischer Relevanz. Das zentrale Ergebnis dieser Arbeit, ein nahezu vollständiger statistischer, aber nur beim MVP nennenswerter ökonomischer Vorsprung der GARCH-Modelle, reiht sich in eine etablierte Diskussion ein. **engle2006** argumentieren, dass die Auswahl eines Kovarianzschätzers anhand der Sharpe Ratio irreführend sein kann, was die durchweg insignifikanten Tests in Tab. ?? für den vorliegenden Datensatz unmittelbar bestätigen. **patton2011** liefert mit den robusten Verlustfunktionen die Alternative, der diese Arbeit mit QLIKE und MSE folgt, wobei **laurent2012** die multivariate Erweiterung beisteuern. Den statistischen Teil der Ergebnisse stützen **ardia2017**, die zeigen, dass eine Fehlspezifikation der Kovarianzmatrix die Portfoliogewichte spürbar verzerrt. Am nächsten liegt jedoch **moura2020**, da die Autoren für hochdimensionale bedingte Kovarianzmatrizen ebenfalls finden, dass die statistisch beste Spezifikation nicht die ökonomisch beste sein muss und Transaktionskosten den Ausschlag geben. Die Turnover- und Kostenrechnung in Tab. ?? repliziert diesen Mechanismus in einem Sektoruniversum.

Forschungslücke. Die Verbindung beider Themenfelder, risikobasierter Allokationsverfahren einschließlich HRP auf der einen und multivariater GARCH-Kovarianzprognosen auf der anderen Seite, ist bislang nur vereinzelt untersucht worden. Ergänzend fällt auf,

dass die Sensitivität von Rollfensterstudien gegenüber der Zusammensetzung des Anlageuniversums selten explizit thematisiert wird, obwohl sie die Kennzahlenniveaus vollständig dominieren kann. *[Noch zu ergänzen: aktuelle Arbeiten zu HRP-Varianten (HERC, NCO) sowie zur Kombination von DCC-Modellen mit Risk-Parity-Ansätzen.]*

6 Limitationen

Transaktionskosten. Der Backtest rechnet ohne Handelskosten, was angesichts der Turnover-Unterschiede die schwerwiegendste Einschränkung darstellt. Die Größenordnung zeigt Tab. ??, da bereits bei 5 Basispunkten auf das umgeschlagene Volumen die Sharpe Ratio des MVP mit DCC-Kovarianz unter die des 1/N-Portfolios fällt, während die historische Variante nahezu unverändert bleibt. Bei 20 Basispunkten werden die dynamischen MVP-Varianten negativ. Die Rechnung ist eine Näherung, da ein kostenbewusster Optimierer weniger handeln würde, kehrt die Aussage des Ergebnisteils jedoch nicht um, sondern verschärft sie. Der ökonomische Nachteil der GARCH-Modelle ist bereits ohne Kosten vorhanden und wird mit Kosten dominant.

Modell	Kovarianz	Turnover	0 Bp.	5 Bp.	10 Bp.	20 Bp.
MVP	Historisch	0,008	0,695	0,688	0,680	0,666
MVP	GARCH	0,258	0,658	0,425	0,192	-0,274
MVP	DCC-GARCH	0,255	0,671	0,438	0,205	-0,261
HRP	Historisch	0,012	0,614	0,605	0,595	0,577
HRP	GARCH	0,072	0,611	0,555	0,499	0,388
HRP	DCC-GARCH	0,094	0,622	0,548	0,474	0,327
ERC	Historisch	0,006	0,601	0,596	0,592	0,584
ERC	GARCH	0,034	0,592	0,568	0,543	0,494
ERC	DCC-GARCH	0,034	0,591	0,567	0,542	0,492
1/N	–	0,006	0,581	0,577	0,573	0,565

Tabelle 12: Sharpe Ratios nach proportionalen Transaktionskosten (Basisfall)

Sharpe Ratio ($r_f = 0$) nach Abzug von c Basispunkten auf das je Rebalancierung umgeschlagene Volumen.

Zusammensetzung des Anlageuniversums. Der unbalancierte Panelaufbau begrenzt die Vergleichbarkeit über Trainingsfenster und Teilperioden hinweg, wobei die Einschränkung auf den gemeinsamen Bewertungszeitraum ab 2010 zwar den Stichprobeneffekt behebt, nicht aber den Universumseffekt. Eine sauberere Untersuchung würde das Universum über alle Spezifikationen hinweg auf die 16 durchgängig verfügbaren Sektoren fixieren, wofür allerdings auf rund 40 % der zuletzt verfügbaren Sektoren verzichtet werden müsste. Ein solcher Robustheitslauf steht aus, ebenso wie eine Normierung des QLIKE-Verlusts auf N für Vergleiche über unterschiedliche Dimensionen hinweg.

Reichweite der synthetischen Validierung. Die simulierten Datensätze bilden ein vollständig balanciertes Panel, in dem alle 20 Anlagen ab dem ersten Tag verfügbar sind und das investierbare Universum in jedem Rollfenster konstant bleibt. Das ist gewollt, da es die Gegenprobe zum Strukturbruch erst ermöglicht, bedeutet aber zugleich, dass die Simulation den Universumseffekt der empirischen Daten nicht nachbildet. Ein simuliertes Panel mit gestaffelt eintretenden Anlagen wäre der naheliegende Weg, diesen Effekt isoliert zu quantifizieren.

Numerische Probleme der historischen Matrix. Im Anschluss an die Universumserweiterung 2022 ist die Stichprobenkovarianz an 66 Rebalancierungsterminen nicht positiv definit, weshalb für sie kein QLIKE-Verlust berechnet werden kann. Die Mittelwerte der Schätzer beruhen dadurch streng genommen auf unterschiedlichen Terminmengen. Da die fehlenden Termine unmittelbar nach der Universumserweiterung liegen und dort besonders negative QLIKE-Werte auftreten, begünstigt dies die dynamischen Schätzer geringfügig. Auf einer gemeinsamen Terminmenge gerechnet schrumpft ihr Vorsprung um rund einen halben QLIKE-Punkt, ohne dass sich die Rangfolge ändert. Der MSE ist von dem Problem nicht betroffen, da er keine Invertierung voraussetzt, während sich das Problem systematisch durch einen Shrinkage-Schätzer im Sinne von **ledoit2004** lösen ließe. Dieser wäre zugleich ein interessanterer Vergleichsmaßstab als die rohe Stichprobenkovarianz.

Realisierter Proxy. Für $h = 1$ besteht der realisierte Proxy S aus einem einzigen äußeren Produkt und hat damit den Rang eins. Die Verlustfunktionen bleiben nach **patton2011** zwar rangerhaltend, jedoch ist das Signal-Rausch-Verhältnis gering, was insbesondere die Teststärke des MSE-basierten DMW-Tests begrenzt. Dort werden nur noch Signifikanzen auf dem 5%-Niveau erreicht und der Unterschied zwischen GARCH und DCC ist nicht mehr nachweisbar. Intraday-Daten würden einen erheblich präziseren Proxy liefern, standen für diese Arbeit aber nicht zur Verfügung.

Kalibrierung des Risikoniveaus. Bewertet wurde ausschließlich die relative Prognosegüte, nicht die absolute Kalibrierung der prognostizierten Volatilität. Ob die Modelle das Risikoniveau im Mittel treffen, was für Value-at-Risk-Anwendungen entscheidend wäre, bleibt damit offen und wäre in einer Erweiterung zu prüfen.

Modellspezifikation. Es wird ausschließlich GARCH(1,1) unter Normalverteilungsannahme geschätzt, wobei Aktienrenditen typischerweise linksschief und leptokurtisch sind. Erweiterungen um Asymmetrie, etwa GJR-GARCH oder EGARCH, sowie um fat-tailed

Innovationen liegen daher nahe. Die DCC-Parameter werden zudem mit korrelationsgetargetem $\bar{Q}$ und begrenzter Iterationszahl geschätzt, ohne dass Standardfehler ausgewiesen werden.

Weitere Punkte. Über 40 Läufe hinweg werden zahlreiche Tests durchgeführt, ohne für multiples Testen zu korrigieren. Die Analyse beschränkt sich außerdem auf ein einziges Marktsegment, wobei Sektorindizes zudem nicht unmittelbar investierbar sind und Replikationskosten daher unberücksichtigt bleiben. Schließlich sind Leerverkaufsverbot und Vollinvestition die einzigen Restriktionen, während praxisübliche Obergrenzen je Position nicht gesetzt werden.

7 Fazit

Die Arbeit hat zwei Fragen getrennt untersucht, nämlich ob risikobasierte Portfoliomodelle das naive 1/N-Portfolio schlagen und ob GARCH-basierte Kovarianzprognosen gegenüber der historischen Schätzung einen Mehrwert stiften.

Zur ersten Frage fällt die Antwort differenziert aus und hängt stark vom gewählten Verfahren ab. HRP und ERC mit historischer Kovarianz übertreffen das 1/N-Portfolio in allen 40 untersuchten Konstellationen und erweisen sich als robust gegenüber Variationen von Trainings- und Prognosefenster. Das Minimum-Varianz-Portfolio erzielt im Basisfall zwar die höchste Sharpe Ratio, schlägt 1/N über alle Läufe hinweg aber nur in der Hälfte der Fälle und reagiert am empfindlichsten auf Schätzfehler. Für die Praxis sprechen diese Ergebnisse damit eher für die robusteren Verfahren als für die theoretisch elegantere Varianzminimierung, wobei einschränkend gilt, dass keiner der Vorsprünge gegenüber 1/N statistisch signifikant ist.

Zur zweiten Frage hängt die Antwort davon ab, welches Kriterium angelegt wird, worin zugleich der Hauptbefund liegt. Statistisch ist das Ergebnis eindeutig, da DCC-GARCH die Kovarianzmatrix in allen 40 Läufen unter dem MSE und in nahezu allen unter dem QLIKE-Verlust besser prognostiziert als die historische Schätzung und die Unterschiede im DMW-Test signifikant sind. Der Zusatzbeitrag der dynamischen Korrelation gegenüber der konstanten fällt klein aus, wird unter QLIKE aber sehr präzise geschätzt, während er sich unter dem verbrauchteren MSE nicht nachweisen lässt.

Ökonomisch übersetzt sich dieser Vorsprung nur dort, wo die Kovarianzmatrix tatsächlich intensiv genutzt wird. Beim MVP schlagen die dynamischen Schätzer die historische Matrix in gut der Hälfte der Läufe, beim HRP nur vereinzelt und beim ERC in keinem einzigen. Das ist konsistent mit der Konstruktion der Verfahren, da HRP und ERC die Matrix bewusst nur grob nutzen und gerade deshalb robust, zugleich aber auch unemp-

findlich gegenüber ihrer Verbesserung sind. Der Preis der Dynamik ist der Turnover, der beim MVP um den Faktor 32 höher liegt. Bereits moderate Transaktionskosten von 5 Basispunkten drücken die dynamischen Varianten unter das 1/N-Portfolio, wobei sich ihr Vorteil mit wachsendem Prognosehorizont auch ohne Kosten ins Gegenteil kehrt.

Ein methodischer Nebenbefund verdient darüber hinaus Beachtung. Die Auswertung über verschiedene Trainingsfenster, die üblicherweise als Robustheitsprüfung verstanden wird, variiert im vorliegenden Design zugleich den Bewertungszeitraum und die Zusammensetzung des Anlageuniversums. Beide Effekte sind erheblich und gerichtet, da über die volle Historie das längste Trainingsfenster überlegen erscheint, weil es den Einbruch der Finanzkrise ausschließt und nur die Erholung erfasst. Dass sich dieser Effekt auch beim 1/N-Portfolio zeigt, das gar nicht schätzt, belegt seinen rein stichprobenbedingten Charakter. Alle Vergleiche über Fenster und Horizonte hinweg werden daher einheitlich ab 2010 bewertet, wodurch rund die Hälfte der scheinbaren Fenstersensitivität verschwindet. Der verbleibende Teil geht auf das Universum zurück, da das Niveau des QLIKE-Verlusts mit einer Korrelation von $-0,9999$ praktisch vollständig durch die Zahl der investierbaren Sektoren bestimmt wird. Auf den synthetischen Datensätzen mit konstantem Universum und parameterstabilem Prozess tritt dieses Muster erwartungsgemäß nicht auf. Für die Interpretation folgt daraus, dass Niveauvergleiche über Fensterlängen hinweg ohne Kontrolle von Zeitraum und Universum nicht belastbar sind, was für Rollfensterstudien auf unbalancierten Panels allgemein gelten dürfte.

Der übergreifende Schluss lautet damit, dass eine bessere Risikoprognose nicht automatisch eine bessere Anlageentscheidung ist. Die GARCH-Modelle leisten das, wofür sie konstruiert sind, und die synthetische Validierung zeigt, dass sie genau dann einen Mehrwert liefern, wenn der datengenerierende Prozess ihre Annahmen erfüllt. Auf realen Sektordaten ist die verwertbare Struktur jedoch zu schwach, um die Kosten der laufenden Umschichtung zu rechtfertigen, weshalb nicht die Prognosegüte die bindende Restriktion darstellt, sondern der Handel, den ihre Nutzung auslöst.

A Synthetische Validierung

Ob die Modelle korrekt implementiert sind, lässt sich an echten Daten nicht prüfen, weil der wahre datengenerierende Prozess unbekannt ist. Dafür werden drei simulierte Datensätze mit jeweils 20 Anlagen und 6.000 Handelstagen verwendet, die dieselbe unbedingte Risikostruktur besitzen (annualisierte Volatilitäten zwischen 15 % und 35 %, durchschnittliche Korrelation 0,35) und sich ausschließlich in der Dynamik der zweiten Momente unterscheiden. Der *Monte-Carlo*-Datensatz enthält unabhängige Ziehungen mit konstanter Kovarianz und bildet den Nullfall ab, in dem die historische Matrix korrekt spezifiziert

ist. Der *GARCH*-Datensatz ergänzt eine *GARCH*(1,1)-Dynamik je Anlage ($\alpha = 0,08$, $\beta = 0,90$) bei konstanter Korrelation. Der *DCC*-Datensatz fügt zusätzlich eine *DCC*-Rekursion hinzu ($a = 0,03$, $b = 0,96$). Die Ergebnisse bilden damit eine Leiter, auf der jeweils ein Schätzer korrekt spezifiziert ist.

Tabelle ?? zeigt, dass die Modelle dieser Leiter folgen. Im Monte-Carlo-Fall unterscheiden sich die drei Schätzer unter beiden Verlustmaßen praktisch nicht, und die historische Matrix erzielt beim MVP die minimal höchste Sharpe Ratio. Wo keine Struktur vorhanden ist, bringt das komplexere Modell also nichts, wie es sein soll. Im *GARCH*-Fall schlagen beide dynamischen Schätzer die historische Matrix deutlich, in der Prognosegüte ebenso wie in Sharpe Ratio und realisierter Volatilität. Im *DCC*-Fall schließlich schlägt *DCC* auch den *GARCH*-Schätzer klar.

Datensatz	Kovarianz	QLIKE	MSE ($\times 10^{-8}$)	Vola (%)	Sharpe	Turnover
Monte Carlo	Historisch	-154,50	7,04	11,92	1,011	0,011
	<i>GARCH</i>	-154,47	7,04	11,95	1,003	0,074
	<i>DCC-GARCH</i>	-154,47	7,04	11,95	1,002	0,075
<i>GARCH</i> -Sim.	Historisch	-154,23	7,84	11,37	0,869	0,010
	<i>GARCH</i>	-157,25	7,57	9,85	0,984	0,154
	<i>DCC-GARCH</i>	-157,25	7,57	9,85	0,984	0,154
<i>DCC</i> -Sim.	Historisch	-154,13	9,86	11,93	0,668	0,011
	<i>GARCH</i>	-157,02	9,19	9,62	0,907	0,160
	<i>DCC-GARCH</i>	-162,13	8,98	8,99	0,925	0,152

Tabelle 13: Synthetische Validierung: Basisfall je Datengenerierungsprozess
20 simulierte Anlagen, Training 1008 Handelstage, Prognosehorizont 1 Tag; Performancekennzahlen für das MVP.

Die DMW-Tests in Tabelle ?? bestätigen dieses Muster formal. Im Monte-Carlo-Prozess ist die Verlustdifferenz der dynamischen Schätzer gegenüber der historischen Matrix positiv, also minimal schlechter, und zwischen *GARCH* und *DCC* nicht von null verschieden. Die zusätzliche Parametrisierung erzeugt hier reines Rauschen. Im *GARCH*-Prozess sind beide dynamischen Schätzer signifikant besser als die historische Matrix, unterscheiden sich aber untereinander nicht, was korrekt ist, da die Korrelation dort konstant ist. Erst im *DCC*-Prozess wird der Unterschied zwischen *DCC* und *GARCH* signifikant. Die Implementierung erkennt also jeweils genau die Struktur, die tatsächlich vorhanden ist.

Datensatz	Δ G-H	t	Δ D-H	t	Δ D-G	t
Monte Carlo	0,029***	6,07	0,029***	6,12	0,000	0,32
<i>GARCH</i> -Sim.	-3,025***	-24,69	-3,024***	-24,68	0,000	1,28
<i>DCC</i> -Sim.	-2,887***	-15,64	-7,998***	-35,68	-5,111***	-49,85

Tabelle 14: Synthetische Validierung: DMW-Tests auf die QLIKE-Differenzen
G = *GARCH*, D = *DCC-GARCH*, H = historisch; negative Differenzen bedeuten eine bessere Prognose. ***, **, * = 1-, 5-, 10%-Niveau.

Für die Diskussion des Strukturbruchs in Abschnitt ?? ist Tabelle ?? der entscheiden-

de Gegenteil. Da das Universum konstant 20 Anlagen umfasst und die Parameter des Prozesses über die gesamte Stichprobe unverändert bleiben, sollte sich das Niveau der Prognosekennzahlen über die Trainingsfenster hinweg nicht systematisch verschieben. Bewertet wird nach demselben Protokoll wie in Abschnitt ??, also ab 2010. Genau das ist der Fall. Das QLIKE-Niveau der historischen Matrix schwankt über alle zehn Fenster nur um wenige Zehntel, während die entsprechende Spannweite in den empirischen Daten über 30 Punkte beträgt. Beim MSE ist das Niveau sogar praktisch konstant. Auch die Rangfolge kehrt sich in keinem Fenster um, denn DCC prognostiziert in allen 20 ausgewiesenen Läufen unter beiden Verlustmaßen besser als die historische Matrix, und die Differenz stabilisiert sich bei längeren Trainingsfenstern auf einem konstanten Niveau.

Datensatz	Training	N	QLIKE		MSE ($\times 10^{-8}$)		Sharpe MVP	
			Hist.	Δ DCC	Hist.	DCC	Hist.	DCC
GARCH-Sim.	252	20	-154,1	-2,09	7,03	6,90	1,110	0,973
	504	20	-154,3	-2,68	7,03	6,87	1,073	0,986
	756	20	-154,4	-2,83	7,02	6,86	0,942	0,956
	1008	20	-154,4	-2,90	7,02	6,86	0,870	0,936
	1260	20	-154,6	-2,82	7,02	6,86	0,828	0,923
	1512	20	-154,7	-2,79	7,02	6,86	0,840	0,921
	1764	20	-154,6	-2,83	7,02	6,85	0,832	0,905
	2016	20	-154,6	-2,89	7,02	6,85	0,847	0,907
	2268	20	-154,7	-2,85	7,02	6,85	0,840	0,899
	2520	20	-154,7	-2,83	7,02	6,85	0,837	0,896
DCC-Sim.	252	20	-156,1	-4,14	10,06	9,27	0,898	1,021
	504	20	-154,9	-6,62	10,13	9,22	1,041	1,072
	756	20	-154,5	-7,46	10,16	9,21	1,008	1,020
	1008	20	-154,2	-7,89	10,15	9,20	1,032	1,010
	1260	20	-154,1	-8,09	10,16	9,20	1,042	0,996
	1512	20	-154,1	-8,19	10,16	9,20	0,997	1,010
	1764	20	-154,1	-8,29	10,18	9,19	0,941	0,992
	2016	20	-154,0	-8,42	10,18	9,19	0,983	0,995
	2268	20	-153,9	-8,50	10,19	9,19	1,001	0,996
	2520	20	-153,9	-8,53	10,19	9,20	0,996	1,002

Tabelle 15: Synthetische Validierung: Stabilität über die Trainingsfenster

Bewertet ab 01.01.2010; das Universum ist mit 20 Anlagen konstant.

Erwähnenswert ist, dass die ökonomischen Kennzahlen auch hier spürbar schwanken, obwohl der Prozess vollkommen stabil ist. Beim GARCH-Datensatz schlägt der historische Schätzer in den beiden kürzesten Fenstern sogar den DCC-Schätzer, obwohl er dort mit Sicherheit falsch spezifiziert ist. Das ist kein Widerspruch, sondern eine weitere Bestätigung des Arguments aus Abschnitt ??: Die Sharpe Ratio ist selbst bei bekanntem datengenerierendem Prozess zu verrauscht, um Kovarianzschätzer zuverlässig zu ordnen, während die Prognosekennzahlen ein klares Signal liefern.