

Risikobasierte Portfoliooptimierung mit GARCH-Modellen

Abstrakt

1 Einleitung

2 Daten

2.1 Sektorindizes

Kennzahl	Min.	25 %	Median	75 %	Max.
Beobachtungen	1351	1877	7087	7087	7087
Rendite p.a. (%)	-5,34	4,70	6,02	8,97	20,27
Volatilität p.a. (%)	15,06	19,73	22,41	26,32	49,20

Tabelle 1: Deskriptive Statistik der TRBC-Sektorrenditen

Tägliche logarithmierte Renditen von 27 TRBC-Sektorindizes, 02.04.1999 bis 09.06.2026; durchschnittliche paarweise Korrelation 0,562.

2.2 Risikofreier Zins

2.3 Synthetische Datensätze

3 Methodik

3.1 Rolling Window

3.2 Kovarianzschätzer

Historische Kovarianzmatrix:

Generalized Autoregressive Conditional Heteroskedasticity (GARCH):

Dynamic Conditional Correlation (DCC-GARCH):

3.3 Portfoliomodelle

Minimum-Varianz-Portfolio (MVP)

Equal Risk Contribution (ERC)

Hierarchical Risk Parity (HRP)

Benchmark

3.4 Bewertungskriterien

Die Bewertung trennt zwischen der Prognosequalität der Kovarianzmatrix und der ökonomischen Performance der daraus abgeleiteten Portfolios.

Statistische Verlustmaße Die Prognosequalität wird über zwei Verlustmaße gemessen, den multivariaten Quasi-Likelihood-Verlust (QLIKE), oder auch Stein-Loss genannt (Laurent et al., 2013), und den Mean Squared Error (MSE) der Kovarianzmatrix. Da die wahre bedingte Kovarianzmatrix der Testperiode nicht beobachtbar ist, wird die Prognose bei beiden gegen denselben realisierten Proxy gemessen.

$$S = \frac{1}{h} \sum_{t=1}^h r_t r_t' \quad (1)$$

$$\text{QLIKE}(\Sigma, S) = \ln |\Sigma| + \text{tr}(\Sigma^{-1} S) \quad (2)$$

$$\text{MSE}(\Sigma, S) = \frac{1}{N^2} \sum_{i,j} (\Sigma_{ij} - S_{ij})^2 \quad (3)$$

Dabei ist Σ die prognostizierte und S die realisierte Kovarianzmatrix, r_t der Vektor der logarithmierten Tagesrenditen und N die Anzahl der zur Verfügung stehenden Sektorindizes im jeweiligen Zeitfenster. Beide Verluste werden je Rebalancierungsfenster berechnet und anschließend über die Fenster gemittelt, wobei niedrigere Werte eine bessere Prognose bedeuten.

Die beiden Maße unterscheiden sich darin, wie sie Fehler in beide Richtungen gewichten. Der QLIKE-Verlust aus Gleichung 2 bestraft eine Unterschätzung des Risikos stärker als eine Überschätzung, während der MSE aus Gleichung 3 Über- und Unterschätzungen gleichgewichtet. Aus ökonomischer Sicht wiegt eine Unterschätzung des Risikos schwerer als eine Überschätzung, weshalb die Asymmetrie des QLIKE-Verlusts hier erwünscht ist.

Diese beiden Maße werden verwendet, da sie sich in anderen Studien als robust gegenüber verauschten Proxys erwiesen haben. Dies ist insbesondere relevant, da der Proxy für $h = 1$ allein aus dem äußeren Produkt eines einzigen Renditevektors besteht und somit stark verauscht ist. So konnten Patton (2011) und Laurent et al. (2013) zeigen, dass beide Metriken Kovarianzmatrizen unabhängig von der Genauigkeit des Proxys robust ordnen. Folglich ist der absolute Wert der Metriken zwar nur eingeschränkt interpretierbar, jedoch ist die Rangfolge robust, weshalb Qualitätsunterschiede zwischen den Schätzern erkannt werden können. Da zusätzlich die Länge des Trainingsfensters die Zahl der investierbaren Anlagen und damit die Dimension der Kovarianzmatrix beeinflusst, sind Vergleiche zwischen den unterschiedlichen Trainingsfenstern ebenfalls mit Vorsicht zu interpretieren. Aussagekräftig ist daher in erster Linie die Differenz zwischen den Schätzern innerhalb einer Spezifikation.

Da der QLIKE-Verlust ökonomisch besser motiviert ist, wird dieser als primäre Vergleichsmetrik verwendet, während der MSE als weitere Metrik zur Überprüfung der Robustheit dient.

Ökonomische Kennzahlen Als ökonomische Kennzahlen werden die annualisierte Rendite, die realisierte Volatilität, die Sharpe Ratio und der Turnover berichtet. Die folgenden Kennzahlen beruhen auf der Tagesrendite der verschiedenen Portfolios $r_{p,t}$.

$$R_{\text{ann}} = \left(\prod_{t=1}^n (1 + r_{p,t}) \right)^{\frac{252}{n}} - 1 \quad (4)$$

$$\sigma_{\text{ann}} = \sqrt{252} \text{ sd}(r_{p,t}) \quad (5)$$

$$\text{Sharpe Ratio} = \frac{252 \overline{(r_{p,t} - r_{f,t})}}{\sqrt{252} \text{ sd}(r_{p,t} - r_{f,t})} \quad (6)$$

Die annualisierte Rendite aus Gleichung 4 ist die geometrische Wachstumsrate über die n Handelstage des Bewertungszeitraums, während die realisierte Volatilität als annualisierte Standardabweichung derselben Reihe berechnet wird. Bei der Sharpe Ratio beruhen Zähler und Nenner auf der Überschussrendite gegenüber der Fed Funds Rate.

Neben diesen Metriken wird auch der Turnover beachtet, der angibt, welcher Anteil des Portfolios je Rebalancierung umgeschichtet wird.

$$\text{Turnover}_k = \sum_{i=1}^N \left| w_{i,k}^{\text{Ziel}} - w_{i,k-1}^{\text{Ende}} \right| \quad (7)$$

Dabei sind $w_{i,k}^{\text{Ziel}}$ die neuen Zielgewichte der Rebalancierung k und $w_{i,k-1}^{\text{Ende}}$ die über die vorangegangene Halteperiode gedrifteten Endgewichte. Der Turnover dient dabei als Proxy für Transaktionskosten und zugleich als Indiz für die Robustheit der Optimierungsverfahren. In dieser Studie werden die Transaktionskosten bei der Rebalancierung zwar nicht direkt berücksichtigt, jedoch werden die Auswirkungen kurz bei den Ergebnissen und in Anhang B dargestellt.

Signifikanztests Signifikanzaussagen beruhen auf zwei Tests. Unterschiede in der Prognosegüte werden mit dem Diebold-Mariano-Test (DM-Test) auf die Verlustdifferenzen geprüft (Diebold & Mariano, 1995; West, 1996), deren Langfristvarianz autokorrelationsrobust geschätzt wird. Für Unterschiede in den Sharpe Ratios dient der Test von Jobson und Korkie (1981) in der Korrektur von Memmel (2003), der die Korrelation der beiden Renditereihen berücksichtigt. Damit wird für beide Bewertungsebenen getrennt geprüft, ob die beobachteten Unterschiede zwischen den Schätz- und Optimierungsverfahren über zufällige Schwankungen hinausgehen.

4 Ergebnisse

Zunächst wird geprüft, ob die GARCH-basierten Schätzer die Kovarianzmatrix besser prognostizieren, bevor untersucht wird, ob sich ein solcher Vorteil auch in der Portfolioperformance niederschlägt. Diese Reihenfolge folgt dem Einwand von Engle und Colacito (2006), wonach die Sharpe Ratio von den realisierten Renditen dominiert wird, auf die die Kovarianzmatrix nur mittelbar wirkt, was sich ebenso auf andere renditebasierte Kennzahlen übertragen lässt. Anschließend wird die Stabilität beider Befunde über Trainingsfenster und Prognosehorizonte betrachtet, während der Einfluss des Bewertungszeitraums und der Teilperioden im Anhang A behandelt wird.

4.1 Statistische Prognosequalität

Im Basisfall (vier Jahre Training, ein Tag Prognosehorizont) ordnet sich die Prognosegüte unter beiden Verlustmaßen nach der Modellkomplexität, wie Tabelle 2 zeigt. Die historische Matrix schneidet am schlechtesten ab, während der GARCH-Schätzer sie deutlich verbessert und DCC-GARCH nochmals einen kleinen Zusatzgewinn liefert. QLIKE und MSE stimmen hierbei in dieser Reihenfolge überein.

Wie scharf die beiden Verlustmaße trennen, unterscheidet sich allerdings erheblich. Der DM-Test in Tabelle 3 verwirft die Nullhypothese gleicher erwarteter Verluste unter QLIKE in allen

Kovarianzschätzer	QLIKE	MSE ($\times 10^{-7}$)
Historisch	-152,81	4,28
GARCH	-155,37	3,52
DCC-GARCH	-156,12	3,44

Tabelle 2: Prognosequalität der Kovarianzschätzer im Basisfall

TRBC, Training 1008 Handelstage, Prognosehorizont 1 Tag, bewertet über die volle Historie vom 12.02.2003 bis 09.06.2026; niedrigere Werte bedeuten eine bessere Prognose. QLIKE gemittelt über 6013 Termine, an denen alle drei Schätzer definiert sind (die historische Matrix ist an einzelnen Terminen singulär); MSE über alle 6079 Termine, an denen dieser Ausfall nicht auftritt.

drei paarweisen Vergleichen auf dem 1-%-Niveau, wobei dies trotz der insgesamt geringen Differenz auch für den Vergleich von DCC-GARCH und GARCH gilt. Der Grund hierfür liegt darin, dass beide Schätzer dieselben Varianzprognosen verwenden, wodurch die Verlustdifferenz kaum streut und fast ausschließlich aus dem Korrelationsbeitrag stammt. Unter dem MSE sind die Abstände zur historischen Matrix hingegen nur auf dem 5-%-Niveau signifikant, während der Unterschied zwischen DCC und GARCH nicht mehr von null zu trennen ist. Belastbar ist somit, dass beide dynamischen Schätzer die historische Matrix unter dem primären QLIKE-Kriterium hochsignifikant schlagen und auch der Zusatznutzen der dynamischen Korrelation dort nachweisbar ist, während der MSE nur die gröbere Rangfolge bestätigt.

Vergleich	$\emptyset \Delta$ Verlust	t -Statistik	p -Wert	Termine
<i>QLIKE</i>				
GARCH vs. Historisch	-2,563	-4,18	<0,001***	6013
DCC-GARCH vs. Historisch	-3,308	-5,28	<0,001***	6013
DCC-GARCH vs. GARCH	-0,744	-13,86	<0,001***	6079
<i>MSE ($\times 10^{-7}$)</i>				
GARCH vs. Historisch	-0,764	-2,23	0,026**	6079
DCC-GARCH vs. Historisch	-0,846	-2,11	0,035**	6079
DCC-GARCH vs. GARCH	-0,082	-1,26	0,207	6079

Tabelle 3: Diebold-Mariano-Tests auf die Verlustdifferenzen (Basisfall)

Basisfall, bewertet über die volle Historie vom 12.02.2003 bis 09.06.2026. Negative Differenzen bedeuten, dass der erstgenannte Schätzer besser prognostiziert; ***, **, * = 1-, 5-, 10-%-Niveau.

Über das gesamte Untersuchungsdesign hinweg ist der statistische Vorsprung nahezu vollständig, da DCC-GARCH unter dem primären QLIKE-Kriterium in 37 von 40 Kombinationen und unter dem MSE in sämtlichen 40 besser prognostiziert als die historische Matrix (siehe Tabelle 11 im Anhang). Da alle Läufe für diesen Vergleich denselben Bewertungszeitraum ab 2010 nutzen und sich ihre Trainingsfenster stark überlappen, ist diese Auszählung als Robustheit über Spezifikationen hinweg und nicht als 40 voneinander unabhängige Bestätigungen zu verstehen. Wie stark der Vorsprung ausfällt, hängt jedoch von der Spezifikation ab, wie Tabelle 4 zeigt. Mit der Länge des Trainingsfensters nimmt er bis etwa fünf Jahren zu und stabilisiert sich danach, wobei bei einjährigem Training unter QLIKE kein Vorteil vorliegt und der GARCH-Schätzer sogar schlechter abschneidet als die historische Matrix. Eine mögliche Erklärung hierfür ist, dass die dynamischen Modelle insgesamt mehr Parameter schätzen müssen und deshalb bei einer geringen Datenbasis schlechter abschneiden, obwohl ihre Annahmen näher an der Realität

liegen. Beim MSE ist die Ordnung nach Modellkomplexität dagegen über alle dargestellten Trainingsfenster und Prognosehorizonte hinweg vorzufinden.

Über den Prognosehorizont bleibt der Vorsprung unter QLIKE dagegen nahezu konstant, während er unter dem MSE relativ zum Verlustniveau sogar zunimmt. Wie jedoch im Abschnitt zu den Bewertungskriterien dargelegt, verändert sich mit der Fensterlänge wegen der später beginnenden Zeitreihen auch die Zahl der investierbaren Sektoren, weshalb die Entwicklung über die Trainingsfenster nur mit Vorsicht interpretiert werden sollte.

Spezifikation	QLIKE			MSE ($\times 10^{-7}$)		
	Historisch	GARCH	DCC-GARCH	Historisch	GARCH	DCC-GARCH
252	-176,1	-175,9	-176,1	2,99	2,48	2,47
504	-171,0	-171,4	-171,8	3,42	2,81	2,74
756	-165,2	-166,1	-166,8	3,41	2,84	2,75
1008	-159,7	-161,1	-161,9	3,43	2,87	2,77
1260	-154,3	-156,1	-157,1	3,42	2,83	2,75
1512	-150,1	-151,8	-152,9	3,18	2,60	2,52
1764	-146,0	-147,7	-148,8	3,11	2,53	2,45
2016	-142,0	-143,8	-144,9	3,09	2,52	2,45
2268	-140,6	-142,5	-143,7	3,05	2,46	2,41
2520	-140,0	-142,0	-143,3	3,02	2,45	2,40
$h = 1$	-159,7	-161,1	-161,9	3,43	2,87	2,77
$h = 5$	-159,5	-160,9	-161,6	1,68	1,23	1,17
$h = 10$	-159,3	-160,9	-161,5	1,32	0,95	0,90
$h = 21$	-158,9	-160,2	-160,7	0,82	0,49	0,46

Tabelle 4: Prognosequalität über Trainingsfenster und Prognosehorizonte (TRBC)

Beide Blöcke bewertet ab 01.01.2010. Oberer Block: Trainingsfenster in Handelstagen bei $h = 1$, unterer Block: Prognosehorizonte bei 1008 Tagen Training.

Neben der bereits genannten Dimensionsabhängigkeit des QLIKE ist im unteren Block zu beachten, dass der Proxy über h Tage mittelt und damit umso weniger streut, je länger der Horizont ist. Das MSE-Niveau fällt deshalb über die Horizonte, ohne dass die Prognosen dort besser wären, während dies beim QLIKE-Verlust nicht zu beobachten ist. Für die zweite Forschungsfrage fällt die statistische Antwort dennoch eindeutig aus, da beide dynamischen Modelle die Prognose der Kovarianzmatrix im Basisfall signifikant verbessern und DCC-GARCH die historische Schätzung unter QLIKE in nahezu allen und unter dem MSE in sämtlichen 40 Kombinationen schlägt.

4.2 Ökonomische Performance

Die ökonomische Auswertung führt zu einem differenzierteren Bild. Für die erste Forschungsfrage zeigt Tabelle 5 zunächst, dass alle neun risikobasierten Kombinationen im Basisfall eine höhere Sharpe Ratio erreichen als das naive 1/N-Portfolio, bei ERC mit dynamischer Kovarianz allerdings nur um wenige Tausendstel. Vorne liegt dabei das MVP, gefolgt von HRP und ERC. Der Vorsprung entsteht vollständig auf der Risikoseite, da das 1/N-Portfolio zwar die höchste Rendite im Feld

erzielt, diese aber mit der mit Abstand höchsten Volatilität erkaufte.

Modell	Kovarianz	Rendite (%)	Vola (%)	Sharpe	Turnover	Anlagen > 1 %
MVP	Historisch	9,03	13,82	0,567	0,008	4,6
MVP	GARCH	8,55	13,94	0,532	0,258	4,9
MVP	DCC-GARCH	8,65	13,81	0,543	0,255	4,9
HRP	Historisch	9,27	16,74	0,509	0,012	17,6
HRP	GARCH	8,96	16,21	0,502	0,072	17,4
HRP	DCC-GARCH	9,13	16,17	0,513	0,094	17,4
ERC	Historisch	9,46	17,67	0,501	0,006	17,8
ERC	GARCH	9,14	17,32	0,490	0,034	17,8
ERC	DCC-GARCH	9,13	17,31	0,490	0,034	17,8
1/N	–	9,58	18,79	0,488	0,006	17,8

Tabelle 5: Out-of-Sample-Performance im Basisfall

TRBC, Training 1008 Handelstage, Prognosehorizont 1 Tag, bewertet über die volle Historie vom 12.02.2003 bis 09.06.2026; Rendite, Volatilität und Sharpe Ratio annualisiert, Turnover ohne Kosten; Anlagen > 1 % ist die durchschnittliche Zahl der Sektoren mit einem Gewicht von mehr als 1 % je Formationstermin.

Innerhalb der Portfoliomodelle kehrt sich die statistische Rangfolge im Basisfall weitgehend um, da bei MVP und ERC die historische Matrix vorne liegt und allein beim HRP der DCC-Schätzer marginal besser abschneidet. Der GARCH-Schätzer bleibt dabei in allen drei Modellen hinter der historischen Matrix zurück. Bei HRP und ERC senken die dynamischen Schätzer jedoch die realisierte Volatilität spürbar, während der DCC-Schätzer beim MVP auf einem ähnlichen Niveau wie der historische Schätzer liegt, wobei dieser Vorteil in der Sharpe Ratio durch die Einbindung der Rendite jeweils verschwindet. Genau diese Größe schlagen Engle und Colacito (2006) für das Minimum-Varianz-Portfolio als ökonomisches Auswahlkriterium vor, da dessen realisierte Volatilität unmittelbar von der Kovarianzmatrix abhängt und nicht von den Renditen überlagert wird. Diese Idee kann auch auf HRP und ERC übertragen werden, da deren Gewichte ebenfalls allein aus der Kovarianzmatrix stammen.

Gleichzeitig fällt der mittlere Turnover des MVP mit der DCC- wie auch mit der GARCH-Kovarianz rund 32-mal so hoch aus wie mit der historischen, wodurch beide dynamischen Schätzer bei einer realen Umsetzung nochmals schlechter abschneiden würden. Grund für den hohen Turnover ist, dass die beiden dynamischen Modelle deutlich schneller auf Änderungen in der Volatilität reagieren, wodurch auch die Gewichtsverteilung der Portfolios angepasst wird, während die träge Stichprobenkovarianz die Gewichte nahezu unverändert lässt. Bei HRP und ERC fällt der Anstieg mit dem Faktor 5 bis 8 erheblich geringer aus, was auf die robustere Konstruktion der beiden Modelle zurückzuführen ist.

Wie unterschiedlich die Verfahren das Kapital verteilen, zeigt die durchschnittliche Zahl der Sektoren mit einem Gewicht von mehr als 1 % in Tabelle 5. Das MVP konzentriert sich im Mittel auf nur vier bis fünf der rund 18 investierbaren Sektoren, während HRP und ERC nahezu alle Sektoren nennenswert gewichten. Diese deutlich breitere Streuung trägt letztlich zur höheren Robustheit von HRP und ERC bei.

Statistisch abgesichert sind die Unterschiede in der Sharpe Ratio allerdings nicht, da Tabelle 6 für keinen der relevanten Vergleiche einen auch nur annähernd signifikanten p -Wert ausweist. Dies gilt sowohl zwischen den Kovarianzschätzern als auch gegenüber dem 1/N-Portfolio.

Vergleich	Δ Sharpe	z -Statistik	p -Wert
MVP Historisch vs. MVP GARCH	0,0352	0,55	0,584
MVP Historisch vs. MVP DCC-GARCH	0,0243	0,37	0,709
MVP GARCH vs. MVP DCC-GARCH	-0,0109	-0,78	0,435
HRP Historisch vs. HRP GARCH	0,0063	0,30	0,764
HRP Historisch vs. HRP DCC-GARCH	-0,0041	-0,18	0,859
HRP GARCH vs. HRP DCC-GARCH	-0,0104	-1,23	0,220
ERC Historisch vs. ERC GARCH	0,0105	0,95	0,342
ERC Historisch vs. ERC DCC-GARCH	0,0111	0,98	0,329
ERC GARCH vs. ERC DCC-GARCH	0,0006	0,27	0,784
MVP Historisch vs. 1/N	0,0797	0,69	0,487
MVP GARCH vs. 1/N	0,0445	0,41	0,681
MVP DCC-GARCH vs. 1/N	0,0554	0,51	0,611
HRP Historisch vs. 1/N	0,0210	0,66	0,509
HRP GARCH vs. 1/N	0,0147	0,37	0,711
HRP DCC-GARCH vs. 1/N	0,0251	0,61	0,541
ERC Historisch vs. 1/N	0,0132	0,85	0,395
ERC GARCH vs. 1/N	0,0027	0,13	0,898
ERC DCC-GARCH vs. 1/N	0,0021	0,10	0,923

Tabelle 6: Tests auf Unterschiede der Sharpe Ratios (Basisfall)

Basisfall, bewertet über die volle Historie vom 12.02.2003 bis 09.06.2026. Auf Überschussrenditen über die Fed Funds Rate; ***, **, * = 1-, 5-, 10%-Niveau.

Die Auswirkungen proportionaler Transaktionskosten sind in Tabelle 13 im Anhang B dargestellt. Bereits bei 5 Basispunkten auf das umgeschlagene Volumen fällt die Sharpe Ratio des MVP mit DCC-Kovarianz von 0,543 auf 0,310 und liegt damit deutlich unter dem naiven Portfolio mit 0,484, während die historische Variante mit 0,560 nahezu unverändert bleibt. Bei 20 Basispunkten werden beide dynamischen MVP-Varianten negativ.

Tabelle 7 fasst die Ergebnisse über alle 40 Kombinationen aus Trainingsfenster und Prognosehorizont zusammen, wobei je Portfoliomodell angegeben wird, wie oft das 1/N-Portfolio geschlagen wird und wie oft die dynamischen Schätzer die historische Matrix übertreffen. Bewertungsmaßstab ist dabei die Sharpe Ratio, wobei der Befund je nach Portfoliomodell unterschiedlich ausfällt. Zur ersten Forschungsfrage zeigt sich, dass HRP und ERC mit historischer Kovarianz das 1/N-Portfolio in rund 90 Prozent der Konstellationen schlagen, das MVP dagegen nur in einem Fünftel der Fälle. Ausschlaggebend ist die bereits angelegte Anfälligkeit des MVP, dass Schätzfehler im Optimierungsprozess verstärkt werden, wodurch konzentrierte Portfolios entstehen. Die im Basisfall beste Sharpe Ratio des MVP ist insofern nicht repräsentativ.

Zur zweiten Forschungsfrage zeigt sich ein klares Muster entlang der Portfoliomodelle, da die dynamischen Schätzer die historische Matrix beim MVP in mehr als der Hälfte der Läufe schlagen, beim HRP nur vereinzelt und beim ERC in keinem einzigen. Ökonomisch ist das gut erklärbar, weil das MVP als einziges Verfahren die Kovarianzmatrix vollständig einschließlich ihrer Inversen ausnutzt, während HRP lediglich die Clusterordnung und die Varianzen der

Teilcluster verwendet und ERC die Risikobeiträge ausbalanciert. Eine bessere Kovarianzprognose zahlt sich folglich dort aus, wo sie am intensivsten genutzt wird, und bleibt folgenlos, wo das Verfahren die Matrix nur grob verwendet. Somit steht das ökonomische Ergebnis im Gegensatz zum statistischen Befund.

Modell	Kovarianz	vs. 1/N	vs. historischer Matrix
MVP	Historisch	8/40	–
MVP	GARCH	15/40	22/40
MVP	DCC-GARCH	17/40	26/40
HRP	Historisch	35/40	–
HRP	GARCH	16/40	2/40
HRP	DCC-GARCH	19/40	3/40
ERC	Historisch	36/40	–
ERC	GARCH	17/40	0/40
ERC	DCC-GARCH	20/40	0/40

Tabelle 7: Ergebnisse über alle empirischen Läufe

Alle 40 Kombinationen aus Trainingsfenster und Prognosehorizont, bewertet ab 01.01.2010; ausgewiesen ist, wie oft die Sharpe Ratio höher ausfällt als beim jeweiligen Vergleichsmaßstab.

Auch über die Trainingsfenster hinweg bleibt dieses Muster erhalten (siehe Abb. 1). Beim MVP liegt DCC in allen zehn Fenstern über der historischen Matrix, bei HRP in einem und bei ERC in keinem. Der GARCH-Schätzer folgt diesem Muster bei HRP und ERC, erreicht beim MVP mit sechs von zehn Fenstern aber einen deutlich schwächeren Vorsprung als DCC. Dass DCC hier beim MVP vorne liegt, während im Basisfall die historische Matrix führt, ist kein Widerspruch, sondern ein Zeitraumeffekt, da diese Vergleiche auf dem gemeinsamen Zeitraum ab 2010 beruhen und das MVP mit dynamischer Kovarianz gerade in der Phase 2010–2019 vorne liegt (siehe Anhang A). Die absoluten Unterschiede fallen dabei klein aus, weshalb angesichts der insignifikanten Tests auf Sharpe-Differenzen keine belastbare Rangfolge abgeleitet werden sollte.




Abbildung 1: Sharpe Ratio über die Trainingsfenster

TRBC, Prognosehorizont 1 Tag, Bewertung ab 01.01.2010 für alle Fenster.

Deutlicher ist der Befund über den Prognosehorizont in Tabelle 8. Der tägliche Basisfall dient

dabei vor allem dazu, den Effekt der Kovarianzdynamik ohne die Nebenwirkungen seltenerer Rebalancierung zu isolieren, jedoch werden in der Realität auch längere Rebalancierungszyklen relevant. Wird seltener rebalanciert, bleibt die Sharpe Ratio der historischen Matrix beim MVP praktisch konstant, während sie für DCC und ebenso für GARCH bei den beiden längeren Horizonten deutlich fällt und der Turnover je Rebalancierung gleichzeitig auf mehr als das Doppelte steigt. Der Verlauf ist dabei nicht monoton, da beide dynamischen Schätzer bei einem Horizont von fünf Tagen zunächst ihren höchsten Wert im gesamten Feld erreichen und erst danach zurückfallen. Eine Erklärung hierfür ist, dass sich die historisch geschätzte Kovarianzmatrix nur langsam mit der Zeit verändert, weshalb ihre Prognose schon bei kurzen Vorhersagezeiträumen keine aktuelle Dynamik abbildet und über eine längere Halteperiode entsprechend wenig veraltet. Die GARCH-Modelle hingegen reflektieren Abweichungen nahezu sofort, weshalb ihre Prognose zwar den Formationszeitpunkt genau trifft, über die Halteperiode hinweg aber schnell veraltet. Das Maximum bei fünf Tagen deutet darauf hin, dass ein Teil der täglichen Umschichtungen auf Schätzrauschen und nicht auf verwertbare Dynamik reagiert, sodass dessen Wegfall die Performance zunächst verbessert, bevor das Veralten der Prognose überwiegt. Erkennbar ist das auch am Turnover, da dessen hohes Niveau anzeigt, wie stark sich die Kovarianzmatrix der dynamischen Modelle über eine längere Halteperiode verändert. Aufgrund der selteneren Rebalancierung fällt der über die gesamte Historie kumulierte Turnover trotz des höheren Werts je Rebalancierung jedoch geringer aus, womit auch die Kostenbelastung einer realen Umsetzung sinken würde. Bei HRP und ERC bleiben die Sharpe Ratios hingegen weitestgehend stabil, was wiederum auf die Robustheit dieser Verfahren hindeutet.

h (Tage)	1/N	Kovarianz	MVP	HRP	ERC	Turnover MVP
1	0,594	Historisch	0,606	0,592	0,604	0,008
		GARCH	0,599	0,592	0,591	0,258
		DCC-GARCH	0,620	0,611	0,592	0,255
5	0,597	Historisch	0,597	0,588	0,605	0,021
		GARCH	0,639	0,587	0,592	0,527
		DCC-GARCH	0,654	0,596	0,594	0,522
10	0,601	Historisch	0,610	0,600	0,610	0,033
		GARCH	0,524	0,578	0,589	0,603
		DCC-GARCH	0,545	0,575	0,590	0,598
21	0,602	Historisch	0,615	0,605	0,612	0,058
		GARCH	0,524	0,598	0,598	0,587
		DCC-GARCH	0,532	0,595	0,600	0,587

Tabelle 8: Sharpe Ratios und Turnover über die Prognosehorizonte (TRBC, Training 1008 Tage)
Annualisierte Sharpe Ratio, bewertet ab 01.01.2010; Turnover je Rebalancierung, also nicht auf gleiche Frequenz normiert.

5 Einordnung in die Literatur

6 Limitationen

6.1 Ausblick

Aus den Ergebnissen und den genannten Einschränkungen ergeben sich vier Ansatzpunkte für weitere Untersuchungen.

Auf der Modellseite wird ausschließlich ein GARCH(1,1) geschätzt, obwohl dieses Modell im Vergleich zur Realität vereinfachte Annahmen trifft. Beispielsweise zeigt sich in empirischen Untersuchungen, dass negative Schocks in der Regel einen stärkeren Einfluss auf die nachfolgende Volatilität haben als positive. Anders als das einfache GARCH-Modell binden Modelle wie GJR-GARCH und EGARCH diese Asymmetrie ein und sind somit realitätsnäher, während sich über höhere Ordnungen oder ein GARCH-MIDAS zusätzlich längerfristige Komponenten der Volatilität erfassen lassen. Da der ökonomische Nachteil der dynamischen Schätzer hier hauptsächlich aus dem Turnover und nicht aus der Prognosegüte stammt, wäre allerdings zu prüfen, ob eine realitätsnähere Varianzdynamik daran überhaupt etwas ändert.

Auf der Allokationsseite ließe sich das Feld um modernere Verfahren wie Hierarchical Equal Risk Contribution (Raffinot, 2018) oder Nested Clustered Optimization (López de Prado, 2019) erweitern, die die hierarchische Struktur von HRP anders auswerten. Beide nutzen die Kovarianzmatrix intensiver als HRP, ohne sie wie das MVP vollständig zu invertieren. Da sich der Mehrwert einer besseren Prognose in dieser Arbeit genau danach richtet, wie intensiv ein Verfahren die Matrix nutzt, ließe sich an ihnen prüfen, ob der Zusammenhang auch auf den Stufen dazwischen gilt. Offen bleibt zudem, ob eine bessere Kovarianzmatrix in Verfahren, die zusätzlich eine Renditeprognose verwenden, einen größeren Vorteil liefert, da die Matrix dort nicht nur das Risiko begrenzt, sondern auch die Gewichtung der erwarteten Renditen bestimmt.

Der dritte Ansatzpunkt betrifft die Transaktionskosten, die hier weder im Backtest noch in der Optimierung berücksichtigt werden. Ein kostenbewusster Optimierer würde den Turnover in die Zielfunktion aufnehmen und dadurch einen Teil der Belastung vermeiden, statt sie nur zu erleiden. Ob die dynamischen Schätzer unter einer solchen Nebenbedingung weiterhin zurückfallen, ist offen und wäre für die praktische Bewertung der entscheidende Test.

Schließlich sollten die Befunde an weiteren Datensätzen überprüft werden, etwa an Einzeltiteln, anderen Regionen oder Anlageklassen mit geringerer durchschnittlicher Korrelation. Gerade die hohe paarweise Korrelation des hier verwendeten Universums begrenzt die Diversifikationsmöglichkeiten von vornherein und könnte den Spielraum für eine bessere Kovarianzprognose systematisch verengen.

7 Fazit

Die Arbeit hat zwei Fragen getrennt untersucht, nämlich ob risikobasierte Portfoliomodelle das naive 1/N-Portfolio schlagen und ob GARCH-basierte Kovarianzprognosen gegenüber der historischen Schätzung einen Mehrwert stiften.

Zur ersten Frage hängt die Antwort stark vom gewählten Verfahren ab. HRP und ERC mit historischer Kovarianz übertreffen das 1/N-Portfolio in rund neun von zehn untersuchten Konstellationen und erweisen sich als robust gegenüber Variationen von Trainings- und Prognosefenster. Das Minimum-Varianz-Portfolio erzielt im Basisfall zwar die höchste Sharpe Ratio, schlägt 1/N über alle Läufe hinweg aber nur in einem Fünftel der Fälle und reagiert am empfindlichsten auf Schätzfehler. Für die Praxis sprechen diese Ergebnisse damit eher für die robusteren Verfahren als für die Varianzminimierung, wobei einschränkend gilt, dass keiner der Vorsprünge gegenüber 1/N statistisch signifikant ist.

Zur zweiten Frage entscheidet das angelegte Kriterium über die Antwort, worin zugleich der Hauptbefund liegt. Statistisch ist das Ergebnis eindeutig, da DCC-GARCH die Kovarianzmatrix in allen 40 Läufen unter dem MSE und in nahezu allen unter dem QLIKE-Verlust besser prognostiziert als die historische Schätzung und die Abstände zur historischen Matrix im DM-Test signifikant sind. Ökonomisch schlägt sich dieser Vorsprung jedoch nur dort nieder, wo die Kovarianzmatrix tatsächlich intensiv genutzt wird, also beim MVP und nicht bei HRP oder ERC. Das ist konsistent mit der Konstruktion der Verfahren, da beide die Matrix nur grob nutzen und gerade deshalb robust, zugleich aber auch unempfindlich gegenüber ihrer Verbesserung sind. Der Preis der Dynamik ist der Turnover, der beim MVP um den Faktor 32 höher liegt und den ohnehin geringen Vorsprung unter realen Handelskosten aufzehren würde.

Der übergreifende Schluss lautet damit, dass eine bessere Risikoprognose nicht automatisch eine bessere Anlageentscheidung ist. Die GARCH-Modelle leisten das, wofür sie konstruiert sind, und die synthetische Validierung zeigt, dass sie genau dann einen Mehrwert liefern, wenn der datengenerierende Prozess ihre Annahmen erfüllt. Selbst dann ist dieser Mehrwert jedoch nicht garantiert. Im DCC-Datensatz aus Anhang C liefert das korrekt spezifizierte DCC-Modell zwar in allen zehn Trainingsfenstern den besseren QLIKE-Verlust und die niedrigere realisierte Volatilität, unterliegt beim MVP-Sharpe aber in drei von zehn Fenstern dem falsch spezifizierten GARCH-Modell. Prognosegüte und Anlageerfolg fallen somit bereits bei bekanntem datengenerierendem Prozess auseinander. Auf realen Sektordaten ist die verwertbare Struktur jedoch zu schwach, um die Kosten der laufenden Umschichtung zu rechtfertigen. Nicht die Prognosegüte ist folglich die bindende Restriktion, sondern der Handel, den ihre Nutzung auslöst.

A Voller und gemeinsamer Bewertungszeitraum

Sämtliche im Ergebnisteil berichteten Vergleiche über Trainingsfenster hinweg wurden auf dem gemeinsamen Zeitraum ab 2010 gerechnet. Dieser Anhang begründet, warum diese Einschränkung nötig ist, und zeigt, was ohne sie gemessen würde.

Ohne die Einschränkung bewertet jedes Trainingsfenster einen anderen Zeitraum, da der Out-of-Sample-Beginn von März 2000 beim kürzesten auf November 2008 beim längsten Fenster wandert. Der Lauf mit einem Jahr Training enthält damit das Platzen der Dotcom-Blase, während der Lauf mit zehn Jahren Training erst nach der Finanzkrise beginnt und nur die Erholung abdeckt, wodurch dessen Kennzahlen angehoben werden, ohne dass dies etwas über die Schätzqualität aussagt. Wie stark der Effekt wiegt, zeigt Abbildung 2, in der die Sharpe Ratio über die Trainingsfenster einmal über die volle Historie und einmal über den gemeinsamen Zeitraum aufgetragen ist. Der Sprung beim längsten Fenster tritt links auch beim 1/N-Portfolio auf, obwohl dieses überhaupt keine Schätzung vornimmt, und verschwindet rechts vollständig. Es handelt sich somit um einen reinen Stichprobeneffekt.




Abbildung 2: Sharpe Ratio über die Trainingsfenster, voller und gemeinsamer Bewertungszeitraum

TRBC, Prognosehorizont 1 Tag, links die volle Historie des jeweiligen Fensters, rechts der für alle Fenster identische Zeitraum ab 01.01.2010.

Tabelle 9 und Tabelle 10 stellen je Trainingsfenster die Kennzahlen über die volle Historie denen über den gemeinsamen Zeitraum ab 2010 gegenüber. Die erste Tabelle weist neben der mittleren Größe des Anlageuniversums den QLIKE-Verlust der historischen Matrix und der beiden dynamischen Kovarianzschätzer aus, die zweite die Sharpe Ratio des MVP mit allen drei Kovarianzschätzern sowie die des 1/N-Portfolios. Die 90-%-Verfügbarkeitsregel lässt die zuletzt hinzugekommenen Sektoren in langen Fenstern erst spät oder gar nicht zu, weshalb die Fensterlänge über die Dimension der Kovarianzmatrix auch das QLIKE-Niveau mitbestimmt.

Wie oft welcher Schätzer über alle 40 Kombinationen vorne liegt, weist Tabelle 11 aus, getrennt nach der Sharpe Ratio je Portfoliomodell und den beiden Verlustmaßen. Dass die Rangfolge

Training	$\varnothing N$	Historisch		GARCH		DCC-GARCH	
		voll	gem.	voll	gem.	voll	gem.
252	20,3	-161,5	-176,1	-161,8	-175,9	-162,0	-176,1
504	19,7	-159,2	-171,0	-160,4	-171,4	-160,8	-171,8
756	19,1	-156,0	-165,2	-157,9	-166,1	-158,4	-166,8
1008	18,5	-152,8	-159,7	-155,4	-161,1	-156,1	-161,9
1260	17,9	-149,1	-154,3	-152,2	-156,1	-153,1	-157,1
1512	17,4	-146,1	-150,1	-149,2	-151,8	-150,2	-152,9
1764	16,9	-143,0	-146,0	-145,9	-147,7	-147,0	-148,8
2016	16,4	-139,6	-142,0	-142,4	-143,8	-143,7	-144,9
2268	16,2	-138,3	-140,6	-141,0	-142,5	-142,3	-143,7
2520	16,2	-139,1	-140,0	-141,3	-142,0	-142,7	-143,3

Tabelle 9: QLIKE über vollen und gemeinsamen Bewertungszeitraum (TRBC, $h = 1$)

voll bezeichnet die volle Historie des jeweiligen Fensters, *gem.* den gemeinsamen Zeitraum ab 01.01.2010. $\varnothing N$ ist die mittlere Zahl investierbarer Sektoren im gemeinsamen Zeitraum.

Training	MVP Historisch		MVP GARCH		MVP DCC-GARCH		1/N	
	voll	gem.	voll	gem.	voll	gem.	voll	gem.
252	0,419	0,515	0,377	0,505	0,384	0,518	0,400	0,592
504	0,406	0,495	0,453	0,627	0,452	0,633	0,406	0,601
756	0,432	0,525	0,427	0,561	0,425	0,564	0,422	0,593
1008	0,567	0,606	0,532	0,599	0,543	0,620	0,488	0,594
1260	0,496	0,613	0,458	0,592	0,470	0,620	0,412	0,573
1512	0,445	0,574	0,424	0,562	0,440	0,587	0,407	0,576
1764	0,403	0,535	0,429	0,563	0,437	0,578	0,373	0,537
2016	0,363	0,525	0,398	0,545	0,398	0,547	0,378	0,545
2268	0,375	0,550	0,427	0,581	0,416	0,574	0,395	0,551
2520	0,556	0,521	0,606	0,582	0,600	0,580	0,603	0,563

Tabelle 10: Sharpe Ratio über vollen und gemeinsamen Bewertungszeitraum (TRBC, $h = 1$)

voll bezeichnet die volle Historie des jeweiligen Fensters, *gem.* den gemeinsamen Zeitraum ab 01.01.2010. Ausgewiesen ist die annualisierte Sharpe Ratio.

der Schätzer nicht am Basisfall hängt, zeigt sich dort deutlich, da unter beiden Verlustmaßen DCC-GARCH nahezu durchgängig vorne liegt, während ökonomisch bei HRP und ERC die historische Matrix dominiert.

Kennzahl	Historisch	GARCH	DCC-GARCH
Sharpe MVP	14/40	6/40	20/40
Sharpe HRP	36/40	1/40	3/40
Sharpe ERC	40/40	0/40	0/40
QLIKE	3/40	0/40	37/40
Kovarianz-MSE	0/40	1/40	39/40
QLIKE (DCC vs. Hist.)	–	–	37/40
MSE (DCC vs. Hist.)	–	–	40/40

Tabelle 11: Häufigkeit des besten Kovarianzschätzers je Kennzahl

Alle 40 Kombinationen aus Trainingsfenster und Prognosehorizont, bewertet ab 01.01.2010. In den oberen beiden Blöcken ist ausgewiesen, wie oft der jeweilige Schätzer die höchste Sharpe Ratio beziehungsweise den niedrigsten Verlust liefert; der untere Block zählt zusätzlich direkt, in wie vielen der 40 Läufe DCC-GARCH die historische Matrix schlägt, unabhängig davon, ob GARCH dort noch besser abschneidet.

Zeitlich lokalisieren lässt sich der Bruch über die Teilperioden des Basisfalls in Tabelle 12. Das QLIKE-Niveau springt ab 2022 deutlich nach unten, wobei dieser Sprung exakt mit der Erweiterung des Universums von 17 auf 25 Sektoren im September 2022 zusammenfällt. Innerhalb der Periode 2022–2026 wächst das Universum anschließend nochmals von 25 auf 27 Sektoren, da zwei erst 2019 gestartete Reihen die 90-%-Verfügbarkeitsregel im 1008-Tage-Fenster erst 2024 beziehungsweise Ende 2024 erfüllen. Die Tabellenspanne 17–27 für diese Periode bildet somit beide Schritte ab. Der MSE zeigt an dieser Stelle keinen vergleichbaren Bruch, folgt dafür aber dem Volatilitätsniveau der Periode und steigt in der Finanzkrise auf mehr als das Siebzigfache des Werts der ruhigen Phase 2003–2007. Beide Kennzahlen sind über Perioden hinweg somit nur eingeschränkt vergleichbar, wenn auch aus unterschiedlichen Gründen.

Periode	N	QLIKE			MSE ($\times 10^{-7}$)			Sharpe			
		Hist.	GARCH	DCC	Hist.	GARCH	DCC	MVP Hist.	MVP GARCH	MVP DCC	1/N
2003–2007	16–16	-143,5	-146,8	-147,3	0,28	0,23	0,23	1,190	1,146	1,158	0,845
2008–2009	16–16	-119,7	-130,1	-131,2	21,03	16,87	16,72	-0,246	-0,303	-0,339	-0,120
2010–2019	16–17	-146,1	-147,2	-147,8	0,79	0,61	0,60	0,886	0,969	0,982	0,719
2020–2021	17–17	-133,1	-139,5	-140,3	20,18	16,67	15,88	0,436	0,391	0,417	0,828
2022–2026	17–27	-205,1	-204,7	-205,9	1,79	1,71	1,70	0,259	0,116	0,144	0,224

Tabelle 12: Teilperioden des Basisfalls: Universum, Prognosequalität und Performance

N ist die Spannweite der investierbaren Sektoren; QLIKE-Niveaus sind zwischen Perioden mit unterschiedlichem N nicht vergleichbar.

Aussagekräftig bleibt die Differenz zwischen den Schätzern innerhalb einer Periode, die erheblich variiert. In der Finanzkrise 2008/09 und im COVID-Zeitraum fällt sie um ein Vielfaches größer aus als in den ruhigen Phasen. Der Mehrwert der dynamischen Modellierung konzentriert sich damit auf Phasen mit ausgeprägten Volatilitätsschocks, in denen eine statische Matrix dem Risikoniveau am stärksten nachläuft.

Ökonomisch ist die Rangfolge ebenfalls periodenabhängig, da das MVP mit DCC-Kovarianz und ebenso mit GARCH-Kovarianz die historische Variante in der Phase 2010–2019 klar schlägt, in allen übrigen Teilperioden jedoch zurückliegt. Der Basisfall umfasst die volle Historie ab 2003 und mittelt über gegenläufige Teilperioden, weshalb dort die historische Matrix vorne liegt, während die auf 2010 eingeschränkten Tabellen für das MVP zugunsten von DCC ausfallen. Beide Rechnungen sind korrekt, messen aber Unterschiedliches, wobei die Unterschiede in beide Richtungen durchgängig insignifikant sind und daher keine starke Aussage zulassen.

B Transaktionskosten

Tabelle 13 weist die Sharpe Ratios des Basisfalls nach Abzug proportionaler Transaktionskosten auf das je Rebalancierung umgeschlagene Volumen aus.

Modell	Kovarianz	Turnover	0 Bp.	5 Bp.	10 Bp.	20 Bp.
MVP	Historisch	0,008	0,567	0,560	0,553	0,539
MVP	GARCH	0,258	0,532	0,299	0,066	-0,400
MVP	DCC-GARCH	0,255	0,543	0,310	0,077	-0,388
HRP	Historisch	0,012	0,509	0,499	0,490	0,472
HRP	GARCH	0,072	0,502	0,447	0,391	0,279
HRP	DCC-GARCH	0,094	0,513	0,439	0,366	0,219
ERC	Historisch	0,006	0,501	0,497	0,493	0,484
ERC	GARCH	0,034	0,490	0,466	0,442	0,393
ERC	DCC-GARCH	0,034	0,490	0,465	0,440	0,391
1/N	–	0,006	0,488	0,484	0,480	0,472

Tabelle 13: Sharpe Ratios nach proportionalen Transaktionskosten (Basisfall)

Sharpe Ratio auf Überschussrenditen über die Fed Funds Rate nach Abzug von c Basispunkten auf das je Rebalancierung umgeschlagene Volumen; die 0-Bp.-Spalte entspricht damit exakt Tabelle 5.

C Synthetische Validierung

Ob die Modelle korrekt implementiert sind, lässt sich an echten Daten nicht prüfen, da der wahre datengenerierende Prozess unbekannt ist. Stattdessen werden drei simulierte Datensätze mit jeweils 20 Anlagen und 6.000 Handelstagen verwendet, die dieselbe unbedingte Risikostruktur besitzen (annualisierte Volatilitäten zwischen 15 % und 35 %, durchschnittliche Korrelation 0,35) und sich ausschließlich in der Dynamik der zweiten Momente unterscheiden. Der Monte-Carlo-Datensatz enthält unabhängige Ziehungen mit konstanter Kovarianz, in denen die historische Matrix korrekt spezifiziert ist. Beim GARCH-Datensatz kommt eine GARCH(1,1)-Dynamik je Anlage mit $\alpha = 0,08$ und $\beta = 0,90$ bei konstanter Korrelation hinzu, während der DCC-Datensatz zusätzlich eine DCC-Rekursion mit $a = 0,03$ und $b = 0,96$ enthält. Obwohl die wahre bedingte Kovarianzmatrix hier bekannt wäre, wird die Prognosegüte auch in der Simulation gegen den realisierten Proxy aus Gleichung 1 gemessen, damit die Ergebnisse mit denen auf den realen Daten vergleichbar sind.

Die Ergebnisse des Basisfalls zeigen Tabelle 14 und die DM-Tests in Tabelle 15. Im Monte-Carlo-Fall unterscheiden sich die drei Schätzer praktisch nicht, denn die Verlustdifferenz der dynamischen Schätzer gegenüber der historischen Matrix ist zwar signifikant, in der Höhe aber verschwindend gering. Im GARCH-Fall schlagen beide dynamischen Schätzer die historische Matrix signifikant, auch in Sharpe Ratio und realisierter Volatilität, unterscheiden sich untereinander aber nicht, da die Korrelation dort konstant ist. Erst im DCC-Fall ist DCC dem GARCH-Schätzer signifikant überlegen, sodass die Implementierung jeweils genau die Struktur erkennt, die tatsächlich vorhanden ist.

Wie stabil dieses Bild über die Länge des Trainingsfensters ist, zeigt Tabelle 16. Da das Universum konstant 20 Anlagen umfasst und die Parameter des Prozesses über die gesamte Stichprobe unverändert bleiben, verschiebt sich das Niveau der Prognosekennzahlen kaum, denn das QLIKE-Niveau der historischen Matrix schwankt über alle zehn Fenster um höchstens gut zwei Punkte

Datensatz	Kovarianz	QLIKE	MSE ($\times 10^{-8}$)	Vola (%)	Sharpe	Turnover
Monte Carlo	Historisch	-154,50	7,04	11,92	0,903	0,011
	GARCH	-154,47	7,04	11,95	0,896	0,074
	DCC-GARCH	-154,47	7,04	11,95	0,896	0,075
GARCH-Sim.	Historisch	-154,23	7,84	11,37	0,756	0,010
	GARCH	-157,25	7,57	9,85	0,854	0,154
	DCC-GARCH	-157,25	7,57	9,85	0,854	0,154
DCC-Sim.	Historisch	-154,13	9,86	11,93	0,561	0,011
	GARCH	-157,02	9,19	9,62	0,773	0,160
	DCC-GARCH	-162,13	8,98	8,99	0,783	0,152

Tabelle 14: Synthetische Validierung: Basisfall je Datengenerierungsprozess

20 simulierte Anlagen, Training 1008 Handelstage, Prognosehorizont 1 Tag; Performancekennzahlen für das MVP.

Datensatz	$\Delta G-H$	t	$\Delta D-H$	t	$\Delta D-G$	t
Monte Carlo	0,029***	6,07	0,029***	6,12	0,000	0,32
GARCH-Sim.	-3,025***	-24,69	-3,024***	-24,68	0,000	1,28
DCC-Sim.	-2,887***	-15,64	-7,998***	-35,68	-5,111***	-49,85

Tabelle 15: Synthetische Validierung: DM-Tests auf die QLIKE-Differenzen

G = GARCH, D = DCC-GARCH, H = historisch; negative Differenzen bedeuten eine bessere Prognose. ***, **, * = 1-, 5-, 10-%-Niveau.

und das MSE-Niveau bleibt praktisch konstant. Auch die Rangfolge kehrt sich in keinem Fenster um, da DCC in allen 20 Läufen unter beiden Verlustmaßen besser prognostiziert als die historische Matrix.

Der Vorsprung der dynamischen Schätzer wächst dabei mit der Länge des Trainingsfensters und stabilisiert sich erst bei den längeren Fenstern. Im DCC-Datensatz steigt der QLIKE-Abstand zwischen DCC und historischer Matrix von 4,1 Punkten bei einem Jahr Training auf 8,5 Punkte bei zehn Jahren, im GARCH-Datensatz von 2,1 auf 2,8 Punkte. Auch wenn die Modelle also korrekt spezifiziert sind und der Prozess sich nicht verändert, zahlt sich eine breitere Datenbasis für die dynamischen Schätzer weiterhin aus, weil deren zusätzliche Parameter mit mehr Beobachtungen präziser geschätzt werden, während sich das Niveau der historischen Matrix kaum verändert.

Die ökonomischen Kennzahlen schwanken dagegen auch hier spürbar, obwohl der Prozess vollkommen stabil ist. Im GARCH-Datensatz erzielt die falsch spezifizierte historische Matrix in den beiden kürzesten Fenstern eine höhere Sharpe Ratio als der DCC-Schätzer. Im DCC-Datensatz liefert der korrekt spezifizierte DCC-Schätzer in allen zehn Fenstern den besseren QLIKE-Verlust und die niedrigere realisierte Volatilität, beim MVP-Sharpe liegt er jedoch nur in sieben Fenstern vorn und unterliegt in den übrigen dem falsch spezifizierten GARCH-Modell. Selbst bei bekanntem datengenerierendem Prozess ist die Sharpe Ratio damit zu verrauscht, um Kovarianzschätzer zuverlässig zu ordnen, während die Prognosekennzahlen ein klares und über alle Fenster stabiles Signal liefern.

Datensatz	Training	N	QLIKE			MSE ($\times 10^{-8}$)			Sharpe MVP		
			Hist.	GARCH	DCC	Hist.	GARCH	DCC	Hist.	GARCH	DCC
GARCH-Sim.	252	20	-154,0	-156,1	-156,1	7,75	7,54	7,54	0,991	0,952	0,952
	504	20	-154,2	-156,9	-156,9	7,74	7,49	7,49	0,930	0,903	0,902
	756	20	-154,2	-157,1	-157,1	7,81	7,54	7,54	0,799	0,841	0,841
	1008	20	-154,2	-157,3	-157,2	7,84	7,57	7,57	0,756	0,854	0,854
	1260	20	-154,4	-157,4	-157,4	7,86	7,58	7,58	0,781	0,889	0,889
	1512	20	-155,0	-157,8	-157,8	6,81	6,64	6,64	0,713	0,801	0,801
	1764	20	-154,8	-157,6	-157,6	7,00	6,84	6,84	0,706	0,826	0,826
	2016	20	-154,7	-157,7	-157,7	7,01	6,84	6,84	0,780	0,878	0,878
	2268	20	-154,7	-157,6	-157,6	7,07	6,89	6,89	0,816	0,900	0,900
	2520	20	-154,7	-157,5	-157,5	7,00	6,84	6,84	0,744	0,823	0,823
DCC-Sim.	252	20	-156,3	-158,0	-160,4	9,56	8,96	8,86	0,525	0,707	0,726
	504	20	-155,0	-157,5	-161,7	9,84	9,18	9,02	0,645	0,817	0,789
	756	20	-154,6	-157,3	-162,1	9,64	8,99	8,80	0,621	0,814	0,794
	1008	20	-154,1	-157,0	-162,1	9,86	9,19	8,98	0,561	0,774	0,783
	1260	20	-154,4	-157,1	-162,4	9,32	8,67	8,48	0,553	0,779	0,787
	1512	20	-154,3	-157,0	-162,4	9,51	8,84	8,64	0,648	0,861	0,889
	1764	20	-154,1	-156,9	-162,3	9,72	9,03	8,82	0,681	0,807	0,868
	2016	20	-154,0	-156,9	-162,4	9,92	9,18	8,97	0,713	0,780	0,816
	2268	20	-153,8	-156,8	-162,4	10,13	9,37	9,15	0,815	0,824	0,830
	2520	20	-154,0	-157,0	-162,5	10,04	9,28	9,06	0,977	0,982	0,964

Tabelle 16: Synthetische Validierung: Stabilität über die Trainingsfenster

Bewertet über die volle simulierte Stichprobe, da das Universum mit 20 Anlagen konstant ist und die Parameter des Prozesses über die gesamte Reihe unverändert bleiben.

Literaturverzeichnis

- Diebold, F. X., & Mariano, R. S. (1995). Comparing Predictive Accuracy. *Journal of Business and Economic Statistics*, 13(3), 253–263. <https://doi.org/10.1080/07350015.1995.10524599>
- Engle, R. F., & Colacito, R. (2006). Testing and Valuing Dynamic Correlations for Asset Allocation. *Journal of Business and Economic Statistics*, 24(2), 238–253. <https://doi.org/10.1198/073500106000000017>
- Jobson, J. D., & Korkie, B. M. (1981). Performance Hypothesis Testing with the Sharpe and Treynor Measures. *The Journal of Finance*, 36(4), 889–908. <https://doi.org/10.1111/j.1540-6261.1981.tb04891.x>
- Laurent, S., Rombouts, J. V. K., & Violante, F. (2013). On loss functions and ranking forecasting performances of multivariate volatility models. *Journal of Econometrics*, 173(1), 1–10. <https://doi.org/10.1016/j.jeconom.2012.08.004>
- López de Prado, M. (2019). A Robust Estimator of the Efficient Frontier. <https://doi.org/10.2139/ssrn.3469961>
- Memmel, C. (2003). Performance Hypothesis Testing with the Sharpe Ratio. *Finance Letters*, 1(1), 21–23.
- Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256. <https://doi.org/10.1016/j.jeconom.2010.03.034>
- Raffinot, T. (2018). The Hierarchical Equal Risk Contribution Portfolio. <https://doi.org/10.2139/ssrn.3237540>

West, K. D. (1996). Asymptotic Inference about Predictive Ability. *Econometrica*, 64(5), 1067–1084. <https://doi.org/10.2307/2171956>