

Risikobasierte Portfoliooptimierung mit GARCH-Modellen

Abstrakt

Diese Arbeit untersucht, ob risikobasierte Portfolioverfahren das naive 1/N-Portfolio schlagen und ob GARCH- und DCC-GARCH-Prognosen der Kovarianzmatrix gegenüber einer historischen Schätzung einen Mehrwert stiften. Die Grundlage bilden tägliche Renditen von 27 US-Sektorindizes über gut 27 Jahre, die in zehn Trainingsfenstern und vier Prognosehorizonten und damit in 40 Konstellationen ausgewertet werden. Bewertet wird getrennt nach statistischen und ökonomischen Kriterien. Statistisch fällt das Ergebnis eindeutig aus, da DCC-GARCH die Kovarianzmatrix unter dem MSE in allen 40 Konstellationen besser prognostiziert als die historische Matrix. Ökonomisch schlägt sich dieser Vorsprung jedoch nur beim Minimum-Varianz-Portfolio nieder, während er bei Hierarchical Risk Parity und Equal Risk Contribution folgenlos bleibt. Ausschlaggebend ist der Turnover, der beim Minimum-Varianz-Portfolio mit dynamischer Kovarianz um den Faktor 32 höher liegt und die dynamischen Varianten unter realen Handelskosten zusätzlich belasten würde. Eine bessere Risikoprognose ist folglich nicht automatisch eine bessere Anlageentscheidung.

1 Einleitung

Seit Markowitz (1952) ist die Zusammenstellung eines Portfolios als Optimierungsproblem formuliert, bei dem die Gewichte gesucht werden, die bei gegebener erwarteter Rendite die Portfoliovarianz minimieren. In der praktischen Anwendung erweist sich dieser Ansatz jedoch als fragil, da sowohl die Erwartungswerte als auch die Kovarianzmatrix aus historischen Daten geschätzt werden müssen. Weil das Verfahren Anlagen mit zufällig überschätzter Rendite systematisch übergewichtet, verstärkt es Schätzfehler, statt sie auszumitteln. Michaud (1989) bezeichnet die Markowitz-Optimierung deshalb als Fehlermaximierung.

Von diesem Problem sind die beiden Eingangsgrößen unterschiedlich stark betroffen. Broadie (1993) zeigt in einer Simulationsstudie, dass Fehler in den geschätzten Erwartungswerten die Lage der effizienten Grenze deutlich stärker verzerren als Fehler in den geschätzten Varianzen und Kovarianzen. Erwartete Renditen lassen sich aus Kursdaten nur mit großer Unsicherheit bestimmen, während Risikokennzahlen stabiler zu schätzen sind. Wie gravierend die Folgen

sind, zeigen DeMiguel et al. (2009), da in ihrem Vergleich über mehrere Datensätze keine der optimierten Strategien das naive, gleichgewichtete 1/N-Portfolio verlässlich schlagen konnte. Der Aufwand einer Optimierung lohnt sich folglich nur, wenn ihr Gewinn den Verlust durch Schätzfehler übersteigt.

An dieser Stelle setzen risikobasierte Portfolioverfahren an, die vollständig auf Renditeprognosen verzichten und die Gewichte allein aus der Kovarianzmatrix bestimmen. Untersucht werden hier das Minimum-Varianz-Portfolio, das Equal-Risk-Contribution-Portfolio sowie die Hierarchical Risk Parity (HRP) von López de Prado (2016). Die drei Verfahren unterscheiden sich vor allem darin, wie intensiv sie die geschätzte Kovarianzmatrix nutzen, weshalb deren Qualität unterschiedlich stark auf die Gewichte durchschlägt. Gerade diese Abstufung macht sie zu einem geeigneten Prüffeld für die Frage, wie viel eine bessere Risikoprognose überhaupt wert sein kann.

Damit rückt die Kovarianzmatrix selbst in den Mittelpunkt, denn werden die Gewichte ausschließlich aus ihr abgeleitet, sollte eine bessere Schätzung auch zu besseren Portfolios führen. Der übliche Stichprobenschätzer unterstellt jedoch konstante Varianzen und Korrelationen über das gesamte Schätzfenster. Diese Annahme widerspricht der Beobachtung, dass ruhige und turbulente Phasen einander ablösen und große Kursausschläge weitere große Ausschläge nach sich ziehen. Engle (1982) hat diese Volatilitätscluster erstmals ökonometrisch erfasst, worauf Bollerslev (1986) das heute übliche Generalized-Autoregressive-Conditional-Heteroskedasticity-Modell (GARCH) aufbaute.

Für ein Portfolio genügt es allerdings nicht, die Varianzen einzeln zu modellieren, da auch die Abhängigkeitsstruktur zwischen den Anlagen zeitvariabel ist. Dass Korrelationen in Stressphasen ansteigen und die Diversifikation gerade dann versagt, wenn sie am dringendsten gebraucht wird, kann ein Modell mit konstanter Korrelation nicht abbilden. Engle (2002) überträgt die GARCH-Rekursion deshalb auf die Korrelationsmatrix selbst und erhält mit dem Dynamic-Conditional-Correlation-Modell (DCC) eine vollständig zeitvariable Kovarianzprognose. Dass diese Erweiterung für die Allokation relevant ist, legen Ardia et al. (2017) nahe, die eine Fehlspezifikation der Kovarianzmatrix als spürbare Verzerrung der Gewichte risikobasierter Portfolios ausweisen.

Ob eine statistisch bessere Prognose auch zu einer besseren Anlageentscheidung führt, ist damit jedoch nicht beantwortet. Engle und Colacito (2006) weisen darauf hin, dass die Sharpe Ratio als Kriterium für die Auswahl eines Kovarianzschätzers irreführend sein kann, da sie von den realisierten Renditen dominiert wird, auf die die Kovarianzmatrix nur mittelbar wirkt. Als Alternative bietet Patton (2011) Verlustfunktionen an, deren Rangfolge auch bei einem verrauschten Proxy der wahren Varianz erhalten bleibt, während Laurent et al. (2012) dieses Konzept auf vollständige Kovarianzmatrizen übertragen. Wie weit beide Kriterien auseinanderfallen können, zeigen Moura et al. (2020) für hochdimensionale bedingte Kovarianzmatrizen, wo die statistisch beste Spezifikation nicht die ökonomisch beste ist.

Die Verbindung beider Themenfelder, risikobasierter Allokation einschließlich neuerer Verfahren

wie HRP auf der einen und multivariater GARCH-Prognosen auf der anderen Seite, ist bislang nur vereinzelt untersucht worden. Vor diesem Hintergrund verfolgt diese Arbeit zwei Fragen. Erstens wird geprüft, ob Minimum-Varianz-, Equal-Risk-Contribution- und Hierarchical-Risk-Parity-Portfolios eine höhere risikoadjustierte Out-of-Sample-Performance erzielen als das naive 1/N-Portfolio. Zweitens wird untersucht, ob GARCH- und DCC-GARCH-basierte Risiko- und Kovarianzprognosen die Ergebnisse gegenüber einer historischen Schätzung verbessern. Beide Fragen werden getrennt nach statistischen und ökonomischen Kriterien beantwortet, da sich gerade in der Differenz zwischen beiden der zentrale Befund dieser Arbeit zeigt.

Die empirische Grundlage bilden tägliche Renditen von 27 US-Sektorindizes über gut 27 Jahre. Zehn Trainingsfenster und vier Prognosehorizonte ergeben 40 Konstellationen, in denen jede der drei Kovarianzschätzungen mit jedem der vier Allokationsverfahren bewertet wird. Als Kriterien dienen statistisch QLIKE-Verlust und Kovarianz-MSE, ökonomisch Sharpe Ratio, realisierte Volatilität und Turnover. Ergänzend prüfen drei simulierte Datensätze mit bekanntem datengenerierendem Prozess, ob die Modelle das leisten, wofür sie konstruiert sind.

Diesem Vorgehen folgt auch der weitere Aufbau der Arbeit. Der folgende Abschnitt beschreibt die Datengrundlage, während der 3. Abschnitt das Untersuchungsdesign darlegt. Im 4. Abschnitt werden die Ergebnisse zunächst zur Prognosequalität und anschließend zur Portfolioperformance berichtet, bevor ihre Stabilität über verschiedene Zeiträume und Anlageuniversen untersucht wird. Anschließend ordnet der 5. Abschnitt die Befunde in die Literatur ein und der 6. Abschnitt diskutiert die Grenzen der Untersuchung. Am Ende werden die zentralen Erkenntnisse zusammengefasst.

2 Daten

In diesem Abschnitt wird die Datengrundlage der empirischen Untersuchung beschrieben. Dabei wird zwischen den empirischen Sektordaten und den simulierten Datensätzen unterschieden, die ausschließlich der Validierung der Implementierung dienen.

2.1 Sektorindizes

Verwendet werden tägliche Kurse US-amerikanischer Sektorindizes, die über Datastream bezogen wurden. Als Sektorabgrenzung dienen die Business Groups der Refinitiv Business Classification (TRBC), wobei für die Vereinigten Staaten nur Daten für 28 der insgesamt 32 Business Groups verfügbar sind. Eine davon zeigt an rund zwei Dritteln ihrer Datenpunkte keine Kursbewegung und wird als inaktive Reihe verworfen, sodass 27 Sektoren in die Analyse eingehen. Der Beobachtungszeitraum reicht vom 02.04.1999 bis zum 09.06.2026 und umfasst 7.087 Handelstage, wobei nur für 16 Sektorindizes Daten über die gesamte Historie vorliegen, während die übrigen Datenreihen erst zu späteren Zeitpunkten starten.

Als risikofreier Zins dient die Fed Funds Rate, die wie auch die Sektorindizes über Datastream bezogen wird. Der risikofreie Zinssatz fließt nicht in die Optimierung der einzelnen Portfolios ein, sondern wird ausschließlich für die Berechnung der Sharpe Ratio verwendet.

Die Querschnittsverteilung der Sektorrenditen ist in Tabelle 1 dargestellt. Auffällig ist dabei die durchschnittliche paarweise Korrelation von 0,562, die aufgrund der Begrenzung auf den US-Aktienmarkt erwartungsgemäß hoch ausfällt und die Diversifikationsmöglichkeiten innerhalb des Universums von vornherein einschränkt.

Kennzahl	Min.	25 %	Median	75 %	Max.
Beobachtungen	1351	1877	7087	7087	7087
Rendite p.a. (%)	-5,34	4,70	6,02	8,97	20,27
Volatilität p.a. (%)	15,06	19,73	22,41	26,32	49,20

Tabelle 1: Deskriptive Statistik der TRBC-Sektorrenditen

Tägliche logarithmierte Renditen von 27 TRBC-Sektorindizes, 02.04.1999 bis 09.06.2026; durchschnittliche paarweise Korrelation 0,562.

2.2 Synthetische Datensätze

Hinzu kommen drei künstlich erzeugte Datensätze, die ausschließlich der Validierung der Implementierung dienen. Simuliert werden ein Prozess mit konstanter Kovarianzmatrix sowie je ein CCC- und ein DCC-GARCH-Prozess, sodass für jeden der drei Kovarianzschätzer ein Datensatz vorliegt, auf dem er korrekt spezifiziert ist. Auf diese Weise lässt sich prüfen, ob die Modelle genau die Struktur erkennen, für die sie konstruiert sind, was an echten Daten wegen des unbekannten datengenerierenden Prozesses nicht möglich ist. Die Parametrisierung ist im Anhang A dokumentiert.

3 Methodik

In diesem Abschnitt wird das Untersuchungsvorgehen vorgestellt. Dabei wird auf die Schätzung der Kovarianzmatrix, die Portfoliooptimierung und die Vergleichsmetriken eingegangen.

3.1 Rolling Window

Um für mögliche Strukturbrüche in den Daten zu kontrollieren und zugleich einer realistischen Anwendung nahe zu kommen, wird ein Rolling-Window-Ansatz gewählt. Die Kovarianzmatrix wird dabei auf einem Trainingsfenster der Länge T geschätzt, daraus werden die Portfoliogewichte bestimmt und diese über den Prognosehorizont von h Handelstagen gehalten, bevor das Fenster um h Tage weiterrückt. Variiert werden beide Größen, wobei das Trainingsfenster zwischen

einem und zehn Jahren liegt und der Prognosehorizont 1, 5, 10 oder 21 Handelstage beträgt. Der Vergleich der daraus resultierenden 40 Kombinationen zeigt zum einen, ob die Befunde robust gegenüber der Wahl von Trainings- und Prognosefenster sind, und zum anderen, bei welcher Fensterlänge sich Schätzfehler aus zu wenigen Beobachtungen und Fehlspezifikation aus sich ändernden Parametern am besten ausgleichen.

Je Zeitfenster werden dabei nur Sektoren beachtet, die an mindestens 90 % der Handelstage verfügbar sind, um so eine ausreichende Datenbasis für die Schätzung zu gewährleisten und zugleich nicht ganze Anlagen wegen einzelner fehlender Datenpunkte auszuschließen. Das investierbare Universum wird somit in jedem Fenster neu bestimmt und variiert sowohl über die Zeit als auch über die Fensterlänge. Als Basisfall werden durchgängig $T = 1008$ (vier Jahre) und $h = 1$ berichtet und von da ausgehend die Robustheit der Ergebnisse überprüft.

Ein Nachteil des Untersuchungsdesigns ist jedoch, dass ein längeres Trainingsfenster den Out-of-Sample-Zeitraum verkürzt. So beginnt dieser bei einem Jahr Trainingsdaten bereits im März 2000, bei zehn Jahren dagegen erst im November 2008. Der lange Lauf schließt damit den Einbruch der Finanzkrise aus und deckt im Wesentlichen nur die anschließende Erholung ab. Diese Unterschiede führen dazu, dass die Ergebnisse durch die jeweils abgedeckten Marktphasen beeinflusst werden, wodurch die Vergleichbarkeit eingeschränkt wird. Sämtliche Vergleiche über Trainingsfenster und Prognosehorizonte werden daher auf dem gemeinsamen Bewertungszeitraum ab dem 01.01.2010 gerechnet, sodass alle Testzeiträume rund 4.280 Handelstage umfassen und alle Ergebnisse über die gleichen Marktphasen bestimmt werden. Der Basisfall wird zusätzlich zuerst über seine volle verfügbare Historie ab Februar 2003 berichtet, da dort keine Vergleichbarkeitsfrage besteht. Wie weit beide Rechnungen auseinanderliegen zeigt der Abschnitt zur Robustheit.

3.2 Kovarianzschätzer

Verglichen werden drei Schätzer der bedingten Kovarianzmatrix, die eine aufsteigende Leiter an Dynamik abbilden. Den Ausgangspunkt bildet der statische historische Schätzer, der zunächst um eine zeitvariable Varianz im GARCH-Modell und anschließend um eine dynamische Korrelation im DCC-GARCH-Modell erweitert wird. Da jeder Schritt genau eine Annahme aufhebt, lässt sich der Beitrag der jeweiligen Komponente isoliert bewerten.

Historische Kovarianzmatrix Verwendet wird zunächst die Stichprobenkovarianz der Trainingsrenditen, in der die Annahme konstanter Varianzen und Korrelationen über das gesamte Fenster unverändert erhalten bleibt.

Der Vorteil dieses Schätzers liegt in seiner Einfachheit, da er keine Parameterschätzung im engeren Sinn benötigt und deshalb weder von Konvergenzproblemen noch von einer Fehlspezifikation der Dynamik betroffen sein kann. Dem steht seine Trägheit gegenüber, weil ein Volatilitätsschock mit dem Gewicht $1/(T - 1)$ in die Schätzung eingeht und erst nach T Handelstagen wieder aus

ihr verschwindet. Aus diesen Gründen dient die historische Matrix in dieser Arbeit als statischer Referenzpunkt, gegen den der Mehrwert der beiden dynamischen Modelle gemessen wird.

Generalized Autoregressive Conditional Heteroskedasticity (GARCH) Das GARCH-Modell wurde im Jahr 1986 von Bollerslev vorgestellt und verallgemeinert das ARCH-Modell, mit dem Engle (1982) die zeitvariable Varianz von Finanzzeitreihen erstmals ökonometrisch erfasst hatte. Beide Modelle greifen die Beobachtung auf, dass große Kursausschläge gehäuft auftreten und weitere große Ausschläge nach sich ziehen, was der historische Schätzer per Konstruktion ignoriert. Der Grundgedanke besteht darin, die Varianz nicht als Konstante, sondern als bedingte Größe zu behandeln, die aus der Information bis zur Vorperiode fortgeschrieben wird.

Ein GARCH(1,1) beschreibt die Rendite als Summe aus einem konstanten Mittelwert und einem Störterm, dessen Varianz einer eigenen Rekursion folgt.

$$r_t = \mu + \varepsilon_t \quad (1)$$

$$\varepsilon_t = \sqrt{h_t} z_t, \quad z_t \sim \mathcal{N}(0, 1) \quad (2)$$

$$h_t = \omega + \alpha \varepsilon_{t-1}^2 + \beta h_{t-1} \quad (3)$$

Die bedingte Varianz h_t setzt sich damit aus drei Bestandteilen zusammen (Gleichung 3). Das langfristige Varianzniveau verankert die Konstante ω , während α steuert, wie stark ein neuer Schock die Varianz bewegt, und β misst, wie lange dieser Einfluss anhält. Damit die unbedingte Varianz existiert und der Prozess stationär bleibt, müssen $\omega > 0$, $\alpha, \beta \geq 0$ sowie $\alpha + \beta < 1$ gelten (Bollerslev, 1986).

Da die Portfoliogewichte nicht für den Folgetag, sondern für die kommenden h Handelstage gelten, wird die Rekursion über den Horizont fortgeschrieben und anschließend gemittelt. Weil der erwartete quadrierte Schock der bedingten Varianz entspricht, vereinfacht sich die Fortschreibung ab dem zweiten Schritt zu einer Konvergenz gegen die unbedingte Varianz.

$$E_t[h_{t+k}] = \omega + (\alpha + \beta) E_t[h_{t+k-1}], \quad k \geq 2 \quad (4)$$

$$\bar{h}_{t,h} = \frac{1}{h} \sum_{k=1}^h E_t[h_{t+k}] \quad (5)$$

Die horizontgemittelte Varianzprognose $\bar{h}_{t,h}$ aus Gleichung 5 geht als Diagonalelement in die Kovarianzmatrix ein.

Für ein Portfolio genügt die Modellierung der einzelnen Varianzen allerdings nicht, da für die

Gewichte die vollständige Kovarianzmatrix benötigt wird. Die Umsetzung folgt deshalb dem Constant-Conditional-Correlation-Ansatz (CCC) von Bollerslev (1990), bei dem für jeden Sektor ein eigenes GARCH(1,1) geschätzt, die Korrelationsmatrix dagegen konstant gehalten wird:

$$\Sigma_t = D_t R D_t, \quad D_t = \text{diag} \left(\sqrt{\bar{h}_1}, \dots, \sqrt{\bar{h}_N} \right) \quad (6)$$

Die Diagonalmatrix D_t enthält die prognostizierten Standardabweichungen der N Sektoren, während R als Stichprobenkorrelation der standardisierten Residuen z_t aus Gleichung 2 geschätzt wird. Diese werden statt der Rohrenditen verwendet, da in ihnen die Volatilitätscluster bereits herausgefiltert sind und Tage hoher Volatilität die Korrelationsschätzung sonst verzerren würden. Gegenüber der historischen Matrix ändert sich damit ausschließlich die Behandlung der Varianzen, wodurch der Vergleich beider Schätzer den Beitrag der dynamischen Volatilität isoliert.

Dynamic Conditional Correlation (DCC-GARCH) Da das GARCH-Modell weiterhin von einer konstanten Korrelation ausgeht, die in der Realität nur selten vorliegt, entwickelte Engle (2002) mit dem DCC-GARCH-Modell eine Erweiterung, die auch diese Restriktion aufhebt. Engle überträgt dafür die Rekursion aus Gleichung 3 auf die Korrelation selbst und erhält so eine vollständig zeitvariable Kovarianzprognose.

Modelliert wird dabei zunächst eine Hilfsmatrix Q_t , die anschließend zu einer gültigen Korrelationsmatrix normiert wird.

$$Q_t = (1 - a - b) \bar{Q} + a z_{t-1} z'_{t-1} + b Q_{t-1} \quad (7)$$

$$R_t = \text{diag}(Q_t)^{-1/2} Q_t \text{diag}(Q_t)^{-1/2} \quad (8)$$

$$\Sigma_t = D_t R_t D_t \quad (9)$$

Der Aufbau von Gleichung 7 entspricht dem der GARCH-Rekursion, wobei $\bar{Q}$ die Rolle des langfristigen Niveaus übernimmt und auf die Stichprobenkorrelation der standardisierten Residuen gesetzt wird. Wie stark die Korrelationen auf neue gemeinsame Schocks reagieren, misst der Parameter a , während b deren Persistenz angibt. Analog zum univariaten Fall müssen dafür $a, b \geq 0$ und $a + b < 1$ gelten. Da Q_t auf der Diagonale keine Einsen aufweisen muss, ist die Normierung in Gleichung 8 nötig, um eine Korrelationsmatrix zu erhalten. Aus dieser und den prognostizierten Standardabweichungen ergibt sich die Kovarianzmatrix schließlich nach Gleichung 9.

Geschätzt wird das Modell in zwei Schritten, indem zuerst die univariaten GARCH-Modelle und anschließend die beiden Parameter a und b per Maximum-Likelihood auf den standardisierten Residuen bestimmt werden. Für $h > 1$ wird die Korrelationsprognose gemäß Engle und Sheppard (2001) auf $\bar{Q}$ zurückgeführt und über den Horizont gemittelt, damit sie zur ebenfalls

horizontgemittelten Varianzprognose passt.

Da GARCH- und DCC-Schätzer dieselben Varianzprognosen und dieselben standardisierten Residuen verwenden, isoliert ihr Vergleich exakt den Beitrag der dynamischen Korrelation. Die drei Schätzer bilden somit eine Leiter, auf der jeder Schritt genau eine Annahme aufhebt.

3.3 Portfoliomodelle

Allen vier Allokationsverfahren ist gemeinsam, dass in ihre Gewichte ausschließlich die zweiten Momente eingehen und keine Renditeprognose benötigt wird. Damit entfällt die Fehlerquelle, die nach Broadie (1993) die Lage der effizienten Grenze am stärksten verzerrt. Berücksichtigt werden Verfahren mit unterschiedlichen Zielen, die die geschätzte Kovarianzmatrix verschieden intensiv nutzen und deshalb auch verschieden empfindlich auf deren Fehler reagieren.

Minimum-Varianz-Portfolio (MVP) Das Minimum-Varianz-Portfolio bildet nach dem Ansatz von Markowitz (1952) das Portfolio, das ohne Berücksichtigung der erwarteten Renditen die geringste Volatilität aufweist. Daraus ergibt sich die folgende Zielfunktion:

$$\min_w w' \Sigma w \quad \text{unter} \quad \mathbf{1}' w = 1, \quad w \geq 0 \quad (10)$$

Der Vektor w enthält die Portfoliogewichte und Σ die prognostizierte Kovarianzmatrix, während die Budgetrestriktion $\mathbf{1}' w = 1$ die Vollinvestition sicherstellt. Zusätzlich wird mit $w \geq 0$ ein Leerverkaufsverbot gesetzt. Nach Behr et al. (2008) überzeugt das MVP besonders in volatilen Marktphasen.

Zugleich ist es das anfälligste Verfahren, da die Minimierung gezielt die Richtungen kleinster geschätzter Varianz aufsucht, in denen die Schätzfehler relativ am größten sind. Fehler werden dadurch nicht ausgemittelt, sondern verstärkt, weshalb Lee (2011) auf die typischerweise stark konzentrierten MVP-Lösungen hinweist.

Equal Risk Contribution (ERC) Das Equal-Risk-Contribution-Portfolio verfolgt nach Maillard et al. (2010) das Ziel, das Gesamtrisiko nicht zu minimieren, sondern gleichmäßig auf die Anlagen zu verteilen. Grundlage ist die Zerlegung der Portfoliovolatilität in die Beiträge der einzelnen Anlagen, die sich aufgrund der Homogenität der Volatilität zur Gesamtvolatilität aufsummieren.

$$RC_i = \frac{w_i (\Sigma w)_i}{\sqrt{w' \Sigma w}} \quad (11)$$

$$RC_i = RC_j \quad \text{für alle } i, j \quad (12)$$

Der Risikobeitrag RC_i aus Gleichung 11 ist das Produkt aus dem Gewicht der Anlage und ihrem Grenzkrisikobeitrag, wobei die Gewichte so bestimmt werden, dass alle Beiträge übereinstimmen (Gleichung 12). Anders als das MVP nutzt ERC die Kovarianzmatrix somit nur über das Produkt Σw und nicht über ihre Inverse, weshalb Schätzfehler weniger stark durchschlagen und ein robusteres Portfolio entsteht.

Das Ergebnis liegt konstruktionsbedingt zwischen dem MVP und dem gleichgewichteten Portfolio und ist in der Regel deutlich besser diversifiziert. Dennoch schlägt ERC das naive Portfolio nach Chaves et al. (2011) nicht durchgängig.

Hierarchical Risk Parity (HRP) Hierarchical Risk Parity wurde von López de Prado (2016) mit dem Ziel entwickelt, die Matrixinversion des MVP durch eine hierarchische Struktur zu ersetzen und das Verfahren dadurch robuster gegenüber schlecht konditionierten Kovarianzmatrizen zu machen. Der Algorithmus läuft in drei Schritten ab, von denen der erste die Korrelationen in eine Distanz überführt.

$$d_{ij} = \sqrt{0,5 (1 - \rho_{ij})} \quad (13)$$

Zwei Sektoren stehen sich nach Gleichung 13 umso näher, je höher ihre Korrelation ρ_{ij} ausfällt. Auf Basis dieser Distanz werden die Sektoren im zweiten Schritt zu einem Binärbaum geclustert und die Kovarianzmatrix quasi-diagonal geordnet, sodass ähnliche Anlagen nebeneinander stehen. Im dritten Schritt wird das Kapital durch rekursive Bisektion verteilt, wobei die geordnete Liste wiederholt halbiert und das Gewicht zwischen beiden Hälften invers zu deren Varianz aufgeteilt wird.

Entscheidend ist, dass HRP die Kovarianzmatrix nie invertiert und von ihr nur die Ordnungsinformation sowie die Varianzen der Teilcluster nutzt. Das Verfahren ist dadurch unempfindlich gegenüber genau der Fehlerquelle, die dem MVP zu schaffen macht, verwertet aber auch eine bessere Schätzung nur eingeschränkt. López de Prado (2016) und Sen et al. (2022) berichten entsprechend stabilere Gewichte und eine konkurrenzfähige risikoadjustierte Rendite.

Benchmark Als Vergleichsmaßstab dient das gleichgewichtete 1/N-Portfolio, das jeder im Fenster verfügbaren Anlage denselben Anteil zuweist. Es benötigt keine Schätzung der zweiten Momente und ist damit als einziges der vier Verfahren immun gegen Schätzfehler.

Das naive Portfolio bildet den relevanten Maßstab für die erste Forschungsfrage, da ein Optimierungsverfahren seinen Aufwand nur rechtfertigt, wenn dessen Gewinn den Verlust durch Schätzfehler übersteigt. Wie hoch dieser Maßstab liegt, zeigt der Vergleich von DeMiguel et al. (2009), in dem keine der optimierten Strategien das gleichgewichtete Portfolio verlässlich schlagen konnte.

3.4 Bewertungskriterien

Die Bewertung trennt zwischen der Prognosequalität der Kovarianzmatrix und der ökonomischen Performance der daraus abgeleiteten Portfolios.

Statistische Verlustmaße Die Prognosequalität wird über zwei Verlustmaße gemessen, den multivariaten Quasi-Likelihood-Verlust (QLIKE) und den Mean Squared Error (MSE) der Kovarianzeinträge. Da die wahre bedingte Kovarianzmatrix der Testperiode nicht beobachtbar ist, wird die Prognose bei beiden gegen denselben realisierten Proxy gemessen.

$$S = \frac{1}{h} \sum_{t=1}^h r_t r_t' \quad (14)$$

$$\text{QLIKE}(\Sigma, S) = \ln |\Sigma| + \text{tr}(\Sigma^{-1} S) \quad (15)$$

$$\text{MSE}(\Sigma, S) = \frac{1}{N^2} \sum_{i,j} (\Sigma_{ij} - S_{ij})^2 \quad (16)$$

Dabei ist Σ die prognostizierte und S die realisierte Kovarianzmatrix, r_t der Vektor der logarithmierten Tagesrenditen und N die Zahl der Anlagen im jeweiligen Fenster. Beide Verluste werden je Rebalancierungsfenster berechnet und anschließend über die Fenster gemittelt, wobei niedrigere Werte eine bessere Prognose bedeuten.

Die beiden Maße unterscheiden sich darin, wie sie Fehler in beide Richtungen gewichten. Der QLIKE-Verlust aus Gleichung 15 bestraft eine Unterschätzung des Risikos stärker als eine Überschätzung, da der Term $\text{tr}(\Sigma^{-1} S)$ stark ansteigt, sobald die Matrix zu klein prognostiziert wurde. Damit ist er ökonomisch besser motiviert als ein symmetrisches Maß. Der MSE aus Gleichung 16 misst dagegen den quadratischen Abstand über alle Matrixeinträge und gewichtet Über- wie Unterschätzung gleich.

Die Wahl gerade dieser beiden Maße folgt aus den Eigenschaften des Proxys, der zwar erwartungstreu, aber verrauscht ist. Für $h = 1$ besteht er aus einem einzigen äußeren Produkt, wodurch insbesondere in diesem Fall das Rauschen des Schätzers zu beachten ist. QLIKE und MSE gehören beide zu den gegenüber einem solchen Proxy robusten Verlusten, für die die erwartete Rangfolge zweier Prognosen dieselbe ist, unabhängig davon, ob gegen den verrauschten Proxy oder gegen die unbeobachtbare Wahrheit gemessen wird. Patton (2011) entwickelt dieses Konzept für den univariaten Fall der Varianzprognose, während Laurent et al. (2012) es auf vollständige Kovarianzmatrizen übertragen. Folglich ist der absolute Wert der Metriken zwar nur eingeschränkt interpretierbar, jedoch ist die Rangfolge robust, weshalb Qualitätsunterschiede zwischen den Schätzern erkannt werden können.

Bei der Interpretation der Niveaus sind zwei Eigenschaften zu beachten. Der QLIKE-Verlust ist

nicht dimensionsnormiert, da der Term $\ln |\Sigma|$ über alle Eigenwerte summiert und sein Niveau somit mit der Zahl der Anlagen N skaliert. Weit weniger betroffen ist der MSE, der über die Matrixeinträge mittelt, dafür aber dem Volatilitätsniveau der Bewertungsperiode und dem Horizont h des Proxys folgt. In beiden Fällen ist daher nur die Differenz zwischen den Schätzern innerhalb einer Spezifikation aussagekräftig, nicht das Niveau zwischen Spezifikationen.

Ökonomische Kennzahlen Berichtet werden die annualisierte Rendite, die realisierte Volatilität, die Sharpe Ratio und der Turnover. Alle vier Kennzahlen beruhen auf der Tagesrendite des Portfolios $r_{p,t}$, die sich als mit den Portfoliogewichten gewichtete Summe der Sektorrenditen ergibt.

$$R_{\text{ann}} = \left(\prod_{t=1}^n (1 + r_{p,t}) \right)^{\frac{252}{n}} - 1 \quad (17)$$

$$\sigma_{\text{ann}} = \sqrt{252} \text{ sd}(r_{p,t}) \quad (18)$$

$$\text{SR} = \frac{252 \overline{(r_{p,t} - r_{f,t})}}{\sqrt{252} \text{ sd}(r_{p,t} - r_{f,t})} \quad (19)$$

Die annualisierte Rendite aus Gleichung 17 ist die geometrische Wachstumsrate über die n Handelstage des Bewertungszeitraums, während die realisierte Volatilität als annualisierte Standardabweichung derselben Reihe berechnet wird. Bei der Sharpe Ratio beruhen Zähler und Nenner auf derselben Überschussrenditereihe, damit die Annualisierung beider Größen konsistent bleibt.

Der Turnover misst, wie viel Handel ein Verfahren je Rebalancierung auslöst.

$$\text{TO}_k = \sum_{i=1}^N \left| w_{i,k}^{\text{Ziel}} - w_{i,k-1}^{\text{Ende}} \right| \quad (20)$$

Dabei sind $w_{i,k}^{\text{Ziel}}$ die neuen Zielgewichte der Rebalancierung k und $w_{i,k-1}^{\text{Ende}}$ die über die vorangegangene Halteperiode gedrifteten Endgewichte. Der Turnover entspricht folglich dem je Rebalancierung umgeschlagenen Anteil des Portfoliovolumens und bestimmt somit direkt die Transaktionskosten. In dieser Studie werden die Transaktionskosten beim Rebalancing zwar nicht beachtet, jedoch würde ein deutlich höherer Turnover die Rendite und somit auch die Sharpe Ratio stark negativ beeinflussen.

Signifikanztests Signifikanzaussagen beruhen auf zwei Tests. Unterschiede in der Prognosegüte werden mit dem Test von Diebold und Mariano (1995) in der Erweiterung von West (1996) auf die Verlustdifferenzen geprüft.

4 Ergebnisse

Zunächst wird geprüft, ob die GARCH-basierten Schätzer die Kovarianzmatrix besser prognostizieren, bevor untersucht wird, ob sich ein solcher Vorteil auch in der Portfolioperformance niederschlägt. Anschließend wird die Stabilität beider Befunde über Trainingsfenster, Prognosehorizonte und Teilperioden betrachtet.

4.1 Statistische Prognosequalität

Im Basisfall ordnet sich die Prognosegüte unter beiden Verlustmaßen nach der Modellkomplexität, wie Tabelle 2 zeigt. Die historische Matrix schneidet am schlechtesten ab, während der GARCH-Schätzer sie deutlich verbessert und DCC-GARCH nochmals einen kleinen Zusatzgewinn liefert. QLIKE und MSE stimmen in dieser Reihenfolge überein.

Kovarianzschätzer	QLIKE	MSE ($\times 10^{-7}$)
Historisch	-152,81	4,28
GARCH	-155,94	3,52
DCC-GARCH	-156,68	3,44

Tabelle 2: Prognosequalität der Kovarianzschätzer im Basisfall

TRBC, Training 1008 Handelstage, Prognosehorizont 1 Tag; niedrigere Werte bedeuten eine bessere Prognose.

Wie scharf die beiden Verlustmaße trennen, unterscheidet sich allerdings erheblich. Der DMW-Test in Tabelle 3 verwirft die Nullhypothese gleicher erwarteter Verluste unter QLIKE in allen drei paarweisen Vergleichen auf dem 1-%-Niveau, wobei dies auch beim Vergleich DCC-GARCH und GARCH trotz einer insgesamt geringen Differenz der Fall ist. Unter dem MSE sind die Abstände zur historischen Matrix hingegen nur auf dem 5-%-Niveau signifikant, während der Unterschied zwischen DCC und GARCH nicht mehr von null zu trennen ist. Belastbar ist somit, dass beide dynamischen Schätzer die historische Matrix unter beiden Maßen schlagen, während sich der Zusatznutzen der dynamischen Korrelation nur unter QLIKE nachweisen lässt.

Vergleich	Δ Verlust	t -Statistik	p -Wert	Termine
<i>QLIKE</i>				
GARCH vs. Historisch	-2,563	-4,18	<0,001***	6013
DCC-GARCH vs. Historisch	-3,308	-5,28	<0,001***	6013
DCC-GARCH vs. GARCH	-0,744	-13,86	<0,001***	6079
<i>MSE ($\times 10^{-7}$)</i>				
GARCH vs. Historisch	-0,764	-2,23	0,026**	6079
DCC-GARCH vs. Historisch	-0,846	-2,11	0,035**	6079
DCC-GARCH vs. GARCH	-0,082	-1,26	0,207	6079

Tabelle 3: Diebold-Mariano-West-Tests auf die Verlustdifferenzen (Basisfall)

Negative Differenzen bedeuten, dass der erstgenannte Schätzer besser prognostiziert; ***, **, * = 1-, 5-, 10-%-Niveau.

Über das gesamte Untersuchungsdesign hinweg ist der statistische Vorsprung nahezu vollständig, da DCC-GARCH unter dem MSE in sämtlichen 40 Kombinationen besser prognostiziert als die

historische Matrix und unter QLIKE in nahezu allen. Wie stark der Vorsprung ausfällt, hängt jedoch von der Spezifikation ab, wie Tabelle 4 zeigt. Mit der Länge des Trainingsfensters nimmt er monoton zu, wobei DCC bei einjährigem Training unter QLIKE keinen Vorteil mehr liefert. Die rund 250 Beobachtungen reichen dort nicht aus, um die DCC-Parameter zusätzlich zu den univariaten GARCH-Parametern verlässlich zu schätzen. Über den Prognosehorizont fällt der Vorsprung dagegen ab, da die Korrelationsprognose mit wachsendem Horizont gegen ihren unbedingten Mittelwert konvergiert. Der MSE zeigt dasselbe Muster, ordnet DCC aber auch im kürzesten Fenster vorne ein.

Spezifikation	QLIKE			MSE ($\times 10^{-7}$)		
	Historisch	Δ GARCH	Δ DCC	Historisch	GARCH	DCC-GARCH
252	-176,1	0,25	0,04	2,99	2,48	2,47
504	-171,0	-0,37	-0,81	3,42	2,81	2,74
756	-165,2	-0,95	-1,58	3,41	2,84	2,75
1008	-159,7	-1,36	-2,15	3,43	2,87	2,77
1260	-154,3	-1,84	-2,76	3,42	2,83	2,75
1512	-150,1	-1,74	-2,78	3,18	2,60	2,52
1764	-146,0	-1,71	-2,81	3,11	2,53	2,45
2016	-142,0	-1,80	-2,94	3,09	2,52	2,45
2268	-140,6	-1,85	-3,05	3,05	2,46	2,41
2520	-140,0	-2,02	-3,32	3,02	2,45	2,40
$h = 1$	-159,7	-1,36	-2,15	3,43	2,87	2,77
$h = 5$	-159,5	-1,37	-2,04	1,68	1,23	1,17
$h = 10$	-159,3	-1,53	-2,14	1,32	0,95	0,90
$h = 21$	-158,9	-1,25	-1,73	0,82	0,49	0,46

Tabelle 4: Prognosequalität über Trainingsfenster und Prognosehorizonte (TRBC)

Oberer Block: Trainingsfenster in Handelstagen ($h = 1$), unterer Block: Prognosehorizonte, bewertet ab 01.01.2010; Δ ist die Differenz zur historischen Matrix.

Die Niveaus beider Verluste sind zwischen den Zeilen dieser Tabelle nicht vergleichbar, obwohl alle Zeilen denselben Zeitraum abdecken. Beim QLIKE liegt das an der Dimension der Kovarianzmatrix, beim MSE im unteren Block dagegen am Horizont, über den der Proxy mittelt. Für die zweite Forschungsfrage fällt die statistische Antwort dennoch eindeutig aus, da GARCH- und DCC-GARCH-Modelle die Prognose der Kovarianzmatrix gegenüber der historischen Schätzung signifikant und unter dem MSE ausnahmslos verbessern.

4.2 Ökonomische Performance

Die ökonomische Auswertung führt zu einem differenzierteren Bild. Für die erste Forschungsfrage zeigt Tabelle 5 zunächst, dass alle neun risikobasierten Kombinationen im Basisfall eine höhere Sharpe Ratio erreichen als das naive 1/N-Portfolio. Vorne liegt dabei das MVP, gefolgt von HRP und ERC. Der Vorsprung entsteht vollständig über die Risikoseite, da das 1/N-Portfolio zwar die höchste Rendite im Feld erzielt, diese aber mit der mit Abstand höchsten Volatilität erkaufte.

Innerhalb der Portfoliomodelle kehrt sich die statistische Rangfolge im Basisfall weitgehend um,

Modell	Kovarianz	Rendite (%)	Vola (%)	Sharpe ($r_f = 0$)	Sharpe	Turnover
MVP	Historisch	9,03	13,82	0,695	0,567	0,008
MVP	GARCH	8,55	13,94	0,658	0,532	0,258
MVP	DCC-GARCH	8,65	13,81	0,671	0,543	0,255
HRP	Historisch	9,27	16,74	0,614	0,509	0,012
HRP	GARCH	8,96	16,21	0,611	0,502	0,072
HRP	DCC-GARCH	9,13	16,17	0,622	0,513	0,094
ERC	Historisch	9,46	17,67	0,601	0,501	0,006
ERC	GARCH	9,14	17,32	0,592	0,490	0,034
ERC	DCC-GARCH	9,13	17,31	0,591	0,490	0,034
1/N	–	9,58	18,79	0,581	0,488	0,006

Tabelle 5: Out-of-Sample-Performance im Basisfall

TRBC, Training 1008 Handelstage, Prognosehorizont 1 Tag; Rendite, Volatilität und Sharpe Ratio annualisiert, Turnover ohne Kosten.

da bei MVP und ERC die historische Matrix vorne liegt und allein beim HRP der DCC-Schätzer marginal besser abschneidet. Hierbei ist jedoch zu beachten, dass beispielsweise beim MVP der DCC-Schätzer die niedrigste Volatilität und somit eigentlich die beste modelspezifische Performance liefert. Dieser Vorsprung ist jedoch so klein, dass ihn die etwas höhere Rendite der historischen Variante überkompensiert. Gleichzeitig fällt der mittlere Turnover des MVP mit der DCC-Kovarianz rund 32-mal so hoch aus wie mit der historischen, wodurch bei einer realen Umsetzung der DCC-GARCH-Schätzer nochmal schlechter abschneiden würde. Grund für den hohen Turnover ist, dass die beiden dynamischen Modelle deutlich schneller auf Änderungen in der Volatilität reagieren, wodurch auch die Gewichtsverteilung der Portfolios angepasst wird, während die träge Stichprobenkovarianz die Gewichte nahezu unverändert lässt. Bei HRP und ERC fällt der Anstieg mit dem Faktor acht beziehungsweise sechs erheblich geringer aus.

Statistisch abgesichert sind die Unterschiede in der Sharpe Ratio allerdings nicht, da Tabelle 6 für keinen der relevanten Vergleiche einen auch nur annähernd signifikanten p -Wert ausweist. Dies gilt sowohl zwischen den Kovarianzschätzern als auch gegenüber dem 1/N-Portfolio. Das ist weniger ein Argument gegen die Modelle als eines gegen die Sharpe Ratio als Auswahlkriterium, da sie von den realisierten Renditen dominiert wird, auf die die Kovarianzmatrix nur mittelbar wirkt. Genau diesen Einwand formulieren Engle und Colacito (2006).

Vergleich	Sharpe A	Sharpe B	Differenz	z-Statistik	p-Wert
MVP Historical vs. MVP DCC	0,567	0,543	0,0243	0,37	0,709
HRP Historical vs. HRP DCC	0,509	0,513	-0,0041	-0,18	0,859
ERC Historical vs. ERC DCC	0,501	0,490	0,0111	0,98	0,329
MVP GARCH vs. MVP DCC	0,532	0,543	-0,0109	-0,78	0,435
MVP Historical vs. Naive	0,567	0,488	0,0797	0,69	0,487
HRP Historical vs. Naive	0,509	0,488	0,0210	0,66	0,509
ERC Historical vs. Naive	0,501	0,488	0,0132	0,85	0,395

Tabelle 6: Tests auf Unterschiede der Sharpe Ratios (Basisfall)

Auf Überschussrenditen über die Fed Funds Rate; ***, **, * = 1-, 5-, 10%-Niveau.

Tabelle 7 fasst die Ergebnisse über alle 40 Kombinationen aus Trainingsfenster und Prognosehorizont zusammen, wobei je Portfoliomodell angegeben wird, wie oft das 1/N-Portfolio geschlagen wird und wie oft die dynamischen Schätzer die historische Matrix übertreffen. Da neben der Sharpe Ratio auch QLIKE und MSE angegeben werden, lassen sich der statistische und der ökonomische Vergleich direkt gegenüberstellen, wobei der Befund je nach Portfoliomodell unterschiedlich ausfällt. Zur ersten Forschungsfrage zeigt sich, dass HRP und ERC mit historischer Kovarianz das 1/N-Portfolio in allen 40 Konstellationen schlagen, das MVP dagegen nur in der Hälfte der Fälle. Ausschlaggebend ist die bereits angelegte Anfälligkeit des MVP, dessen Varianzminimierung Schätzfehler in den kleinsten Eigenwerten der Kovarianzmatrix maximal ausnutzt und zu konzentrierten Portfolios führt. Die im Basisfall beste Sharpe Ratio des MVP ist insofern nicht repräsentativ.

Zur zweiten Forschungsfrage zeigt sich ein klares Muster entlang der Portfoliomodelle, da die dynamischen Schätzer die historische Matrix beim MVP in gut der Hälfte der Läufe schlagen, beim HRP nur vereinzelt und beim ERC in keinem einzigen. Ökonomisch ist das gut erklärbar, weil das MVP als einziges Verfahren die Kovarianzmatrix vollständig einschließlich ihrer Inversen ausnutzt, während HRP lediglich die Clusterordnung und die Varianzen der Teilcluster verwendet und ERC die Risikobeiträge ausbalanciert. Eine bessere Kovarianzprognose zahlt sich folglich dort aus, wo sie am intensivsten genutzt wird, und bleibt folgenlos, wo das Verfahren die Matrix nur grob verwendet. Dem steht ein statistischer Vorsprung gegenüber, der unter dem MSE in allen 40 Läufen auftritt.

Modell	Kovarianz	vs. 1/N	vs. historische Matrix		
		Sharpe	Sharpe	QLIKE	MSE
MVP	Historisch	20/40	–	–	–
MVP	GARCH	19/40	22/40	36/40	40/40
MVP	DCC-GARCH	20/40	25/40	37/40	40/40
HRP	Historisch	40/40	–	–	–
HRP	GARCH	32/40	3/40	36/40	40/40
HRP	DCC-GARCH	31/40	3/40	37/40	40/40
ERC	Historisch	40/40	–	–	–
ERC	GARCH	31/40	0/40	36/40	40/40
ERC	DCC-GARCH	32/40	0/40	37/40	40/40

Tabelle 7: Ergebnisse über alle empirischen Läufe

Alle 40 Kombinationen aus Trainingsfenster und Prognosehorizont, bewertet ab 01.01.2010.

Auch über die Trainingsfenster hinweg bleibt dieses Muster erhalten (siehe Tab. 8). Beim MVP liegt DCC in neun von zehn Fenstern über der historischen Matrix, bei HRP in einem und bei ERC in keinem. Die absoluten Unterschiede fallen dabei klein aus, weshalb angesichts der insignifikanten Tests auf Sharpe-Differenzen keine belastbare Rangfolge abgeleitet werden sollte.

Deutlicher ist der Befund über den Prognosehorizont in Tabelle 9. Wird seltener rebalanciert, bleibt die Sharpe Ratio der historischen Matrix beim MVP praktisch konstant, während sie für DCC deutlich fällt und der Turnover je Rebalancierung gleichzeitig auf mehr als das Doppelte

Training	MVP			HRP			ERC			1/N
	Hist.	GARCH	DCC	Hist.	GARCH	DCC	Hist.	GARCH	DCC	
252	0,628	0,612	0,625	0,695	0,677	0,665	0,685	0,676	0,674	0,676
504	0,605	0,735	0,741	0,696	0,700	0,690	0,688	0,682	0,681	0,685
756	0,633	0,668	0,672	0,695	0,683	0,685	0,689	0,678	0,678	0,676
1008	0,714	0,706	0,728	0,684	0,686	0,706	0,692	0,680	0,682	0,677
1260	0,721	0,699	0,729	0,686	0,669	0,672	0,675	0,663	0,665	0,656
1512	0,681	0,669	0,696	0,685	0,667	0,669	0,675	0,663	0,665	0,660
1764	0,642	0,670	0,686	0,656	0,641	0,649	0,642	0,634	0,636	0,621
2016	0,631	0,652	0,655	0,657	0,649	0,647	0,650	0,644	0,645	0,628
2268	0,657	0,689	0,683	0,671	0,653	0,656	0,661	0,654	0,655	0,635
2520	0,627	0,690	0,689	0,679	0,663	0,660	0,669	0,661	0,662	0,647

Tabelle 8: Sharpe Ratios über die Trainingsfenster (TRBC, $h = 1$)

Annualisierte Sharpe Ratio ($r_f = 0$), bewertet ab 01.01.2010.

steigt. Über längere Horizonte beruhen die Umschichtungen der dynamischen Modelle somit auf zunehmend veralteten Prognosen, wodurch sich ihr Vorteil auch ohne Kosten in einen Nachteil umkehrt. Da der Bewertungszeitraum über alle Zeilen identisch ist und allein die Rebalancierungsfrequenz variiert, ist dieser Vergleich frei von den Stichprobenproblemen, die der folgende Abschnitt behandelt.

h (Tage)	MVP		HRP		ERC		1/N	Turnover MVP	
	Hist.	DCC	Hist.	DCC	Hist.	DCC		Hist.	DCC
1	0,714	0,728	0,684	0,706	0,692	0,682	0,677	0,008	0,255
5	0,705	0,762	0,681	0,690	0,694	0,684	0,680	0,021	0,522
10	0,717	0,654	0,692	0,670	0,698	0,680	0,684	0,033	0,598
21	0,721	0,640	0,697	0,689	0,700	0,689	0,685	0,058	0,587

Tabelle 9: Sharpe Ratios und Turnover über die Prognosehorizonte (TRBC, Training 1008 Tage)

Annualisierte Sharpe Ratio ($r_f = 0$), bewertet ab 01.01.2010; Turnover je Rebalancierung, also nicht auf gleiche Frequenz normiert.

4.3 Robustheit über Zeiträume und Anlageuniversen

Sämtliche bisher berichteten Vergleiche über Trainingsfenster hinweg wurden bereits auf dem gemeinsamen Zeitraum ab 2010 gerechnet. Dieser Abschnitt begründet, warum diese Einschränkung nötig ist, und zeigt, was ohne sie gemessen würde.

Ohne die Einschränkung bewertet jedes Trainingsfenster einen anderen Zeitraum, da der Out-of-Sample-Beginn von März 2000 beim kürzesten auf November 2008 beim längsten Fenster wandert. Der Lauf mit einem Jahr Training enthält damit das Platzen der Dotcom-Blase, während der Lauf mit zehn Jahren Training erst nach der Finanzkrise beginnt und nur die Erholung abdeckt, wodurch dessen Kennzahlen angehoben werden, ohne dass dies etwas über die Schätzqualität aussagt. Am deutlichsten zeigt Tabelle 10 diesen Effekt, da das 1/N-Portfolio über die volle Historie beim längsten Fenster eine merklich höhere Sharpe Ratio erreicht als bei allen anderen Fenstern. Weil

es überhaupt keine Schätzung vornimmt und die Fensterlänge für seine Konstruktion nahezu bedeutungslos ist, handelt es sich um einen reinen Stichprobeneffekt. Auf dem gemeinsamen Zeitraum verschwindet dieser Sprung, wodurch sich die Spannweite der MVP-Sharpe-Ratio nahezu halbiert.

Training	$\varnothing N$	QLIKE DCC		Sharpe MVP Hist.		Sharpe 1/N	
		voll	gem.	voll	gem.	voll	gem.
252	20,3	-162,0	-176,1	0,568	0,628	0,505	0,676
504	19,7	-161,0	-172,1	0,539	0,605	0,502	0,685
756	19,1	-158,9	-167,3	0,558	0,633	0,514	0,676
1008	18,5	-156,7	-162,6	0,695	0,714	0,581	0,677
1260	17,9	-153,6	-157,7	0,624	0,721	0,507	0,656
1512	17,4	-150,2	-152,9	0,571	0,681	0,501	0,660
1764	16,9	-147,0	-148,8	0,522	0,642	0,462	0,621
2016	16,4	-143,7	-144,9	0,469	0,631	0,458	0,628
2268	16,2	-142,3	-143,7	0,468	0,657	0,466	0,635
2520	16,2	-142,7	-143,3	0,654	0,627	0,677	0,647

Tabelle 10: Voller versus gemeinsamer Bewertungszeitraum (TRBC, $h = 1$)

voll bezeichnet die volle Historie des jeweiligen Fensters, *gem.* den gemeinsamen Zeitraum ab 01.01.2010.

Ein zweiter Effekt bleibt jedoch auch nach Angleichung des Zeitraums bestehen, da die 90-%-Verfügbarkeitsregel die 2019 hinzugekommenen Sektoren in langen Fenstern erst spät oder gar nicht zulässt und die Fensterlänge somit über die Dimension der Kovarianzmatrix auch das QLIKE-Niveau mitbestimmt. Die Korrelation zwischen mittlerer Universumsgröße und QLIKE-Niveau beträgt $-0,9999$, wodurch das Niveau der Kennzahl praktisch vollständig durch die Dimension und nicht durch die Prognosequalität determiniert ist. Den direkten Beleg liefert erneut das 1/N-Portfolio, das im identischen Bewertungszeitraum je nach Trainingsfenster unterschiedlich abschneidet. Da sich an seiner Konstruktion nichts ändert, kann dieser Unterschied nur aus dem unterschiedlichen Anlageuniversum stammen.

Zeitlich lokalisieren lässt sich der Bruch über die Teilperioden des Basisfalls in Tabelle 11. Das QLIKE-Niveau springt ab 2022 deutlich nach unten, wobei dieser Sprung exakt mit der Erweiterung des Universums von 17 auf 25 Sektoren im September 2022 zusammenfällt. Der MSE zeigt an dieser Stelle keinen vergleichbaren Bruch, folgt dafür aber dem Volatilitätsniveau der Periode und steigt in der Finanzkrise auf mehr als das Siebzigfache des Werts der ruhigen Phase 2003–2007. Beide Kennzahlen sind über Perioden hinweg somit nur eingeschränkt vergleichbar, wenn auch aus unterschiedlichen Gründen.

Aussagekräftig bleibt die Differenz zwischen den Schätzern innerhalb einer Periode, die erheblich variiert. In der Finanzkrise 2008/09 und im COVID-Zeitraum fällt sie um ein Vielfaches größer aus als in den ruhigen Phasen. Der Mehrwert der dynamischen Modellierung konzentriert sich damit auf Phasen mit ausgeprägten Volatilitätsschocks, in denen eine statische Matrix dem Risikoniveau am stärksten nachläuft.

Ökonomisch ist die Rangfolge ebenfalls periodenabhängig, da das MVP mit DCC-Kovarianz die

Periode	N	QLIKE		MSE ($\times 10^{-7}$)		Sharpe		
		Hist.	Δ DCC	Hist.	DCC	MVP Hist.	MVP DCC	1/N
2003–2007	16–16	-143,5	-3,79	0,28	0,23	1,490	1,485	1,087
2008–2009	16–16	-119,7	-11,50	21,03	16,72	-0,200	-0,294	-0,092
2010–2019	16–17	-146,1	-1,75	0,79	0,60	0,940	1,036	0,760
2020–2021	17–17	-133,1	-7,15	20,18	15,88	0,446	0,427	0,836
2022–2026	17–27	-205,1	-0,69	1,79	1,70	0,578	0,462	0,461

Tabelle 11: Teilperioden des Basisfalls: Universum, Prognosequalität und Performance

N ist die Spannweite der investierbaren Sektoren; QLIKE-Niveaus sind zwischen Perioden mit unterschiedlichem N nicht vergleichbar.

historische Variante in der Phase 2010–2019 klar schlägt, in allen übrigen Teilperioden jedoch zurückliegt. Der Basisfall umfasst die volle Historie ab 2003 und mittelt über gegenläufige Teilperioden, weshalb dort die historische Matrix vorne liegt, während die auf 2010 eingeschränkten Tabellen für das MVP zugunsten von DCC ausfallen. Beide Rechnungen sind korrekt, messen aber Unterschiedliches, wobei die Unterschiede in beide Richtungen durchgängig insignifikant sind und daher keine starke Aussage zulassen.

Der Vergleich über Trainingsfenster variiert somit selbst nach Angleichung des Zeitraums noch zwei Größen gleichzeitig, nämlich Schätzpräzision und Anlageuniversum, und ist als Robustheitsprüfung im engeren Sinn nur eingeschränkt geeignet. Dass es sich dabei um eine Eigenschaft der empirischen Datenbasis und nicht um einen Fehler der Implementierung handelt, zeigt der Gegentest an den synthetischen Datensätzen im Anhang. Dort ist das Universum mit 20 Anlagen konstant und der datengenerierende Prozess parameterstabil, weshalb das QLIKE-Niveau über alle Fensterlängen praktisch unverändert bleibt und sich die Rangfolge der Schätzer in keinem einzigen Fenster umkehrt.

Robust ist der Befund dort, wo tatsächlich nur ein Faktor variiert wird. Über die Prognosehorizonte bleiben Bewertungszeitraum und Universum konstant, wodurch der Vorteil der historischen Matrix monoton mit dem Horizont wächst. Zudem gilt die statistische Rangfolge unter dem MSE über alle 40 Läufe hinweg ausnahmslos.

5 Einordnung in die Literatur

In diesem Abschnitt werden die Befunde in die eingangs skizzierte Literatur eingeordnet.

Der Befund, dass alle drei risikobasierten Verfahren das naive Portfolio im Basisfall übertreffen, steht in Spannung zu DeMiguel et al. (2009), die 1/N gegenüber optimierten Strategien als schwer zu schlagen ausweisen. Die Ursache dürfte weniger in den Verfahren als im Untersuchungsobjekt liegen, da hier über breit diversifizierte Sektorindizes statt über Einzeltitel optimiert wird und die Kovarianzmatrix dadurch stabiler zu schätzen ist. Innerhalb der risikobasierten Verfahren fügen sich die Ergebnisse dagegen gut in die vorliegende Evidenz ein. Die hohe Robustheit von HRP

mit 40 von 40 Läufen über $1/N$ entspricht den Aussagen von López de Prado (2016) und Sen et al. (2022). Mit Chaves et al. (2011) deckt sich zudem die Beobachtung, dass ERC zwar besser diversifiziert, das naive Portfolio aber nicht durchgängig schlägt. Dass das MVP im Basisfall dennoch die höchste Sharpe Ratio erzielt, über alle Läufe hinweg aber nur in der Hälfte der Fälle über $1/N$ liegt, illustriert genau die Instabilität, die Lee (2011) und Behr et al. (2008) beschreiben.

Das zentrale Ergebnis dieser Arbeit ist ein nahezu vollständiger statistischer, aber nur beim MVP nennenswerter ökonomischer Vorsprung der GARCH-Modelle. Die durchweg insignifikanten Tests in Tabelle 6 bestätigen den Einwand von Engle und Colacito (2006) für den vorliegenden Datensatz unmittelbar, während die von Patton (2011) und Laurent et al. (2012) vorgeschlagenen robusten Verluste im selben Datensatz sehr wohl trennscharf sind. Nur scheinbar im Widerspruch dazu stehen Ardia et al. (2017), die eine Fehlspezifikation der Kovarianzmatrix als spürbare Verzerrung der Portfoliogewichte ausweisen. Verzerrte Gewichte schlagen sich hier nur dort in der Performance nieder, wo ein Verfahren die Matrix intensiv nutzt, sodass sich beide Befunde nicht ausschließen, sondern die Verzerrung je nach Allokationsverfahren unterschiedlich teuer ist. Am nächsten liegt jedoch Moura et al. (2020), da die Autoren für hochdimensionale bedingte Kovarianzmatrizen ebenfalls finden, dass die statistisch beste Spezifikation nicht die ökonomisch beste sein muss und Transaktionskosten den Ausschlag geben. Der um ein Vielfaches erhöhte Turnover der dynamischen Schätzer zeigt denselben Mechanismus in einem Sektoruniversum.

6 Limitationen

Die Aussagekraft der Ergebnisse ist in mehrfacher Hinsicht begrenzt, wobei die Einschränkungen im Folgenden nach ihrem Gewicht für die Interpretation geordnet werden.

Am schwersten wiegt, dass der Backtest ohne Handelskosten rechnet, obwohl sich die Verfahren im Turnover um den Faktor 32 unterscheiden. Die berichteten Kennzahlen begünstigen damit die dynamischen Schätzer, deren Nachteil unter realen Kosten größer ausfiel als ausgewiesen. Umgekehrt wird die Aussage des Abschnitts zur ökonomischen Performance dadurch nicht, sondern verschärft, da dieser Nachteil bereits ohne Kosten vorhanden ist.

Der unbalancierte Panelaufbau begrenzt zudem die Vergleichbarkeit über Trainingsfenster und Teilperioden hinweg, da die Einschränkung auf den gemeinsamen Bewertungszeitraum ab 2010 zwar den Stichprobeneffekt behebt, nicht aber den Universumseffekt. Eine sauberere Untersuchung würde das Universum über alle Spezifikationen hinweg auf die 16 durchgängig verfügbaren Sektoren fixieren, wofür allerdings auf rund 40 % der zuletzt verfügbaren Sektoren verzichtet werden müsste. Ein solcher Robustheitslauf steht ebenso aus wie eine Normierung des QLIKE-Verlusts auf N , die Niveauvergleiche über unterschiedliche Dimensionen hinweg zulassen würde. Die synthetischen Datensätze können diese Lücke nicht schließen, da sie ein vollständig balanciertes Panel bilden, in dem alle 20 Anlagen ab dem ersten Tag verfügbar sind. Das ist gewollt, weil es die Gegenprobe zum Strukturbruch erst ermöglicht, bedeutet aber

zugleich, dass erst ein simuliertes Panel mit gestaffelt eintretenden Anlagen den Universumseffekt isoliert quantifizieren könnte.

Ein technisches Problem mit derselben Ursache betrifft die historische Matrix, die im Anschluss an die Universumserweiterung 2022 an 66 Rebalancierungsterminen nicht positiv definit ist und dort keinen QLIKE-Verlust zulässt. Die Mittelwerte der Schätzer beruhen dadurch streng genommen auf unterschiedlichen Terminmengen, was die dynamischen Schätzer geringfügig begünstigt, da an den fehlenden Terminen besonders negative QLIKE-Werte auftreten. Auf einer gemeinsamen Terminmenge gerechnet schrumpft ihr Vorsprung um rund einen halben QLIKE-Punkt, ohne dass sich die Rangfolge ändert. Der MSE ist von dem Problem nicht betroffen, da er keine Invertierung voraussetzt, während sich das Problem systematisch durch einen Shrinkage-Schätzer im Sinne von Ledoit und Wolf (2004) lösen ließe. Dieser wäre zugleich ein interessanterer Vergleichsmaßstab als die rohe Stichprobenkovarianz.

Auf der Messseite ist der realisierte Proxy die wesentliche Einschränkung, da er für $h = 1$ aus einem einzigen äußeren Produkt besteht und damit den Rang eins hat. Die Verlustfunktionen bleiben nach Patton (2011) zwar rangerhaltend, jedoch begrenzt das geringe Signal-Rausch-Verhältnis die Teststärke des MSE-basierten DMW-Tests spürbar. Intraday-Daten würden einen erheblich präziseren Proxy liefern, standen für diese Arbeit aber nicht zur Verfügung. Hinzu kommt, dass ausschließlich die relative Prognosegüte bewertet wurde und nicht die absolute Kalibrierung der prognostizierten Volatilität. Ob die Modelle das Risikoniveau im Mittel treffen, was für Value-at-Risk-Anwendungen entscheidend wäre, bleibt damit offen.

Auf der Modellseite wird ausschließlich GARCH(1,1) unter Normalverteilungsannahme geschätzt, obwohl Aktienrenditen typischerweise linksschief und leptokurtisch sind. Erweiterungen um Asymmetrie, etwa GJR-GARCH oder EGARCH, sowie um fat-tailed Innovationen liegen daher nahe. Die DCC-Parameter werden zudem mit korrelationsgetargetem $\bar{Q}$ und begrenzter Iterationszahl geschätzt, ohne dass Standardfehler ausgewiesen werden. Auf der Allokationsseite sind Leerverkaufsverbot und Vollinvestition die einzigen Restriktionen, während praxisübliche Obergrenzen je Position nicht gesetzt werden.

Schließlich werden über 40 Läufe hinweg zahlreiche Tests durchgeführt, ohne für multiples Testen zu korrigieren. Die Analyse beschränkt sich außerdem auf ein einziges Marktsegment, wobei Sektorindizes zudem nicht unmittelbar investierbar sind und Replikationskosten daher unberücksichtigt bleiben.

7 Fazit

Die Arbeit hat zwei Fragen getrennt untersucht, nämlich ob risikobasierte Portfoliomodelle das naive 1/N-Portfolio schlagen und ob GARCH-basierte Kovarianzprognosen gegenüber der historischen Schätzung einen Mehrwert stiften.

Zur ersten Frage hängt die Antwort stark vom gewählten Verfahren ab. HRP und ERC mit historischer Kovarianz übertreffen das 1/N-Portfolio in allen 40 untersuchten Konstellationen und erweisen sich als robust gegenüber Variationen von Trainings- und Prognosefenster. Das Minimum-Varianz-Portfolio erzielt im Basisfall zwar die höchste Sharpe Ratio, schlägt 1/N über alle Läufe hinweg aber nur in der Hälfte der Fälle und reagiert am empfindlichsten auf Schätzfehler. Für die Praxis sprechen diese Ergebnisse damit eher für die robusteren Verfahren als für die Varianzminimierung, wobei einschränkend gilt, dass keiner der Vorsprünge gegenüber 1/N statistisch signifikant ist.

Zur zweiten Frage entscheidet das angelegte Kriterium über die Antwort, worin zugleich der Hauptbefund liegt. Statistisch ist das Ergebnis eindeutig, da DCC-GARCH die Kovarianzmatrix in allen 40 Läufen unter dem MSE und in nahezu allen unter dem QLIKE-Verlust besser prognostiziert als die historische Schätzung und die Unterschiede im DMW-Test signifikant sind. Ökonomisch übersetzt sich dieser Vorsprung jedoch nur dort, wo die Kovarianzmatrix tatsächlich intensiv genutzt wird, also beim MVP und nicht bei HRP oder ERC. Das ist konsistent mit der Konstruktion der Verfahren, da beide die Matrix nur grob nutzen und gerade deshalb robust, zugleich aber auch unempfindlich gegenüber ihrer Verbesserung sind. Der Preis der Dynamik ist der Turnover, der beim MVP um den Faktor 32 höher liegt und den ohnehin geringen Vorsprung unter realen Handelskosten aufzehren würde.

Hinzu kommt ein methodischer Nebenfund. Die Auswertung über verschiedene Trainingsfenster, die üblicherweise als Robustheitsprüfung verstanden wird, variiert im vorliegenden Design zugleich den Bewertungszeitraum und die Zusammensetzung des Anlageuniversums. Beide Effekte sind erheblich und gerichtet, da über die volle Historie das längste Trainingsfenster überlegen erscheint, weil es den Einbruch der Finanzkrise ausschließt und nur die Erholung erfasst. Dass sich dieser Effekt auch beim 1/N-Portfolio zeigt, das gar nicht schätzt, belegt seinen rein stichprobenbedingten Charakter. Nach der Angleichung des Bewertungszeitraums ab 2010 verschwindet rund die Hälfte der scheinbaren Fenstersensitivität, während der verbleibende Teil mit einer Korrelation von $-0,9999$ praktisch vollständig auf die Zahl der investierbaren Sektoren zurückgeht. Auf den synthetischen Datensätzen mit konstantem Universum und parameterstabilem Prozess tritt dieses Muster erwartungsgemäß nicht auf, weshalb Niveauvergleiche über Fensterlängen hinweg ohne Kontrolle von Zeitraum und Universum nicht belastbar sind.

Der übergreifende Schluss lautet damit, dass eine bessere Risikoprognose nicht automatisch eine bessere Anlageentscheidung ist. Die GARCH-Modelle leisten das, wofür sie konstruiert sind, und die synthetische Validierung zeigt, dass sie genau dann einen Mehrwert liefern, wenn der datengenerierende Prozess ihre Annahmen erfüllt. Auf realen Sektordaten ist die verwertbare Struktur jedoch zu schwach, um die Kosten der laufenden Umschichtung zu rechtfertigen. Nicht die Prognosegüte ist folglich die bindende Restriktion, sondern der Handel, den ihre Nutzung auslöst.

A Synthetische Validierung

Ob die Modelle korrekt implementiert sind, lässt sich an echten Daten nicht prüfen, da der wahre datengenerierende Prozess unbekannt ist. Stattdessen werden drei simulierte Datensätze mit jeweils 20 Anlagen und 6.000 Handelstagen verwendet, die dieselbe unbedingte Risikostruktur besitzen und sich ausschließlich in der Dynamik der zweiten Momente unterscheiden. Die annualisierten Volatilitäten liegen dabei zwischen 15 % und 35 % bei einer durchschnittlichen Korrelation von 0,35. Der Monte-Carlo-Datensatz enthält unabhängige Ziehungen mit konstanter Kovarianz und bildet den Nullfall ab, in dem die historische Matrix korrekt spezifiziert ist. Beim GARCH-Datensatz kommt eine GARCH(1,1)-Dynamik je Anlage mit $\alpha = 0,08$ und $\beta = 0,90$ bei konstanter Korrelation hinzu, während der DCC-Datensatz zusätzlich eine DCC-Rekursion mit $a = 0,03$ und $b = 0,96$ enthält. Die drei Datensätze bilden damit eine Leiter, auf der jeweils ein anderer Schätzer korrekt spezifiziert ist.

Dass die Modelle dieser Leiter folgen, zeigt Tabelle 12. Im Monte-Carlo-Fall unterscheiden sich die drei Schätzer unter beiden Verlustmaßen praktisch nicht, wobei die historische Matrix beim MVP die minimal höchste Sharpe Ratio erzielt. Wo keine Struktur vorhanden ist, bringt das komplexere Modell folglich nichts. Im GARCH-Fall schlagen beide dynamischen Schätzer die historische Matrix deutlich, sowohl in der Prognosegüte als auch in Sharpe Ratio und realisierter Volatilität. Sobald mit dem DCC-Prozess auch die Korrelation dynamisch ist, schlägt DCC schließlich den GARCH-Schätzer klar.

Datensatz	Kovarianz	QLIKE	MSE ($\times 10^{-8}$)	Vola (%)	Sharpe	Turnover
Monte Carlo	Historisch	-154,50	7,04	11,92	1,011	0,011
	GARCH	-154,47	7,04	11,95	1,003	0,074
	DCC-GARCH	-154,47	7,04	11,95	1,002	0,075
GARCH-Sim.	Historisch	-154,23	7,84	11,37	0,869	0,010
	GARCH	-157,25	7,57	9,85	0,984	0,154
	DCC-GARCH	-157,25	7,57	9,85	0,984	0,154
DCC-Sim.	Historisch	-154,13	9,86	11,93	0,668	0,011
	GARCH	-157,02	9,19	9,62	0,907	0,160
	DCC-GARCH	-162,13	8,98	8,99	0,925	0,152

Tabelle 12: Synthetische Validierung: Basisfall je Datengenerierungsprozess

20 simulierte Anlagen, Training 1008 Handelstage, Prognosehorizont 1 Tag; Performancekennzahlen für das MVP.

Die DMW-Tests in Tabelle 13 bestätigen dieses Muster formal. Im Monte-Carlo-Prozess ist die Verlustdifferenz der dynamischen Schätzer gegenüber der historischen Matrix positiv, also minimal schlechter, und zwischen GARCH und DCC nicht von null verschieden, weshalb die zusätzliche Parametrisierung dort keinen Beitrag liefert. Beide dynamischen Schätzer sind im GARCH-Prozess signifikant besser als die historische Matrix, unterscheiden sich untereinander jedoch nicht, was korrekt ist, da die Korrelation dort konstant ist. Erst im DCC-Prozess wird der Unterschied zwischen DCC und GARCH signifikant, sodass die Implementierung jeweils genau die Struktur erkennt, die tatsächlich vorhanden ist.

Datensatz	$\Delta G-H$	t	$\Delta D-H$	t	$\Delta D-G$	t
Monte Carlo	0,029***	6,07	0,029***	6,12	0,000	0,32
GARCH-Sim.	-3,025***	-24,69	-3,024***	-24,68	0,000	1,28
DCC-Sim.	-2,887***	-15,64	-7,998***	-35,68	-5,111***	-49,85

Tabelle 13: Synthetische Validierung: DMW-Tests auf die QLIKE-Differenzen

G = GARCH, D = DCC-GARCH, H = historisch; negative Differenzen bedeuten eine bessere Prognose. ***, **, * = 1-, 5-, 10-%-Niveau.

Den Gegentest zur Diskussion des Strukturbruchs liefert Tabelle 14. Bewertet wird nach demselben Protokoll wie im empirischen Teil, also ab 2010. Da das Universum konstant 20 Anlagen umfasst und die Parameter des Prozesses über die gesamte Stichprobe unverändert bleiben, sollte sich das Niveau der Prognosekennzahlen über die Trainingsfenster hinweg nicht systematisch verschieben. Genau das ist der Fall, da das QLIKE-Niveau der historischen Matrix über alle zehn Fenster nur um wenige Zehntel schwankt, während die entsprechende Spannweite in den empirischen Daten über 30 Punkte beträgt. Beim MSE ist das Niveau sogar praktisch konstant. Auch die Rangfolge kehrt sich in keinem Fenster um, weil DCC in allen 20 ausgewiesenen Läufen unter beiden Verlustmaßen besser prognostiziert als die historische Matrix und sich die Differenz bei längeren Trainingsfenstern auf einem konstanten Niveau stabilisiert.

Datensatz	Training	N	QLIKE		MSE ($\times 10^{-8}$)		Sharpe MVP	
			Hist.	Δ DCC	Hist.	DCC	Hist.	DCC
GARCH-Sim.	252	20	-154,1	-2,09	7,03	6,90	1,110	0,973
	504	20	-154,3	-2,68	7,03	6,87	1,073	0,986
	756	20	-154,4	-2,83	7,02	6,86	0,942	0,956
	1008	20	-154,4	-2,90	7,02	6,86	0,870	0,936
	1260	20	-154,6	-2,82	7,02	6,86	0,828	0,923
	1512	20	-154,7	-2,79	7,02	6,86	0,840	0,921
	1764	20	-154,6	-2,83	7,02	6,85	0,832	0,905
	2016	20	-154,6	-2,89	7,02	6,85	0,847	0,907
	2268	20	-154,7	-2,85	7,02	6,85	0,840	0,899
	2520	20	-154,7	-2,83	7,02	6,85	0,837	0,896
DCC-Sim.	252	20	-156,1	-4,14	10,06	9,27	0,898	1,021
	504	20	-154,9	-6,62	10,13	9,22	1,041	1,072
	756	20	-154,5	-7,46	10,16	9,21	1,008	1,020
	1008	20	-154,2	-7,89	10,15	9,20	1,032	1,010
	1260	20	-154,1	-8,09	10,16	9,20	1,042	0,996
	1512	20	-154,1	-8,19	10,16	9,20	0,997	1,010
	1764	20	-154,1	-8,29	10,18	9,19	0,941	0,992
	2016	20	-154,0	-8,42	10,18	9,19	0,983	0,995
	2268	20	-153,9	-8,50	10,19	9,19	1,001	0,996
	2520	20	-153,9	-8,53	10,19	9,20	0,996	1,002

Tabelle 14: Synthetische Validierung: Stabilität über die Trainingsfenster

Bewertet ab 01.01.2010; das Universum ist mit 20 Anlagen konstant.

Die ökonomischen Kennzahlen schwanken auch hier spürbar, obwohl der Prozess vollkommen stabil ist. Beim GARCH-Datensatz schlägt der historische Schätzer in den beiden kürzesten Fenstern sogar den DCC-Schätzer, obwohl er dort mit Sicherheit falsch spezifiziert ist. Das ist kein Widerspruch, sondern eine weitere Bestätigung des Arguments aus dem Abschnitt zur öko-

nomischen Performance. Selbst bei bekanntem datengenerierendem Prozess ist die Sharpe Ratio zu verrauscht, um Kovarianzschätzer zuverlässig zu ordnen, während die Prognosekennzahlen ein klares Signal liefern.

Literaturverzeichnis

- Ardia, D., Bolliger, G., Boudt, K., & Gagnon-Fleury, J.-P. (2017). The impact of covariance misspecification in risk-based portfolios. *Annals of Operations Research*, 254(1–2), 1–16. <https://doi.org/10.1007/s10479-017-2474-7>
- Behr, P., Güttler, A., & Miebs, F. (2008). *Is minimum-variance investing really worth the while? An analysis with robust performance inference* (Techn. Ber.). EDHEC-Risk Institute. https://www.cfr-cologne.de/download/kolloquium/2009/beh_r_et_al.pdf
- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327. [https://doi.org/10.1016/0304-4076\(86\)90063-1](https://doi.org/10.1016/0304-4076(86)90063-1)
- Bollerslev, T. (1990). Modelling the Coherence in Short-Run Nominal Exchange Rates: A Multivariate Generalized ARCH Model. *The Review of Economics and Statistics*, 72(3), 498–505. <https://doi.org/10.2307/2109358>
- Broadie, M. (1993). Computing efficient frontiers using estimated parameters. *Annals of Operations Research*, 45(1), 21–58. <https://doi.org/10.1007/BF02282040>
- Chaves, D., Hsu, J., Li, F., & Shakernia, O. (2011). Risk Parity Portfolio vs. Other Asset Allocation Heuristic Portfolios. *The Journal of Investing*, 20(1), 108–118. <https://doi.org/10.3905/joi.2011.20.1.108>
- DeMiguel, V., Garlappi, L., & Uppal, R. (2009). Optimal Versus Naive Diversification: How Inefficient is the 1/N Portfolio Strategy? *The Review of Financial Studies*, 22(5), 1915–1953. <https://doi.org/10.1093/rfs/hhm075>
- Diebold, F. X., & Mariano, R. S. (1995). Comparing Predictive Accuracy. *Journal of Business and Economic Statistics*, 13(3), 253–263. <https://doi.org/10.1080/07350015.1995.10524599>
- Engle, R. F. (1982). Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation. *Econometrica*, 50(4), 987–1007. <https://doi.org/10.2307/1912773>
- Engle, R. F. (2002). Dynamic Conditional Correlation: A Simple Class of Multivariate Generalized Autoregressive Conditional Heteroskedasticity Models. *Journal of Business and Economic Statistics*, 20(3), 339–350. <https://doi.org/10.1198/073500102288618487>
- Engle, R. F., & Colacito, R. (2006). Testing and Valuing Dynamic Correlations for Asset Allocation. *Journal of Business and Economic Statistics*, 24(2), 238–253. <https://doi.org/10.1198/073500106000000017>
- Engle, R. F., & Sheppard, K. (2001). *Theoretical and Empirical Properties of Dynamic Conditional Correlation Multivariate GARCH* (NBER Working Paper Nr. 8554). National Bureau of Economic Research. <https://doi.org/10.3386/w8554>

- Laurent, S., Rombouts, J. V. K., & Violante, F. (2012). On the forecasting accuracy of multivariate GARCH models. *Journal of Applied Econometrics*, 27(6), 934–955. <https://doi.org/10.1002/jae.1248>
- Ledoit, O., & Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411. [https://doi.org/10.1016/S0047-259X\(03\)00096-4](https://doi.org/10.1016/S0047-259X(03)00096-4)
- Lee, W. (2011). Risk-Based Asset Allocation: A New Answer to an Old Question? *The Journal of Portfolio Management*, 37(4), 11–28. <https://doi.org/10.3905/jpm.2011.37.4.011>
- López de Prado, M. (2016). Building Diversified Portfolios that Outperform Out of Sample. *The Journal of Portfolio Management*, 42(4), 59–69. <https://doi.org/10.3905/jpm.2016.42.4.059>
- Maillard, S., Roncalli, T., & Teïletche, J. (2010). The Properties of Equally Weighted Risk Contribution Portfolios. *The Journal of Portfolio Management*, 36(4), 60–70. <https://doi.org/10.3905/jpm.2010.36.4.060>
- Markowitz, H. (1952). Portfolio Selection. *The Journal of Finance*, 7(1), 77–91. <https://doi.org/10.1111/j.1540-6261.1952.tb01525.x>
- Michaud, R. O. (1989). The Markowitz Optimization Enigma: Is 'Optimized' Optimal? *Financial Analysts Journal*, 45(1), 31–42. <https://doi.org/10.2469/faj.v45.n1.31>
- Moura, G. V., Santos, A. A. P., & Ruiz, E. (2020). Comparing high-dimensional conditional covariance matrices: Implications for portfolio selection. *Journal of Banking & Finance*, 118, 105882. <https://doi.org/10.1016/j.jbankfin.2020.105882>
- Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256. <https://doi.org/10.1016/j.jeconom.2010.03.034>
- Sen, J., Mehtab, S., Dutta, A., & Mondal, S. (2022). Hierarchical Risk Parity and Minimum Variance Portfolio Design on NIFTY 50 Stocks. <https://doi.org/10.48550/arXiv.2202.02728>
- West, K. D. (1996). Asymptotic Inference about Predictive Ability. *Econometrica*, 64(5), 1067–1084. <https://doi.org/10.2307/2171956>