

UNIVERSITÄT BREMEN

FACHBEREICH 07 – WIRTSCHAFTSWISSENSCHAFTEN

HAUSARBEIT

Risikobasierte Portfoliooptimierung mit GARCH-Modellen

Verfasser: Simon Johannes Jähn
jaehn1@uni-bremen.de
6186771

Angela Nikoyan

Veranstaltung: Portfoliotheorie und Asset Management
07-M37-4-02-01

Dozent: Prof. Dr. Thorsten Poddig

Studiengang: Master Betriebswirtschaftslehre

Abgabedatum: 26.09.2026

Inhaltsverzeichnis

Abbildungsverzeichnis	II
Tabellenverzeichnis	III
1 Einleitung	1
2 Daten	4
2.1 Sektorindizes	5
2.2 Risikofreier Zins	5
2.3 Synthetische Datensätze	5
3 Theoretische Grundlagen	6
3.1 Methodik	6
3.2 Kovarianzschätzer	7
3.3 Portfoliomodelle	10
4 Bewertungskriterien	21
4.1 Statistische Verlustmaße	21
4.2 Ökonomische Kennzahlen	22
4.3 Signifikanztests	23
5 Ergebnisse und Diskussion	24
5.1 Statistische Prognosequalität	24
5.2 Ökonomische Performance	26
5.3 Einordnung in die Literatur	30
6 Limitationen	31
6.1 Ausblick	32
7 Fazit	33
Literatur	35
Appendices	37
A Voller und gemeinsamer Bewertungszeitraum	37
B Tests auf Sharpe-Differenzen	40
C Transaktionskosten	40
D Synthetische Validierung	41
E Dokumentation KI-Nutzung	44

Abbildungsverzeichnis

1	MV-Portfolio, Effizienzlinie	12
2	Dendrogramm der Clusterbildung	20
3	Sharpe Ratio über die Trainingsfenster	29
4	Sharpe Ratio über die Trainingsfenster, voller und gemeinsamer Bewertungs- zeitraum	37

Tabellenverzeichnis

1	Deskriptive Statistik der TRBC-Sektorrenditen	5
2	Prognosequalität der Kovarianzschätzer im Basisfall	24
3	Diebold-Mariano-Tests auf die Verlustdifferenzen (Basisfall)	25
4	Prognosequalität über Trainingsfenster und Prognosehorizonte (TRBC)	26
5	Out-of-Sample-Performance im Basisfall	27
6	Ergebnisse über alle empirischen Läufe	28
7	Sharpe Ratios und Turnover über die Prognosehorizonte (TRBC, Training 1008 Tage)	30
8	QLIKE über vollen und gemeinsamen Bewertungszeitraum (TRBC, $h = 1$) . . .	38
9	Sharpe Ratio über vollen und gemeinsamen Bewertungszeitraum (TRBC, $h = 1$)	38
10	Häufigkeit des besten Kovarianzschätzers je Kennzahl	39
11	Teilperioden des Basisfalls: Universum, Prognosequalität und Performance . . .	39
12	Tests auf Unterschiede der Sharpe Ratios (Basisfall)	40
13	Sharpe Ratios nach proportionalen Transaktionskosten (Basisfall)	41
14	Synthetische Validierung: Basisfall je Datengenerierungsprozess	42
15	Synthetische Validierung: DM-Tests auf die QLIKE-Differenzen	42
16	Synthetische Validierung: Stabilität über die Trainingsfenster	43
17	Dokumentation der Nutzung von KI-basierten Anwendungen und Werkzeugen .	44

Abstrakt

Diese Arbeit untersucht, ob risikobasierte Portfolioverfahren das naive 1/N-Portfolio schlagen und ob GARCH- und DCC-GARCH-Prognosen der Kovarianzmatrix gegenüber einer historischen Schätzung einen Mehrwert stiften. Die Grundlage bilden tägliche Renditen von 27 US-Sektorindizes über gut 27 Jahre, die in zehn Trainingsfenstern und vier Prognosehorizonten und damit in 40 Konstellationen ausgewertet werden. Bewertet wird getrennt nach statistischen und ökonomischen Kriterien. Statistisch fällt das Ergebnis eindeutig aus, da DCC-GARCH die Kovarianzmatrix unter dem primären QLIKE-Kriterium in 37 und unter dem MSE in allen 40 Konstellationen besser prognostiziert als die historische Matrix. Ökonomisch schlägt sich dieser Vorsprung allenfalls beim Minimum-Varianz-Portfolio nieder, während er bei Hierarchical Risk Parity und Equal Risk Contribution folgenlos bleibt. Belastbar ist er jedoch auch dort nicht, da sämtliche Tests auf Sharpe-Differenzen insignifikant ausfallen. Ausschlaggebend ist der Turnover, der beim Minimum-Varianz-Portfolio mit dynamischer Kovarianz um den Faktor 32 höher liegt und die dynamischen Varianten unter realen Handelskosten zusätzlich belasten würde. Eine bessere Risikoprognose ist folglich nicht automatisch eine bessere Anlageentscheidung. Code und Daten liegen im begleitenden Repository.

1 Einleitung

Investitionen bilden einen wesentlichen Bestandteil des Finanzsystems und spielen sowohl für Privatpersonen als auch für Unternehmen und staatliche Institutionen eine wichtige Rolle. Im Mittelpunkt von Anlageentscheidungen steht das Ziel, das verfügbare Kapital unter Berücksichtigung eines angemessenen Verhältnisses zwischen Rendite und Risiko zu vermehren. Eine zentrale Herausforderung besteht dabei darin, das Kapital so auf verschiedene Vermögenswerte zu verteilen, dass eine möglichst hohe Rendite bei gleichzeitig begrenztem Risiko erzielt wird. Zur Lösung dieses Problems werden unterschiedliche Verfahren der Portfoliooptimierung eingesetzt. Mit der modernen Portfoliotheorie von Markowitz (1952) wurde erstmals ein quantitativer Rahmen geschaffen, der die erwartete Rendite und das Risiko verschiedener Anlagen systematisch miteinander verknüpft. Die Zusammenstellung eines Portfolios wird dabei als Optimierungsproblem formuliert, bei dem diejenigen Portfoliogewichte ermittelt werden, die für eine vorgegebene erwartete Rendite die geringste Portfoliovarianz aufweisen. Der Markowitz-Ansatz bildet bis heute eine wesentliche Grundlage moderner Portfoliooptimierungsverfahren. Seine praktische Anwendung ist jedoch mit erheblichen Herausforderungen verbunden, da die für die Optimierung benötigten erwarteten Renditen sowie Varianzen und Kovarianzen aus historischen Daten geschätzt werden müssen. Die damit verbundenen Unsicherheiten können die resultierende Portfolioallokation erheblich beeinflussen. Insbesondere neigen klassische Optimierungsverfahren dazu, Anlagen mit zufällig überschätzten erwarteten Renditen überzugewichten und solche mit unterschätzten Renditen unterzugewichten. Dadurch werden bestehende Schätzfehler im Optimierungsprozess verstärkt, anstatt ausgeglichen zu werden. Michaud (1989) bezeichnet

die Markowitz-Optimierung aus diesem Grund als Fehlermaximierung. Allerdings wirken sich Ungenauigkeiten bei den einzelnen Eingangsparametern unterschiedlich stark auf das Optimierungsergebnis aus. Broadie (1993) zeigt anhand einer Simulationsstudie, dass Schätzfehler bei den erwarteten Renditen die Lage der effizienten Grenze deutlich stärker verzerren als Fehler bei den geschätzten Varianzen und Kovarianzen. Während sich zukünftige Renditen aus historischen Kursdaten nur mit erheblicher Unsicherheit prognostizieren lassen, können Risikoparameter vergleichsweise zuverlässiger geschätzt werden. Welche Bedeutung diese Problematik für die praktische Portfolioallokation besitzt, verdeutlichen DeMiguel et al. (2009). In ihrem empirischen Vergleich verschiedener Optimierungsverfahren konnte keine der untersuchten Strategien das naive, gleichgewichtete 1/N-Portfolio über die betrachteten Datensätze hinweg durchgängig übertreffen. Der potenzielle Nutzen einer Optimierung hängt somit wesentlich davon ab, ob die erzielten Vorteile die negativen Auswirkungen der zugrunde liegenden Schätzfehler übersteigen.

Vor diesem Hintergrund haben risikobasierte Portfolioverfahren zunehmend an Bedeutung gewonnen. Im Gegensatz zu klassischen Optimierungsansätzen verzichten diese auf die Prognose erwarteter Renditen und bestimmen die Portfoliogewichte ausschließlich anhand von Risikoparametern. Zu den entsprechenden Ansätzen zählen das Minimum-Varianz-Portfolio (MVP), das Equal-Risk-Contribution-Portfolio (ERC) sowie das von López de Prado (2016) entwickelte Hierarchical-Risk-Parity-Verfahren (HRP). Während das MVP die Gesamtvarianz des Portfolios minimiert, strebt ERC eine gleichmäßige Verteilung der Risikobeiträge auf die einzelnen Anlagen an. HRP nutzt hingegen die hierarchische Struktur der Abhängigkeiten zwischen den Vermögenswerten, um das Kapital schrittweise auf verschiedene Anlagegruppen zu verteilen. Die Verfahren unterscheiden sich somit sowohl hinsichtlich ihrer Allokationsprinzipien als auch darin, wie sie die geschätzten Varianzen und Kovarianzen zur Bestimmung der Portfoliogewichte verwenden. Daraus ergibt sich die Frage, in welchem Umfang sich die Qualität der zugrunde liegenden Risikoschätzungen auf die Ergebnisse der einzelnen Strategien auswirkt. Für eine zuverlässige Portfolioallokation ist daher eine möglichst präzise Erfassung der Varianzen und Abhängigkeiten zwischen den einzelnen Anlagen von besonderer Bedeutung. Der übliche historische Stichprobenschätzer berücksichtigt jedoch keine zeitlichen Veränderungen der Risikoparameter innerhalb des betrachteten Schätzfensters. Tatsächlich unterliegen die Finanzmärkte einer dynamischen Entwicklung, bei der sich Phasen geringer und hoher Volatilität abwechseln und große Kursausschläge häufig von weiteren starken Schwankungen gefolgt werden. Dieses als Volatilitätsclustering bezeichnete Phänomen wurde von Engle (1982) mithilfe des Autoregressive-Conditional-Heteroskedasticity-Modells (ARCH) ökonometrisch erfasst. Darauf aufbauend entwickelte Bollerslev (1986) das Generalized-Autoregressive-Conditional-

Heteroskedasticity-Modell (GARCH), das die zeitliche Dynamik der bedingten Varianz unter Berücksichtigung vergangener Schocks und Varianzwerte modelliert. Für die Risikoanalyse eines Portfolios reicht es allerdings nicht aus, die zeitliche Entwicklung der einzelnen Varianzen zu berücksichtigen, da auch die Abhängigkeitsstruktur zwischen den Vermögenswerten Veränderungen unterliegt. Insbesondere können Korrelationen zwischen Anlagen in turbulenten Marktphasen ansteigen und dadurch die Wirksamkeit der Diversifikation einschränken. Modelle mit konstanten Korrelationen können diese zeitliche Dynamik nur unzureichend erfassen. Engle (2002) entwickelte deshalb das Dynamic-Conditional-Correlation-Modell (DCC), das die Modellierung bedingter Varianzen um zeitvariable Korrelationen erweitert und damit die Prognose einer dynamischen Kovarianzmatrix ermöglicht. Die Bedeutung einer angemessenen Modellierung der Kovarianzstruktur für die Portfolioallokation wird unter anderem von Ardia et al. (2017) hervorgehoben, die zeigen, dass eine Fehlspezifikation der Kovarianzmatrix zu erheblichen Verzerrungen der Portfoliogewichte risikobasierter Strategien führen kann. Allerdings lässt sich aus einer höheren statistischen Prognosegenauigkeit nicht unmittelbar ableiten, dass ein Kovarianzmodell auch zu einer besseren Anlageentscheidung führt. Engle und Colacito (2006) weisen darauf hin, dass die Sharpe Ratio als alleiniges Kriterium zur Auswahl eines Kovarianzschätzers irreführend sein kann, da sie maßgeblich von den realisierten Renditen beeinflusst wird, während die Kovarianzmatrix in erster Linie die Risikostruktur des Portfolios bestimmt. Zur statistischen Beurteilung von Risikoprognosen bietet Patton (2011) einen Ansatz auf Grundlage robuster Verlustfunktionen, deren Rangfolge auch bei Verwendung eines fehlerbehafteten Proxys für die nicht direkt beobachtbare wahre Varianz erhalten bleibt. Laurent et al. (2013) übertragen dieses Konzept auf die Bewertung vollständiger Kovarianzmatrizen. Dass statistische Prognosequalität und ökonomischer Nutzen zu unterschiedlichen Ergebnissen führen können, verdeutlichen zudem Moura et al. (2020) bei der Untersuchung hochdimensionaler bedingter Kovarianzmatrizen. Für eine umfassende Bewertung von Kovarianzprognosen ist es daher erforderlich, sowohl ihre statistische Genauigkeit als auch ihre Auswirkungen auf die tatsächlich realisierte Portfolioperformance zu untersuchen. Die Verbindung risikobasierter Allokationsverfahren, einschließlich neuerer Ansätze wie HRP, mit multivariaten GARCH-basierten Kovarianzprognosen wurde bislang nur vereinzelt untersucht. Insbesondere ist unklar, in welchem Umfang eine verbesserte Modellierung der zeitlichen Dynamik von Varianzen und Korrelationen zu einer höheren Prognosequalität führt und ob sich daraus auch ein ökonomischer Vorteil für die unterschiedlichen Portfoliostrategien ergibt. Vor diesem Hintergrund verfolgt die vorliegende Arbeit zwei zentrale Forschungsfragen: Zum einen erzielen risikobasierte Portfoliostrategien wie MVP, ERC und HRP eine höhere risikoadjustierte Out-of-Sample-Performance

als das naive, gleichgewichtete 1/N-Portfolio? Zum anderen verbessert die Verwendung von GARCH- und DCC-GARCH-basierten Risiko- und Kovarianzprognosen die Performance dieser Portfoliostrategien gegenüber einer Modellierung auf Grundlage historischer Varianzen und Kovarianzen?

Die empirische Untersuchung basiert auf täglichen Renditen von 27 US-Sektorindizes über einen Zeitraum von mehr als 27 Jahren. Durch die Kombination von zehn Trainingsfenstern und vier Prognosehorizonten ergeben sich insgesamt 40 Untersuchungskonstellationen, in denen drei unterschiedliche Kovarianzschätzverfahren mit jeweils vier Allokationsstrategien verglichen werden. Die Bewertung der statistischen Prognosequalität erfolgt anhand des QLIKE-Loss und des mittleren quadratischen Fehlers der Kovarianzschätzung (MSE). Zur Beurteilung der ökonomischen Performance werden die Sharpe Ratio, die realisierte Portfoliovolatilität sowie der Portfolioumschlag (Turnover) herangezogen. Ergänzend werden drei simulierte Datensätze mit bekanntem datengenerierendem Prozess untersucht, um die Fähigkeit der Prognosemodelle zur Erfassung der zugrunde liegenden Risikodynamik unter kontrollierten Bedingungen zu überprüfen.

Der weitere Aufbau der Arbeit orientiert sich an diesem Untersuchungsansatz. Zunächst wird im 2. Abschnitt die zugrunde liegende Datenbasis beschrieben, bevor der 3. Abschnitt das methodische Vorgehen, die verglichenen Kovarianzschätzer und die Portfoliomodelle erläutert. Der 4. Abschnitt legt die statistischen und ökonomischen Bewertungskriterien dar. Anschließend werden im 5. Abschnitt die empirischen Ergebnisse hinsichtlich der statistischen Prognosequalität und der ökonomischen Portfolioperformance dargestellt, ihre Stabilität über unterschiedliche Untersuchungszeiträume und Anlageuniversen hinweg analysiert und die Befunde in den bestehenden Forschungsstand eingeordnet. Der 6. Abschnitt diskutiert die Limitationen der Untersuchung und den sich daraus ergebenden weiteren Forschungsbedarf. Abschließend werden die zentralen Ergebnisse zusammengefasst und die daraus resultierenden Schlussfolgerungen dargestellt.

2 Daten

In diesem Abschnitt wird die Datengrundlage der empirischen Untersuchung beschrieben. Dabei wird zwischen den empirischen Sektoraten und den simulierten Datensätzen unterschieden.

2.1 Sektorindizes

Verwendet werden tägliche Kurse US-amerikanischer Sektorindizes, die über Datastream bezogen wurden. Als Sektorabgrenzung dienen die Business Groups der Refinitiv Business Classification (TRBC), wobei für die Vereinigten Staaten nur Daten für 28 der insgesamt 32 Business Groups verfügbar sind. Eine davon zeigt an rund zwei Dritteln ihrer Datenpunkte keine Kursbewegung und wird als inaktive Reihe verworfen, sodass 27 Sektoren in die Analyse eingehen. Der Beobachtungszeitraum reicht vom 02.04.1999 bis zum 09.06.2026 und umfasst 7.087 Handelstage, wobei nur für 16 Sektorindizes Daten über die gesamte Historie vorliegen, während die übrigen Datenreihen erst zu späteren Zeitpunkten starten. Die Querschnittsverteilung der Sektorrenditen ist in Tabelle 1 dargestellt. Auffällig ist dabei die durchschnittliche paarweise Korrelation von 0,562, die aufgrund der Begrenzung auf den US-Aktienmarkt erwartungsgemäß hoch ausfällt und die Diversifikationsmöglichkeiten innerhalb des Universums von vornherein einschränkt.

Kennzahl	Min.	25 %	Median	75 %	Max.
Beobachtungen	1351	1877	7087	7087	7087
Rendite p.a. (%)	-5,34	4,70	6,02	8,97	20,27
Volatilität p.a. (%)	15,06	19,73	22,41	26,32	49,20

Tabelle 1: Deskriptive Statistik der TRBC-Sektorrenditen

Tägliche logarithmierte Renditen von 27 TRBC-Sektorindizes, 02.04.1999 bis 09.06.2026; durchschnittliche paarweise Korrelation 0,562.

2.2 Risikofreier Zins

Als risikofreier Zinssatz dient die Fed Funds Rate, die wie auch die Sektorindizes über Datastream bezogen wird. Bezogen wird sie als täglicher Total-Return-Index, sodass die tägliche risikofreie Rendite direkt als dessen prozentuale Veränderung berechnet wird, ohne eine annualisierte Rate erst auf Tagesbasis umrechnen zu müssen. Sie fließt nicht in die Optimierung der einzelnen Portfolios ein, sondern wird ausschließlich für die Berechnung der Sharpe Ratio verwendet.

2.3 Synthetische Datensätze

Hinzu kommen drei künstlich erzeugte Datensätze, die ausschließlich der Validierung der Implementierung dienen. Simuliert werden ein Prozess mit konstanter Kovarianzmatrix sowie je ein CCC- und ein DCC-GARCH-Prozess, sodass für jeden der drei Kovarianzschätzer ein Datensatz vorliegt, auf dem er korrekt spezifiziert ist. Auf diese Weise lässt sich prüfen, ob die Modelle genau die Struktur erkennen, für die sie konstruiert sind, was an echten Daten wegen

des unbekannten datengenerierenden Prozesses nicht möglich ist. Die Parametrisierung ist im Anhang D dokumentiert.

3 Theoretische Grundlagen

3.1 Methodik

In diesem Abschnitt wird das Untersuchungsvorgehen vorgestellt. Dabei wird auf die Schätzung der Kovarianzmatrix, die Portfoliooptimierung und die Vergleichsmetriken eingegangen. Um für mögliche Strukturbrüche in den Daten zu kontrollieren und zugleich einer realistischen Anwendung nahe zu kommen, wird ein Rolling-Window-Ansatz gewählt. Die Kovarianzmatrix wird dabei auf einem Trainingsfenster der Länge T geschätzt, wobei alle Modellparameter an jedem Termin neu bestimmt werden, daraus werden die Portfoliogewichte bestimmt und diese über den Prognosehorizont von h Handelstagen gehalten, bevor das Fenster um h Tage weiterrückt. Variiert werden beide Größen, wobei das Trainingsfenster zwischen einem und zehn Jahren liegt und der Prognosehorizont 1, 5, 10 oder 21 Handelstage beträgt. Der Vergleich der daraus resultierenden 40 Kombinationen zeigt zum einen, ob die Befunde robust gegenüber der Wahl von Trainings- und Prognosefenster sind, und zum anderen, bei welcher Fensterlänge sich Schätzfehler aus zu wenigen Beobachtungen und Fehlspezifikation aus sich ändernden Parametern am besten ausgleichen. Als Basisfall werden durchgängig $T = 1008$ (vier Jahre) und $h = 1$ berichtet und von da ausgehend die Robustheit der Ergebnisse überprüft.

Je Zeitfenster werden dabei nur Sektoren berücksichtigt, die an mindestens 90 % der Handelstage verfügbar sind, um so eine ausreichende Datenbasis für die Schätzung zu gewährleisten und zugleich nicht ganze Anlagen wegen einzelner fehlender Datenpunkte auszuschließen. Das investierbare Universum wird somit in jedem Fenster neu bestimmt und variiert sowohl über die Zeit als auch über die Fensterlänge.

Ein Nachteil des Untersuchungsdesigns ist jedoch, dass ein längeres Trainingsfenster den Out-of-Sample-Zeitraum verkürzt. So beginnt dieser bei einem Jahr Trainingsdaten bereits im März 2000, bei zehn Jahren dagegen erst im November 2008. Der lange Lauf setzt damit erst nach dem Kurssturz vom Herbst 2008 ein und erfasst im Wesentlichen nur die anschließende Erholung. Diese Unterschiede führen dazu, dass die Ergebnisse durch die jeweils abgedeckten Marktphasen beeinflusst werden, wodurch die Vergleichbarkeit eingeschränkt wird. Sämtliche Vergleiche über Trainingsfenster und Prognosehorizonte werden daher auf dem gemeinsamen Bewertungszeitraum ab dem 01.01.2010 gerechnet, sodass alle Testzeiträume rund 4.280

Handelstage umfassen und alle Ergebnisse über die gleichen Marktphasen bestimmt werden. Der Basisfall wird zusätzlich zuerst über seine volle verfügbare Historie ab Februar 2003 berichtet, da sich die Frage der Vergleichbarkeit dort nicht stellt. Wie weit beide Rechnungen auseinanderliegen, zeigt Anhang A.

3.2 Kovarianzschätzer

Verglichen werden drei Schätzer der bedingten Kovarianzmatrix, die eine aufsteigende Leiter an Dynamik abbilden. Den Ausgangspunkt bildet der statische historische Schätzer, der zunächst um eine zeitvariable Varianz im GARCH-Modell und anschließend um eine dynamische Korrelation im DCC-GARCH-Modell erweitert wird. Da jeder Schritt genau eine Annahme aufhebt, lässt sich der Beitrag der jeweiligen Komponente isoliert bewerten.

3.2.1 Historische Kovarianzmatrix

Verwendet wird zunächst die Stichprobenkovarianz der Trainingsrenditen, in der die Annahme konstanter Varianzen und Korrelationen über das gesamte Fenster unverändert erhalten bleibt.

Der Vorteil dieses Schätzers liegt in seiner Einfachheit, da er keine Parameterschätzung im engeren Sinn benötigt und deshalb weder von Konvergenzproblemen noch von einer Fehlspezifikation der Dynamik betroffen sein kann. Dem steht seine Trägheit gegenüber, weil ein Volatilitätsschock nur mit einem geringen Gewicht in die Schätzung eingeht und erst nach T Handelstagen wieder aus ihr verschwindet. Aus diesen Gründen dient die historische Matrix in dieser Arbeit als statischer Referenzpunkt, gegen den der Mehrwert der beiden dynamischen Modelle gemessen wird.

3.2.2 Generalized Autoregressive Conditional Heteroskedasticity (GARCH)

Das GARCH-Modell wurde im Jahr 1986 von Bollerslev vorgestellt und verallgemeinert das ARCH-Modell, mit dem Engle (1982) die zeitvariable Varianz von Finanzzeitreihen erstmals ökonometrisch erfasst hatte. Beide Modelle greifen die Beobachtung auf, dass große Kursausschläge gehäuft auftreten und weitere große Ausschläge nach sich ziehen, was der historische Schätzer per Konstruktion ignoriert. Der Grundgedanke besteht darin, die Varianz nicht als Konstante, sondern als bedingte Größe zu behandeln, die aus der Information bis zur Vorperiode fortgeschrieben wird.

Ein GARCH(1,1) beschreibt die Rendite als Summe aus einem konstanten Mittelwert und einem Störterm, dessen Varianz einer eigenen Rekursion folgt.

$$r_t = \mu + \varepsilon_t \quad (1)$$

$$\varepsilon_t = \sqrt{h_t} z_t, \quad z_t \sim \mathcal{N}(0, 1) \quad (2)$$

$$h_t = \omega + \alpha \varepsilon_{t-1}^2 + \beta h_{t-1} \quad (3)$$

Die bedingte Varianz h_t setzt sich damit aus drei Bestandteilen zusammen (Gleichung 3). Die Konstante ω verankert das langfristige Varianzniveau, während α steuert, wie stark ein neuer Schock die Varianz bewegt, und β misst, wie lange dieser Einfluss anhält. Damit die unbedingte Varianz existiert und der Prozess stationär bleibt, müssen $\omega > 0$, $\alpha, \beta \geq 0$ sowie $\alpha + \beta < 1$ gelten (Bollerslev, 1986).

Da die Portfoliogewichte nicht nur für den Folgetag, sondern für die kommenden h Handelstage gelten, wird die Rekursion über den Horizont fortgeschrieben und anschließend gemittelt. Weil der erwartete quadrierte Schock der bedingten Varianz entspricht, vereinfacht sich die Fortschreibung ab dem zweiten Schritt zu einer Konvergenz gegen die unbedingte Varianz.

$$E_t[h_{t+k}] = \omega + (\alpha + \beta) E_t[h_{t+k-1}], \quad k \geq 2 \quad (4)$$

$$\bar{h}_{t,h} = \frac{1}{h} \sum_{k=1}^h E_t[h_{t+k}] \quad (5)$$

Die horizontgemittelte Varianzprognose $\bar{h}_{t,h}$ aus Gleichung 5 geht als Diagonalelement in die Kovarianzmatrix ein.

Für ein Portfolio genügt die Modellierung der einzelnen Varianzen allerdings nicht, da für die Gewichte die vollständige Kovarianzmatrix benötigt wird. Die Umsetzung folgt deshalb dem Constant-Conditional-Correlation-Ansatz (CCC) von Bollerslev (1990), bei dem für jeden Sektor ein eigenes GARCH(1,1) geschätzt, die Korrelationsmatrix dagegen konstant gehalten wird:

$$\Sigma_t = D_t R D_t, \quad D_t = \text{diag} \left(\sqrt{\bar{h}_1}, \dots, \sqrt{\bar{h}_N} \right) \quad (6)$$

Die Diagonalmatrix D_t enthält die prognostizierten Standardabweichungen der N Sektoren, während R als Stichprobenkorrelation der standardisierten Residuen z_t aus Gleichung 2 geschätzt wird. Dabei bezeichnet $\bar{h}_i$ die horizontgemittelte Varianzprognose $\bar{h}_{t,h}$ aus Gleichung 5 für Sektor i , wobei der Zeit- und Horizontindex der Übersichtlichkeit halber unterdrückt wird. Diese werden statt der Rohrenditen verwendet, da in ihnen die Volatilitätscluster bereits herausgefiltert sind und Tage hoher Volatilität die Korrelationsschätzung sonst verzerren würden. Gegenüber

der historischen Matrix ändert sich damit ausschließlich die Behandlung der Varianzen, wodurch der Vergleich beider Schätzer den Beitrag der dynamischen Volatilität isoliert.

3.2.3 Dynamic Conditional Correlation (DCC-GARCH)

Da das GARCH-Modell weiterhin von einer konstanten Korrelation ausgeht, die in der Realität nur selten vorliegt, entwickelte Engle (2002) mit dem DCC-GARCH-Modell eine Erweiterung, die auch diese Restriktion aufhebt. Engle überträgt dafür die Rekursion aus Gleichung 3 auf die Korrelation selbst und erhält so eine vollständig zeitvariable Kovarianzprognose.

Modelliert wird dabei zunächst eine Hilfsmatrix Q_t , die anschließend zu einer gültigen Korrelationsmatrix normiert wird.

$$Q_t = (1 - a - b) \bar{Q} + a z_{t-1} z'_{t-1} + b Q_{t-1} \quad (7)$$

$$R_t = \text{diag}(Q_t)^{-1/2} Q_t \text{diag}(Q_t)^{-1/2} \quad (8)$$

$$\Sigma_t = D_t R_t D_t \quad (9)$$

Der Aufbau von Gleichung 7 entspricht dem der GARCH-Rekursion, wobei $\bar{Q}$ die Rolle des langfristigen Niveaus übernimmt und auf die Stichprobenkorrelation der standardisierten Residuen gesetzt wird. Wie stark die Korrelationen auf neue gemeinsame Schocks reagieren, misst der Parameter a , während b deren Persistenz angibt. Analog zum univariaten Fall müssen dafür $a, b \geq 0$ und $a + b < 1$ gelten. Da Q_t auf der Diagonale keine Einsen aufweisen muss, ist die Normierung in Gleichung 8 nötig, um eine Korrelationsmatrix zu erhalten. Aus dieser und den prognostizierten Standardabweichungen ergibt sich die Kovarianzmatrix schließlich nach Gleichung 9.

Geschätzt wird das Modell in zwei Schritten, indem zuerst die univariaten GARCH-Modelle und anschließend die beiden Parameter a und b per Maximum-Likelihood auf den standardisierten Residuen bestimmt werden. Für $h > 1$ wird die Korrelationsprognose gemäß Engle und Sheppard (2001) auf $\bar{Q}$ zurückgeführt und über den Horizont gemittelt, damit sie zur ebenfalls horizontgemittelten Varianzprognose passt.

Da GARCH- und DCC-Schätzer dieselben Varianzprognosen und dieselben standardisierten Residuen verwenden, isoliert ihr Vergleich exakt den Beitrag der dynamischen Korrelation. Die drei Schätzer bilden somit die eingangs beschriebene Leiter, deren Stufen sich um jeweils genau eine Annahme unterscheiden.

3.3 Portfoliomodelle

3.3.1 Die moderne Portfoliotheorie nach Markowitz

Die moderne Portfoliotheorie (MPT), eingeführt von Markowitz (1952), beschäftigt sich mit der optimalen Aufteilung eines bestimmten Vermögens (Budgets) auf mindestens zwei Vermögensgegenstände. Als Pionier dieser Theorie bietet Markowitz einen Lösungsansatz für das Auswahl- oder Entscheidungsproblem bei der Portfoliozusammenstellung. Die erwartete Rendite dient als Maß für die Rentabilität einer Anlage, während die Varianz das Risiko repräsentiert. Alternativ kann das Risiko einer Anlage auch durch die Standardabweichung ausgedrückt werden, wobei sich die qualitativen Ergebnisse nicht ändern. Durch die Fokussierung auf die beiden Kriterien erwartete Rendite und Varianz wird das Auswahlproblem auf eine Teilmenge von Portfolios, die als effizient gelten, begrenzt. Das Hauptziel besteht darin, eine optimale Vermögensallokation über verschiedene Vermögenswerte zu finden, um die besten Ergebnisse für den Investor zu erzielen und sein Vermögen über einen bestimmten Zeitraum zu maximieren.

Die erwartete Rendite μ_p ergibt sich aus der Summe der gewichteten erwarteten Renditen aller Anlageklassen im Portfolio. Dabei werden die erwarteten Renditen jeder Anlageklasse μ_i mit ihren entsprechenden Portfoliogewichten w_i multipliziert und addiert:

$$\mu_p = \sum_{i=1}^N \mu_i w_i \quad (10)$$

Die Varianz des Portfolios wird durch die folgende Formel definiert:

$$\sigma_p = \sum_{i=1}^N \sum_{k=1}^N \text{Cov}(r_i; r_k) w_i w_k \quad (11)$$

und wird mit $\text{Cov}(r_i; r_k)$ der Renditen der verschiedenen Anlageklassen i und k bestimmt. Wird die Korrelation zwischen zwei Anlageklassen i und k , die sich aus ihrer Kovarianz $\text{Cov}(r_i; r_k)$ und den jeweiligen Standardabweichungen σ_i und σ_k der Renditen ergibt, berücksichtigt, so wird die Formel des Portfoliorisikos wie folgt formuliert:

$$\sigma_p = \sum_{i=1}^N \sum_{k=1}^N \sigma_i \sigma_k \text{Cor}(r_i; r_k) w_i w_k \quad (12)$$

Die Portfoliovarianz ergibt sich aus einer Kombination der Standardabweichungen und der Korrelationen zwischen den Anlageklassen, wobei niedrige Korrelationen eine wirksame Risikoreduzierung ermöglichen. Bei der Umsetzung der Portfoliooptimierung nach Markowitz ist es unerlässlich, die zugehörigen Varianzen und Kovarianzen zu schätzen. Eine ausschließliche Verwendung von Zeitreihendaten für diese Schätzungen kann jedoch dazu führen, dass das

resultierende Portfolio deutlich vom optimalen entfernt ist. Daher gibt es zahlreiche Ansätze in der Literatur, um das Schätzrisiko bei der Portfoliooptimierung zu reduzieren.

Untersuchungen wie die von Memmel (2004)¹Quelle Memmel (2004) fehlt in literatur/bibliography.bib – Eintrag ergänzen und \textcite{} setzen haben gezeigt, dass Schätzfehler in den erwarteten Renditen einen größeren Einfluss auf die Abweichungen von den optimalen Gewichten und damit auf den Anlageerfolg haben als Schätzfehler in den Varianzen und Kovarianzen. Gleichzeitig ist die Schätzung der erwarteten Renditen deutlich ungenauer als die Schätzung der Varianzen und Kovarianzen, wie von Merton (1980)²Quelle Merton (1980) fehlt in literatur/bibliography.bib gezeigt wurde. Demzufolge besteht eine weitgehende Einigkeit in der Literatur darüber, dass die Schätzung der erwarteten Renditen die primäre Herausforderung bei der Umsetzung der Markowitz-Optimierung darstellt, im Gegensatz zur Schätzung der Varianz-Kovarianz-Matrix, die weniger problematisch ist.

3.3.2 Risikobasierte Portfolioplanung

Das Ziel der risikobasierten Portfoliooptimierung besteht darin, die Abhängigkeit von unsicheren Renditeschätzungen zu minimieren, indem primär auf risikobasierte Kennzahlen wie Varianzen und Kovarianzen gesetzt wird. In diesem Zusammenhang werden im weiteren Verlauf verschiedene Methoden wie das Minimum-Varianz-Portfolio (MVP), das Konzept der Equal Risk Contribution (ERC), der gleichgewichtete Portfolioansatz (1/N) sowie die Hierarchical Risk Parity (HRP) betrachtet, um dieses Ziel zu erreichen.

Das Minimum-Varianz-Portfolio

Das Minimum-Varianz-Portfolio (MVP), auch als Global Minimum-Variance Portfolio (GMV) bezeichnet, nimmt innerhalb der modernen Portfoliotheorie nach Markowitz eine zentrale Stellung ein. Es beschreibt dasjenige Portfolio aus einem gegebenen Universum risikobehafteter Vermögenswerte, das die geringstmögliche Gesamtvarianz und damit die niedrigste Volatilität aufweist. Im Risiko-Rendite-Diagramm bildet das MVP den linksäußersten Punkt der Minimum-Varianz-Grenze und markiert zugleich den Übergang zwischen ihrem effizienten und ineffizienten Abschnitt, siehe Abbildung 1. Auf dem effizienten Abschnitt der Grenze befinden sich Portfolios, die bei höherem Risiko eine höhere erwartete Rendite ermöglichen, während Portfolios auf dem ineffizienten Abschnitt bei höherem Risiko eine geringere erwartete Rendite als das MVP aufweisen. Die Konstruktion des MVP erfolgt ausschließlich auf Grundlage der Kovarianzmatrix der Vermögenswerte, sodass keine Schätzungen der erwarteten Renditen erforderlich sind. Ziel der Optimierung ist es, die Portfoliogewichte unter der Bedingung einer vollständigen Investition des verfügbaren Kapitals so zu bestimmen, dass die Gesamtvarianz minimiert wird. Das zugrunde

liegende Optimierungsproblem lässt sich mathematisch wie folgt darstellen:

$$\min_w w^T V w, \quad \text{u. d. N.} \quad \sum_{i=1}^N w_i = 1, \quad w_i \geq 0 \quad (13)$$

Hierbei repräsentiert w die Portfoliogewichte und V die Kovarianzmatrix der Vermögenswerte im Portfolio. Die Budgetrestriktion stellt die Vollinvestition sicher, während $w_i \geq 0$ ein Leerverkaufsverbot setzt.




Abbildung 1: MV-Portfolio, Effizienzlinie
Eigene Darstellung.

Eine wesentliche theoretische Eigenschaft des unbeschränkten MVP besteht darin, dass der marginale Risikobeitrag jedes Vermögenswerts identisch ist und der Volatilität des Gesamtportfolios entspricht. Daraus folgt, dass der prozentuale Beitrag eines Vermögenswerts zum Gesamtrisiko seinem jeweiligen Portfoliogewicht entspricht. Darüber hinaus ist die Kovarianz jedes einzelnen Vermögenswerts mit dem MVP gleich der Varianz des MVP, sodass das Beta sämtlicher Vermögenswerte in Bezug auf dieses Portfolio den Wert eins annimmt. Diese Zusammenhänge gelten für die unbeschränkte Optimierung und müssen bei zusätzlichen Gewichtsbeschränkungen nicht mehr für sämtliche Vermögenswerte erfüllt sein.

Ein wesentlicher Vorteil des MVP liegt in der Vermeidung von Schätzfehlern, die mit der Bestimmung erwarteter Renditen verbunden sind. Merton (1980)³.[Quelle Merton \(1980\) fehlt in literatur/bibliography.bib](#) verdeutlicht die statistischen Schwierigkeiten bei der Schätzung von Renditeerwartungen. Durch den Verzicht auf diese Schätzungen kann die Robustheit der Portfoliooptimierung

verbessert werden. Allerdings bleibt das MVP gegenüber Fehlschätzungen der Varianzen und Korrelationen empfindlich. Insbesondere bei einer unbeschränkten Optimierung können bereits geringe Veränderungen der geschätzten Kovarianzmatrix zu erheblichen Verschiebungen der Portfoliogewichte führen.

Die empirische Untersuchung von Behr et al. (2008) liefert Hinweise auf die praktische Bedeutung der Minimum-Varianz-Strategie. Die Autoren analysierten das US-Aktienuniversum im Zeitraum von April 1968 bis Dezember 2007 und stellten fest, dass Minimum-Varianz-Portfolios insbesondere in Phasen hoher Marktvolatilität und Unsicherheit positive und signifikante Renditen erzielen können. Im Vergleich zu einem wertgewichteten Benchmark zeigte die Strategie eine höhere Performance. Gegenüber einem gleichgewichteten Portfolio konnte jedoch keine statistisch signifikante Verbesserung der Sharpe Ratio nachgewiesen werden. Die Ergebnisse deuten darauf hin, dass die Minimum-Varianz-Strategie zur Risikoreduzierung beitragen kann, ohne dabei zwangsläufig eine höhere risikoadjustierte Rendite als alternative Portfolioansätze zu erzielen.

Eine zentrale Schwäche des MVP besteht in seiner potenziell hohen Konzentration auf einzelne Vermögenswerte. Da die Optimierung ausschließlich auf die Minimierung der Gesamtvarianz ausgerichtet ist, können bestimmte Positionen stark gewichtet werden, während andere vollständig aus dem Portfolio ausgeschlossen werden. Dies verdeutlicht die Untersuchung von Lee (2011), in der zehn Sektoren des Russell-1000-Universums anhand historischer monatlicher Renditen analysiert wurden. Unter der Nebenbedingung nicht negativer Portfoliogewichte erhielten vier der zehn Sektoren im optimierten Portfolio ein Gewicht von null. Ohne diese Beschränkung hätten die betreffenden Sektoren negative Gewichte aufgewiesen. Auch Maillard et al. (2010) weisen auf die Konzentrationsanfälligkeit von Minimum-Varianz-Portfolios hin.

Die Portfoliozusammensetzung wird dabei nicht allein durch die individuellen Volatilitäten der Vermögenswerte bestimmt, sondern auch durch deren gegenseitige Korrelationen. Daher können selbst Vermögenswerte mit vergleichsweise hoher Einzelvolatilität zur Reduzierung des Gesamtrisikos beitragen, sofern sie günstige Diversifikationseigenschaften aufweisen. Um einer übermäßigen Konzentration entgegenzuwirken, können zusätzliche Gewichtsbeschränkungen eingeführt werden. Jagannathan und Ma (2003)⁴Quelle Jagannathan & Ma (2003) fehlt in literatur/bibliography.bib zeigen, dass solche Beschränkungen zugleich einen regulierenden Effekt auf die Verwendung geschätzter Kovarianzen haben können.

Eine weitere theoretische Besonderheit des MVP ergibt sich unter der Annahme identischer erwarteter Renditen aller Vermögenswerte. In diesem Fall besitzen sämtliche vollständig investierten Portfolios dieselbe erwartete Rendite, sodass das MVP aufgrund seines geringsten

Risikos zugleich das optimale Portfolio im Sinne der Mean-Variance-Optimierung darstellt. Liegt die gemeinsame erwartete Rendite oberhalb des risikofreien Zinssatzes, entspricht das MVP zudem dem Tangentialportfolio mit der höchsten Sharpe Ratio. Lee (2011) sowie Chaves et al. (2011) befassen sich mit diesem Zusammenhang und untersuchen die Bedeutung gleicher erwarteter Renditen für die Konstruktion risikobasierter Portfolios.

Gleichgewichtetes Portfolio (1/N-Portfolio)

Das 1/N-Portfolio, auch bekannt als gleichgewichtete Portfoliostrategie, ist eine einfache Anlagestrategie, bei der jeder der n risikoreichen Vermögenswerte im Portfolio mit einem gleichmäßigen Gewicht gehalten wird. Die Formel zur Berechnung der Gewichte im 1/N-Portfolio lautet:

$$w = \frac{1}{n} \quad (14)$$

Hierbei repräsentiert w das Gewicht des Vermögenswerts und n die Gesamtanzahl der Vermögenswerte im Portfolio. Durch diese Strategie wird sichergestellt, dass alle Vermögenswerte im Portfolio gleichbehandelt werden und jeder einen gleichwertigen Beitrag zum Gesamtrisiko leistet. Für die Bestimmung der Portfoliogewichte müssen weder erwartete Renditen noch Varianzen oder Kovarianzen geschätzt werden. Darüber hinaus kann die gleichmäßige Kapitalverteilung einer übermäßigen Konzentration auf einzelne Positionen entgegenwirken.

Die empirische Untersuchung von DeMiguel et al. (2009) verdeutlicht die praktische Bedeutung der 1/N-Strategie. Die Autoren verglichen die Out-of-Sample-Performance von 14 optimierten Portfoliomodellen, darunter klassische Mean-Variance-Modelle, bayesianische Ansätze und Modelle mit Gewichtsbeschränkungen, anhand von sieben empirischen Datensätzen mit der gleichgewichteten Strategie. Dabei konnte keines der untersuchten Optimierungsmodelle die 1/N-Strategie hinsichtlich der Sharpe Ratio, der risikoadjustierten Nutzenkennzahl (Certainty-Equivalent Return, CEQ) und des Portfolioumschlags konsistent übertreffen. Als wesentlichen Grund identifizierten die Autoren die Anfälligkeit komplexer Optimierungsverfahren gegenüber Schätzfehlern, insbesondere bei der Bestimmung erwarteter Renditen und der Kovarianzmatrix. Diese können dazu führen, dass Vermögenswerte mit überschätzten Renditeerwartungen oder unterschätzten Risiken überproportional gewichtet werden. Um den Einfluss solcher Schätzfehler ausreichend zu reduzieren, wären bei klassischen Mean-Variance-Modellen teilweise außergewöhnlich lange historische Beobachtungszeiträume erforderlich. Die Ergebnisse verdeutlichen somit, dass eine höhere mathematische Komplexität nicht zwangsläufig mit einer besseren tatsächlichen Portfolioperformance einhergeht.

Die Befunde von DeMiguel et al. (2009) wurden in der nachfolgenden Literatur jedoch differenziert betrachtet. Kritzman et al. (2010)⁵.Quelle Kritzman et al. (2010) fehlt in literatur/bibliography.bib

argumentieren, dass die Ergebnisse zugunsten der 1/N-Strategie unter anderem durch die Verwendung kurzer historischer Schätzfenster beeinflusst werden können. Bei der Berücksichtigung langfristiger Renditeannahmen können optimierte Portfolios hingegen bessere Ergebnisse erzielen. Kirby und Ostdiek (2012)⁶.Quelle Kirby & Ostdiek (2012) fehlt in literatur/bibliography.bib zeigen zudem, dass die Leistungsfähigkeit der Optimierungsverfahren von der Wahl der zugrunde liegenden Zielrenditen und Gewichtungsbegrenzungen abhängt. Durch die Berücksichtigung geeigneter Zielrenditen oder alternativer Gewichtungsansätze, beispielsweise auf Grundlage von Volatilitäts- oder Rendite-Risiko-Signalen, können optimierte Strategien die gleichgewichtete Portfoliokonstruktion auch unter Berücksichtigung von Transaktionskosten übertreffen. Einen weiteren Ansatz verfolgen Tu und Zhou (2011)⁷.Quelle Tu & Zhou (2011) fehlt in literatur/bibliography.bib, indem sie die 1/N-Strategie mit optimierten Portfolios kombinieren. Ziel dieser Kombination ist es, die Robustheit der Gleichgewichtung mit den Vorteilen einer risikoorientierten Optimierung zu verbinden und dadurch die Auswirkungen von Schätzfehlern zu reduzieren.

Trotz ihrer einfachen Konstruktion weist die 1/N-Strategie Einschränkungen hinsichtlich der Risikodiversifizierung auf. Da die individuellen Volatilitäten und Korrelationen der Vermögenswerte bei der Gewichtung unberücksichtigt bleiben, können insbesondere Positionen mit hoher Volatilität einen überproportionalen Beitrag zum Gesamtrisiko leisten. In Phasen ausgeprägter Marktturbulenzen kann sich diese ungleiche Risikoverteilung zusätzlich auf die Portfolioentwicklung auswirken. Risikoorientierte Optimierungsverfahren, wie das Minimum-Varianz-Portfolio, können in solchen Marktphasen Vorteile hinsichtlich der Begrenzung des Gesamtrisikos bieten.

In dieser Arbeit dient das 1/N-Portfolio als Vergleichsmaßstab, das jeder im Fenster verfügbaren Anlage denselben Anteil zuweist. Es bildet den relevanten Maßstab für die erste Forschungsfrage, da ein Optimierungsverfahren seinen Aufwand nur rechtfertigt, wenn dessen Gewinn den Verlust durch Schätzfehler übersteigt.

Das Equal-Risk-Contribution-Portfolio

Das Equal-Risk-Contribution-Portfolio (ERC) stellt einen risikobasierten Ansatz zur Portfoliooptimierung dar, dessen Grundlagen unter anderem von Qian (2005)⁸.Quelle Qian (2005) fehlt in literatur/bibliography.bib und Neukirch (2008)⁹.Quelle Neukirch (2008) fehlt in literatur/bibliography.bib entwickelt und von Maillard et al. (2010) näher untersucht wurden. Im Gegensatz zum gleichgewichteten Portfolio (1/N), bei dem das Kapital gleichmäßig auf sämtliche Vermögenswerte verteilt wird, und zum Minimum-Varianz-Portfolio (MVP), das auf die Minimierung der Gesamtvarianz ausgerichtet ist, verfolgt die ERC-Strategie das Ziel einer gleichmäßigen Verteilung der Risikobeiträge. Hierbei werden die Portfoliogewichte so bestimmt, dass jeder Vermögenswert unabhängig von seinem Kapitalanteil den gleichen Beitrag zum Gesamtrisiko leistet. Dabei werden sowohl

die individuellen Volatilitäten als auch die Korrelationen zwischen den Vermögenswerten berücksichtigt.

Die ERC-Portfoliokonstruktion beginnt damit, das Produkt des Gewichts eines Vermögenswerts mit seinem marginalen Risikobeitrag zu berechnen. Der marginale Risikobeitrag wird durch die Veränderung des Gesamtrisikos des Portfolios infolge einer Erhöhung des Bestands des Vermögenswerts definiert. Diese marginalen Risikobeiträge (MRC) geben Aufschluss darüber, wie sehr sich die Volatilität des Portfolios verändert, wenn das Gewicht eines Vermögenswerts leicht erhöht wird. Die Berechnung der MRC basiert hauptsächlich auf der Portfoliovolatilität und den Gewichtungen der Vermögenswerte:

$$\text{MRC}_i = \frac{\partial \sigma(w)}{\partial w_i} = \frac{(Vw)_i}{\sigma(w)} \quad (15)$$

Dabei steht $\sigma(w)$ für die Standardabweichung des Portfolios, V für die Varianz-Kovarianz-Matrix und w für den Vektor der Portfoliogewichte. Die Portfoliovolatilität wird dann als Summe der absoluten Risikobeiträge (ARC) aller Vermögenswerte berechnet. Jeder ARC gibt an, wie viel Risiko ein Vermögenswert zum Gesamtrisiko des Portfolios beiträgt, und ermöglicht somit eine detaillierte Analyse der einzelnen Risikokomponenten im Portfolio:

$$\sigma(w) = \sum_{i=1}^n \text{ARC}_i \quad (16)$$

Hierbei ist $\text{ARC}_i = w_i \cdot \text{MRC}_i$ der absolute Risikobeitrag des Vermögenswerts i . Um sicherzustellen, dass alle Vermögenswerte im Portfolio einen gleichmäßigen Beitrag zum Risiko leisten, wird die Differenz zwischen den absoluten Risikobeiträgen jedes Vermögenswerts minimiert. Dies geschieht durch die Lösung eines Optimierungsproblems, bei dem das Ziel ist, die Quadratsumme der Differenzen zwischen den ARC-Werten aller Vermögenswerte zu minimieren:

$$\min_w f(w), \quad \text{wobei} \quad f(w) = \sum_{i=1}^n \sum_{j=1}^n (\text{ARC}_i - \text{ARC}_j)^2 \quad (17)$$

Dabei ist $f(w)$ die Zielfunktion, die die Quadratsumme der Differenzen zwischen den ARC-Werten aller Vermögenswerte im Portfolio darstellt. Das ERC-Portfolio strebt somit eine gleichmäßige Verteilung des Risikos auf alle Vermögenswerte im Portfolio an, was zu einer ausgewogeneren Risikoposition führt. Durch diese ausgewogene Risikoverteilung wird die Stabilität des Portfolios verbessert und die Abhängigkeit von einzelnen Vermögenswerten verringert. Anders als das MVP nutzt ERC die Kovarianzmatrix somit nur über das Produkt Vw und nicht über ihre Inverse, weshalb Schätzfehler weniger stark durchschlagen.

Maillard et al. (2010) beschreiben das ERC-Portfolio als einen Ansatz, der Eigenschaften des gleichgewichteten Portfolios und des Minimum-Varianz-Portfolios miteinander verbindet. Während das MVP zu einer hohen Konzentration auf einzelne Vermögenswerte neigen kann, werden bei der ERC-Methode unter den üblichen Annahmen einer positiv definiten Kovarianzmatrix und nicht negativer Portfoliogewichte sämtliche Vermögenswerte des Anlageuniversums berücksichtigt. Allerdings weist das ERC-Portfolio im Vergleich zum MVP eine mindestens ebenso hohe Gesamtvarianz auf, da die gleichmäßige Risikoverteilung nicht zwangsläufig mit der Minimierung des Gesamtrisikos einhergeht. Die Untersuchung von Lee (2011) verdeutlicht zudem, dass Vermögenswerte mit niedriger Volatilität innerhalb eines ERC-Portfolios häufig höhere Kapitalgewichte erhalten, um die Risikobeiträge der einzelnen Positionen anzugleichen.

Die empirische Untersuchung von Chaves et al. (2011) liefert weitere Erkenntnisse zur Leistungsfähigkeit der ERC-Strategie. Die Autoren verglichen unterschiedliche Asset-Allokationsverfahren anhand eines breit gefächerten Anlageuniversums, das unter anderem US-Staatsanleihen, Unternehmensanleihen verschiedener Bonitätsklassen, internationale Anleihen, Aktien aus Industrie- und Schwellenländern, Rohstoffe sowie börsennotierte Immobilien umfasste. Dabei zeigte sich, dass die ERC-Strategie hinsichtlich ihrer Performance nicht durchgehend bessere Ergebnisse als das gleichgewichtete Portfolio erzielte. Gegenüber dem Minimum-Varianz-Portfolio und klassischen Mean-Variance-optimierten Portfolios wurden hingegen in den untersuchten Konstellationen günstigere Ergebnisse beobachtet. Die Autoren verdeutlichen zugleich, dass die Leistungsfähigkeit risikobasierter Allokationsstrategien von der Zusammensetzung des Anlageuniversums abhängt. Insbesondere die hohe Gewichtung von Anleihen kann die historische Performance solcher Strategien in Phasen sinkender Zinsen begünstigen.

Auch Savona und Orsini (2019)¹⁰ Quelle Savona & Orsini (2019) fehlt in literatur/bibliography.bib untersuchten die Leistungsfähigkeit der ERC-Strategie anhand empirischer Daten aus dem Zeitraum von Januar 2001 bis August 2013. Hierzu verglichen sie ERC-Portfolios im Rahmen eines rollierenden Backtests mit klassischen Markowitz-, Minimum-Varianz- und gleichgewichteten Portfolios. Ergänzend führten sie Monte-Carlo-Simulationen und Bootstrap-Analysen durch, um die Robustheit der Ergebnisse und die statistische Signifikanz der beobachteten Renditeunterschiede zu überprüfen. Die Untersuchung zeigte, dass die dynamische ERC-Strategie gegenüber einzelnen Vergleichsstrategien, insbesondere dem MVP und dem 1/N-Portfolio, eine statistisch signifikante Überrendite erzielen konnte. Gleichzeitig wies das Tangentialportfolio in mehreren untersuchten Konstellationen eine höhere Performance und Diversifizierung auf. Weitere empirische Erkenntnisse liefert Bastin (2018)¹¹ Quelle Bastin (2018) fehlt in literatur/bibliography.bib, der verschiedene risikobasierte Portfoliostrategien anhand des deutschen Aktienmarktes im

Zeitraum von 2002 bis 2015 untersuchte. Innerhalb des betrachteten CDAX-Anlageuniversums erzielte das ERC-Portfolio eine Sharpe Ratio von 0,32 und wies damit den höchsten Wert unter den untersuchten Strategien auf. Darüber hinaus wurde eine gegenüber dem Gesamtmarkt um etwa 50 % reduzierte Volatilität sowie ein statistisch signifikantes positives CAPM-Alpha von 7,5 % pro Jahr festgestellt.

Die Leistungsfähigkeit der ERC-Strategie kann zudem in Abhängigkeit von der jeweiligen Marktsituation variieren. Escobar et al. (2013)¹².Quelle Escobar et al. (2013) fehlt in literatur/bibliography.bib untersuchten das Verhalten unterschiedlicher Portfolioallokationsstrategien während ruhiger und turbulenter Marktphasen. Dabei zeigten sich in ruhigeren Marktphasen insbesondere für das gleichgewichtete Portfolio und die Minimum-Varianz-Strategie günstige Ergebnisse. Während ausgeprägter Marktturbulenzen gewannen hingegen risikoorientierte Allokationsverfahren an Bedeutung, wobei ERC- und Minimum-Varianz-Portfolios gegenüber der 1/N-Strategie Vorteile hinsichtlich der risikoadjustierten Performance aufweisen konnten. Die Autoren zeigen zudem, dass eine Anpassung der Portfolioallokation an unterschiedliche Marktregime zu höheren Sharpe Ratios führen kann als die ausschließliche Verwendung einer statischen Gewichtungsstrategie.

Neben der erzielten Risiko-Rendite-Performance ist die Robustheit gegenüber Schätzfehlern ein weiterer wichtiger Aspekt bei der Bewertung der ERC-Strategie. Ardia et al. (2017) untersuchten die Sensitivität verschiedener risikobasierter Portfolioansätze gegenüber Fehlspezifikationen der Kovarianzmatrix. Dabei erwiesen sich die ERC-Strategie und die Inverse-Volatility-Methode in den untersuchten Konstellationen als vergleichsweise robust, während das Minimum-Varianz-Portfolio eine höhere Empfindlichkeit gegenüber Schätzfehlern aufwies. Allerdings reagiert auch die ERC-Methode auf Ungenauigkeiten in den geschätzten Risikoparametern, wobei Fehler in den individuellen Varianzen einen stärkeren Einfluss auf die Portfoliozusammensetzung haben können als Fehler in den Korrelationen.

Insgesamt verdeutlichen die empirischen Untersuchungen, dass die ERC-Strategie in unterschiedlichen Anlageuniversen und Marktphasen sowohl hinsichtlich der Risikodiversifizierung als auch der risikoadjustierten Performance günstige Ergebnisse erzielen kann. Ihre tatsächliche Leistungsfähigkeit hängt jedoch von den jeweiligen Marktbedingungen, der Zusammensetzung des Anlageuniversums und der Qualität der geschätzten Risikoparameter ab.

Die Hierarchical Risk Parity

Der Hierarchical-Risk-Parity-Algorithmus (HRP) wurde von López de Prado (2016) als alternativer Ansatz zur Portfolioallokation entwickelt. Er kombiniert Methoden der Graphentheorie mit hierarchischen Clustering-Verfahren des unüberwachten maschinellen Lernens, um die bei klassischen Portfoliooptimierungsverfahren auftretenden Probleme zu reduzieren. Insbesondere

die Mean-Variance-Optimierung nach Markowitz kann aufgrund von Schätzfehlern in den erwarteten Renditen und der Kovarianzmatrix zu instabilen Portfoliogewichten und einer hohen Konzentration auf einzelne Vermögenswerte führen.

HRP verfolgt daher einen hierarchischen Ansatz, bei dem die Abhängigkeitsstrukturen zwischen den Vermögenswerten berücksichtigt werden, ohne dass eine Invertierung der Kovarianzmatrix erforderlich ist. Dadurch kann der Algorithmus auch bei schlecht konditionierten oder singulären Kovarianzmatrizen angewendet werden. Die Konstruktion des HRP-Portfolios erfolgt in drei aufeinanderfolgenden Schritten. Zunächst werden die Vermögenswerte mithilfe eines hierarchischen Clustering-Verfahrens anhand ihrer Ähnlichkeiten gruppiert. Als Grundlage dient ein Distanzmaß, das üblicherweise aus den Pearson-Korrelationskoeffizienten der Vermögenswertrenditen abgeleitet wird. Auf diese Weise entsteht eine hierarchische Baumstruktur, das sogenannte Dendrogramm (siehe Abbildung 2), in dem Vermögenswerte mit ähnlichen Renditeverläufen zu Clustern zusammengefasst werden. Anschließend erfolgt eine Quasi-Diagonalisierung, bei der die Kovarianzmatrix entsprechend der ermittelten Clusterstruktur umgeordnet wird. Dadurch werden eng miteinander verbundene Vermögenswerte innerhalb der Matrix nebeneinander angeordnet, sodass die Zusammenhänge zwischen den einzelnen Clustern deutlicher hervortreten. Im abschließenden Schritt, der hierarchischen Zweiteilung, wird das verfügbare Kapital schrittweise entlang der Baumstruktur aufgeteilt. Dabei werden die Cluster auf jeder Ebene in zwei Teilgruppen unterteilt, deren Kapitalanteile anhand ihrer jeweiligen Varianzen bestimmt werden. Cluster mit einer höheren Varianz erhalten einen geringeren Kapitalanteil, während risikoärmere Cluster entsprechend stärker gewichtet werden. Auf diese Weise entsteht eine Portfolioallokation, die sowohl die individuellen Risikoeigenschaften der Vermögenswerte als auch deren Abhängigkeitsstrukturen berücksichtigt.

López de Prado (2016) untersuchte die Leistungsfähigkeit des HRP-Algorithmus anhand von Out-of-Sample-Monte-Carlo-Simulationen mit 10.000 Durchläufen, in denen unterschiedliche Marktschocks berücksichtigt wurden. Als Vergleichsmaßstäbe dienten ein mithilfe des Critical Line Algorithm (CLA) optimiertes Minimum-Varianz-Portfolio sowie ein nach inverser Volatilität gewichtetes Portfolio (Inverse Volatility Portfolio, IVP). Die Ergebnisse zeigten, dass HRP in den untersuchten Simulationen eine geringere Out-of-Sample-Varianz aufwies und gegenüber dem CLA-Ansatz eine um etwa 31,3 % höhere Sharpe Ratio erzielte. Darüber hinaus zeigte sich, dass die hierarchische Allokation die Auswirkungen unterschiedlicher Schockarten auf das Portfolio begrenzen konnte. Während der CLA-Ansatz aufgrund seiner teilweise hohen Positionskonzentration insbesondere gegenüber idiosynkratischen Schocks einzelner Vermögenswerte anfällig war, berücksichtigte das IVP die Korrelationsstrukturen zwischen den Vermögenswerten




Exhibit 5 – Dendrogram of cluster formation

Abbildung 2: Dendrogramm der Clusterbildung

Entnommen aus López de Prado (2016).

nicht unmittelbar. Der HRP-Algorithmus ermöglichte hingegen durch die Einbeziehung der Clusterstruktur eine breitere Verteilung des Portfoliorisikos und zeigte sich in den untersuchten Szenarien gegenüber beiden Schockarten vergleichsweise robust.

Weitere empirische Erkenntnisse liefert Sen et al. (2022), der den HRP-Algorithmus mit dem CLA-Ansatz am indischen Aktienmarkt verglich. Die Untersuchung umfasste den Nifty 50 sowie acht Branchensektoren und basierte auf einem Trainingszeitraum von 2016 bis 2020 und einem anschließenden Out-of-Sample-Test im Jahr 2021. Dabei erzielte das HRP-Portfolio in sieben der acht untersuchten Sektoren eine höhere Sharpe Ratio als das mittels CLA konstruierte Portfolio. Darüber hinaus wies HRP eine ausgewogenere Verteilung der Kapitalgewichte auf, während der CLA-Ansatz teilweise zu einer ausgeprägten Konzentration auf einzelne Vermögenswerte führte. Die Ergebnisse verdeutlichen, dass die Berücksichtigung hierarchischer Abhängigkeitsstrukturen unter den untersuchten Marktbedingungen sowohl die Risikodiversifizierung als auch die risikoadjustierte Portfolioperformance verbessern kann.

Neben diesen Ergebnissen wurden in weiteren Untersuchungen, unter anderem von Lohre et al.¹³ Quelle Lohre et al. fehlt in literatur/bibliography.bib – Jahreszahl ebenfalls ergaenzen, die Eigenschaften des HRP-Algorithmus in Multi-Asset- und Multi-Faktor-Anlageuniversen sowie die Auswirkungen alternativer Distanzmaße und von Transaktionskosten analysiert. Dabei zeigte sich, dass die auf Pearson-Korrelationen basierende HRP-Strategie aufgrund von Veränderungen der geschätzten Clusterstrukturen eine vergleichsweise hohe Umschlagshäufigkeit aufweisen kann. In den untersuchten Backtests lag der jährliche Portfolioumschlag bei etwa 18 % bis 23 %, während

traditionelle Risk-Parity-Portfolios Werte zwischen 3,5 % und 5 % erreichten. Die damit verbundenen Transaktionskosten können die Nettoperformance der HRP-Strategie beeinträchtigen und stellen somit eine praktische Einschränkung des Verfahrens dar.

Zur Berücksichtigung extremer Marktrisiken wurden darüber hinaus Erweiterungen des ursprünglichen HRP-Algorithmus entwickelt. Ein Beispiel ist die Verwendung des Lower Tail Dependence Coefficient (LTDC) als alternatives Distanzmaß. Im Gegensatz zur Pearson-Korrelation, die den linearen Zusammenhang zwischen den Renditen beschreibt, berücksichtigt der LTDC die gemeinsame Abhängigkeit der Vermögenswerte bei extrem negativen Renditeentwicklungen. Durch die Einbeziehung dieser sogenannten Tail-Risiken kann die Clusterbildung stärker auf das gemeinsame Verlustverhalten der Vermögenswerte ausgerichtet werden. In den untersuchten Bootstrap-Simulationen erzielten LTDC-basierte HRP-Portfolios geringere maximale Kursverluste (Maximum Drawdowns) als die herangezogenen Vergleichsstrategien. Darüber hinaus wiesen sie eine stabilere Clusterstruktur und eine moderatere Umschlagshäufigkeit auf als die auf Pearson-Korrelationen basierende HRP-Variante.

Insgesamt stellt HRP einen alternativen Ansatz zur risikobasierten Portfolioallokation dar, der die Abhängigkeitsstrukturen zwischen Vermögenswerten durch hierarchisches Clustering in die Gewichtungsentscheidung einbezieht. Die empirischen Untersuchungen zeigen, dass das Verfahren unter bestimmten Marktbedingungen Vorteile hinsichtlich der Risikodiversifizierung, der Stabilität der Portfoliogewichte und der risikoadjustierten Performance bieten kann. Allerdings hängt seine tatsächliche Leistungsfähigkeit von der Qualität der geschätzten Risikoparameter, dem verwendeten Distanzmaß und der Stabilität der ermittelten Clusterstruktur ab. Insbesondere Veränderungen der Abhängigkeitsverhältnisse zwischen den Vermögenswerten können häufige Portfolioanpassungen erforderlich machen und dadurch die erzielten Renditevorteile nach Berücksichtigung der Transaktionskosten reduzieren.

4 Bewertungskriterien

Die Bewertung trennt zwischen der Prognosequalität der Kovarianzmatrix und der ökonomischen Performance der daraus abgeleiteten Portfolios.

4.1 Statistische Verlustmaße

Die Prognosequalität wird über zwei Verlustmaße gemessen, den multivariaten Quasi-Likelihood-Verlust (QLIKE), oder auch Stein-Loss genannt (Laurent et al., 2013), und den Mean Squared Error (MSE) der Kovarianzmatrix. Da die wahre bedingte Kovarianzmatrix der Testperiode nicht

beobachtbar ist, wird die Prognose bei beiden gegen denselben realisierten Proxy gemessen.

$$S = \frac{1}{h} \sum_{t=1}^h r_t r_t' \quad (18)$$

$$\text{QLIKE}(\Sigma, S) = \ln |\Sigma| + \text{tr}(\Sigma^{-1} S) \quad (19)$$

$$\text{MSE}(\Sigma, S) = \frac{1}{N^2} \sum_{i,j} (\Sigma_{ij} - S_{ij})^2 \quad (20)$$

Dabei ist Σ die prognostizierte und S die realisierte Kovarianzmatrix, r_t der Vektor der logarithmierten Tagesrenditen und N die Anzahl der zur Verfügung stehenden Sektorindizes im jeweiligen Zeitfenster. Beide Verluste werden je Rebalancierungsfenster berechnet und anschließend über die Fenster gemittelt, wobei niedrigere Werte eine bessere Prognose bedeuten.

Die beiden Maße unterscheiden sich darin, wie sie Fehler in beide Richtungen gewichten. Der QLIKE-Verlust aus Gleichung 19 bestraft eine Unterschätzung des Risikos stärker als eine Überschätzung, während der MSE aus Gleichung 20 Über- und Unterschätzungen gleichgewichtet. Aus ökonomischer Sicht wiegt eine Unterschätzung des Risikos schwerer als eine Überschätzung, weshalb die Asymmetrie des QLIKE-Verlusts hier erwünscht ist.

Diese beiden Maße werden verwendet, da sie sich in anderen Studien als robust gegenüber verrauschten Proxys erwiesen haben. Dies ist insbesondere relevant, da der Proxy für $h = 1$ allein aus dem äußeren Produkt eines einzigen Renditevektors besteht und somit stark verrauscht ist. So konnten Patton (2011) und Laurent et al. (2013) zeigen, dass beide Metriken Kovarianzmatrizen unabhängig von der Genauigkeit des Proxys robust ordnen. Folglich ist der absolute Wert der Metriken zwar nur eingeschränkt interpretierbar, jedoch ist die Rangfolge robust, weshalb Qualitätsunterschiede zwischen den Schätzern erkannt werden können. Da zusätzlich die Länge des Trainingsfensters die Zahl der investierbaren Anlagen und damit die Dimension der Kovarianzmatrix beeinflusst, sind Vergleiche zwischen den unterschiedlichen Trainingsfenstern ebenfalls mit Vorsicht zu interpretieren. Aussagekräftig ist daher in erster Linie die Differenz zwischen den Schätzern innerhalb einer Spezifikation.

Da der QLIKE-Verlust ökonomisch besser motiviert ist, wird dieser als primäre Vergleichsmetrik verwendet, während der MSE als weitere Metrik zur Überprüfung der Robustheit dient.

4.2 Ökonomische Kennzahlen

Als ökonomische Kennzahlen werden die annualisierte Rendite, die realisierte Volatilität, die Sharpe Ratio und der Turnover berichtet. Die folgenden Kennzahlen beruhen auf der Tagesrendite

der verschiedenen Portfolios $r_{p,t}$.

$$R_{\text{ann}} = \left(\prod_{t=1}^n (1 + r_{p,t}) \right)^{\frac{252}{n}} - 1 \quad (21)$$

$$\sigma_{\text{ann}} = \sqrt{252} \text{ sd}(r_{p,t}) \quad (22)$$

$$\text{Sharpe Ratio} = \frac{252 \overline{(r_{p,t} - r_{f,t})}}{\sqrt{252} \text{ sd}(r_{p,t} - r_{f,t})} \quad (23)$$

Die annualisierte Rendite aus Gleichung 21 ist die geometrische Wachstumsrate über die n Handelstage des Bewertungszeitraums, während die realisierte Volatilität als annualisierte Standardabweichung derselben Reihe berechnet wird. Bei der Sharpe Ratio beruhen Zähler und Nenner auf der Überschussrendite gegenüber der Fed Funds Rate.

Neben diesen Metriken wird auch der Turnover beachtet, der angibt, welcher Anteil des Portfolios je Rebalancierung umgeschichtet wird.

$$\text{Turnover}_k = \sum_{i=1}^N \left| w_{i,k}^{\text{Ziel}} - w_{i,k-1}^{\text{Ende}} \right| \quad (24)$$

Dabei sind $w_{i,k}^{\text{Ziel}}$ die neuen Zielgewichte der Rebalancierung k und $w_{i,k-1}^{\text{Ende}}$ die über die vorangegangene Halteperiode gedrifteten Endgewichte. Der Turnover dient dabei als Proxy für Transaktionskosten und zugleich als Indiz für die Robustheit der Optimierungsverfahren. In dieser Studie werden die Transaktionskosten bei der Rebalancierung zwar nicht direkt berücksichtigt, jedoch werden die Auswirkungen kurz bei den Ergebnissen und in Anhang C dargestellt.

4.3 Signifikanztests

Signifikanzaussagen beruhen auf zwei Tests. Unterschiede in der Prognosegüte werden mit dem Diebold-Mariano-Test (DM-Test) auf die Verlustdifferenzen geprüft (Diebold & Mariano, 1995; West, 1996), deren Langfristvarianz autokorrelationsrobust geschätzt wird. Für Unterschiede in den Sharpe Ratios dient der Test von Jobson und Korkie (1981) in der Korrektur von Memmel (2003), der die Korrelation der beiden Renditereihen berücksichtigt. Damit wird für beide Bewertungsebenen getrennt geprüft, ob die beobachteten Unterschiede zwischen den Schätz- und Optimierungsverfahren über zufällige Schwankungen hinausgehen.

5 Ergebnisse und Diskussion

Zunächst wird geprüft, ob die GARCH-basierten Schätzer die Kovarianzmatrix besser prognostizieren, bevor untersucht wird, ob sich ein solcher Vorteil auch in der Portfolioperformance niederschlägt. Diese Reihenfolge folgt dem Einwand von Engle und Colacito (2006), wonach die Sharpe Ratio von den realisierten Renditen dominiert wird, auf die die Kovarianzmatrix nur mittelbar wirkt, was sich ebenso auf andere renditebasierte Kennzahlen übertragen lässt. Anschließend wird die Stabilität beider Befunde über Trainingsfenster und Prognosehorizonte betrachtet, während der Einfluss des Bewertungszeitraums und der Teilperioden im Anhang A behandelt wird.

5.1 Statistische Prognosequalität

Im Basisfall (vier Jahre Training, ein Tag Prognosehorizont) ordnet sich die Prognosegüte unter beiden Verlustmaßen nach der Modellkomplexität, wie Tabelle 2 zeigt. Die historische Matrix schneidet am schlechtesten ab, während der GARCH-Schätzer sie deutlich verbessert und DCC-GARCH nochmals einen kleinen Zusatzgewinn liefert. QLIKE und MSE stimmen hierbei in dieser Reihenfolge überein.

Kovarianzschätzer	QLIKE	MSE ($\times 10^{-7}$)
Historisch	-152,81	4,28
GARCH	-155,37	3,52
DCC-GARCH	-156,12	3,44

Tabelle 2: Prognosequalität der Kovarianzschätzer im Basisfall

TRBC, Training 1008 Handelstage, Prognosehorizont 1 Tag, bewertet über die volle Historie vom 12.02.2003 bis 09.06.2026; niedrigere Werte bedeuten eine bessere Prognose. QLIKE gemittelt über 6013 Termine, an denen alle drei Schätzer definiert sind (die historische Matrix ist an einzelnen Terminen singulär); MSE über alle 6079 Termine, an denen dieser Ausfall nicht auftritt.

Wie scharf die beiden Verlustmaße trennen, unterscheidet sich allerdings erheblich. Der DM-Test in Tabelle 3 verwirft die Nullhypothese gleicher erwarteter Verluste unter QLIKE in allen drei paarweisen Vergleichen auf dem 1-%-Niveau, wobei dies trotz der insgesamt geringen Differenz auch für den Vergleich von DCC-GARCH und GARCH gilt. Der Grund hierfür liegt darin, dass beide Schätzer dieselben Varianzprognosen verwenden, wodurch die Verlustdifferenz kaum streut und fast ausschließlich aus dem Korrelationsbeitrag stammt. Unter dem MSE sind die Abstände zur historischen Matrix hingegen nur auf dem 5-%-Niveau signifikant, während der Unterschied zwischen DCC und GARCH nicht mehr von null zu trennen ist. Belastbar ist somit, dass beide dynamischen Schätzer die historische Matrix unter dem primären QLIKE-

Kriterium hochsignifikant schlagen und auch der Zusatznutzen der dynamischen Korrelation dort nachweisbar ist, während der MSE nur die gröbere Rangfolge bestätigt.

Vergleich	$\varnothing \Delta$ Verlust	t -Statistik	p -Wert	Termine
<i>QLIKE</i>				
GARCH vs. Historisch	-2,563	-4,18	<0,001***	6013
DCC-GARCH vs. Historisch	-3,308	-5,28	<0,001***	6013
DCC-GARCH vs. GARCH	-0,744	-13,86	<0,001***	6079
<i>MSE ($\times 10^{-7}$)</i>				
GARCH vs. Historisch	-0,764	-2,23	0,026**	6079
DCC-GARCH vs. Historisch	-0,846	-2,11	0,035**	6079
DCC-GARCH vs. GARCH	-0,082	-1,26	0,207	6079

Tabelle 3: Diebold-Mariano-Tests auf die Verlustdifferenzen (Basisfall)

Basisfall, bewertet über die volle Historie vom 12.02.2003 bis 09.06.2026. Negative Differenzen bedeuten, dass der erstgenannte Schätzer besser prognostiziert; ***, **, * = 1-, 5-, 10-%-Niveau.

Über das gesamte Untersuchungsdesign hinweg ist der statistische Vorsprung nahezu vollständig, da DCC-GARCH unter dem primären QLIKE-Kriterium in 37 von 40 Kombinationen und unter dem MSE in sämtlichen 40 besser prognostiziert als die historische Matrix (siehe Tabelle 10 im Anhang). Da alle Läufe für diesen Vergleich denselben Bewertungszeitraum ab 2010 nutzen und sich ihre Trainingsfenster stark überlappen, ist diese Auszählung als Robustheit über Spezifikationen hinweg und nicht als 40 voneinander unabhängige Bestätigungen zu verstehen. Wie stark der Vorsprung ausfällt, hängt jedoch von der Spezifikation ab, wie Tabelle 4 zeigt. Mit der Länge des Trainingsfensters nimmt er bis etwa fünf Jahren zu und stabilisiert sich danach, wobei bei einjährigem Training unter QLIKE kein Vorteil vorliegt und der GARCH-Schätzer sogar schlechter abschneidet als die historische Matrix. Eine mögliche Erklärung hierfür ist, dass die dynamischen Modelle insgesamt mehr Parameter schätzen müssen und deshalb bei einer geringen Datenbasis schlechter abschneiden, obwohl ihre Annahmen näher an der Realität liegen. Beim MSE ist die Ordnung nach Modellkomplexität dagegen über alle dargestellten Trainingsfenster und Prognosehorizonte hinweg vorzufinden.

Über den Prognosehorizont bleibt der Vorsprung unter QLIKE dagegen nahezu konstant, während er unter dem MSE relativ zum Verlustniveau sogar zunimmt. Wie jedoch im Abschnitt zu den Bewertungskriterien dargelegt, verändert sich mit der Fensterlänge wegen der später beginnenden Zeitreihen auch die Zahl der investierbaren Sektoren, weshalb die Entwicklung über die Trainingsfenster nur mit Vorsicht interpretiert werden sollte.

Neben der bereits genannten Dimensionsabhängigkeit des QLIKE ist im unteren Block zu beachten, dass der Proxy über h Tage mittelt und damit umso weniger streut, je länger der Horizont ist. Das MSE-Niveau fällt deshalb über die Horizonte, ohne dass die Prognosen dort besser wären, während dies beim QLIKE-Verlust nicht zu beobachten ist. Für die zweite Forschungsfrage fällt

Spezifikation	QLIKE			MSE ($\times 10^{-7}$)		
	Historisch	GARCH	DCC-GARCH	Historisch	GARCH	DCC-GARCH
252	-176,1	-175,9	-176,1	2,99	2,48	2,47
504	-171,0	-171,4	-171,8	3,42	2,81	2,74
756	-165,2	-166,1	-166,8	3,41	2,84	2,75
1008	-159,7	-161,1	-161,9	3,43	2,87	2,77
1260	-154,3	-156,1	-157,1	3,42	2,83	2,75
1512	-150,1	-151,8	-152,9	3,18	2,60	2,52
1764	-146,0	-147,7	-148,8	3,11	2,53	2,45
2016	-142,0	-143,8	-144,9	3,09	2,52	2,45
2268	-140,6	-142,5	-143,7	3,05	2,46	2,41
2520	-140,0	-142,0	-143,3	3,02	2,45	2,40
$h = 1$	-159,7	-161,1	-161,9	3,43	2,87	2,77
$h = 5$	-159,5	-160,9	-161,6	1,68	1,23	1,17
$h = 10$	-159,3	-160,9	-161,5	1,32	0,95	0,90
$h = 21$	-158,9	-160,2	-160,7	0,82	0,49	0,46

Tabelle 4: Prognosequalität über Trainingsfenster und Prognosehorizonte (TRBC)

Beide Blöcke bewertet ab 01.01.2010. Oberer Block: Trainingsfenster in Handelstagen bei $h = 1$, unterer Block: Prognosehorizonte bei 1008 Tagen Training.

die statistische Antwort dennoch eindeutig aus, da beide dynamischen Modelle die Prognose der Kovarianzmatrix im Basisfall signifikant verbessern und DCC-GARCH die historische Schätzung unter QLIKE in nahezu allen und unter dem MSE in sämtlichen 40 Kombinationen schlägt.

5.2 Ökonomische Performance

Die ökonomische Auswertung führt zu einem differenzierteren Bild. Für die erste Forschungsfrage zeigt Tabelle 5 zunächst, dass alle neun risikobasierten Kombinationen im Basisfall eine höhere Sharpe Ratio erreichen als das naive 1/N-Portfolio, bei ERC mit dynamischer Kovarianz allerdings nur um wenige Tausendstel. Vorne liegt dabei das MVP, gefolgt von HRP und ERC. Der Vorsprung entsteht vollständig auf der Risikoseite, da das 1/N-Portfolio zwar die höchste Rendite im Feld erzielt, diese aber mit der mit Abstand höchsten Volatilität erkauft.

Innerhalb der Portfoliomodelle kehrt sich die statistische Rangfolge im Basisfall weitgehend um, da bei MVP und ERC die historische Matrix vorne liegt und allein beim HRP der DCC-Schätzer marginal besser abschneidet. Der GARCH-Schätzer bleibt dabei in allen drei Modellen hinter der historischen Matrix zurück. Bei HRP und ERC senken die dynamischen Schätzer jedoch die realisierte Volatilität spürbar, während der DCC-Schätzer beim MVP auf einem ähnlichen Niveau wie der historische Schätzer liegt, wobei dieser Vorteil in der Sharpe Ratio durch die Einbindung der Rendite jeweils verschwindet. Genau diese Größe schlagen Engle und Colacito (2006) für das Minimum-Varianz-Portfolio als ökonomisches Auswahlkriterium vor,

Modell	Kovarianz	Rendite (%)	Vola (%)	Sharpe	Turnover	Anlagen > 1 %
MVP	Historisch	9,03	13,82	0,567	0,008	4,6
MVP	GARCH	8,55	13,94	0,532	0,258	4,9
MVP	DCC-GARCH	8,65	13,81	0,543	0,255	4,9
HRP	Historisch	9,27	16,74	0,509	0,012	17,6
HRP	GARCH	8,96	16,21	0,502	0,072	17,4
HRP	DCC-GARCH	9,13	16,17	0,513	0,094	17,4
ERC	Historisch	9,46	17,67	0,501	0,006	17,8
ERC	GARCH	9,14	17,32	0,490	0,034	17,8
ERC	DCC-GARCH	9,13	17,31	0,490	0,034	17,8
1/N	–	9,58	18,79	0,488	0,006	17,8

Tabelle 5: Out-of-Sample-Performance im Basisfall

TRBC, Training 1008 Handelstage, Prognosehorizont 1 Tag, bewertet über die volle Historie vom 12.02.2003 bis 09.06.2026; Rendite, Volatilität und Sharpe Ratio annualisiert, Turnover ohne Kosten; Anlagen > 1 % ist die durchschnittliche Zahl der Sektoren mit einem Gewicht von mehr als 1 % je Formationstermin.

da dessen realisierte Volatilität unmittelbar von der Kovarianzmatrix abhängt und nicht von den Renditen überlagert wird. Diese Idee kann auch auf HRP und ERC übertragen werden, da deren Gewichte ebenfalls allein aus der Kovarianzmatrix stammen.

Gleichzeitig fällt der mittlere Turnover des MVP mit der DCC- wie auch mit der GARCH-Kovarianz rund 32-mal so hoch aus wie mit der historischen, wodurch beide dynamischen Schätzer bei einer realen Umsetzung nochmals schlechter abschneiden würden. Grund für den hohen Turnover ist, dass die beiden dynamischen Modelle deutlich schneller auf Änderungen in der Volatilität reagieren, wodurch auch die Gewichtsverteilung der Portfolios angepasst wird, während die träge Stichprobenkovarianz die Gewichte nahezu unverändert lässt. Bei HRP und ERC fällt der Anstieg mit dem Faktor 5 bis 8 erheblich geringer aus, was auf die robustere Konstruktion der beiden Modelle zurückzuführen ist.

Wie unterschiedlich die Verfahren das Kapital verteilen, zeigt die durchschnittliche Zahl der Sektoren mit einem Gewicht von mehr als 1 % in Tabelle 5. Das MVP konzentriert sich im Mittel auf nur vier bis fünf der rund 18 investierbaren Sektoren, während HRP und ERC nahezu alle Sektoren nennenswert gewichten. Diese deutlich breitere Streuung trägt letztlich zur höheren Robustheit von HRP und ERC bei.

Statistisch abgesichert sind die Unterschiede in der Sharpe Ratio allerdings nicht, da Tabelle 12 im Anhang B für keinen der relevanten Vergleiche einen auch nur annähernd signifikanten p -Wert ausweist. Dies gilt sowohl zwischen den Kovarianzschätzern als auch gegenüber dem 1/N-Portfolio.

Die Auswirkungen proportionaler Transaktionskosten sind in Tabelle 13 im Anhang C dargestellt. Bereits bei 5 Basispunkten auf das umgeschlagene Volumen fällt die Sharpe Ratio des MVP mit DCC-Kovarianz von 0,543 auf 0,310 und liegt damit deutlich unter dem naiven

Portfolio mit 0,484, während die historische Variante mit 0,560 nahezu unverändert bleibt. Bei 20 Basispunkten werden beide dynamischen MVP-Varianten negativ.

Tabelle 6 fasst die Ergebnisse über alle 40 Kombinationen aus Trainingsfenster und Prognosehorizont zusammen, wobei je Portfoliomodell angegeben wird, wie oft das 1/N-Portfolio geschlagen wird und wie oft die dynamischen Schätzer die historische Matrix übertreffen. Bewertungsmaßstab ist dabei die Sharpe Ratio, wobei der Befund je nach Portfoliomodell unterschiedlich ausfällt. Zur ersten Forschungsfrage zeigt sich, dass HRP und ERC mit historischer Kovarianz das 1/N-Portfolio in rund 90 Prozent der Konstellationen schlagen, das MVP dagegen nur in einem Fünftel der Fälle. Ausschlaggebend ist die bereits angelegte Anfälligkeit des MVP, dass Schätzfehler im Optimierungsprozess verstärkt werden, wodurch konzentrierte Portfolios entstehen. Die im Basisfall beste Sharpe Ratio des MVP ist insofern nicht repräsentativ.

Zur zweiten Forschungsfrage zeigt sich ein klares Muster entlang der Portfoliomodelle, da die dynamischen Schätzer die historische Matrix beim MVP in mehr als der Hälfte der Läufe schlagen, beim HRP nur vereinzelt und beim ERC in keinem einzigen. Ökonomisch ist das gut erklärbar, weil das MVP als einziges Verfahren die Kovarianzmatrix vollständig einschließlich ihrer Inversen ausnutzt, während HRP lediglich die Clusterordnung und die Varianzen der Teilcluster verwendet und ERC die Risikobeiträge ausbalanciert. Eine bessere Kovarianzprognose zahlt sich folglich dort aus, wo sie am intensivsten genutzt wird, und bleibt folgenlos, wo das Verfahren die Matrix nur grob verwendet. Somit steht das ökonomische Ergebnis im Gegensatz zum statistischen Befund.

Modell	Kovarianz	vs. 1/N	vs. historischer Matrix
MVP	Historisch	8/40	–
MVP	GARCH	15/40	22/40
MVP	DCC-GARCH	17/40	26/40
HRP	Historisch	35/40	–
HRP	GARCH	16/40	2/40
HRP	DCC-GARCH	19/40	3/40
ERC	Historisch	36/40	–
ERC	GARCH	17/40	0/40
ERC	DCC-GARCH	20/40	0/40

Tabelle 6: Ergebnisse über alle empirischen Läufe

Alle 40 Kombinationen aus Trainingsfenster und Prognosehorizont, bewertet ab 01.01.2010; ausgewiesen ist, wie oft die Sharpe Ratio höher ausfällt als beim jeweiligen Vergleichsmaßstab.

Auch über die Trainingsfenster hinweg bleibt dieses Muster erhalten (siehe Abb. 3). Beim MVP liegt DCC in allen zehn Fenstern über der historischen Matrix, bei HRP in einem und bei ERC in keinem. Der GARCH-Schätzer folgt diesem Muster bei HRP und ERC, erreicht beim MVP mit sechs von zehn Fenstern aber einen deutlich schwächeren Vorsprung als DCC. Dass

DCC hier beim MVP vorne liegt, während im Basisfall die historische Matrix führt, ist kein Widerspruch, sondern ein Zeitraumeffekt, da diese Vergleiche auf dem gemeinsamen Zeitraum ab 2010 beruhen und das MVP mit dynamischer Kovarianz gerade in der Phase 2010–2019 vorne liegt (siehe Anhang A). Die absoluten Unterschiede fallen dabei klein aus, weshalb angesichts der insignifikanten Tests auf Sharpe-Differenzen keine belastbare Rangfolge abgeleitet werden sollte.




Abbildung 3: Sharpe Ratio über die Trainingsfenster
TRBC, Prognosehorizont 1 Tag, Bewertung ab 01.01.2010 für alle Fenster.

Deutlicher ist der Befund über den Prognosehorizont in Tabelle 7. Der tägliche Basisfall dient dabei vor allem dazu, den Effekt der Kovarianzdynamik ohne die Nebenwirkungen seltenerer Rebalancierung zu isolieren, jedoch werden in der Realität auch längere Rebalancierungszyklen relevant. Wird seltener rebalanciert, bleibt die Sharpe Ratio der historischen Matrix beim MVP praktisch konstant, während sie für DCC und ebenso für GARCH bei den beiden längeren Horizonten deutlich fällt und der Turnover je Rebalancierung gleichzeitig auf mehr als das Doppelte steigt. Der Verlauf ist dabei nicht monoton, da beide dynamischen Schätzer bei einem Horizont von fünf Tagen zunächst ihren höchsten Wert im gesamten Feld erreichen und erst danach zurückfallen. Eine Erklärung hierfür ist, dass sich die historisch geschätzte Kovarianzmatrix nur langsam mit der Zeit verändert, weshalb ihre Prognose schon bei kurzen Vorhersagezeiträumen keine aktuelle Dynamik abbildet und über eine längere Halteperiode entsprechend wenig veraltet. Die GARCH-Modelle hingegen reflektieren Abweichungen nahezu sofort, weshalb ihre Prognose zwar den Formationszeitpunkt genau trifft, über die Halteperiode hinweg aber schnell veraltet. Das Maximum bei fünf Tagen deutet darauf hin, dass ein Teil der täglichen Umschichtungen auf Schätzrauschen und nicht auf verwertbare Dynamik reagiert, sodass dessen Wegfall die Performance zunächst verbessert, bevor das Veralten der Prognose überwiegt. Erkennbar ist das auch am Turnover, da dessen hohes Niveau anzeigt, wie stark

sich die Kovarianzmatrix der dynamischen Modelle über eine längere Halteperiode verändert. Aufgrund der selteneren Rebalancierung fällt der über die gesamte Historie kumulierte Turnover trotz des höheren Werts je Rebalancierung jedoch geringer aus, womit auch die Kostenbelastung einer realen Umsetzung sinken würde. Bei HRP und ERC bleiben die Sharpe Ratios hingegen weitestgehend stabil, was wiederum auf die Robustheit dieser Verfahren hindeutet.

h (Tage)	1/N	Kovarianz	MVP	HRP	ERC	Turnover MVP
1	0,594	Historisch	0,606	0,592	0,604	0,008
		GARCH	0,599	0,592	0,591	0,258
		DCC-GARCH	0,620	0,611	0,592	0,255
5	0,597	Historisch	0,597	0,588	0,605	0,021
		GARCH	0,639	0,587	0,592	0,527
		DCC-GARCH	0,654	0,596	0,594	0,522
10	0,601	Historisch	0,610	0,600	0,610	0,033
		GARCH	0,524	0,578	0,589	0,603
		DCC-GARCH	0,545	0,575	0,590	0,598
21	0,602	Historisch	0,615	0,605	0,612	0,058
		GARCH	0,524	0,598	0,598	0,587
		DCC-GARCH	0,532	0,595	0,600	0,587

Tabelle 7: Sharpe Ratios und Turnover über die Prognosehorizonte (TRBC, Training 1008 Tage) Annualisierte Sharpe Ratio, bewertet ab 01.01.2010; Turnover je Rebalancierung, also nicht auf gleiche Frequenz normiert.

5.3 Einordnung in die Literatur

Die berichteten Befunde lassen sich abschließend gegen die eingangs skizzierte Literatur halten.

Dass alle drei risikobasierten Verfahren das naive Portfolio im Basisfall übertreffen, widerspricht zunächst DeMiguel et al. (2009). Deren Argument greift hier jedoch nur zur Hälfte, da von den beiden Schätzfehlerquellen allein die Kovarianzmatrix verbleibt. Nach Broadie (1993) richten gerade die erwarteten Renditen den größeren Schaden an. Hinzu kommt das Anlageuniversum, denn breit diversifizierte Sektorindizes lassen sich stabiler schätzen als Einzeltitel.

Die Unterschiede zwischen den Verfahren fügen sich dagegen gut in die vorliegende Evidenz ein. HRP schlägt das naive Portfolio in 35 von 40 Läufen und stützt damit die Robustheit, die López de Prado (2016) und Sen et al. (2022) berichten, auch wenn dort gegen ein Varianzminimierendes statt gegen ein gleichgewichtetes Portfolio verglichen wird. Für ERC gilt die Einschränkung von Chaves et al. (2011), da der Vorsprung gegenüber dem naiven Portfolio im Basisfall nur wenige Tausendstel beträgt. Deutlich ausgeprägter ist dagegen ihr zweiter Befund, dass ERC das Minimum-Varianz-Portfolio übertrifft, denn ERC liegt in 36 von 40 Läufen über dem naiven Portfolio und das MVP nur in acht. Hinter dieser Schwäche des MVP steht die Fehlermaximierung, die Michaud (1989) beschreibt, sichtbar in der von Lee (2011) dokumentierten Konzentration

auf wenige Anlagen. Am genauesten entspricht das Bild jedoch Behr et al. (2008), denn dort wie hier senkt das MVP das Risiko spürbar, ohne die Sharpe Ratio gegenüber dem gleichgewichteten Portfolio signifikant zu verbessern.

Für die zweite Forschungsfrage ist der Abstand zwischen statistischem und ökonomischem Ergebnis der entscheidende Punkt. Dass die Tests auf Sharpe-Differenzen durchweg insignifikant ausfallen, bestätigt den Einwand von Engle und Colacito (2006) für den vorliegenden Datensatz. Die robusten Verlustfunktionen von Patton (2011) und Laurent et al. (2013) trennen auf denselben Daten dagegen klar. Beide Kriterien verhalten sich damit genau so, wie es die jeweiligen Arbeiten erwarten lassen. Auch Ardia et al. (2017) stehen nur scheinbar im Widerspruch, denn eine verzerrte Kovarianzmatrix wird erst dort teuer, wo ein Verfahren sie intensiv nutzt. Ihre Einordnung, nach der das MVP empfindlicher reagiert als ERC, bildet sich hier ab, denn ein Schätzerwechsel bewegt Sharpe Ratio und Turnover des MVP um ein Mehrfaches stärker. Robustheit hat damit ihren Preis, da ein Verfahren, das eine schlechte Schätzung verzeiht, aus einer besseren auch keinen Nutzen zieht. Die größte Nähe besteht zu Moura et al. (2020), die für hochdimensionale Kovarianzmatrizen ebenfalls finden, dass die statistisch beste Spezifikation nicht die ökonomisch beste sein muss. Dieser bereits existente ökonomische Nachteil würde durch Transaktionskosten noch verstärkt werden.

Jedes der beiden Ergebnisse ist für sich in der Literatur belegt, ihre Verbindung dagegen kaum, da Arbeiten zur Kombination risikobasierter Allokation mit multivariaten GARCH-Prognosen bislang selten sind.

6 Limitationen

Die Aussagekraft der Ergebnisse ist in mehrfacher Hinsicht begrenzt, wobei die Einschränkungen im Folgenden nach ihrem Gewicht für die Interpretation geordnet werden.

Eine zentrale Limitation ist dabei, dass der Backtest ohne Handelskosten rechnet und Kosten nur nachträglich als proportionaler Abschlag berücksichtigt werden, obwohl sich die Verfahren im Turnover um den Faktor 32 unterscheiden. Die berichteten Kennzahlen begünstigen damit die dynamischen Schätzer, deren Nachteil unter realen Kosten größer ausfiele als ausgewiesen. Umgekehrt wird die Aussage des Abschnitts zur ökonomischen Performance dadurch nicht geschwächt, sondern verschärft, da dieser Nachteil bereits ohne Kosten vorhanden ist.

Auf der Messseite ist der realisierte Proxy die wesentliche Einschränkung, da er für $h = 1$ aus einem einzigen äußeren Produkt besteht und damit den Rang eins hat. Beide Verlustfunktionen bleiben nach Patton (2011) und Laurent et al. (2013) unabhängig von der Genauigkeit des

Proxys rangerhaltend, jedoch begrenzt das geringe Signal-Rausch-Verhältnis die Teststärke des DM-Tests, wobei der MSE stärker betroffen ist als der QLIKE-Verlust. Intraday-Daten würden einen erheblich präziseren Proxy liefern, standen für diese Arbeit aber nicht zur Verfügung. Hinzu kommt, dass ausschließlich die relative Prognosegüte bewertet wurde und nicht die absolute Kalibrierung der prognostizierten Volatilität. Ob die Modelle das Risikoniveau im Mittel treffen, bleibt damit offen.

Des Weiteren beruht die gesamte Auswertung auf einem einzigen Universum, dessen Sektorindizes rechnerische Größen sind und sich nicht unmittelbar handeln lassen, weshalb eine direkte Replikation der optimierten Portfolios nicht möglich ist. Gezeigt ist damit, dass die Befunde für diese Datengrundlage gelten, nicht aber, ob sie sich auf andere Märkte übertragen lassen.

6.1 Ausblick

Aus den Ergebnissen und den genannten Einschränkungen ergeben sich vier Ansatzpunkte für weitere Untersuchungen.

Auf der Modellseite wird ausschließlich ein GARCH(1,1) geschätzt, obwohl dieses Modell im Vergleich zur Realität vereinfachte Annahmen trifft. Beispielsweise zeigt sich in empirischen Untersuchungen, dass negative Schocks in der Regel einen stärkeren Einfluss auf die nachfolgende Volatilität haben als positive. Anders als das einfache GARCH-Modell binden Modelle wie GJR-GARCH und EGARCH diese Asymmetrie ein und sind somit realitätsnäher, während sich über höhere Ordnungen oder ein GARCH-MIDAS zusätzlich längerfristige Komponenten der Volatilität erfassen lassen. Da der ökonomische Nachteil der dynamischen Schätzer hier hauptsächlich aus dem Turnover und nicht aus der Prognosegüte stammt, wäre allerdings zu prüfen, ob eine realitätsnähere Varianzdynamik daran überhaupt etwas ändert.

Auf der Allokationsseite ließe sich das Feld um modernere Verfahren wie Hierarchical Equal Risk Contribution (Raffinot, 2018) oder Nested Clustered Optimization (López de Prado, 2019) erweitern, die die hierarchische Struktur von HRP anders auswerten. Beide nutzen die Kovarianzmatrix intensiver als HRP, ohne sie wie das MVP vollständig zu invertieren. Da sich der Mehrwert einer besseren Prognose in dieser Arbeit genau danach richtet, wie intensiv ein Verfahren die Matrix nutzt, ließe sich an ihnen prüfen, ob der Zusammenhang auch auf den Stufen dazwischen gilt. Offen bleibt zudem, ob eine bessere Kovarianzmatrix in Verfahren, die zusätzlich eine Renditeprognose verwenden, einen größeren Vorteil liefert, da die Matrix dort nicht nur das Risiko begrenzt, sondern auch die Gewichtung der erwarteten Renditen bestimmt.

Der dritte Ansatzpunkt betrifft die Transaktionskosten, die hier weder im Backtest noch in der Optimierung berücksichtigt werden. Ein kostenbewusster Optimierer würde den Turnover in die Zielfunktion aufnehmen und dadurch einen Teil der Belastung vermeiden, statt sie nur zu erleiden. Ob die dynamischen Schätzer unter einer solchen Nebenbedingung weiterhin zurückfallen, ist offen und wäre für die praktische Bewertung der entscheidende Test.

Schließlich sollten die Befunde an weiteren Datensätzen überprüft werden, etwa an Einzeltiteln, anderen Regionen oder Anlageklassen mit geringerer durchschnittlicher Korrelation. Gerade die hohe paarweise Korrelation des hier verwendeten Universums begrenzt die Diversifikationsmöglichkeiten von vornherein und könnte den Spielraum für eine bessere Kovarianzprognose systematisch verengen.

7 Fazit

Die Arbeit hat zwei Fragen getrennt untersucht, nämlich ob risikobasierte Portfoliomodelle das naive 1/N-Portfolio schlagen und ob GARCH-basierte Kovarianzprognosen gegenüber der historischen Schätzung einen Mehrwert stiften.

Zur ersten Frage hängt die Antwort stark vom gewählten Verfahren ab. HRP und ERC mit historischer Kovarianz übertreffen das 1/N-Portfolio in rund neun von zehn untersuchten Konstellationen und erweisen sich als robust gegenüber Variationen von Trainings- und Prognosefenster. Das Minimum-Varianz-Portfolio erzielt im Basisfall zwar die höchste Sharpe Ratio, schlägt 1/N über alle Läufe hinweg aber nur in einem Fünftel der Fälle und reagiert am empfindlichsten auf Schätzfehler. Für die Praxis sprechen diese Ergebnisse damit eher für die robusteren Verfahren als für die Varianzminimierung, wobei einschränkend gilt, dass keiner der Vorsprünge gegenüber 1/N statistisch signifikant ist.

Zur zweiten Frage entscheidet das angelegte Kriterium über die Antwort, worin zugleich der Hauptbefund liegt. Statistisch ist das Ergebnis eindeutig, da DCC-GARCH die Kovarianzmatrix in allen 40 Läufen unter dem MSE und in nahezu allen unter dem QLIKE-Verlust besser prognostiziert als die historische Schätzung und die Abstände zur historischen Matrix im DM-Test signifikant sind. Ökonomisch schlägt sich dieser Vorsprung jedoch nur dort nieder, wo die Kovarianzmatrix tatsächlich intensiv genutzt wird, also beim MVP und nicht bei HRP oder ERC. Das ist konsistent mit der Konstruktion der Verfahren, da beide die Matrix nur grob nutzen und gerade deshalb robust, zugleich aber auch unempfindlich gegenüber ihrer Verbesserung sind. Der Preis der Dynamik ist der Turnover, der beim MVP um den Faktor 32 höher liegt und den ohnehin geringen Vorsprung unter realen Handelskosten aufzehren würde.

Der übergreifende Schluss lautet damit, dass eine bessere Risikoprognose nicht automatisch eine bessere Anlageentscheidung ist. Die GARCH-Modelle leisten das, wofür sie konstruiert sind, und die synthetische Validierung zeigt, dass sie genau dann einen Mehrwert liefern, wenn der datengenerierende Prozess ihre Annahmen erfüllt. Selbst dann ist dieser Mehrwert jedoch nicht garantiert. Im DCC-Datensatz aus Anhang D liefert das korrekt spezifizierte DCC-Modell zwar in allen zehn Trainingsfenstern den besseren QLIKE-Verlust und die niedrigere realisierte Volatilität, unterliegt beim MVP-Sharpe aber in drei von zehn Fenstern dem falsch spezifizierten GARCH-Modell. Prognosegüte und Anlageerfolg fallen somit bereits bei bekanntem datengenerierendem Prozess auseinander. Auf realen Sektordaten ist die verwertbare Struktur jedoch zu schwach, um die Kosten der laufenden Umschichtung zu rechtfertigen. Nicht die Prognosegüte ist folglich die bindende Restriktion, sondern der Handel, den ihre Nutzung auslöst.

Literatur

- Ardia, D., Bolliger, G., Boudt, K., & Gagnon-Fleury, J.-P. (2017). The impact of covariance misspecification in risk-based portfolios. *Annals of Operations Research*, 254(1–2), 1–16. <https://doi.org/10.1007/s10479-017-2474-7>
- Behr, P., Güttler, A., & Miebs, F. (2008). *Is minimum-variance investing really worth the while? An analysis with robust performance inference* (Techn. Ber.). EDHEC-Risk Institute. https://www.cfr-cologne.de/download/kolloquium/2009/beh_r_et_al.pdf
- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327. [https://doi.org/10.1016/0304-4076\(86\)90063-1](https://doi.org/10.1016/0304-4076(86)90063-1)
- Bollerslev, T. (1990). Modelling the Coherence in Short-Run Nominal Exchange Rates: A Multivariate Generalized ARCH Model. *The Review of Economics and Statistics*, 72(3), 498–505. <https://doi.org/10.2307/2109358>
- Broadie, M. (1993). Computing efficient frontiers using estimated parameters. *Annals of Operations Research*, 45(1), 21–58. <https://doi.org/10.1007/BF02282040>
- Chaves, D., Hsu, J., Li, F., & Shakernia, O. (2011). Risk Parity Portfolio vs. Other Asset Allocation Heuristic Portfolios. *The Journal of Investing*, 20(1), 108–118. <https://doi.org/10.3905/joi.2011.20.1.108>
- DeMiguel, V., Garlappi, L., & Uppal, R. (2009). Optimal Versus Naive Diversification: How Inefficient is the 1/N Portfolio Strategy? *The Review of Financial Studies*, 22(5), 1915–1953. <https://doi.org/10.1093/rfs/hhm075>
- Diebold, F. X., & Mariano, R. S. (1995). Comparing Predictive Accuracy. *Journal of Business and Economic Statistics*, 13(3), 253–263. <https://doi.org/10.1080/07350015.1995.10524599>
- Engle, R. F. (1982). Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation. *Econometrica*, 50(4), 987–1007. <https://doi.org/10.2307/1912773>
- Engle, R. F. (2002). Dynamic Conditional Correlation: A Simple Class of Multivariate Generalized Autoregressive Conditional Heteroskedasticity Models. *Journal of Business and Economic Statistics*, 20(3), 339–350. <https://doi.org/10.1198/073500102288618487>
- Engle, R. F., & Colacito, R. (2006). Testing and Valuing Dynamic Correlations for Asset Allocation. *Journal of Business and Economic Statistics*, 24(2), 238–253. <https://doi.org/10.1198/073500106000000017>
- Engle, R. F., & Sheppard, K. (2001). *Theoretical and Empirical Properties of Dynamic Conditional Correlation Multivariate GARCH* (NBER Working Paper Nr. 8554). National Bureau of Economic Research. <https://doi.org/10.3386/w8554>
- Jobson, J. D., & Korkie, B. M. (1981). Performance Hypothesis Testing with the Sharpe and Treynor Measures. *The Journal of Finance*, 36(4), 889–908. <https://doi.org/10.1111/j.1540-6261.1981.tb04891.x>
- Laurent, S., Rombouts, J. V. K., & Violante, F. (2013). On loss functions and ranking forecasting performances of multivariate volatility models. *Journal of Econometrics*, 173(1), 1–10. <https://doi.org/10.1016/j.jeconom.2012.08.004>

- Lee, W. (2011). Risk-Based Asset Allocation: A New Answer to an Old Question? *The Journal of Portfolio Management*, 37(4), 11–28. <https://doi.org/10.3905/jpm.2011.37.4.011>
- López de Prado, M. (2016). Building Diversified Portfolios that Outperform Out of Sample. *The Journal of Portfolio Management*, 42(4), 59–69. <https://doi.org/10.3905/jpm.2016.42.4.059>
- López de Prado, M. (2019). A Robust Estimator of the Efficient Frontier. <https://doi.org/10.2139/ssrn.3469961>
- Maillard, S., Roncalli, T., & Teïletche, J. (2010). The Properties of Equally Weighted Risk Contribution Portfolios. *The Journal of Portfolio Management*, 36(4), 60–70. <https://doi.org/10.3905/jpm.2010.36.4.060>
- Markowitz, H. (1952). Portfolio Selection. *The Journal of Finance*, 7(1), 77–91. <https://doi.org/10.1111/j.1540-6261.1952.tb01525.x>
- Memmel, C. (2003). Performance Hypothesis Testing with the Sharpe Ratio. *Finance Letters*, 1(1), 21–23.
- Michaud, R. O. (1989). The Markowitz Optimization Enigma: Is 'Optimized' Optimal? *Financial Analysts Journal*, 45(1), 31–42. <https://doi.org/10.2469/faj.v45.n1.31>
- Moura, G. V., Santos, A. A. P., & Ruiz, E. (2020). Comparing high-dimensional conditional covariance matrices: Implications for portfolio selection. *Journal of Banking & Finance*, 118, 105882. <https://doi.org/10.1016/j.jbankfin.2020.105882>
- Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256. <https://doi.org/10.1016/j.jeconom.2010.03.034>
- Raffinot, T. (2018). The Hierarchical Equal Risk Contribution Portfolio. <https://doi.org/10.2139/ssrn.3237540>
- Sen, J., Mehtab, S., Dutta, A., & Mondal, S. (2022). Hierarchical Risk Parity and Minimum Variance Portfolio Design on NIFTY 50 Stocks. <https://doi.org/10.48550/arXiv.2202.02728>
- West, K. D. (1996). Asymptotic Inference about Predictive Ability. *Econometrica*, 64(5), 1067–1084. <https://doi.org/10.2307/2171956>

Appendices

A Voller und gemeinsamer Bewertungszeitraum

Sämtliche im Ergebnisteil berichteten Vergleiche über Trainingsfenster hinweg wurden auf dem gemeinsamen Zeitraum ab 2010 gerechnet. Dieser Anhang begründet, warum diese Einschränkung nötig ist, und zeigt, was ohne sie gemessen würde.

Ohne die Einschränkung bewertet jedes Trainingsfenster einen anderen Zeitraum, da der Out-of-Sample-Beginn von März 2000 beim kürzesten auf November 2008 beim längsten Fenster wandert. Der Lauf mit einem Jahr Training enthält damit das Platzen der Dotcom-Blase, während der Lauf mit zehn Jahren Training erst nach der Finanzkrise beginnt und nur die Erholung abdeckt, wodurch dessen Kennzahlen angehoben werden, ohne dass dies etwas über die Schätzqualität aussagt. Wie stark der Effekt wiegt, zeigt Abbildung 4, in der die Sharpe Ratio über die Trainingsfenster einmal über die volle Historie und einmal über den gemeinsamen Zeitraum aufgetragen ist. Der Sprung beim längsten Fenster tritt links auch beim 1/N-Portfolio auf, obwohl dieses überhaupt keine Schätzung vornimmt, und verschwindet rechts vollständig. Es handelt sich somit um einen reinen Stichprobeneffekt.




Abbildung 4: Sharpe Ratio über die Trainingsfenster, voller und gemeinsamer Bewertungszeitraum

TRBC, Prognosehorizont 1 Tag, links die volle Historie des jeweiligen Fensters, rechts der für alle Fenster identische Zeitraum ab 01.01.2010.

Tabelle 8 und Tabelle 9 stellen je Trainingsfenster die Kennzahlen über die volle Historie denen über den gemeinsamen Zeitraum ab 2010 gegenüber. Die erste Tabelle weist neben der mittleren Größe des Anlageuniversums den QLIKE-Verlust der historischen Matrix und der

beiden dynamischen Kovarianzschätzer aus, die zweite die Sharpe Ratio des MVP mit allen drei Kovarianzschätzern sowie die des 1/N-Portfolios. Die 90-%-Verfügbarkeitsregel lässt die zuletzt hinzugekommenen Sektoren in langen Fenstern erst spät oder gar nicht zu, weshalb die Fensterlänge über die Dimension der Kovarianzmatrix auch das QLIKE-Niveau mitbestimmt.

Training	$\varnothing N$	Historisch		GARCH		DCC-GARCH	
		voll	gem.	voll	gem.	voll	gem.
252	20,3	-161,5	-176,1	-161,8	-175,9	-162,0	-176,1
504	19,7	-159,2	-171,0	-160,4	-171,4	-160,8	-171,8
756	19,1	-156,0	-165,2	-157,9	-166,1	-158,4	-166,8
1008	18,5	-152,8	-159,7	-155,4	-161,1	-156,1	-161,9
1260	17,9	-149,1	-154,3	-152,2	-156,1	-153,1	-157,1
1512	17,4	-146,1	-150,1	-149,2	-151,8	-150,2	-152,9
1764	16,9	-143,0	-146,0	-145,9	-147,7	-147,0	-148,8
2016	16,4	-139,6	-142,0	-142,4	-143,8	-143,7	-144,9
2268	16,2	-138,3	-140,6	-141,0	-142,5	-142,3	-143,7
2520	16,2	-139,1	-140,0	-141,3	-142,0	-142,7	-143,3

Tabelle 8: QLIKE über vollen und gemeinsamen Bewertungszeitraum (TRBC, $h = 1$)

voll bezeichnet die volle Historie des jeweiligen Fensters, *gem.* den gemeinsamen Zeitraum ab 01.01.2010. $\varnothing N$ ist die mittlere Zahl investierbarer Sektoren im gemeinsamen Zeitraum.

Training	MVP Historisch		MVP GARCH		MVP DCC-GARCH		1/N	
	voll	gem.	voll	gem.	voll	gem.	voll	gem.
252	0,419	0,515	0,377	0,505	0,384	0,518	0,400	0,592
504	0,406	0,495	0,453	0,627	0,452	0,633	0,406	0,601
756	0,432	0,525	0,427	0,561	0,425	0,564	0,422	0,593
1008	0,567	0,606	0,532	0,599	0,543	0,620	0,488	0,594
1260	0,496	0,613	0,458	0,592	0,470	0,620	0,412	0,573
1512	0,445	0,574	0,424	0,562	0,440	0,587	0,407	0,576
1764	0,403	0,535	0,429	0,563	0,437	0,578	0,373	0,537
2016	0,363	0,525	0,398	0,545	0,398	0,547	0,378	0,545
2268	0,375	0,550	0,427	0,581	0,416	0,574	0,395	0,551
2520	0,556	0,521	0,606	0,582	0,600	0,580	0,603	0,563

Tabelle 9: Sharpe Ratio über vollen und gemeinsamen Bewertungszeitraum (TRBC, $h = 1$)

voll bezeichnet die volle Historie des jeweiligen Fensters, *gem.* den gemeinsamen Zeitraum ab 01.01.2010. Ausgewiesen ist die annualisierte Sharpe Ratio.

Wie oft welcher Schätzer über alle 40 Kombinationen vorne liegt, weist Tabelle 10 aus, getrennt nach der Sharpe Ratio je Portfoliomodell und den beiden Verlustmaßen. Dass die Rangfolge der Schätzer nicht am Basisfall hängt, zeigt sich dort deutlich, da unter beiden Verlustmaßen DCC-GARCH nahezu durchgängig vorne liegt, während ökonomisch bei HRP und ERC die historische Matrix dominiert.

Zeitlich lokalisieren lässt sich der Bruch über die Teilperioden des Basisfalls in Tabelle 11. Das QLIKE-Niveau springt ab 2022 deutlich nach unten, wobei dieser Sprung exakt mit der Erweiterung des Universums von 17 auf 25 Sektoren im September 2022 zusammenfällt.

Kennzahl	Historisch	GARCH	DCC-GARCH
Sharpe MVP	14/40	6/40	20/40
Sharpe HRP	36/40	1/40	3/40
Sharpe ERC	40/40	0/40	0/40
QLIKE	3/40	0/40	37/40
Kovarianz-MSE	0/40	1/40	39/40
QLIKE (DCC vs. Hist.)	–	–	37/40
MSE (DCC vs. Hist.)	–	–	40/40

Tabelle 10: Häufigkeit des besten Kovarianzschätzers je Kennzahl

Alle 40 Kombinationen aus Trainingsfenster und Prognosehorizont, bewertet ab 01.01.2010. In den oberen beiden Blöcken ist ausgewiesen, wie oft der jeweilige Schätzer die höchste Sharpe Ratio beziehungsweise den niedrigsten Verlust liefert; der untere Block zählt zusätzlich direkt, in wie vielen der 40 Läufe DCC-GARCH die historische Matrix schlägt, unabhängig davon, ob GARCH dort noch besser abschneidet.

Innerhalb der Periode 2022–2026 wächst das Universum anschließend nochmals von 25 auf 27 Sektoren, da zwei erst 2019 gestartete Reihen die 90-%-Verfügbarkeitsregel im 1008-Tage-Fenster erst 2024 beziehungsweise Ende 2024 erfüllen. Die Tabellenspanne 17–27 für diese Periode bildet somit beide Schritte ab. Der MSE zeigt an dieser Stelle keinen vergleichbaren Bruch, folgt dafür aber dem Volatilitätsniveau der Periode und steigt in der Finanzkrise auf mehr als das Siebzigfache des Werts der ruhigen Phase 2003–2007. Beide Kennzahlen sind über Perioden hinweg somit nur eingeschränkt vergleichbar, wenn auch aus unterschiedlichen Gründen.

Periode	N	QLIKE			MSE ($\times 10^{-7}$)			Sharpe			
		Hist.	GARCH	DCC	Hist.	GARCH	DCC	MVP Hist.	MVP GARCH	MVP DCC	1/N
2003–2007	16–16	-143,5	-146,8	-147,3	0,28	0,23	0,23	1,190	1,146	1,158	0,845
2008–2009	16–16	-119,7	-130,1	-131,2	21,03	16,87	16,72	-0,246	-0,303	-0,339	-0,120
2010–2019	16–17	-146,1	-147,2	-147,8	0,79	0,61	0,60	0,886	0,969	0,982	0,719
2020–2021	17–17	-133,1	-139,5	-140,3	20,18	16,67	15,88	0,436	0,391	0,417	0,828
2022–2026	17–27	-205,1	-204,7	-205,9	1,79	1,71	1,70	0,259	0,116	0,144	0,224

Tabelle 11: Teilperioden des Basisfalls: Universum, Prognosequalität und Performance

N ist die Spannweite der investierbaren Sektoren; QLIKE-Niveaus sind zwischen Perioden mit unterschiedlichem N nicht vergleichbar.

Aussagekräftig bleibt die Differenz zwischen den Schätzern innerhalb einer Periode, die erheblich variiert. In der Finanzkrise 2008/09 und im COVID-Zeitraum fällt sie um ein Vielfaches größer aus als in den ruhigen Phasen. Der Mehrwert der dynamischen Modellierung konzentriert sich damit auf Phasen mit ausgeprägten Volatilitätsschocks, in denen eine statische Matrix dem Risikoniveau am stärksten nachläuft.

Ökonomisch ist die Rangfolge ebenfalls periodenabhängig, da das MVP mit DCC-Kovarianz und ebenso mit GARCH-Kovarianz die historische Variante in der Phase 2010–2019 klar schlägt, in allen übrigen Teilperioden jedoch zurückliegt. Der Basisfall umfasst die volle Historie ab 2003 und mittelt über gegenläufige Teilperioden, weshalb dort die historische Matrix vorne liegt,

während die auf 2010 eingeschränkten Tabellen für das MVP zugunsten von DCC ausfallen. Beide Rechnungen sind korrekt, messen aber Unterschiedliches, wobei die Unterschiede in beide Richtungen durchgängig insignifikant sind und daher keine starke Aussage zulassen.

B Tests auf Sharpe-Differenzen

Tabelle 12 weist den Test von Jobson und Korkie (1981) in der Korrektur von Memmel (2003) für sämtliche paarweisen Vergleiche des Basisfalls aus, sowohl zwischen den Kovarianzschätzern innerhalb eines Portfoliomodells als auch gegenüber dem 1/N-Portfolio. Kein einziger Vergleich erreicht auch nur das 10-%-Niveau.

Vergleich	Δ Sharpe	z -Statistik	p -Wert
MVP Historisch vs. MVP GARCH	0,0352	0,55	0,584
MVP Historisch vs. MVP DCC-GARCH	0,0243	0,37	0,709
MVP GARCH vs. MVP DCC-GARCH	-0,0109	-0,78	0,435
HRP Historisch vs. HRP GARCH	0,0063	0,30	0,764
HRP Historisch vs. HRP DCC-GARCH	-0,0041	-0,18	0,859
HRP GARCH vs. HRP DCC-GARCH	-0,0104	-1,23	0,220
ERC Historisch vs. ERC GARCH	0,0105	0,95	0,342
ERC Historisch vs. ERC DCC-GARCH	0,0111	0,98	0,329
ERC GARCH vs. ERC DCC-GARCH	0,0006	0,27	0,784
MVP Historisch vs. 1/N	0,0797	0,69	0,487
MVP GARCH vs. 1/N	0,0445	0,41	0,681
MVP DCC-GARCH vs. 1/N	0,0554	0,51	0,611
HRP Historisch vs. 1/N	0,0210	0,66	0,509
HRP GARCH vs. 1/N	0,0147	0,37	0,711
HRP DCC-GARCH vs. 1/N	0,0251	0,61	0,541
ERC Historisch vs. 1/N	0,0132	0,85	0,395
ERC GARCH vs. 1/N	0,0027	0,13	0,898
ERC DCC-GARCH vs. 1/N	0,0021	0,10	0,923

Tabelle 12: Tests auf Unterschiede der Sharpe Ratios (Basisfall)

Basisfall, bewertet über die volle Historie vom 12.02.2003 bis 09.06.2026. Auf Überschussrenditen über die Fed Funds Rate; ***, **, * = 1-, 5-, 10-%-Niveau.

C Transaktionskosten

Tabelle 13 weist die Sharpe Ratios des Basisfalls nach Abzug proportionaler Transaktionskosten auf das je Rebalancierung umgeschlagene Volumen aus.

Modell	Kovarianz	Turnover	0 Bp.	5 Bp.	10 Bp.	20 Bp.
MVP	Historisch	0,008	0,567	0,560	0,553	0,539
MVP	GARCH	0,258	0,532	0,299	0,066	-0,400
MVP	DCC-GARCH	0,255	0,543	0,310	0,077	-0,388
HRP	Historisch	0,012	0,509	0,499	0,490	0,472
HRP	GARCH	0,072	0,502	0,447	0,391	0,279
HRP	DCC-GARCH	0,094	0,513	0,439	0,366	0,219
ERC	Historisch	0,006	0,501	0,497	0,493	0,484
ERC	GARCH	0,034	0,490	0,466	0,442	0,393
ERC	DCC-GARCH	0,034	0,490	0,465	0,440	0,391
1/N	–	0,006	0,488	0,484	0,480	0,472

Tabelle 13: Sharpe Ratios nach proportionalen Transaktionskosten (Basisfall)

Sharpe Ratio auf Überschussrenditen über die Fed Funds Rate nach Abzug von c Basispunkten auf das je Rebalancierung umgeschlagene Volumen; die 0-Bp.-Spalte entspricht damit exakt Tabelle 5.

D Synthetische Validierung

Ob die Modelle korrekt implementiert sind, lässt sich an echten Daten nicht prüfen, da der wahre datengenerierende Prozess unbekannt ist. Stattdessen werden drei simulierte Datensätze mit jeweils 20 Anlagen und 6.000 Handelstagen verwendet, die dieselbe unbedingte Risikostruktur besitzen (annualisierte Volatilitäten zwischen 15 % und 35 %, durchschnittliche Korrelation 0,35) und sich ausschließlich in der Dynamik der zweiten Momente unterscheiden. Der Monte-Carlo-Datensatz enthält unabhängige Ziehungen mit konstanter Kovarianz, in denen die historische Matrix korrekt spezifiziert ist. Beim GARCH-Datensatz kommt eine GARCH(1,1)-Dynamik je Anlage mit $\alpha = 0,08$ und $\beta = 0,90$ bei konstanter Korrelation hinzu, während der DCC-Datensatz zusätzlich eine DCC-Rekursion mit $a = 0,03$ und $b = 0,96$ enthält. Obwohl die wahre bedingte Kovarianzmatrix hier bekannt wäre, wird die Prognosegüte auch in der Simulation gegen den realisierten Proxy aus Gleichung 18 gemessen, damit die Ergebnisse mit denen auf den realen Daten vergleichbar sind.

Die Ergebnisse des Basisfalls zeigen Tabelle 14 und die DM-Tests in Tabelle 15. Im Monte-Carlo-Fall unterscheiden sich die drei Schätzer praktisch nicht, denn die Verlustdifferenz der dynamischen Schätzer gegenüber der historischen Matrix ist zwar signifikant, in der Höhe aber verschwindend gering. Im GARCH-Fall schlagen beide dynamischen Schätzer die historische Matrix signifikant, auch in Sharpe Ratio und realisierter Volatilität, unterscheiden sich untereinander aber nicht, da die Korrelation dort konstant ist. Erst im DCC-Fall ist DCC dem GARCH-Schätzer signifikant überlegen, sodass die Implementierung jeweils genau die Struktur erkennt, die tatsächlich vorhanden ist.

Datensatz	Kovarianz	QLIKE	MSE ($\times 10^{-8}$)	Vola (%)	Sharpe	Turnover
Monte Carlo	Historisch	-154,50	7,04	11,92	0,903	0,011
	GARCH	-154,47	7,04	11,95	0,896	0,074
	DCC-GARCH	-154,47	7,04	11,95	0,896	0,075
GARCH-Sim.	Historisch	-154,23	7,84	11,37	0,756	0,010
	GARCH	-157,25	7,57	9,85	0,854	0,154
	DCC-GARCH	-157,25	7,57	9,85	0,854	0,154
DCC-Sim.	Historisch	-154,13	9,86	11,93	0,561	0,011
	GARCH	-157,02	9,19	9,62	0,773	0,160
	DCC-GARCH	-162,13	8,98	8,99	0,783	0,152

Tabelle 14: Synthetische Validierung: Basisfall je Datengenerierungsprozess

20 simulierte Anlagen, Training 1008 Handelstage, Prognosehorizont 1 Tag; Performancekennzahlen für das MVP.

Datensatz	$\Delta G-H$	t	$\Delta D-H$	t	$\Delta D-G$	t
Monte Carlo	0,029***	6,07	0,029***	6,12	0,000	0,32
GARCH-Sim.	-3,025***	-24,69	-3,024***	-24,68	0,000	1,28
DCC-Sim.	-2,887***	-15,64	-7,998***	-35,68	-5,111***	-49,85

Tabelle 15: Synthetische Validierung: DM-Tests auf die QLIKE-Differenzen

G = GARCH, D = DCC-GARCH, H = historisch; negative Differenzen bedeuten eine bessere Prognose. ***, **, * = 1-, 5-, 10-%-Niveau.

Wie stabil dieses Bild über die Länge des Trainingsfensters ist, zeigt Tabelle 16. Da das Universum konstant 20 Anlagen umfasst und die Parameter des Prozesses über die gesamte Stichprobe unverändert bleiben, verschiebt sich das Niveau der Prognosekennzahlen kaum, denn das QLIKE-Niveau der historischen Matrix schwankt über alle zehn Fenster um höchstens gut zwei Punkte und das MSE-Niveau bleibt praktisch konstant. Auch die Rangfolge kehrt sich in keinem Fenster um, da DCC in allen 20 Läufen unter beiden Verlustmaßen besser prognostiziert als die historische Matrix.

Der Vorsprung der dynamischen Schätzer wächst dabei mit der Länge des Trainingsfensters und stabilisiert sich erst bei den längeren Fenstern. Im DCC-Datensatz steigt der QLIKE-Abstand zwischen DCC und historischer Matrix von 4,1 Punkten bei einem Jahr Training auf 8,5 Punkte bei zehn Jahren, im GARCH-Datensatz von 2,1 auf 2,8 Punkte. Auch wenn die Modelle also korrekt spezifiziert sind und der Prozess sich nicht verändert, zahlt sich eine breitere Datenbasis für die dynamischen Schätzer weiterhin aus, weil deren zusätzliche Parameter mit mehr Beobachtungen präziser geschätzt werden, während sich das Niveau der historischen Matrix kaum verändert.

Die ökonomischen Kennzahlen schwanken dagegen auch hier spürbar, obwohl der Prozess vollkommen stabil ist.

Datensatz	Training	N	QLIKE			MSE ($\times 10^{-8}$)			Sharpe MVP		
			Hist.	GARCH	DCC	Hist.	GARCH	DCC	Hist.	GARCH	DCC
GARCH-Sim.	252	20	-154,0	-156,1	-156,1	7,75	7,54	7,54	0,991	0,952	0,952
	504	20	-154,2	-156,9	-156,9	7,74	7,49	7,49	0,930	0,903	0,902
	756	20	-154,2	-157,1	-157,1	7,81	7,54	7,54	0,799	0,841	0,841
	1008	20	-154,2	-157,3	-157,2	7,84	7,57	7,57	0,756	0,854	0,854
	1260	20	-154,4	-157,4	-157,4	7,86	7,58	7,58	0,781	0,889	0,889
	1512	20	-155,0	-157,8	-157,8	6,81	6,64	6,64	0,713	0,801	0,801
	1764	20	-154,8	-157,6	-157,6	7,00	6,84	6,84	0,706	0,826	0,826
	2016	20	-154,7	-157,7	-157,7	7,01	6,84	6,84	0,780	0,878	0,878
	2268	20	-154,7	-157,6	-157,6	7,07	6,89	6,89	0,816	0,900	0,900
	2520	20	-154,7	-157,5	-157,5	7,00	6,84	6,84	0,744	0,823	0,823
DCC-Sim.	252	20	-156,3	-158,0	-160,4	9,56	8,96	8,86	0,525	0,707	0,726
	504	20	-155,0	-157,5	-161,7	9,84	9,18	9,02	0,645	0,817	0,789
	756	20	-154,6	-157,3	-162,1	9,64	8,99	8,80	0,621	0,814	0,794
	1008	20	-154,1	-157,0	-162,1	9,86	9,19	8,98	0,561	0,774	0,783
	1260	20	-154,4	-157,1	-162,4	9,32	8,67	8,48	0,553	0,779	0,787
	1512	20	-154,3	-157,0	-162,4	9,51	8,84	8,64	0,648	0,861	0,889
	1764	20	-154,1	-156,9	-162,3	9,72	9,03	8,82	0,681	0,807	0,868
	2016	20	-154,0	-156,9	-162,4	9,92	9,18	8,97	0,713	0,780	0,816
	2268	20	-153,8	-156,8	-162,4	10,13	9,37	9,15	0,815	0,824	0,830
	2520	20	-154,0	-157,0	-162,5	10,04	9,28	9,06	0,977	0,982	0,964

Tabelle 16: Synthetische Validierung: Stabilität über die Trainingsfenster

Bewertet über die volle simulierte Stichprobe, da das Universum mit 20 Anlagen konstant ist und die Parameter des Prozesses über die gesamte Reihe unverändert bleiben.

E Dokumentation KI-Nutzung

Nr.	KI-Hilfsmittel	Einsatzform	Betroffene Teile	Beschreibung der KI-Verwendung	Bemerkung
1	Claude	Code	Implementierung	Verwendung von Claude zum Verbessern der Implementierung und Dokumentation	Verwendung zum „Aufräumen“ und Kommentieren des Codes sowie Hilfe bei einzelnen Bugs
2	Claude & ChatGPT	Formulierung	Ausformulierung und Stil	Verbesserung der sprachlichen Qualität durch Reduktion von Wortwiederholungen und Korrekturlesen	Hauptsächlich um den Ton einer wissenschaftlichen Arbeit besser zu treffen
3	Claude	LaTeX	Gesamtes Dokument	Verwendung zur Formatierung in LaTeX	—
4	NotebookLM	Analyse von Literatur	Literaturauswertung	Verwendung von KI zur Validierung von selbst recherchierten Aussagen aus der Literatur	Literatur wurde selbst recherchiert und selbstständig ausgewertet. KI wurde ausschließlich zur Validierung dieser Aussagen und einer besseren Verknüpfung verschiedener Paper verwendet

Tabelle 17: Dokumentation der Nutzung von KI-basierten Anwendungen und Werkzeugen